

MoF 梯度分析：与 OPD Aggregation 范式的对比

理论最优解、梯度方向与超越单 Teacher 的可能性

Flow Factory

Abstract

本文分析 MoF (Mixture of Temporal Velocities) 的 loss 结构和梯度方向，与 OPD 中已有的 average、route_by_source、pcgrad 范式做严格对比。MoF 通过 DiffusionNFT 算法在 **reward** 空间中优化 per-timestep 的 teacher 混合权重 $\lambda_{k,i}$ ，其优化目标根本不同于 OPD 的 KL distillation。我们证明：(1) MoF 的有效参数空间与梯度方向与 OPD 各模式本质不同；(2) 在理论上存在严格超越最优单 **teacher** 的充分条件——当不同 teacher 在不同 timestep 上各有优势时。

Contents

1	问题设定回顾	2
1.1	已有的 OPD 范式及其局限	2
1.2	MoF 的基本设定	2
2	MoF Loss 与梯度的严格推导	3
2.1	DiffusionNFT Loss 回顾	3
2.2	关于 ℓ 的梯度	3
2.3	梯度的直观解释	4
3	与 OPD 各模式的对比	4
3.1	核心差异总览	4
3.2	梯度方向对比	4
3.3	最优解对比	5
3.4	Timestep 解耦的意义	5
4	MoF 能否超越单 Teacher?	6
4.1	OPD 中超越单 Teacher 的不可能性	6
4.2	MoF 超越单 Teacher 的充分条件	6
4.3	直觉示例：为什么时间互补性是自然的	6
4.4	MoF 搜索空间的几何	7
5	梯度动力学分析	7
5.1	MoF 的梯度流	7
5.2	与 OPD-Average 梯度方向的本质区别	7
5.3	收敛行为	8
6	与 PCGrad 的关系	8
6.1	PCGrad 解决的问题 MoF 不存在	8
6.2	但 Teacher 间的“竞争”仍然存在	8
7	能否实现 Pareto 改进?	8
7.1	Multi-Objective 视角	8
7.2	现实中的限制	9

1 问题设定回顾

1.1 已有的 OPD 范式及其局限

设有 K 个 teacher flow-model $v_\phi^{(1)}, \dots, v_\phi^{(K)}$ 和一个 student model v_θ 。OPD trainer 通过如下 pathwise KL loss 训练 student:

$$\mathcal{L}^{\text{OPD}}(\theta) = \sum_{i=0}^{T-1} \mathbb{E}_{\tau \sim q_\theta} \left[\frac{1}{2\sigma_i^2} \|\mu_\theta^i - \mu_T^i\|^2 \right] \quad (1)$$

其中 μ_T^i 是各模式下由 teacher velocities 构造的 target (average、PCGrad、route_by_source 等)。

核心观察： 从实验结果 (Table 1 of experiments.tex) 可看到:

- **route_by_source**: student 在每个 prompt set 上达到对应 teacher 的 in-domain 性能 (如 OCR teacher 在 OCR set 上的 score), 但也继承了该 teacher 的 out-of-domain 性能 (如 OCR teacher 在 PickScore set 上的表现)。本质上等价于分别训练 K 个 student, 再按 source 路由。
- **average/sum/pcgrad** (不 **route**): student 拟合所有 teacher 的“共识方向”。根据 Jensen 不等式和 Bias-Variance 分解, in-domain 性能必然低于对应 single teacher (梯度方向是 $\frac{1}{K} \sum_m \delta_m$ 的方向, 最优解是 teacher velocity 的均值)。

OPD 的根本限制

无论选择哪种 aggregation, OPD 的最优 student velocity 在每个 (x, t) 点上都被锁定为 teacher velocities 的某种 (可能投影后的) 组合。Student 的 velocity field 被 teacher 的“当前点信息”直接约束——无法利用 **trajectory-level** 的全局 **reward** 信号来选择性地在不同 **timestep** 偏向不同 **teacher**。

1.2 MoF 的基本设定

MoF 定义一个新的 velocity field 为 teacher velocities 的 per-timestep 凸组合:

$$v_\lambda(x, t_i) = \sum_{k=1}^K \lambda_{k,i} v_\phi^{(k)}(x, t_i), \quad \lambda_{k,i} = \frac{\exp(\ell_{k,i}/\tau)}{\sum_{k'} \exp(\ell_{k',i}/\tau)} \geq 0, \quad \sum_{k=1}^K \lambda_{k,i} = 1 \quad (2)$$

其中 $\ell \in \mathbb{R}^{K \times T}$ 是可学习的 logits, τ 是 temperature。

Proposition 1 (Flow Model 有效性). 若 $v_\phi^{(1)}, \dots, v_\phi^{(K)}$ 都是有效的 flow-matching velocity field (即各自的 ODE 将标准高斯 $p_0 = \mathcal{N}(0, I)$ 映射到各自的数据分布), 则对任意凸系数 $\lambda_{k,i} \geq 0, \sum_k \lambda_{k,i} = 1$:

$$v_\lambda(x, t_i) = \sum_k \lambda_{k,i} v_\phi^{(k)}(x, t_i) \quad (3)$$

是一个有效的 velocity field, 其对应的 ODE 解定义了一个合法的概率流。

Proof. Flow-matching velocity 满足 $\partial_t p_t + \nabla \cdot (p_t v) = 0$ (连续性方程)。凸组合下的概率流可视作 teacher 概率流的 mixture: $p_t^\lambda = \sum_k \lambda_{k,i} p_t^{(k)}$ (当 λ 不随 x 变化时)。严格来说, per-timestep 凸组合在 ODE 离散化框架下生成的分布是各 teacher 分布在该 timestep 步上的“分段凸组合”, 每段内是有效概率流的凸组合, 仍是有效概率流。□

Remark 1. 不同于 model-level interpolation (在 weight space 上做凸组合, 需要满足模型 linearity 条件), MoF 在 **velocity output space** 上做凸组合——这对任何参数化的网络都成立, 不依赖于网络架构。

2 MoF Loss 与梯度的严格推导

2.1 DiffusionNFT Loss 回顾

DiffusionNFT 的核心 loss 为 (对单个 timestep t_i , 单个 sample):

$$\mathcal{L}_i^{\text{NFT}}(\ell) = \frac{1}{\beta} [r \cdot L_i^+ + (1-r) \cdot L_i^-] \quad (4)$$

其中:

$$r = \frac{\mathcal{A} + A_{\max}}{2A_{\max}} \in [0, 1] \quad (\text{normalized advantage}) \quad (5)$$

$$v_i^{\text{new}} = \sum_k \lambda_{k,i} v_\phi^{(k)}(x_{t_i}, t_i) \quad (\text{current policy}) \quad (6)$$

$$v_i^{\text{old}} = \sum_k \bar{\lambda}_{k,i} v_\phi^{(k)}(x_{t_i}, t_i) \quad (\text{EMA/old policy}) \quad (7)$$

$$v_i^+ = \beta v_i^{\text{new}} + (1-\beta) v_i^{\text{old}} \quad (8)$$

$$v_i^- = (1+\beta) v_i^{\text{old}} - \beta v_i^{\text{new}} \quad (9)$$

$$L_i^+ = \left\| \frac{x_{t_i} - \sigma_i v_i^+ - x_0}{w^+} \right\|^2, \quad L_i^- = \left\| \frac{x_{t_i} - \sigma_i v_i^- - x_0}{w^-} \right\|^2 \quad (10)$$

w^+, w^- 是 detached 的归一化权重 (mean absolute error), $\bar{\lambda}$ 是 EMA logits 对应的权重。

2.2 关于 ℓ 的梯度

Theorem 1 (MoF Gradient). 设 $\Phi_i = [v_\phi^{(1)}(x_{t_i}), \dots, v_\phi^{(K)}(x_{t_i})]^\top \in \mathbb{R}^{K \times d}$ 为 teacher velocity matrix (frozen, detached), 则 MoF 关于 logits ℓ 的梯度为:

$$\frac{\partial \mathcal{L}_i^{\text{NFT}}}{\partial \ell_{k,i}} = \frac{2}{\tau} \cdot \lambda_{k,i} [v_\phi^{(k)} - v_i^{\text{new}}]^\top \left[\frac{r(x_0^+ - x_0)}{(w^+)^2} - \frac{(1-r)(x_0^- - x_0)}{(w^-)^2} \right] \cdot (-\sigma_i) \quad (11)$$

其中 $x_0^+ = x_{t_i} - \sigma_i v_i^+$, $x_0^- = x_{t_i} - \sigma_i v_i^-$ 。

对于 $j \neq i$ (不同 timestep), $\frac{\partial \mathcal{L}_i^{\text{NFT}}}{\partial \ell_{k,j}} = 0$ ——**timestep** 间完全解耦。

Proof. 链式法则:

$$\frac{\partial \mathcal{L}}{\partial \ell_{k,i}} = \frac{\partial \mathcal{L}}{\partial v_i^{\text{new}}} \cdot \frac{\partial v_i^{\text{new}}}{\partial \lambda_{k,i}} \cdot \frac{\partial \lambda_{k,i}}{\partial \ell_{k,i}} \quad (12)$$

第一项 (loss 对 v^{new} 的梯度):

注意 $\frac{\partial v^+}{\partial v^{\text{new}}} = \beta$, $\frac{\partial v^-}{\partial v^{\text{new}}} = -\beta$, 且 $\frac{\partial x_0^+}{\partial v^+} = -\sigma_i$, $\frac{\partial x_0^-}{\partial v^-} = -\sigma_i$ (两者形式相同)。

$$\frac{\partial \mathcal{L}}{\partial v_i^{\text{new}}} = \frac{1}{\beta} \left[r \cdot \frac{\partial L^+}{\partial v^+} \cdot \beta + (1-r) \cdot \frac{\partial L^-}{\partial v^-} \cdot (-\beta) \right] \quad (13)$$

$$= r \cdot \frac{\partial L^+}{\partial v^+} - (1-r) \cdot \frac{\partial L^-}{\partial v^-} \quad (14)$$

$$= r \cdot \frac{2(x_0^+ - x_0) \cdot (-\sigma_i)}{(w^+)^2} - (1-r) \cdot \frac{2(x_0^- - x_0) \cdot (-\sigma_i)}{(w^-)^2} \quad (15)$$

第二项 (v^{new} 对 $\lambda_{k,i}$ 的梯度):

$$\frac{\partial v_i^{\text{new}}}{\partial \lambda_{k,i}} = v_\phi^{(k)}(x_{t_i}, t_i) \quad (16)$$

第三项 (softmax 的 Jacobian):

$$\frac{\partial \lambda_{k,i}}{\partial \ell_{k,i}} = \frac{1}{\tau} \lambda_{k,i} (1 - \lambda_{k,i}), \quad \frac{\partial \lambda_{j,i}}{\partial \ell_{k,i}} = -\frac{1}{\tau} \lambda_{j,i} \lambda_{k,i} \quad (j \neq k) \quad (17)$$

综合 (利用 $\sum_j \lambda_j v_\phi^{(j)} = v^{\text{new}}$):

$$\sum_j \frac{\partial v^{\text{new}}}{\partial \ell_{k,i}} = \frac{\lambda_{k,i}}{\tau} [v_\phi^{(k)} - v^{\text{new}}] \quad (18)$$

组合即得 (11)。 □

2.3 梯度的直观解释

MoF 梯度的物理含义

$\frac{\partial \mathcal{L}}{\partial \ell_{k,i}}$ 由三个因子决定:

1. 偏离方向 $[v_\phi^{(k)} - v_i^{\text{new}}]$: teacher k 相对于当前混合 velocity 的“差异方向”。若 $\lambda_{k,i}$ 已经为 1, 此项为 0 (该 teacher 已被完全采用)。
2. **Reward signal**: 包含 advantage r 的加权误差方向。正 advantage ($r > 0.5$) 时, 梯度推动 policy 向减小 L^+ (让 v^+ 更准确) 的方向移动; 负 advantage 时推动减小 L^- 。
3. 当前权重 $\lambda_{k,i}$: softmax 的梯度天然包含 $\lambda_{k,i}(1 - \lambda_{k,i})$ 项, 确保已经很高权重的 teacher 梯度减小 (趋于饱和), 而中间权重的 teacher 梯度最大。

3 与 OPD 各模式的对比

3.1 核心差异总览

维度	OPD (avg/sum)	OPD (route)	MoF
可训练参数	Model weights $\theta \in \mathbb{R}^P$	Model weights $\theta \in \mathbb{R}^P$	Logits $\ell \in \mathbb{R}^{K \times T}$
参数量	$P \sim 10^7 - 10^9$	P	$K \times T \sim 60$
优化目标	KL distillation	KL distillation	Reward maximization
Target 构造	$\bar{\mu} = \frac{1}{K} \sum_k \mu_k$	μ_{m^*} (matched source)	无显式 target; reward 驱动
梯度方向	指向 teacher 均值	指向 matched teacher	指向 reward 提升方向
Timestep 耦合	通过共享 θ 耦合	通过共享 θ 耦合	完全解耦 ($\ell_{:,i}$ 独立)
Trajectory awareness	弱 (仅 REINFORCE 项)	弱	强 (reward 直接反馈)

3.2 梯度方向对比

设第 i 个 timestep 的 teacher velocity 为 $v_i^{(k)} \in \mathbb{R}^d$, student velocity 为 $v_{\theta,i}$ 。

OPD-Average 的梯度方向（在 **velocity space** 中的投影）:

$$g_i^{\text{avg}} \propto \left(v_{\theta,i} - \frac{1}{K} \sum_k v_i^{(k)} \right)^\top J_i \quad (19)$$

方向: 将 student 拉向 teacher velocity 的算术均值。与 reward 无关。

OPD-Route 的梯度方向:

$$g_i^{\text{route}} \propto \left(v_{\theta,i} - v_i^{(m^*)} \right)^\top J_i \quad (20)$$

方向: 将 student 拉向 source-matched teacher。与 reward 无关。

MoF 的梯度方向（在 **logit space** 中）:

$$\frac{\partial \mathcal{L}}{\partial \ell_{k,i}} \propto \lambda_{k,i} \left[v_i^{(k)} - v_i^{\text{new}} \right]^\top \cdot \underbrace{(\text{reward-dependent error signal})}_{\text{depends on } \mathcal{A}} \quad (21)$$

方向: 由 reward signal 决定。若当前 trajectory 的 reward 高, 梯度方向鼓励保持当前 λ 分布; 若 reward 低, 梯度方向调整 λ 使 velocity 远离当前组合。

3.3 最优解对比

Proposition 2 (OPD-Average 的最优解). 在 OPD pathwise loss 下, 最优 student velocity 为:

$$v_{\theta,i}^*(x) = \frac{1}{K} \sum_{k=1}^K v_i^{(k)}(x), \quad \forall x, i \quad (22)$$

即所有 teacher 在每个 (x, t) 的 velocity 均值。

Proposition 3 (OPD-Route 的最优解). 当 route_by_source 时, 对 prompt set $\mathcal{P}_m$ 中的 prompt:

$$v_{\theta}^*(x, t_i | p \in \mathcal{P}_m) = v_i^{(m)}(x) \quad (23)$$

即 student 在每个 prompt set 上完美复制对应 teacher。

Theorem 2 (MoF 的最优解). MoF 的最优 logits ℓ^* 满足:

$$\ell^* = \arg \max_{\ell \in \mathbb{R}^{K \times T}} \mathbb{E}_{p \sim \mathcal{D}} [R(\text{ODE}(v_\lambda; x_T, p))] \quad (24)$$

其中 $R(\cdot)$ 是外部 reward function, $\text{ODE}(v_\lambda; x_T, p)$ 是以 v_λ 为 velocity 的 ODE 从 noise x_T 生成的 image。

关键差异: MoF 的最优解由 **end-to-end reward** 决定, 而非由逐点 KL 决定。

3.4 Timestep 解耦的意义

Proposition 4 (Per-timestep 独立性). MoF 中, $\frac{\partial \mathcal{L}_i}{\partial \ell_{k,j}} = 0$ 对 $j \neq i$ 成立。即:

- 每个 timestep 的权重可以独立于其他 timestep 优化。
- 不存在“通过共享参数传播”的 timestep 间串扰。

而在 OPD 中, $\frac{\partial \mathcal{L}_i}{\partial \theta}$ 和 $\frac{\partial \mathcal{L}_j}{\partial \theta}$ 作用于同一个 θ , 导致不同 timestep 的梯度在参数空间中竞争和折衷。

Corollary 1 (无跨 timestep 冲突). MoF 中不存在跨 timestep 的梯度冲突。PCGrad 在 OPD 中存在的意义（解决 teacher 间梯度冲突）在 MoF 中不需要——因为每个 timestep 的梯度作用于不同的参数维度 $\ell_{:,i}$ 。

4 MoF 能否超越单 Teacher?

4.1 OPD 中超越单 Teacher 的不可能性

Proposition 5 (OPD 的 In-Domain 上界). 在 OPD-Average 模式下, 设 reward R_m 为 teacher m 的 in-domain metric (如 OCR score on OCR set), 则:

$$R_m(v_{\text{avg}}^*) \leq R_m(v_\phi^{(m)}) \quad (25)$$

等号成立当且仅当所有 teacher 在 prompt set $\mathcal{P}_m$ 上给出相同 velocity。

Proof. Student 的最优 velocity 为 teacher 均值。对于单调依赖于 $\|v_\theta - v_\phi^{(m)}\|$ 的 in-domain metric, 均值必然偏离 $v_\phi^{(m)}$ (当 teacher 间有分歧时)。□

Remark 2. 这解释了实验中 OPD-Average 在所有 in-domain metric 上均红色下降的现象。

4.2 MoF 超越单 Teacher 的充分条件

Theorem 3 (Temporal Complementarity $\rightarrow$ 超越单 Teacher). 设 reward function R 评价最终生成的 image quality。如果存在时间互补性 (temporal complementarity):

Definition 1 (时间互补性). 对于 prompt p , 存在权重向量 $\lambda^* \in \Delta^K$ 使得使用 v_{λ^*} 生成的 ODE trajectory 的 reward 严格高于任何单一 teacher:

$$R(\text{ODE}(v_{\lambda^*}; x_T, p)) > \max_k R(\text{ODE}(v_\phi^{(k)}; x_T, p)) \quad (26)$$

则 MoF 可以严格超越最优单 teacher。

时间互补性成立的典型场景:

1. **Teacher** 在不同 **timestep** 有不同优势: 如 GenEval teacher 在早期 timestep (确定 layout/composition) 表现更好, 而 PickScore teacher 在晚期 timestep (细化 aesthetics) 表现更好。
2. **Multi-aspect reward**: 当 $R = w_1 R_1 + w_2 R_2 + \dots$ 时, 每个 teacher 可能擅长不同 aspect。通过在不同 timestep 选择不同 teacher 的“擅长阶段”, 可以获得综合 reward 的提升。

Proof sketch. MoF 的搜索空间是 $\prod_{i=1}^T \Delta^K$ (每个 timestep 一个 K -simplex)。单一 teacher k 对应 $\lambda_{k,i} = 1, \forall i$, 这是搜索空间的一个顶点。如果 reward landscape 在这个乘积 simplex 上的最大值不在顶点上取得 (即最优不是某个 teacher 恒取权重 1), 则 MoF 严格优于单 teacher。

由连续优化在紧集上的性质, 最优解存在。在时间互补性假设下, 最优解不退化为某个顶点。□

4.3 直觉示例: 为什么时间互补性是自然的

Example 1 (Layout vs. Aesthetics 互补). 考虑一个 “two cats sitting on a red carpet” 的 prompt, reward 为 GenEval accuracy + PickScore。

- GenEval teacher: 专注于 counting 和 spatial relations。在早期 **timestep** ($t_1, \dots, t_5$, 确定全局 layout) 时其 velocity 指向正确的 “two cats” 构图。
- PickScore teacher: 专注于 aesthetics。在晚期 **timestep** ($t_{20}, \dots, t_{28}$, 细化 texture 和 lighting) 时其 velocity 产生更高美学质量。

使用 GenEval teacher 全程: 得到正确构图但美学一般。

使用 PickScore teacher 全程: 美学好但可能只画一只猫。

MoF 的最优策略: 早期偏向 GenEval teacher (确保构图正确), 晚期偏向 PickScore teacher (提升美学) $\rightarrow$ 综合 reward 超越任何单一 teacher。

Example 2 (OCR + PickScore 互补). OCR teacher 在早期确保文字 layout 的正确性 (文字区域的粗结构), PickScore teacher 在晚期提升整体 aesthetics。两者在不同 denoising 阶段各有贡献——OCR 确保文字可读, PickScore 确保非文字区域美观。

4.4 MoF 搜索空间的几何

Proposition 6 (搜索空间 vs 参数空间). • OPD 的搜索空间: $\mathbb{R}^P$ (模型参数) ——student velocity 可以是任意函数。

- MoF 的搜索空间: $(\Delta^K)^T \cong$ 乘积 simplex ——只有 $K \times T$ 维。

MoF 的搜索空间远小于 OPD, 但它直接在 reward 空间中优化。OPD 的大搜索空间并不意味着能找到更好的解——因为它的目标函数 (KL distillation) 将 student 锁定为 teacher 的“模仿者”。

5 梯度动力学分析

5.1 MoF 的梯度流

简化分析: 设 $\beta = 1$ (标准 NFT), $w^+ = w^- = 1$ (忽略 normalization), single sample。此时 $v^+ = v^{\text{new}}$, $v^- = 2v^{\text{old}} - v^{\text{new}}$, $x_0^\pm - x_0 = -\sigma_i(v^\pm - v_i^*)$ (其中 $v_i^* = (x_{t_i} - x_0)/\sigma_i$ 是 ground truth velocity)。代入 (11):

$$\frac{\partial \mathcal{L}_i}{\partial \ell_{k,i}} \propto \lambda_{k,i} [v_i^{(k)} - v_i^{\text{new}}]^\top \left[r(v_i^{\text{new}} - v_i^*) - (1-r)(2v_i^{\text{old}} - v_i^{\text{new}} - v_i^*) \right] \sigma_i^2 \quad (27)$$

设 $v^{\text{old}} \approx v^{\text{new}}$ (off-policy 小偏移), 则 $2v^{\text{old}} - v^{\text{new}} - v^* \approx v^{\text{new}} - v^*$, 得到:

$$\frac{\partial \mathcal{L}_i}{\partial \ell_{k,i}} \approx \frac{2\sigma_i^2}{\tau} \lambda_{k,i} [v_i^{(k)} - v_i^{\text{new}}]^\top [(2r-1)(v_i^{\text{new}} - v_i^*)] \quad (28)$$

梯度解读

设 advantage $\mathcal{A} > 0$ (即 $r > 0.5$, 当前 trajectory 产出好 reward):

- 若 $v_i^{(k)}$ 与 v_i^{new} 在 error $(v^{\text{new}} - v^*)$ 方向上有负投影 (即 $v_i^{(k)}$ 比当前混合更“正确”), 则 $\ell_{k,i}$ 增加——增加该 **teacher** 的权重。
- 若 $v_i^{(k)}$ 比当前混合更“偏离 ground truth”, 则 $\ell_{k,i}$ 减小。

设 advantage $\mathcal{A} < 0$ ($r < 0.5$, 当前 trajectory 不好):

- 梯度方向反转: 惩罚当前混合方向, 鼓励远离当前权重分布。

5.2 与 OPD-Average 梯度方向的本质区别

Proposition 7 (方向差异). OPD-Average 的梯度方向 (在 velocity space 投影中):

$$g_i^{\text{avg}} = v_{\theta,i} - \frac{1}{K} \sum_k v_i^{(k)} \quad (\text{指向 teacher 均值}) \quad (29)$$

MoF 的“有效 velocity 调整方向”:

$$\Delta v_i^{\text{mof}} \propto \sum_k \frac{\partial \lambda_{k,i}}{\partial \ell_{k,i}} \cdot \Delta \ell_{k,i} \cdot v_i^{(k)} \quad (\text{reward-weighted rebalancing}) \quad (30)$$

两者不共线: OPD-Average 总是指向均值 (与 reward 无关), 而 MoF 指向 reward 提升方向 (可能偏向某个 teacher)。

5.3 收敛行为

Proposition 8 (MoF 的固定点). 在 $\tau \rightarrow 0$ (低温极限) 下, MoF 收敛到 “winner-take-all”: 每个 timestep 选择一个 teacher。

在 $\tau \rightarrow \infty$ (高温极限) 下, MoF 退化为均匀混合 $\lambda_{k,i} = 1/K$ ——此时等价于 OPD-Average 的 target。

在适中的 τ 下, MoF 找到介于两个极端之间的 soft 分配。

6 与 PCGrad 的关系

6.1 PCGrad 解决的问题 MoF 不存在

PCGrad 的核心动机是: 当多个 teacher 的梯度在共享参数空间中冲突时, 通过投影消除冲突分量。

MoF 中:

- 不同 teacher 贡献到同一个 $\ell_{k,i}$ 的梯度——但由 softmax 的结构保证 $\sum_k \lambda_k = 1$, 不存在 “某个 teacher 的梯度消灭另一个 teacher” 的问题。
- 不同 timestep 的梯度作用于不同参数, 天然正交。

因此, **PCGrad** 的冲突投影机制在 **MoF** 框架中没有意义。

6.2 但 Teacher 间的 “竞争” 仍然存在

虽然没有参数空间冲突, MoF 中 teacher 间存在 **simplex** 竞争:

$$\sum_k \lambda_{k,i} = 1 \quad \Rightarrow \quad \text{增加 teacher } k \text{ 的权重必然减少其他 teacher 的权重} \quad (31)$$

这种竞争由 reward signal 仲裁: reward 高的 trajectory 中哪个 teacher 贡献大, 哪个 teacher 的权重就被提升。

7 能否实现 Pareto 改进?

7.1 Multi-Objective 视角

设 reward 由多个分项组成: $R = \sum_j w_j R_j$ (如 $R_1 = \text{GenEval}$, $R_2 = \text{PickScore}$, $R_3 = \text{OCR}$)。

Definition 2 (Pareto 改进). v_λ 实现了相对于 teacher 集合 $\{v_\phi^{(k)}\}_{k=1}^K$ 的 Pareto 改进, 如果:

$$R_j(v_\lambda) \geq R_j(v_\phi^{(k)}), \quad \forall j, k, \quad \text{且至少一个不等式严格} \quad (32)$$

Theorem 4 (Pareto 改进的充分条件). 设 teacher k 在 reward R_k 上最优 (in-domain), 在其他 reward 上为 baseline。如果存在 **timestep** 分区 $\{I_1, \dots, I_K\}$ ($\bigcup_k I_k = \{1, \dots, T\}$) 使得:

1. Teacher k 在 timestep 集 I_k 上对 reward R_k 的边际贡献为正且显著。
2. Teacher k 在 timestep 集 I_k 上对其他 reward R_j ($j \neq k$) 的边际贡献为非负或可忽略。

则存在 λ^* 使得 $R_j(v_{\lambda^*}) \geq R_j(v_\phi^{(j)})$ 对所有 j 。

直觉: 如果不同 teacher 的 “贡献区间” 在 timestep 维度上可分离, 则可以在各自的区间上分配高权重而不损害其他 reward。

7.2 现实中的限制

Remark 3 (何时 Pareto 改进不可能). 当 teacher 间的冲突集中在同一 timestep 区间（如所有 teacher 都在 $t \in [0.3, 0.5]$ 这个“关键布局阶段”产生分歧），则 MoF 无法同时满足所有 reward——此时退化为 weighted trade-off。

Remark 4 (从实验数据看可行性). 从 experiments.tex 的数据看：

- GenEval teacher 的主要贡献在 counting/position (layout-sensitive, 倾向早期 timestep)
- OCR teacher 的主要贡献在文字渲染（需要中期-晚期精确笔画）
- PickScore teacher 的贡献在整体 aesthetics（倾向晚期 timestep）

三者 in timestep 维度上有一定程度的自然分离，这为 Pareto 改进提供了可能性。

8 总结与关键 Insight

核心结论

1. 本质差异：OPD 是 distillation (KL 最小化)，MoF 是 RL (reward 最大化)。前者的最优解由 teacher velocity 的几何关系决定，后者由下游 reward 决定。
2. 梯度方向：OPD 的梯度始终指向 teacher velocity 的某种均值/投影；MoF 的梯度指向 reward 提升方向——可以在不同 timestep 偏向不同 teacher。
3. **Timestep** 解耦：MoF 的每个 timestep 的权重完全独立优化，不存在跨 timestep 的梯度冲突。PCGrad 等冲突解决机制在 MoF 中无需使用。
4. 超越单 **Teacher**：在存在时间互补性时（不同 teacher 在不同 timestep 各有优势），MoF 理论上可以严格超越最优单 teacher。OPD-Average 则受 Jensen 不等式约束，in-domain 性能必然下降。
5. 搜索空间 **trade-off**：MoF 的搜索空间极小 ($K \times T \sim 60$ 维) 但精准对准 reward 目标；OPD 的搜索空间巨大 ($\sim 10^7$) 但被 distillation objective 限制了探索方向。
6. **OPD** 与 **MoF** 的互补性：OPD (route_by_source) 可作为 MoF 的“warm start”——先通过 OPD 训练一个接近各 teacher in-domain 表现的 student，再用 MoF 的 reward-driven 方式做 **per-timestep** 精细调整超越 single teacher。

	Average	Route	PCGrad	MoF
In-domain 性能	< single teacher	$\approx$ single teacher	< single teacher	可 > single teacher
OOD 性能	有少量提升	继承 teacher OOD	有少量提升	reward-driven 提升
需要 reward?	✗	✗	✗	✓
解决 teacher 冲突?	无（直接平均）	回避（分离）	投影消除	simplex 竞争
超越 single teacher?	✗ 不可能	✗ 不可能	✗ 不可能	✓ 理论可能