

MoF Loss & Gradient Analysis

NFT vs. GRPO Optimization for Mixture-of-Flow

Flow Factory

Abstract

本文对 MoF (Mixture-of-Flow) 的两种优化算法——NFT (DiffusionNFT) 和 GRPO (PPO-clipped ratio) ——给出完整的 loss 公式和梯度推导。分析表明二者对 logits 的梯度结构具有本质差异: NFT 的梯度通过 velocity 空间的 MSE 投影间接传递, 而 GRPO 通过 log-probability ratio 直接传递。我们给出两种情况下 $\partial \mathcal{L} / \partial \ell_{k,i,s}$ 的闭式表达, 并分析各自的梯度量级、数值稳定性及与 softmax Jacobian 的交互。

Contents

1	共同基础: Per-Set Combined Velocity	2
1.1	符号回顾	2
1.2	Softmax Jacobian	2
2	NFT Loss & Gradient	2
2.1	NFT Loss 公式	2
2.2	NFT Gradient w.r.t. Logits	3
2.3	NFT Gradient: Expanded Form	3
3	GRPO Loss & Gradient	4
3.1	Background: Flow Matching Transition	4
3.2	GRPO Loss 公式	4
3.3	GRPO Gradient w.r.t. Logits	4
3.4	GRPO 梯度: CPS Dynamics 特化	5
4	比较分析	5
4.1	梯度结构对比	5
4.2	梯度量级分析	5
4.3	信号传递路径	6
5	数值稳定性	6
5.1	GRPO 特有的数值问题	6
5.2	NFT 特有的数值问题	6
6	总结	6

1 共同基础: Per-Set Combined Velocity

1.1 符号回顾

- Logits: $\ell \in \mathbb{R}^{K \times T \times S}$, 唯一可训练参数
- Softmax weights: $\lambda_{k,i,s} = \text{softmax}_k(\ell_{\cdot,i,s}/\tau)$
- Combined velocity: $v_s(x, t_i) = \sum_{k=1}^K \lambda_{k,i,s} v^{(k)}(x, t_i)$
- Teacher velocities: $v^{(k)}$ frozen, detached 一无梯度流经 teachers

1.2 Softmax Jacobian

对于固定 (i, s) , 令 $\lambda = \text{softmax}(\ell/\tau) \in \mathbb{R}^K$ 。Jacobian 为:

$$\frac{\partial \lambda_k}{\partial \ell_j} = \frac{1}{\tau} (\lambda_k \cdot \mathbf{1}[k=j] - \lambda_k \lambda_j) = \frac{\lambda_k}{\tau} (\delta_{kj} - \lambda_j) \quad (1)$$

这是所有后续梯度推导的起点。

2 NFT Loss & Gradient

2.1 NFT Loss 公式

给定 sample x with advantage A , noised latents $x_t = (1 - \sigma)x_0 + \sigma\epsilon$:

Step 1: Advantage normalization.

$$r = \text{clamp}\left(\frac{A}{A_{\max}} \cdot \frac{1}{2} + \frac{1}{2}, 0, 1\right) \quad (2)$$

Step 2: Positive/Negative predictions.

$$v^+ = \beta \cdot v_{\text{new}} + (1 - \beta) \cdot v_{\text{old}} \quad (3)$$

$$v^- = (1 + \beta) \cdot v_{\text{old}} - \beta \cdot v_{\text{new}} \quad (4)$$

其中 $v_{\text{new}} = \sum_k \lambda_k v^{(k)}$ (current logits), $v_{\text{old}} = \sum_k \bar{\lambda}_k v^{(k)}$ (EMA logits, detached)。

Step 3: Self-normalized MSE.

$$\mathcal{M}(v) = \frac{\|x_0^{\text{pred}}(v) - x_0\|^2}{\text{sg}\left(\|x_0^{\text{pred}}(v) - x_0\|_1/d\right)}, \quad x_0^{\text{pred}}(v) = x_t - \sigma \cdot v \quad (5)$$

其中 $\text{sg}(\cdot)$ 表示 stop-gradient。

Step 4: Combined loss.

$$\boxed{\mathcal{L}_{\text{NFT}} = \frac{r \cdot \mathcal{M}(v^+) + (1 - r) \cdot \mathcal{M}(v^-)}{\beta} \cdot A_{\max}} \quad (6)$$

2.2 NFT Gradient w.r.t. Logits

Proposition 1 (NFT Gradient). 对固定 timestep i 和 prompt set s , NFT 对 logit $\ell_{j,i,s}$ 的梯度为:

$$\frac{\partial \mathcal{L}_{\text{NFT}}}{\partial \ell_{j,i,s}} = \frac{A_{\max}}{\tau} \sum_{k=1}^K \lambda_k (\delta_{kj} - \lambda_j) \cdot \left\langle \frac{\partial \mathcal{L}_{\text{NFT}}}{\partial v_{\text{new}}}, v^{(k)} \right\rangle \quad (7)$$

其中 $\langle \cdot, \cdot \rangle$ 为 $\mathbb{R}^d$ 上的内积, 且:

$$\frac{\partial \mathcal{L}_{\text{NFT}}}{\partial v_{\text{new}}} = \frac{\beta \cdot A_{\max}}{\beta} \left[r \cdot \frac{\partial \mathcal{M}(v^+)}{\partial v^+} + (1-r) \cdot \frac{\partial \mathcal{M}(v^-)}{\partial v^-} \cdot (-1) \right] \quad (8)$$

Proof. Chain rule:

$$\frac{\partial \mathcal{L}}{\partial \ell_{j,i,s}} = \sum_k \frac{\partial \mathcal{L}}{\partial \lambda_k} \cdot \frac{\partial \lambda_k}{\partial \ell_j} \quad (9)$$

$$= \sum_k \left\langle \frac{\partial \mathcal{L}}{\partial v_{\text{new}}}, v^{(k)} \right\rangle \cdot \frac{\lambda_k}{\tau} (\delta_{kj} - \lambda_j) \quad (10)$$

第一步用了 $\partial v_{\text{new}} / \partial \lambda_k = v^{(k)}$ (因为 teachers frozen). $\square$

Remark 1 (NFT 梯度特征).

1. 间接传递: 梯度必须通过 $\langle \nabla_v \mathcal{L}, v^{(k)} \rangle$ 这个「velocity-space projection」传递。如果 $\nabla_v \mathcal{L}$ 与所有 $v^{(k)}$ 正交, 则梯度为零。
2. β 无关: 展开后 β 在分子分母中消去 (positive/negative 的系数 $\pm\beta$ 除以分母 β), 最终梯度幅值与 β 无关。
3. **Softmax** 缩放: $1/\tau$ 系数 + $\lambda_k(\delta_{kj} - \lambda_j)$ 的乘积导致梯度被 $O(\lambda_{\max}(1 - \lambda_{\max}))$ 缩放。当某个 teacher 占优 ($\lambda_k \rightarrow 1$) 时, 所有梯度趋于零。

2.3 NFT Gradient: Expanded Form

$\mathcal{M}(v)$ 对 v 的梯度为:

$$\frac{\partial \mathcal{M}(v)}{\partial v} = \frac{-2\sigma}{w} \cdot (x_0^{\text{pred}} - x_0) \quad (11)$$

其中 $w = \text{sg}(\|x_0^{\text{pred}} - x_0\|_1/d)$ 是 detached weight。因此:

$$\frac{\partial \mathcal{L}_{\text{NFT}}}{\partial v_{\text{new}}} = A_{\max} \left[\frac{-2\sigma \cdot r}{w^+} (x_0^+ - x_0) + \frac{2\sigma(1-r)}{w^-} (x_0^- - x_0) \right] \quad (12)$$

其中 $x_0^\pm = x_t - \sigma v^\pm$ 。

最终:

$$\frac{\partial \mathcal{L}_{\text{NFT}}}{\partial \ell_{j,i,s}} = \frac{2\sigma A_{\max}}{\tau} \sum_k \lambda_k (\delta_{kj} - \lambda_j) \left[\frac{(1-r)}{w^-} \langle x_0^- - x_0, v^{(k)} \rangle - \frac{r}{w^+} \langle x_0^+ - x_0, v^{(k)} \rangle \right] \quad (13)$$

3 GRPO Loss & Gradient

3.1 Background: Flow Matching Transition

在 dynamics type CPS/Flow-SDE 下, denoising step 的 transition distribution 为:

$$p(x_{t+1} | x_t; v) = \mathcal{N}(x_{t+1}; \mu(x_t, v, t), \sigma_{\text{trans}}^2 I) \quad (14)$$

其中 $\mu = f(x_t, v, t, t_{\text{next}})$ 是 dynamics-dependent mean (CPS: $\mu = x_0(1 - \sigma') + x_1\sqrt{\sigma'^2 - \sigma_{\text{trans}}^2}$)。

Log-probability per sample:

$$\log p(x_{t+1} | x_t; v) = -\frac{\|x_{t+1} - \mu\|^2}{2\sigma_{\text{trans}}^2} - \frac{d}{2} \log(2\pi\sigma_{\text{trans}}^2) \quad (15)$$

3.2 GRPO Loss 公式

Ratio.

$$\rho_i = \exp(\log p(x_{t_{i+1}} | x_{t_i}; v_{\text{new}}) - \log p(x_{t_{i+1}} | x_{t_i}; v_{\text{old}})) \quad (16)$$

其中 $v_{\text{new}} = \sum_k \lambda_k^{\text{new}} v^{(k)}$, $v_{\text{old}} = \text{sampling-time combined velocity (detached)}$ 。

由于 $x_{t_{i+1}}$ 和 σ_{trans} 相同 (仅 μ 不同), ratio 简化为:

$$\log \rho_i = -\frac{\|x_{t_{i+1}} - \mu_{\text{new}}\|^2 - \|x_{t_{i+1}} - \mu_{\text{old}}\|^2}{2\sigma_{\text{trans}}^2} \quad (17)$$

PPO Clipped Loss.

$$\mathcal{L}_{\text{GRPO}} = -A \cdot \max(\rho, \text{clamp}(\rho, 1 - \epsilon, 1 + \epsilon)) \quad (18)$$

KL-Adv Mask Variant (DPPO). 定义 x-space KL:

$$D_i = \frac{\|\mu_{\text{new}} - \mu_{\text{old}}\|^2}{2\sigma_{\text{trans}}^2} \quad (19)$$

Mask:

$$m_i = \begin{cases} 0 & \text{if } D_i \geq \theta \text{ and } (\rho_i > 1, A > 0) \text{ or } (\rho_i < 1, A < 0) \\ 1 & \text{otherwise} \end{cases} \quad (20)$$

$$\mathcal{L}_{\text{DPPO}} = -A \cdot \rho \cdot m \quad (21)$$

3.3 GRPO Gradient w.r.t. Logits

Proposition 2 (GRPO Gradient). 在 unclipped region (ρ 未被 clip), GRPO 对 $\text{logit } \ell_{j,i,s}$ 的梯度为:

$$\frac{\partial \mathcal{L}_{\text{GRPO}}}{\partial \ell_{j,i,s}} = \frac{-A \cdot \rho_i}{\tau \cdot \sigma_{\text{trans}}^2} \sum_{k=1}^K \lambda_k (\delta_{kj} - \lambda_j) \cdot \left\langle x_{t_{i+1}} - \mu_{\text{new}}, \frac{\partial \mu_{\text{new}}}{\partial v^{(k)}} \cdot v^{(k)} \right\rangle \quad (22)$$

Proof. Chain rule:

$$\frac{\partial \mathcal{L}}{\partial \ell_j} = -A \cdot \rho \cdot \frac{\partial \log \rho}{\partial \ell_j} \quad (23)$$

$$\frac{\partial \log \rho}{\partial \ell_j} = \frac{\partial}{\partial \ell_j} \left[-\frac{\|x_{t_{i+1}} - \mu_{\text{new}}\|^2}{2\sigma_{\text{trans}}^2} \right] \quad (24)$$

$$= \frac{1}{\sigma_{\text{trans}}^2} \left\langle x_{t_{i+1}} - \mu_{\text{new}}, \frac{\partial \mu_{\text{new}}}{\partial \ell_j} \right\rangle \quad (25)$$

$$= \frac{1}{\sigma_{\text{trans}}^2} \sum_k \frac{\partial \lambda_k}{\partial \ell_j} \left\langle x_{t_{i+1}} - \mu_{\text{new}}, \frac{\partial \mu}{\partial \lambda_k} \right\rangle \quad (26)$$

其中 $\partial\mu/\partial\lambda_k$ 取决于 dynamics type。对 Flow-SDE: $\partial\mu/\partial v \propto dt$ ；对 CPS 更复杂但同样是 $v^{(k)}$ 的线性函数。□

3.4 GRPO 梯度：CPS Dynamics 特化

对 CPS dynamics:

$$x_0^{\text{pred}} = x_t - \sigma \cdot v \quad (27)$$

$$x_1^{\text{pred}} = x_t + (1 - \sigma) \cdot v \quad (28)$$

$$\mu = x_0^{\text{pred}}(1 - \sigma') + x_1^{\text{pred}}\sqrt{\sigma'^2 - \sigma_{\text{trans}}^2} \quad (29)$$

因此：

$$\frac{\partial\mu}{\partial v} = -\sigma(1 - \sigma') + (1 - \sigma)\sqrt{\sigma'^2 - \sigma_{\text{trans}}^2} \triangleq c(t, t') \quad (30)$$

$c(t, t')$ 是仅依赖于 timesteps 的标量系数。代入得：

$$\frac{\partial\mathcal{L}_{\text{GRPO}}}{\partial\ell_{j,i,s}} = \frac{-A \cdot \rho_i \cdot c(t_i, t_{i+1})}{\tau \cdot \sigma_{\text{trans}}^2} \sum_{k=1}^K \lambda_k (\delta_{kj} - \lambda_j) \langle x_{t_{i+1}} - \mu_{\text{new}}, v^{(k)} \rangle \quad (31)$$

4 比较分析

4.1 梯度结构对比

	NFT	GRPO
Direction	$\langle x_0^\pm - x_0, v^{(k)} \rangle$	$\langle x_{t_{i+1}} - \mu_{\text{new}}, v^{(k)} \rangle$
Signal source	x_0 reconstruction error	Transition residual
Scaling	$\sigma A_{\text{max}}/(\tau w^\pm)$	$A \cdot \rho \cdot c/(\tau \sigma_{\text{trans}}^2)$
Advantage role	Weights pos/neg via $r(A)$	Direct multiplicative $-A \cdot \rho$
Ratio ρ	无	$\exp(\Delta \log p)$ —adaptive step size
Clipping	无显式 clip	PPO clip or DPPO mask
Off-policy	Yes (EMA for v_{old})	On-policy (sample = train policy)

4.2 梯度量级分析

Proposition 3 (GRPO 的 ratio 放大效应). GRPO 梯度中额外包含 ratio $\rho_i = \exp(\Delta \log p_i)$ 。当 policy 变化较大时 ($\Delta \log p$ 远离 0)，ratio 指数放大梯度。PPO clip 限制了这种放大：

$$|\text{effective } \rho| \leq 1 + \epsilon \quad (32)$$

但在 clip region 内梯度为零。DPPO mask 在高 KL 时直接置零，避免梯度爆炸。

Proposition 4 (NFT 的自归一化). NFT 的 weight $w^\pm = \text{sg}(\|x_0^\pm - x_0\|_1/d)$ 提供了自适应归一化：当 reconstruction error 大时 w 大，梯度被自动缩小。这提供了数值稳定性，但也可能在训练早期抑制有用信号。

4.3 信号传递路径

NFT: Velocity-Space Projection

$$\ell \xrightarrow{\text{softmax}} \lambda \xrightarrow{\text{combine}} v_{\text{new}} \xrightarrow{x_0=x_t-\sigma v} x_0^{\text{pred}} \xrightarrow{\text{MSE}} \mathcal{L} \quad (33)$$

梯度路径: $\partial \mathcal{L} / \partial \ell$ 需要 $\nabla_v \mathcal{L}$ 投影到 teacher basis $\{v^{(k)}\}$ 上。

GRPO: Log-Probability Chain

$$\ell \xrightarrow{\text{softmax}} \lambda \xrightarrow{\text{combine}} v_{\text{new}} \xrightarrow{\text{dynamics}} \mu_{\text{new}} \xrightarrow{-\|\cdot\|^2/(2\sigma^2)} \log p \xrightarrow{\text{exp}} \rho \xrightarrow{-A\cdot} \mathcal{L} \quad (34)$$

梯度路径更长但每步都是标准的 differentiable operation。

5 数值稳定性

5.1 GRPO 特有的数值问题

σ_{trans}^2 在分母. 当 $\sigma_{\text{trans}} \rightarrow 0$ (ODE limit), 梯度 $\propto 1/\sigma_{\text{trans}}^2 \rightarrow \infty$. 因此 MoF-GRPO 必须使用 **stochastic dynamics** (CPS/Flow-SDE), 不能用 ODE。

Ratio explosion. 当 logits 变化剧烈时, ρ 可能 $\gg 1$. PPO clip 限制在 $[1-\epsilon, 1+\epsilon]$, DPPO mask 在 high-KL 时直接归零. 对 MoF (仅 $K \times T \times S$ 个参数), logits 变化受 LR 限制, ratio explosion 风险较低。

5.2 NFT 特有的数值问题

Weight $w \rightarrow 0$. 当 $x_0^{\text{pred}} \approx x_0$ 时, $w = \|x_0^{\text{pred}} - x_0\|_1/d$ 趋近 0, 代码中 clip 到 10^{-5} . 这导致梯度 $\propto 1/w$ 可能瞬间放大. 实际中训练后期接近收敛时才出现。

6 总结

特性	NFT	GRPO
Loss 类型	Weighted MSE on x_0	PPO policy gradient
需要 log-prob	否	是
Dynamics 要求	ODE (deterministic)	CPS/SDE (stochastic)
Off-policy	是 (EMA v_{old})	否 (on-policy sampling)
梯度方向	Velocity-space projection	Log-prob chain
自适应步长	$1/w$ (self-norm)	ρ (importance ratio)
Clipping/Mask	无	PPO clip / DPPO mask
额外内存	仅 final latents	Full trajectory + log-probs

两种优化目标对 MoF logits 的梯度信号传递路径不同: NFT 通过 reconstruction 质量间接传递 reward 信号, GRPO 通过 likelihood ratio 直接传递. NFT 适合 ODE dynamics (确定性, 无需 log-prob), GRPO 需要 stochastic dynamics (CPS/SDE) 支持。