

# 多-Teacher 合并的形式化与“更好混合”判据路线图

从 DiffusionOPD 的平凡路由到凸包约束下的最优混合

Flow Factory

## Abstract

本文把“将  $K$  个在不同 prompt set 上、由 single-reward RL 各自训练的 teacher flow model 合并为单个 student”形式化为在 *multi-teacher* 路由凸组合  $v^\theta = \sum_k \lambda_k(t, c) v^{(k)}$  上的优化问题，并理顺“如何得到更好的混合”这一思路。(i) 在该形式化下，先前工作 DiffusionOPD 的 per-step KL 蒸馏，其最优解恰是一个平凡路由——单 teacher 监督时为 one-hot、多 teacher 监督时为各 teacher velocity 的监督权重加权均值。(ii) 平凡解继承 single-reward teacher 的 reward-hacking，导致 in-domain 输出分布坍塌/锐化，而 prompt-rewriting 只能缓解、不能根治坍塌。(iii) 由于混合本身即合法 flow model，“更好的混合”可统一写成凸包约束优化  $\max_\lambda Q(v_\lambda)$ ，真正的难点在于如何定义  $Q$ 。我们逐条分析五条候选目标（旧 / 强 reward RL、training-free user study、min-KL-to-pretrained、真实数据 SFT），并指出 reward 自循环下“更高分  $\neq$  更好”这一根本困难。本文为 roadmap 文档，凸组合合法性的自包含证明见附录。

## Contents

|     |                                            |   |
|-----|--------------------------------------------|---|
| 1   | 引言与问题形式化                                   | 2 |
| 1.1 | 动机：从单 reward 专家到统一 student                 | 2 |
| 1.2 | 记号                                         | 2 |
| 1.3 | 目标层次                                       | 2 |
| 2   | 背景：DiffusionOPD 作为 per-step KL 蒸馏          | 2 |
| 2.1 | 单步 KL 退化为 velocity MSE                     | 3 |
| 2.2 | DiffusionOPD 目标                            | 3 |
| 3   | 凸组合形式化与 DiffusionOPD 的平凡路由最优解              | 3 |
| 3.1 | Student 作为 multi-teacher 路由凸组合             | 3 |
| 3.2 | DiffusionOPD 最优解 = 平凡路由                    | 4 |
| 3.3 | 多 teacher 监督下最优混合系数的闭式推导                   | 4 |
| 4   | 平凡解的病理：in-domain 坍塌与锐化                     | 5 |
| 4.1 | single-reward teacher 的 reward-hacking 必然性 | 5 |
| 4.2 | in-domain 坍塌 vs. OOD 平滑泛化                  | 5 |
| 4.3 | 坍塌/锐化的形式化判据（TODO）                          | 6 |
| 5   | “更好的混合”：凸包约束优化及其目标的选择                      | 6 |
| 5.1 | 统一框架：凸包约束下的目标最大化                           | 6 |
| 5.2 | O1：用训练 teacher 的 reward 做 RL               | 6 |
| 5.3 | O2：用一个更强的 reward 做 RL                      | 7 |
| 5.4 | O3：training-free user study / 成对偏好         | 7 |
| 5.5 | O4：最小化与 pretrained 模型的 KL                  | 8 |
| 5.6 | O5：小规模真实数据 SFT                             | 8 |
| 5.7 | 五条目标对比                                     | 9 |

|          |                                                     |           |
|----------|-----------------------------------------------------|-----------|
| <b>6</b> | 综合与开放问题                                             | <b>9</b>  |
| 6.1      | 统一视角：凸包内的约束微调 . . . . .                             | 9         |
| 6.2      | 开放问题 . . . . .                                      | 10        |
| <b>7</b> | 与现有文档的关系                                            | <b>10</b> |
| <b>A</b> | 凸组合的合法性：仿射闭包、真传输与 <b>well-posedness</b>             | <b>11</b> |
| A.1      | 共享 marginal 下的仿射闭包 . . . . .                        | 11        |
| A.2      | 非共享 marginal：真传输是 responsibility-weighted . . . . . | 11        |
| A.3      | 为何 MoF 不依赖上述合法性 . . . . .                           | 11        |

# 1 引言与问题形式化

## 1.1 动机：从单 reward 专家到统一 student

现代文生图扩散/流匹配模型的对齐已成为多目标问题：组合准确性（GenEval）、文字渲染（OCR）、人类偏好（PickScore / Aesthetic）各有其 reward 与训练集。主流做法是分而治之：对每个目标用 single-reward RL 训练一个专家 teacher，得到一组互不相同的 LoRA 快照  $\{v^{(k)}\}_{k=1}^K$ 。但部署需要单个模型同时具备这些能力，于是产生本文的核心问题：

### 核心问题

给定  $K$  个分别在 prompt set  $\{\mathcal{P}_k\}$  上训练好的、冻结的 teacher flow model  $\{v^{(k)}\}$ ，如何把它们合并成单个 student flow model  $v^\theta$ ，使其在每个 in-domain set 上不退化于对应 teacher，并在 out-of-domain (OOD) prompt 上获得跨目标的能力增益？或者说，让 student flow model 获得何种程度的能力提升？

## 1.2 记号

| 符号                                         | 含义                                                                    |
|--------------------------------------------|-----------------------------------------------------------------------|
| $K, k$                                     | teacher 数量与索引                                                         |
| $S, s$                                     | prompt set (source) 数量与索引； $s(c) = \text{prompt } c \text{ 的 source}$ |
| $\mathcal{P}_s$                            | source $s$ 的 prompt set； $\pi_s = \Pr(p \in \mathcal{P}_s)$           |
| $v^{(k)}(x, t, c)$                         | 第 $k$ 个 teacher 的 velocity field (冻结 LoRA 快照)                         |
| $v_{\text{base}}(x, t, c)$                 | base (pretrained) 模型 velocity field                                   |
| $\delta^{(k)} = v^{(k)} - v_{\text{base}}$ | teacher $k$ 的 LoRA residual (skill 方向)                                |
| $v^\theta(x, t, c)$                        | student velocity field (待求)                                           |
| $\lambda_k(t, c)$                          | 路由 (混合) 系数， $\sum_k \lambda_k = 1$                                    |
| $M_s \subseteq \{1, \dots, K\}$            | 监督 prompt set $\mathcal{P}_s$ 的 teacher 子集                            |
| $q_\theta$                                 | student 自身 rollout 的轨迹/状态分布 (on-policy)                               |
| $p_\theta(\cdot   x_t)$                    | student 在 $x_t$ 的单步 denoising transition kernel                       |
| $\bar{\sigma}_t^2$                         | 单步 transition 方差 (由 scheduler 决定，所有模型共享)                              |
| $R_j, f_j^{(s)}(\lambda)$                  | 第 $j$ 个 reward；混合 $\lambda$ 在 $\mathcal{P}_s$ 上的期望 $R_j$              |
| $\Delta^{K-1}$                             | 概率单纯形 $\{\lambda \geq 0, \sum_k \lambda_k = 1\}$                      |

## 1.3 目标层次

沿用姊妹文档 (mof\_per\_set\_analysis.tex / mof\_notes.tex) 的两层目标：

- **Level-1 (in-domain 不退化)**：对每个  $s$ ， $f_s^{(s)}(v^\theta) \geq f_s^{(s)}(v^{(s)})$ 。
- **Level-2 (OOD 增益)**：存在  $j \neq s$  使  $f_j^{(s)}(v^\theta)$  超过最佳单 teacher baseline。

本文的贡献不是再证这两层保证 (已分别在 mof\_per\_set\_analysis.tex 与 mof\_ood\_guarantee\_analysis.tex 中讨论)，而是形式化合并问题本身、刻画 DiffusionOPD 平凡解的结构与病理，并理顺“如何定义更好混合”的路线图。

## 2 背景：DiffusionOPD 作为 per-step KL 蒸馏

DiffusionOPD<sup>1</sup> 把 on-policy distillation (OPD) 从离散 token 生成推广到连续扩散 Markov 过程，给出 denoising transition 的闭式 per-step KL 目标，并以 round-robin 的方式蒸馏：每轮从

<sup>1</sup><https://github.com/ali-vilab/DiffusionOPD>, *DiffusionOPD: A Unified Perspective of On-Policy Distillation in Diffusion Models* (Li et al., 2026)。

各 task 采 prompt, 用当前 student rollout 得到 on-policy 轨迹, 在 student 访问到的状态处查询对应 task 的 teacher 作为监督, 累加各 task 的 OPD loss 后更新一次 student。

### 2.1 单步 KL 退化为 velocity MSE

设 student 与 teacher 的单步 transition 均为同方差高斯  $p(\cdot | x_t) = \mathcal{N}(\cdot; \mu(x_t, t), \sigma_t^2 I)$ , 且均值是 velocity 的仿射函数  $\mu(x_t, t) = a_t x_t + b_t v(x_t, t)$  (flow-matching / DDPM 调度的标准形式)。则两个同方差高斯的 KL 退化为均值差的二范数:

$$\text{KL}(p_\theta(\cdot | x_t) \| p^{(s)}(\cdot | x_t)) = \frac{1}{2\sigma_t^2} \|\mu_\theta - \mu_s\|^2 = \underbrace{\frac{b_t^2}{2\sigma_t^2}}_{\triangleq w_t} \|v^\theta(x_t, t, c) - v^{(s)}(x_t, t, c)\|^2. \quad (1)$$

### 2.2 DiffusionOPD 目标

按 source 路由 (route-by-source) 的 DiffusionOPD 目标即

$$\mathcal{L}_{\text{OPD}}(\theta) = \sum_{s=1}^S \pi_s \mathbb{E}_{p \sim \mathcal{P}_s, (x_t, t) \sim q_\theta} \left[ w_t \|v^\theta(x_t, t, c) - v^{(s(c))}(x_t, t, c)\|^2 \right]. \quad (2)$$

其优势是: 闭式目标避免了 PPO 风格 policy gradient 的 score-function 额外方差, 且 SDE/ODE 采样器统一适用 (transition / mean matching)。本文把它作为合并问题的 *baseline*, 并在下一节中放入凸组合形式化加以分析。

## 3 凸组合形式化与 DiffusionOPD 的平凡路由最优解

### 3.1 Student 作为 multi-teacher 路由凸组合

我们的关键观察是: 把 student 写成各 teacher velocity 的仿射组合  $v_\lambda = \sum_k \lambda_k v^{(k)}$  ( $\sum_k \lambda_k = 1$ ), 它始终定义一个 well-posed 的采样 ODE  $\dot{x}_t = v_\lambda(x_t, t)$ , 因而本身就是一个可采样、可打分、可蒸馏的 flow model。两点结论需分清 (自包含推导见附录 A):

- 共享 **marginal** 下精确: 若各 teacher 传输同一 marginal path, 则  $v_\lambda$  恰是该 path 的合法 flow-matching velocity (仅需 sum-to-one, 凸性非必需; CFG 即非凸仿射之例)。
- 非共享 **marginal** 下仅为近似: 本文 teacher 是同一 base 的 LoRA/RL 微调, 其 marginal 相近但不相同; 此时常权平均并不传输各 marginal 的混合, 正确传输需 data-dependent 的 responsibility 加权  $\tilde{v}_\lambda$ 。但 MoF 不依赖这一合法性结论——它把  $v_\lambda$  直接当采样器、按实际产出的 reward / 蒸馏 target 优化, 故 “well-posed ODE” 这一点已足够。

因此可以不把 student 当作自由网络, 而是参数化为一个 multi-teacher 路由凸组合:

$$\boxed{v^\theta(x, t, c) = \sum_{k=1}^K \lambda_k(t, c) v^{(k)}(x, t, c), \quad \sum_k \lambda_k(t, c) = 1, \lambda_k \geq 0.} \quad (3)$$

其中路由系数  $\lambda$  与 timestep  $t$  和 prompt  $c$  (经由  $s(c)$  或其 embedding) 有关。这一形式化把搜索空间从模型权重  $\mathbb{R}^P$  ( $P \sim 10^7\text{--}10^9$ ) 压缩到路由空间 ( $\Delta^{K-1}$ ), 且让我们能在同一坐标系下比较 DiffusionOPD 与各种 “更好混合” 方案。

### 3.2 DiffusionOPD 最优解 = 平凡路由

命题 1 (DiffusionOPD 在凸组合参数化下的最优解). 将 (3) 代入 (2), 并假设路由具备足够表达力 (可对每个  $(t, c)$  独立取值)。则在每个  $(t, x_t, c)$  点上 OPD 最优解为:

1. 一一对应情形 (DiffusionOPD 的 prompt set 不相交假设,  $\mathcal{P}_s$  仅由单 teacher  $s$  监督):  $\lambda^*(t, c \in \mathcal{P}_s) = \mathbf{e}_s$  (one-hot), 即  $v^\theta = v^{(s)}$ 。此即 route-by-source 的 hard routing。
2. 多 teacher 情形 (把 OPD 推广到  $\mathcal{P}_s$  由子集  $M_s$  以监督权重  $\pi_{k|s}$  监督):  $\lambda_k^*(t, c \in \mathcal{P}_s) = \pi_{k|s}$ , 即  $v^\theta = \sum_{k \in M_s} \pi_{k|s} v^{(k)}$ , 是各 teacher velocity 的 (监督权重加权) 均值; 等权监督时退化为算术平均  $\frac{1}{|M_s|} \sum_{k \in M_s} v^{(k)}$ 。

*Proof.* 情形 1 是情形 2 在  $M_s = \{s\}$  时的特例。情形 2 的闭式推导见 §3.3。  $\square$

注 1 (与  $\mathcal{T}_B \subseteq \mathcal{T}_A$  的衔接). 平凡路由 (one-hot 顶点或固定均值) 只覆盖凸包的顶点或一个固定点, 而 (3) 的整个路由空间是  $(\Delta^{K-1})$  (可随  $t, c$  变化)。这正是 `mof_vs_direct_opd_gap.tex` 中  $\mathcal{T}_B^{\text{ext}} \subseteq \mathcal{T}_A$  的几何内容: DiffusionOPD 把 student 钉在凸包的平凡点上, MoF 则放开为整个凸包并按下游目标搜索。本文 §5 讨论“放开后如何定义最优”。

### 3.3 多 teacher 监督下最优混合系数的闭式推导

本节回答: 当一个 *prompt set* 被多个 *teacher* 同时监督时, OPD 学到的混合系数由什么决定?

设定. 设  $\mathcal{P}_s$  由 teacher 子集  $M_s$  监督, 监督权重  $\pi_{k|s} \geq 0$ ,  $\sum_{k \in M_s} \pi_{k|s} = 1$  (DiffusionOPD 的原始设定是  $M_s = \{s\}$ ; 这里把它的 per-step KL 目标推广到  $\mathcal{P}_s$  落在多个 teacher 适用域内的情形)。on-policy per-step OPD 目标为

$$\mathcal{L}_s(\theta) = \mathbb{E}_{(x_t, t) \sim q_\theta} \left[ \sum_{k \in M_s} \pi_{k|s} \text{KL}(p_\theta(\cdot | x_t) \| p^{(k)}(\cdot | x_t)) \right]. \quad (4)$$

闭式最优. 由 (1), 在固定  $(x_t, t, c)$  处目标对  $v^\theta$  是二次型

$$J(v^\theta) = w_t \sum_{k \in M_s} \pi_{k|s} \|v^\theta - v^{(k)}\|^2, \quad (5)$$

严格凸, 令  $\nabla_{v^\theta} J = 0$  即  $\sum_k \pi_{k|s} (v^\theta - v^{(k)}) = 0$ , 得

$$\boxed{v^{\theta*}(x_t, t, c) = \sum_{k \in M_s} \pi_{k|s} v^{(k)}(x_t, t, c) \implies \lambda_k^* = \pi_{k|s}.} \quad (6)$$

命题 2 (多 teacher OPD 最优系数 = 监督权重). 在共享 scheduler (同方差高斯 transition、velocity 仿射均值) 下, 多 teacher OPD 的最优混合系数等于监督权重  $\pi_{k|s}$ , 它与  $(x_t, t)$  无关; 等权监督时为均匀  $1/|M_s|$ , 对应  $v^{\theta*} = \frac{1}{|M_s|} \sum_{k \in M_s} v^{(k)}$ 。

残差形式. 把 teacher 写成 base 加 residual  $v^{(k)} = v_{\text{base}} + \delta^{(k)}$ , 代入 (6) 得最优解的等价残差形式

$$v^{\theta*} = v_{\text{base}} + \sum_{k \in M_s} \pi_{k|s} \delta^{(k)}, \quad (7)$$

即最优 student 在 base 之上、按监督权重  $\pi_{k|s}$  线性叠加各 teacher 的 residual (skill 方向)。该形式便于在 §4 中讨论混合如何继承各 teacher 的行为。

#### 本节小结

DiffusionOPD 在凸组合视角下的最优解是平凡路由: 单 teacher 监督  $\rightarrow$  one-hot; 多 teacher 监督  $\rightarrow$  监督权重加权均值 (命题 1、2)。最优系数等于监督权重  $\pi_{k|s}$ 、与  $(x_t, t)$  无关; 因此平凡均值会按监督权重继承每个 teacher 的行为 (含其 hacking 成分, 见 §4)。

## 4 平凡解的病理：in-domain 坍缩与锐化

平凡路由（无论 one-hot 还是均值）虽然在 OPD 的 KL 意义下最优，却继承了 teacher 的一个结构性缺陷，并在 in-domain 上放大它。本节刻画这一病理。

### 4.1 single-reward teacher 的 reward-hacking 必然性

注 2 (reward-hacking 是 single-reward RL 的内禀属性). 任一在 single reward  $R_k$  上充分 RL 微调的 teacher  $v^{(k)}$ , 都会在  $\mathcal{P}_k$  的某个 prompt 子集上利用  $R_k$  的盲区而非真正提升质量。典型实例：GenEval teacher 在其 train set（甚至 test set）上学会消除背景——因为 GenEval 的物体检测打分对干净背景更友好，去掉背景能稳定提分，却牺牲了整体图像质量。

因此 (7) 中的 residual  $\delta^{(k)}$  不是纯粹的“技能”方向，而是“技能 + hacking”方向；最优混合  $v^{\theta*} = v_{\text{base}} + \sum_k \pi_{k|s} \delta^{(k)}$  会按监督权重把各 teacher 的 hacking 成分一并叠加进来。

注 3 (Prompt-Enhance / Rewriting 只能缓解、不能根治分布锐化). 一个自然的设想是用 Prompt-Enhance / Prompt-Rewriting (PE) 改写训练 prompt 以规避 hacking。我们论证它只能缩小坍缩的范围、而非将其消除，逻辑链如下：

1. 前提（无完美 **reward**）：reward model 与真实质量之间永远存在 gap。RL 训练中只要  $R_k$  持续上升，就必然伴随一定程度的 reward hack——Policy Model 会同时吃进“真实质量提升”与“利用 reward 盲区”两部分，二者在训练信号层面无法区分。
2. 推论：因此任何 RL-tuned teacher（及由其混合的 student）都必然在训练分布的某些 prompt 上 hack，区别只在程度轻重，而非有无。
3. **PE** 的作用与局限：PE 改写消除特定触发 pattern（如诱发背景消失的措辞 “a photo of a ...”），从而收窄坍缩发生的 prompt 范围、减轻其程度；但它不改变第 2 条“必然在某处 hack”的事实——hack 只会转移到改写后仍存在 reward 盲区的其它 prompt 子集上。即 PE 平移 / 收窄了坍缩的支撑，却无法消去它。

待验证 (**future work**)：上述“收窄而非消除”的判断需要一个 GenEval 实验来量化——对比 PE 前后在 train / test prompt 上的 in-domain recall 下降幅度与背景消失率，确认 hacking 子集是被收窄 / 转移还是被真正消除。

### 4.2 in-domain 坍缩 vs. OOD 平滑泛化

实验上观察到一个不对称现象：

- 在 **in-domain** prompt (teacher 见过、且 reward 可打分) 上，合并模型倾向于复刻该 teacher 的 hacking 模式（如背景消失），输出分布在该 prompt pattern 上坍缩/锐化——同一 prompt 反复生成高度相似、低多样性的图像。
- 在 **OOD** prompt (reward 不直接适用，或 teacher 未特化) 上，合并模型反而较好地融合了多个 teacher 的特性，呈现平滑的泛化行为。

即模型在 in-domain 上的输出分布不是一个良好的平滑分布，而是被 reward 的盲区“尖锐化”到了一个狭窄支撑上。

### 4.3 坍缩/锐化的形式化判据 (TODO)

我们用一个无需 *reward*、且以真实数据为 ground truth 的量来刻画这一病理：特征空间的 precision-recall。

**Precision–Recall** (模式坍塌). 固定 prompt (或 prompt 子集  $\mathcal{S}$ ), 对模型生成的一批图像  $\{x_i\}$  与一批真实参考图像  $\{y_j\}$ , 在某特征空间 (如 DINO / CLIP embedding) 中用  $k$ NN 估计各自的支撑 (manifold), 按 improved precision–recall (Kynkäänniemi et al.) 定义:

- **precision** = 生成样本落入真实流形的比例, 度量保真度 (生成的图是否像真图);
- **recall** = 真实样本落入生成流形的比例, 度量覆盖度 / 多样性 (生成分布是否覆盖了真实分布的各个模式)。

分布锐化在这把尺子上的特征很清晰: 当模型把质量塞进一个被 reward 偏好的狭窄模式 (如背景消失) 时, **recall** 显著下降 (真实分布中 “有背景” 等模式不再被覆盖), 且当该模式本身偏离真实图像时 **precision** 也可能下降 (落入非真实的 hacking 模式)。这给出 Definition 1 的可操作量。

注 4 (为何不用基于 teacher 互相分歧的判据). 一类看似自然的 reward-free 判据是 “teacher 分歧加权方差”  $D(x, t) = \sum_k \lambda_k \|v^{(k)} - v_\lambda\|^2$  (混合内部一致性)。我们不采用它:  $D$  把 teacher 的输出默认当成 “干净流形”, 仅度量混合是否偏离 teacher 们的共识。但 single-reward RL 微调后的 teacher 自身已可能带 artifacts / 已 hack, 其分布并不 “好”; 以一组本身可疑的分布为基准来判定 “是否 off-manifold” 并不严谨。precision–recall 以真实数据为 ground truth, 绕开了这一循环依赖, 故是更可靠的判据。

定义 1 (in-domain 分布坍塌/锐化). 称合并模型在 prompt 子集  $\mathcal{S}$  上发生坍塌/锐化, 若相对 base 模型其 recall 显著下降而 reward 上升:

$$\text{recall}_{\mathcal{S}}(v^\theta) \ll \text{recall}_{\mathcal{S}}(v_{\text{base}}), \quad \mathbb{E}_{p \in \mathcal{S}}[R(v^\theta)] > \mathbb{E}_{p \in \mathcal{S}}[R(v_{\text{base}})]. \quad (8)$$

注 5 (与 reward 自循环的关系). Definition 1 刻画的正是一种典型 reward hacking: reward 升而覆盖度掉。关键在于, 判定它不能用训练 reward (那会与造 teacher 的尺子构成自循环, 见 `mof_mixing_quality_analysis.tex` § 自循环), 而要用独立于 reward 的 recall。这也预告了 §5: “更好的混合” 必须引入 reward 之外的信号。

## 5 “更好的混合”: 凸包约束优化及其目标的选择

§3–4 说明: DiffusionOPD 给出的是凸包内的一个平凡点, 且该点在 in-domain 上有坍塌病理。但一旦写成 (3), 混合本身就是一个合法 *flow model*, 我们可以用任意适用于 flow model 的方法去微调路由  $\lambda$ , 在 multi-teacher 凸包内寻找 “更好” 的解。本节把所有方案统一为一个约束优化问题, 并指出真正的难点不在优化, 而在目标  $Q$  的定义。

### 5.1 统一框架: 凸包约束下的目标最大化

$$\lambda^* = \arg \max_{\lambda(\cdot)} Q(v_\lambda) \quad \text{s.t.} \quad \lambda(t, c) \in \Delta^{K-1} \quad \forall (t, c), \quad (9)$$

其中  $v_\lambda = \sum_k \lambda_k(t, c) v^{(k)}$  由 (3) 给出。DiffusionOPD 对应  $Q = -\mathcal{L}_{\text{OPD}}$  (其最优是平凡路由, 命题 1)。下面逐条讨论五个候选  $Q$ , 每条给出定义  $\rightarrow$  分析  $\rightarrow$  现状  $\rightarrow$  与现有 doc 关系。

### 5.2 O1: 用训练 teacher 的 reward 做 RL

定义. 取  $Q_{\text{O1}}(v_\lambda) = \sum_s \pi_s F^{(s)}(\lambda)$ , 其中复合目标  $F^{(s)}(\lambda) = f_s^{(s)}(\lambda) + \gamma \frac{1}{|\mathcal{R}_{\text{OOD}}^{(s)}|} \sum_{j \neq s} f_j^{(s)}(\lambda)$  完全由训练 reward  $\{R_k\}$  构成, 用 DiffusionNFT / Flow-GRPO 优化  $\lambda$ 。




Figure 1: O1 (用训练复合 reward 做 NFT) 下三种神经 router 变体的 eval reward 曲线: **adaLN-router** (绿)、**MLP-router** (红)、**Time-router** (灰)。没有任何一个变体能让三项 in-domain reward 同时维持高位: **Time-router** 把 universal 的 PickScore 单调推到最高 (c,  $\sim 0.92$ ), 却让 OCR (b, 崩到  $\sim 0.55$ ) 与 GenEval (a, 降到  $\sim 0.62$ ) 严重坍缩; **adaLN** 守住 GenEval ( $\sim 0.86$ ) 但 OCR/PickScore 后期下滑; **MLP** 的 GenEval 后期掉到  $\sim 0.73$ 。即优化同一个复合 reward 收敛到一个 trade-off——某项 in-domain metric 必然退化, 印证 O1 的“平凡 / 坍缩”结局。

分析. 实验上 O1 几乎必然收敛到两类平凡结局之一: (a) 达到 DiffusionOPD 的 in-domain ceiling, 但伴随质量退化 (即复刻 hacking, §4.1); (b) 整体不再对特定 prompt pattern 坍缩, 但 in-domain metric 也随之下落。即鱼与熊掌不可兼得 (图 1)。

注 6 (O1 的根本局限). O1 与造 teacher 用的是同一把尺子  $\{R_k\}$ , 因此“最好的混合 = reward 最高的混合”是同义反复。它暗示: 在“旧 reward”指标上, 可能不存在显著优于平凡解的混合——平凡解已逼近该指标的可达上界。要超越, 必须换一把尺子或换一个目标空间。

### 5.3 O2: 用一个更强的 reward 做 RL

定义. 取  $Q_{O2}(v_\lambda) = \mathbb{E}_p[R^\dagger(\text{ODE}(v_\lambda; p))]$ , 其中  $R^\dagger$  是比  $\{R_k\}$  更强/更可靠的 reward (如更强 VLM judge)。

元问题. O2 立刻引出两个必须回答的对照问题:

1. 若有更强的  $R^\dagger$ , 为何不直接用  $R^\dagger$  对 base 做 RL?
2. “先 RL (造 teacher) 再 OPD 混合”相比“直接 multi-reward RL”或“分阶段 RL”究竟好在哪? (这正是 `mof_vs_direct_opd_gap.tex` 的 A vs. B 对比所形式化的: A 的 reward 上界不低于 B, 但实得取决于 Stage-1 优化与蒸馏 gap。)

**reward false-negative.** O2 的动机部分来自  $\{R_k\}$  的不可靠: reward 会产生 false-negative。例如一张背景美观、且含 *GenEval* 要求的正确物体与属性的图像, 因背景干扰物体检测而被 GenEval 判低分 (人眼判满分); GenEval 偏好无背景图, PickScore 偏好有背景图。混合模型有时能生成“人眼判定下 GenEval 正确且美观”的图像 (人眼高分), 却在 reward model 下是低分 (图 2)。

### 5.4 O3: training-free user study / 成对偏好

定义. 不用 reward; 对若干候选混合方案在同一 prompt 上离线生成图像 (图 3), 用 user study / pairwise preference 直接比较, 选出最优混合后再蒸馏到单模型。形式上  $Q_{O3}$  = 人类偏好胜率。

分析. 优点: *training-free*, 且以人眼为 ground truth, 天然规避 reward false-negative 与自循环; 确定最优混合后只需一次蒸馏。






Figure 2: GenEval false-negative 实例。Prompt: “a photo of a blue baseball bat and a pink book”。两张生成图都清晰包含蓝色棒球棒与粉色书本（人眼判定物体、颜色属性与计数均正确，且构图美观），却均被 GenEval 判为 0.5。

### 5.5 O4: 最小化与 pretrained 模型的 KL

定义.

$$Q_{O4}(v_\lambda) = \underbrace{-\mathbb{E}_{(x_t, t) \sim q_\lambda} [\text{KL}(p_\lambda(\cdot | x_t) \| p_{\text{base}}(\cdot | x_t))]}_{= -\mathbb{E}[w_t \|v_\lambda - v_{\text{base}}\|^2]} + \underbrace{c_{\text{ent}} \mathbb{E}_b[H(\lambda)] - c_{\text{unif}} \mathbb{E}_b[\|\lambda - \frac{1}{K}\mathbf{1}\|^2]}_{\text{(optional balancing terms default 0, i.e. pure KL-to-base)}}. \quad (10)$$

含义：在最小化 *distribution shift* 的前提下，获取部分 multi-teacher 的 performance gain——第一项惩罚  $\|v_\lambda - v_{\text{base}}\|$ ，把 student 约束在 base 附近，从而抑制对各 teacher hacking 成分的过度叠加。其余两项为可选平衡项（默认系数 0）：

- **entropy bonus**  $c_{\text{ent}} \mathbb{E}_b[H(\lambda)]$ ：以路由权重的熵作奖励， $c_{\text{ent}} > 0$  让权重保持分散、避免坍塌到单一 teacher（仅 softmax 参数化适用）；对应配置项 `klmin_entropy_coeff`。
- **uniform anchor**  $-c_{\text{unif}} \mathbb{E}_b\|\lambda - \frac{1}{K}\mathbf{1}\|^2$ ：以到均匀分布  $1/K$  的距离作惩罚， $c_{\text{unif}} > 0$  把权重拉向均匀；对应配置项 `klmin_uniform_anchor_coeff`。

二者都在“贴近 base”与“保留多-teacher 混合”之间提供调节旋钮（ $\mathbb{E}_b$  为 batch 内对 per-sample 权重向量  $\lambda$  取平均）。

现状. 正在实验：目前在 pure-KL-to-base 下得到一个指标略高于 *pretrained*、图像质量与 *pretrained* 相近的模型。这符合“适当微调”的直觉，但指标并不亮眼——因为它更接近未 RL-tuned 的 base，在多个 prompt set 上的 reward 都偏低。换言之 O4 牺牲了 in-domain 峰值换取了平滑与稳健。

### 5.6 O5: 小规模真实数据 SFT

定义. 收集一个小的真实图像数据集，对混合模型（或其蒸馏 student）做 SFT，即最小化留出真实数据上的 flow-matching 残差（对应 `mof_mixing_quality_analysis.tex` 度量 A 的 FMres 作为 ground truth）。

分析. 以真实数据分布而非 reward 代理为 ground truth，因果上独立于  $\{R_k\}$ ，可同时抑制 hacking 与坍塌。尚未尝试（需收集真实数据）。必须比较的 baseline 是直接在 *base model* 上 SFT——若混合 + SFT 不优于 base + SFT，则混合这一步的价值存疑。此外，sft 的数据与 base model 的预训练数据分布存在偏差，这可能存在问题。




Figure 3: O3 的离线对比示例 (prompt: “a photo of a blue baseball bat and a pink book”)。

## 5.7 五目标对比

| 目标 $Q$            | 需 reward?          | prompt-dep.? | training-free? | 预期结果                                    | 对应 doc                            |
|-------------------|--------------------|--------------|----------------|-----------------------------------------|-----------------------------------|
| O1 旧 reward RL    | 是 (旧 $\{R_k\}$ )   | 是 (router)   | 否              | 平凡解 / 坍塌, 鱼与熊掌不可兼得                      | ood_guarantee, notes              |
| O2 强 reward RL    | 是 (强 $R^\dagger$ ) | 是            | 否              | 元问题 (vs 直接/分阶段 RL); 受 false-negative 制约 | vs_direct_opd_gap, mixing_quality |
| O3 user study     | 否 (人评)             | ✗ 弱          | ✓              | 全局/粗粒度最优混合, 难学 prompt-dependent         | mixing_quality                    |
| O4 min-KL-to-base | 否                  | 是            | 否              | 接近 base、质量稳健、指标偏低 (实验中)                 | 本文 (新)                            |
| O5 真实数据 SFT       | 否 (需数据)            | 是            | 否              | 取决于数据; base-line=base+SFT (未试)          | mixing_quality (度量 A)             |

## 6 综合与开放问题

### 6.1 统一视角：凸包内的约束微调

本文把“合并  $K$  个 teacher”重述为：先用凸组合 (3) 把搜索空间约束在 multi-teacher 凸包内 (保证合法 flow model 且参数极少), 再用 (9) 在该凸包内按某个目标  $Q$  微调路由。DiffusionOPD 是  $Q = -\mathcal{L}_{\text{OPD}}$  的特例, 其解是凸包的平凡点; O1–O5 则是对  $Q$  的不同选择。真正的开放问题不是如何优化, 而是如何定义  $Q$  (即“更好”)。

## 核心论断

1. DiffusionOPD 最优 = 平凡路由：单 teacher one-hot，多 teacher 监督权重均值（命题 1、2）；最优系数等于监督权重  $\pi_{k|s}$ 、与  $(x_t, t)$  无关。
2. 平凡解继承 single-reward teacher 的 hacking，在 in-domain 上坍缩/锐化（定义 1），需用独立于 reward、以真实数据为 ground truth 的判据（precision-recall）才能诊断。
3. 由于混合本身是合法 flow model，“更好”= 凸包约束下某目标  $Q$  的最优；但在旧 reward 这把尺子下（O1），平凡解可能已近上界——“更高分  $\neq$  更好”。
4. 因此有价值的方向是换尺子或换目标空间：强 reward 但需打破自循环（O2）、人评（O3）、最小 distribution shift（O4）、真实数据 ground truth（O5）。

## 6.2 开放问题

1. “更好”的可操作定义：能否给出一个因果上独立于训练 reward、且可 *prompt-dependent* 学习的标量  $Q$ ？（O3 独立但不 prompt-dependent；O1 prompt-dependent 但自循环。）
2. **O2** 的对照：在统一 setting 下实测“RL $\rightarrow$ OPD 混合” vs. “直接强-reward RL” vs. “分阶段 RL”，验证 `mof_vs_direct_opd_gap.tex` 的  $A \geq B$  边界条件。
3. **O4** 的价值：简单来看 O4 的策略可能会比较有价值——其符合“适当微调”的直觉，但其指标上的劣势是否可以接受？
4. 其他“好”的定义？是否存在其他好的定义？

## 7 与现有文档的关系

本文是 roadmap / position 文档，承上启下地把姊妹文档串成一条线：

| 文档                                           | 关系                                                                                                                                                    |
|----------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>mof_notes.tex</code>                   | 凸组合合法性、两阶段流水线、teacher 训练与保守 checkpoint 选择——其 affine-closure 与本文附录 A 的自包含证明一致；§4.1 引其 teacher-training 经验。                                             |
| <code>mof_vs_direct_opd_gap.tex</code>       | MoF $\rightarrow$ Distill (A) vs. route-by-source OPD (B) 的形式化；本文 §3.2 的 $\mathcal{T}_B \subsetneq \mathcal{T}_A$ 与 §5.3 的元问题直接复用。                    |
| <code>mof_ood_guarantee_analysis.tex</code>  | OOD 严格超越的负面定理与不对称性；本文 §5.2（O1 平凡 / 鱼与熊掌）的理论根据。                                                                                                        |
| <code>mof_mixing_quality_analysis.tex</code> | PoE/responsibility-weighted 真传输（其结论与本文附录 A 一致）、reward 自循环、reward-free 度量（FMres、precision-recall 等）——§4 复用其 precision-recall，§5.4-5.6 复用 FMres / 独立裁判。 |
| <code>mof_per_set_analysis.tex</code>        | per-set Level-1 构造性保证与梯度分析；本文 §1.3 目标层次的来源。                                                                                                           |
| <code>mof_reward_design.tex</code>           | 复合 reward 与 advantage 设计；本文 §5.2 复合目标 $F^{(s)}$ 的定义对齐。                                                                                                |

参考. DiffusionOPD: A Unified Perspective of On-Policy Distillation in Diffusion Models (Li et al., 2026), <https://github.com/ali-vilab/DiffusionOPD>。

## A 凸组合的合法性：仿射闭包、真传输与 well-posedness

本附录给出 §3.1 所用结论的自包含推导。记 marginal density  $p_t(x)$  与速度场  $v(x, t)$  满足连续性方程

$$\partial_t p_t + \nabla \cdot (p_t v) = 0. \quad (11)$$

### A.1 共享 marginal 下的仿射闭包

命题 3 (仿射闭包). 设  $v^{(1)}, \dots, v^{(K)}$  传输同一 marginal path  $p_t$ , 即各自满足 (11)。则对任意  $\lambda \in \mathbb{R}^K$  且  $\sum_k \lambda_k = 1$  (允许  $\lambda_k < 0$  或  $> 1$ )，仿射组合  $v_\lambda = \sum_k \lambda_k v^{(k)}$  也满足 (11) (对同一  $p_t$ )。

*Proof.* 由  $\nabla \cdot$  的线性性，

$$\begin{aligned} \partial_t p_t + \nabla \cdot (p_t v_\lambda) &= \partial_t p_t + \sum_k \lambda_k \nabla \cdot (p_t v^{(k)}) \\ &= \sum_k \lambda_k \underbrace{[\partial_t p_t + \nabla \cdot (p_t v^{(k)})]}_{=0} + \left(1 - \sum_k \lambda_k\right) \partial_t p_t = \left(1 - \sum_k \lambda_k\right) \partial_t p_t. \end{aligned}$$

对非定常 (time-varying)  $p_t$ ，末项为零当且仅当  $\sum_k \lambda_k = 1$ 。□

注 7 (仿射即可，凸性非必需). 证明只用到 sum-to-one，未用  $\lambda_k \geq 0$ ，故权重可为负或超过 1——classifier-free guidance  $v = (1 - w)v_{\text{uncond}} + w v_{\text{cond}}$  ( $w > 1$ ) 即典型的非凸仿射组合。反之，若  $\sum_k \lambda_k = c \neq 1$ ，残留项  $(1 - c) \partial_t p_t$  等价于把速度场整体缩放，是一次时间重参数化，会把样本推离该 marginal path。

### A.2 非共享 marginal：真传输是 responsibility-weighted

命题 4 (混合 marginal 的真传输). 连续性方程关于对  $(p, m)$  (其中 flux  $m = p v$ ) 是线性的。若各  $(p_t^{(k)}, p_t^{(k)} v^{(k)})$  满足 (11)，则混合 marginal  $p_t^{\text{mix}} = \sum_k \lambda_k p_t^{(k)}$  ( $\lambda_k \geq 0, \sum_k \lambda_k = 1$ ) 由

$$\tilde{v}_\lambda(x, t) = \frac{\sum_k \lambda_k p_t^{(k)}(x) v^{(k)}(x, t)}{\sum_k \lambda_k p_t^{(k)}(x)} = \sum_k r_k(x, t) v^{(k)}(x, t), \quad r_k = \frac{\lambda_k p_t^{(k)}}{\sum_j \lambda_j p_t^{(j)}} \quad (12)$$

传输 ( $\sum_k r_k = 1$ )。且  $\tilde{v}_\lambda = v_\lambda$  当且仅当所有  $p_t^{(k)}$  在该点相等 (此时  $r_k \equiv \lambda_k$ )。

*Proof.* 取 flux  $m_t = \sum_k \lambda_k p_t^{(k)} v^{(k)}$ ，则  $\partial_t p_t^{\text{mix}} + \nabla \cdot m_t = \sum_k \lambda_k [\partial_t p_t^{(k)} + \nabla \cdot (p_t^{(k)} v^{(k)})] = 0$ ，故  $(p_t^{\text{mix}}, m_t)$  满足 (11)；传输  $p_t^{\text{mix}}$  的速度即  $m_t / p_t^{\text{mix}} = \tilde{v}_\lambda$ 。□

注 8 (这解释了为何命题 3 必须共享 marginal)。常权平均  $v_\lambda = \sum_k \lambda_k v^{(k)}$  与真传输  $\tilde{v}_\lambda$  (responsibility 权) 仅在所有  $p_t^{(k)}$  重合时一致。teacher 经 RL/LoRA 微调后 marginal 被有意推移，彼此不同，故  $v_\lambda$  一般不传输  $p_t^{\text{mix}}$ ，命题 3 的精确性随之失效。

### A.3 为何 MoF 不依赖上述合法性

注 9 (well-posed ODE 已足够)。

1. 对任意足够正则的向量场，ODE  $\dot{x}_t = v_\lambda(x_t, t)$  解存在且唯一，把先验 pushforward 到某分布  $\tilde{p}_t$ ——它一般既非  $p_t^{\text{mix}}$ 、也非任一 teacher marginal。
2. MoF 把  $v_\lambda$  直接当采样器：rollout、计算 reward/advantage、或用作蒸馏 target，全部基于其实际生成的样本，从不预设它传输某个指定 marginal。因此对 RL/LoRA teacher 而言，命题 3 的失效只否定“ $v_\lambda$  是某干净分布的合法 FM”这一解释，并不影响 §3 之后的任何推导与流水线。

3. 近似的强弱沿时间不均匀：高噪声端各 marginal 同趋  $\mathcal{N}(0, I)$ 、近似最好，越靠近数据端分歧累积、近似越差；在 one-hot 顶点 ( $\lambda = \mathbf{e}_k$ ，即 DiffusionOPD 平凡解)  $v_\lambda = v^{(k)}$  严格合法，近似仅在 simplex 内部（真正混合）被调用。其定量误差界本文不作声称。

以上命题与 `mof_notes.tex`、`mof_mixing_quality_analysis.tex` 中相应结论一致，此处给出自包含证明，正文 §3.1 不再依赖外部文档。