

MoF 混合质量的本质判据

跳出 Reward 自循环：用分布层面的 Reward-Free 准则衡量多 Teacher 混合

Flow Factory

Abstract

MoF 用同一组 reward $\{R_k\}$ 既训练 teacher $\{v^{(k)}\}$ 、又选择混合权重 λ 、还评判混合好坏——这是一个自循环：评价“最好的混合”的尺子，恰好就是定义 teacher 的那把尺子。本文形式化这一自循环及其四类病理 (reward 盲区、放大“万能/可刷”reward、饱和后“更高分 $\neq$ 更好”、无有效性概念)，并提出一个认知跃迁：“好的混合”不应由标量 **reward** 定义，而应由“混合诱导的分布是否是我们想要的那个”来定义。上升到分布层面后，我们给出两条本质视角：(i) 在 Gaussian 路径下 velocity 与 score 仿射相关，因此 **affine velocity** 混合 ($\sum_k \lambda_k = 1$) 在几何上等价于 **score** 求和，即 **Product-of-Experts(AND/共识)**；而分布混合 (OR) $\sum_k \lambda_k p^{(k)}$ 的正确 velocity 是 responsibility-weighted 的——当前 softmax 凸组合偏向“软选择/ OR”，与多技能想要的“AND 共识”存在与 **reward** 无关的结构性错配。(ii) 给出四个因果上独立于训练 **reward** 的度量 (留出真实数据的 FM 残差/似然、marginal 一致性/off-manifold 漂移、teacher skill-residual 干涉、多样性/precision-recall)，它们以数据分布而非 reward 代理为 ground truth。最后把“best mixing”重新定义为三类分布层面目标 (mixture / product / barycenter) 的选择问题，并给出一套纯诊断 (无需训练 student) 的实验顺序。本文是 `mof_reward_design.tex` 与 `mof_ood_guarantee_analysis.tex` 的补充，聚焦“评价准则”而非“优化目标”。

Contents


1	引言与问题陈述	3
1.1	自循环	3
1.2	两条来自本项目内部的证据	3
1.3	本文贡献	3
2	背景与代码地图 (简)	4
2.1	符号表	4
2.2	混合构造与代码地图	6
3	Reward 自循环的形式化与四类病理	6
4	本质视角一：从标量 Reward 到分布层面 (OR vs AND)	7
4.1	Velocity 与 score 的仿射关系	7
4.2	Affine velocity 混合 $\equiv$ Score 求和 $\equiv$ Product-of-Experts	7
4.3	Mixture 分布 (OR) 需要 responsibility-weighted velocity	8
4.4	分布语义谱与结构性错配	8
4.5	适用边界	9
4.6	由此得到的第一个 reward-free 判据	9
5	本质视角二：四个 Reward-Free 度量	9
5.1	度量 A：留出真实数据的 FM 残差 / 似然 (覆盖 + 有效性)	9
5.2	度量 B：Marginal 一致性 / Off-manifold 漂移	9
5.3	度量 C：Teacher Skill-Residual 干涉 (可组合性上限)	10
5.4	度量 D：多样性 / Precision-Recall(模式坍塌)	11

6	若仍用 Reward : 如何打破循环	11
7	综合: 把” Best Mixing ” 重新定义为分布层面目标	11
8	与现有 docs 的关系 + 纯诊断实验顺序	12
8.1	与现有 docs 的关系	12
8.2	纯诊断实验顺序 (无需训练 student)	12

1 引言与问题陈述

1.1 自循环

MoF 的两阶段流水线 (`mof_two_stage_pipeline.tex`) 与 reward 的关系可以画成一个闭环:



形式化地:

1. teacher $v^{(k)} \approx \arg \max_v \mathbb{E}_{p \sim \mathcal{P}_k} [R_k(\text{ODE}(v; p))]$;
2. 混合 $\lambda^* = \arg \max_{\lambda} F(\lambda)$, 其中复合目标 $F(\lambda) = f_s(\lambda) + \gamma \overline{f_{\text{OOD}}}(\lambda)$ 完全由 $\{R_k\}$ 构成 (`mof_notes.tex` eq. advantage);
3. 报告“混合比 single teacher 好”时, 用的还是 $\{R_k\}$ 。

于是“最好的混合 = reward 最高的混合”成为同义反复: 我们从未引入一个独立于 $\{R_k\}$ 的信号去判断混合究竟变好了, 还是仅仅在同一代理指标上爬得更高。

1.2 两条来自本项目内部的证据

自循环并非纯理论顾虑——MoF 自己的实验记录里已有两处征兆, 说明 $\{R_k\}$ 在峰值附近不是质量的可靠 ground truth:

- 保守 **checkpoint** 选择 (`mof_notes.tex` §Teacher training)。三个 teacher 的 frozen 快照都故意取在 *reward* 峰值之前: “later checkpoints continue to climb in reward but exhibit qualitative degradation (especially OCR overfitting to text-detection heuristics at the cost of overall image quality)”。这等于已经承认: 在峰值附近, R_k 继续升高对应的是 reward hacking 而非质量提升。
- **PickScore-dominance** (`mof_notes.tex` §pickscore_dominance)。neural router 把所有样本 (包括 OCR prompt) 都路由到 PickScore teacher, 并非因为图更好, 而是因为 PickScore 的 `applicable_sources` 覆盖全集, 信号覆盖率最高 ($F_{\text{pick}}/F_{\text{ocr}} = 1.4$)。优化器学到的是 reward 的结构, 不是图像质量。

把同一个 $\{R_k\}$ 再用于“评价混合好坏”, 与上面这个保守选择是自相矛盾的: Stage 1 正是在用那把已被判定为“峰值附近不可信”的尺子, 把混合往更高分推。

1.3 本文贡献

1. 自循环的形式化与四类病理 (§3)。
2. 本质视角一 (§4): 证明在共享 Gaussian 路径下, affine velocity 混合 $\equiv$ score 求和 $\equiv$ Product-of-Experts(AND); mixture 分布 (OR) 需要 responsibility-weighted velocity。由此揭示 softmax/affine/none 三种模式的分布语义谱, 以及当前实现与“多技能共识”目标之间与 reward 无关的结构性错配。

3. 本质视角二 (§5): 四个 reward-free 度量及其在本仓库的估计方式。
4. 打破循环的 **reward** 用法 (§6) 与 ”**best mixing**” 的分布层面再定义 (§7)。
5. 纯诊断实验顺序 (§8), 全部无需训练 student。

2 背景与代码地图 (简)

2.1 符号表

本表汇总全文符号, 可随时回查。三处重载需特别注意: s ——作为下标 / $\mathcal{P}_s$ 时是 *source(prompt set)*, 作为 (x, t) 的函数 $s(x, t)$ 时是 *score*; A ——无参数的 A 是 *advantage*, $A(t)$ 是 *velocity-score* 仿射系数; ρ ——无下标的 ρ 是 外推幅度, $\rho_j^{(s), \text{const}}$ 是 single-teacher baseline。

符号	含义
模型与速度场	
K, k	teacher 数量与索引 ($k = 1, \dots, K$)
$v^{(k)}(x, t, c)$	第 k 个 teacher 的速度场 (冻结 LoRA 快照)
v_{base}	base 模型速度场 (无 LoRA, 经 <code>use_ref_parameters</code>)
v_{λ}	常权混合速度 $\sum_k \lambda_k v^{(k)}$ (MoF 实际使用)
$\tilde{v}_{\lambda}$	responsibility-weighted 速度 $\sum_k r_k(x) v^{(k)}$ (mixture/OR 的正确场)
$\bar{v}$	均匀平均 $\frac{1}{K} \sum_k v^{(k)}$
$\Delta v^{(k)}$	teacher 残差 $v^{(k)} - v_{\text{base}}$ (skill 方向)
$\hat{x}_0^{(k)}$	teacher k 隐式预测的干净图 $x_t - \sigma v^{(k)}$
混合权重	
λ, λ_k	混合权重 $\lambda_k = \lambda_k(t, s(c), c), \sum_k \lambda_k = 1$
λ^*	Stage 1 优化得到的混合
δ_s^{const}	恒取 teacher s 的 one-hot 权重 (退化为 single teacher s)
ℓ, τ	原始 logits; softmax 温度
Δ^{K-1}	概率单纯形 ($\lambda_k \geq 0, \sum_k \lambda_k = 1$)
$r_k(x)$	responsibility (责任) 权 $\lambda_k p^{(k)}(x) / \sum_j \lambda_j p^{(j)}(x)$
概率与 score	
p_{data}	真实数据分布
$p_t, p_t^{(k)}$	(teacher k 的) 时刻 t marginal 分布
p_{λ}^{PoE}	Product-of-Experts $\propto \prod_k (p^{(k)})^{\lambda_k}$ (AND/共识)
p_{λ}^{mix}	分布混合 $\sum_k \lambda_k p^{(k)}$ (OR/并集)
$s(x, t)$	score $\nabla_x \log p_t(x)$ (作为 (x, t) 的函数时)
$s^{(k)}, s_{\lambda}, s^{\text{mix}}$	teacher score、score 加权和、mixture 的 score
$A(t), B(t)$	velocity-score 仿射系数 (Lemma 1, 带 t)
时间、样本、采样	
x_0	干净数据样本 ($t = 0$ 端)
x_1, ϵ	噪声样本 ($t = 1$ 端), $\epsilon \sim \mathcal{N}(0, I)$
x_t	加噪 latent $(1 - t)x_0 + t\epsilon$
t, σ	flow 时间 $\in [0, 1]$; 噪声水平 (本约定下 $\sigma = t$)
c, p	prompt 的 embedding; prompt 本身
$\text{ODE}(v; x_T, p)$	用速度场 v 从噪声 x_T 积分采样
索引与集合	
s, S	source (prompt set) 索引与数量; $s(c) = \text{prompt } c$ 的 source
T	推理 timestep 数 (logits 的 T 维)
j	reward 索引 (常指 OOD, $j \neq s$)
$\mathcal{P}_s$	source s 的 prompt set
$J, J $	某样本的 OOD reward 集合及其大小
Reward 与目标	
$R_k, R_j, \{R_k\}$	reward 函数 (训练 teacher 所用)
$R_{\text{in}(s)}$	source s 的 in-domain reward
a_j, A	R_j 的归一化 advantage 分量; 复合 advantage (无参数 A)
$f_j^{(s)}(\lambda)$	混合 λ 在 $\mathcal{P}_s$ 上的期望 reward R_j
$F(\lambda), F^{(s)}$	复合目标 $f_s + \gamma \overline{f_{\text{OOD}}}$
γ	OOD bonus 系数
$\rho_j^{(s), \text{const}}$	R_j 在 $\mathcal{P}_s$ 上的最佳 single-teacher baseline
本文判据量	
$Q, Q_{\text{train}}, Q_{\text{judge}}$	评价混合质量的泛函 (训练用 / 独立裁判)
$\Delta_{\text{train}}, \Delta_{\text{judge}}$	相对 δ_s^{const} 的分数提升
$\text{FMres}(v_{\lambda})$	留出真实数据上的 FM 残差 (度量 A)
$D(x, t)$	teacher 分歧加权方差 (度量 $\hat{B}$, off-manifold 风险)
d_{OR}	到 OR 目标距离 $\ v_{\lambda} - \tilde{v}_{\lambda}\ $
ρ	外推幅度 $\max_k (\lambda_k - 1)_+ + \max_k (-\lambda_k)_+$ (无下标 ρ)

2.2 混合构造与代码地图

记 teacher $v^{(k)} (k = 1, \dots, K, \text{均为同一 base flow model 的冻结 LoRA 快照})$ 、prompt set $\mathcal{P}_s$ 、reward R_j 。MoF 的混合构造 (`mof_notes.tex` eq. `mof_def`):

$$v_\lambda(x, t, c) = \sum_{k=1}^K \lambda_k(t, s(c), c) v^{(k)}(x, t, c), \quad \sum_k \lambda_k = 1. \quad (1)$$

λ 是唯一可学对象 (LUT 模式约 $K \cdot T \cdot S \sim 10^2$ 个参数, router 模式约 10^6 个)。logits $\rightarrow$ weights 由 `weight_normalization` 决定 (`trainers/mof/utils.py:apply_weight_normalization`):

- **softmax**: $\lambda = \text{softmax}(\ell/\tau) \in \Delta^{K-1}$, 凸组合, v_λ 落在 teacher velocity 的凸包内 (插值/软选择);
- **affine**: $\lambda = \ell - (\sum_k \ell_k - 1)/K$, 只要 $\sum \lambda = 1$, 允许 $\lambda < 0, > 1$, 可外推到凸包外 (CFG 即此类);
- **none**: $\lambda = \ell$ 自由线性组合, 靠 `weight_sum_penalty` 软约束 $\sum \lambda \approx 1$ 。

Reward 进入点. Stage 1 用 DiffusionNFT, 把 per-set composite advantage $A = a_{R_{\text{in}(s)}} + \gamma \cdot \frac{1}{|J|} \sum_{j \in J} a_j$ 折进自归一化 MSE(`trainers/mof/nft.py:200---231`)。Stage 2 把 v_{λ^*} 用纯 velocity MSE 蒸馏进单个 student LoRA。

混合发生的代码位置.

- Stage 1 rollout: `common.py:_mof_inference_context` 的 `patched_forward`——先跑 K 个 teacher, 再按当前 λ 合成;
- Stage 1 optimize: `common.py:_combine_velocities_per_sample`;
- Stage 2 distill: `distill.py:_combine_weighted`。

有效性细节 (承上启下). 凸/affine velocity 平均并不采样”分布的混合” $\sum_k \lambda_k p^{(k)}$ 。后者的正确传输场是 density-weighted 的 (`mof_notes.tex` eq. `density_weighted`)。只有在 **shared marginals** (teacher 是同一 base 的 LoRA) 下 v_λ 才近似合法。下一节把这个细节推到底, 得到本文第一条本质判据。

3 Reward 自循环的形式化与四类病理

Definition 1 (Reward 自循环). 设评价混合质量的泛函 $Q(\lambda)$ 仅是训练 teacher 所用 reward 集合 $\{R_k\}$ 的函数。则 Q 与 teacher 的定义因果不独立: 不存在 $\{R_k\}$ 之外的信号进入 Q 。称此为 *reward* 自循环。

Proposition 1 (四类病理). 在 Definition 1 下, $Q = \text{composite reward}$ 至少有四类失效:

1. **Reward 盲区**。 $\{R_k\}$ 未捕捉的质量维度 (真实感、分布覆盖、多样性、校准) 在 Q 中不存在, 因此对它们既不奖励也不惩罚。
2. 放大”万能/可刷”reward。若某 R_{k_0} 的 applicable 范围更广或更易优化, 则它在 Q 中的有效梯度覆盖率最高, λ^* 会系统性偏向 k_0 ——这不由图像质量驱动。PickScore-dominance (§1.2) 是其实例。
3. 饱和后”更高分 $\neq$ 更好”。teacher 已 plateau 且选点在峰值前 (§1.2); Q 继续把 λ 推向更高 $\{R_k\}$, 大概率进入 hacking 区而非质量区。

4. 无有效性概念。affine/none 模式可外推到所有 teacher 流形之外 (§2); 只要碰巧刷分, Q 不会惩罚”跑到无人区”的混合。

Remark 1 (与 OOD 不可证性的关系). `mof_ood_guarantee_analysis.tex` 已证明: 复合 reward 的 argmax 与单个 R_j 的 argmax 一般不一致, 故 OOD 严格超越不可证。那是在 *reward* 内部讨论”能不能更高分”。本文更进一步: 即便分更高, **reward** 这把尺子本身是否度量了我们真正想要的东西, 是一个 reward 内部无法回答的问题——必须引入外部信号。

4 本质视角一: 从标量 **Reward** 到分布层面 (OR vs AND)

认知跃迁:”好的混合”应当用” v_λ 诱导的分布是不是我们想要的那个”来定义, 而非一个标量分数。一旦上升到分布层面, ”如何混合”会分裂成几个数学上精确、且都与 *reward* 无关的算子。

4.1 Velocity 与 score 的仿射关系

采用本仓库约定 (`nft.py`): $x_0 \sim p_{\text{data}}, \epsilon \sim \mathcal{N}(0, I), x_t = (1-t)x_0 + t\epsilon$, FM 速度目标 $v = \epsilon - x_0$ 。marginal p_t 是 Gaussian 路径 (给定 $x_0, x_t \mid x_0 \sim \mathcal{N}((1-t)x_0, t^2 I)$)。

Lemma 1 (Velocity 仿射于 score). 记 $s(x, t) = \nabla_x \log p_t(x)$ 。则

$$v(x, t) = -\frac{1}{1-t}x - \frac{t}{1-t}s(x, t) \triangleq A(t)x + B(t)s(x, t), \quad (2)$$

即 velocity 是 score 的仿射函数, 系数 $A(t), B(t)$ 是只依赖 t 的标量。

Proof. 速度场是条件期望 $v(x, t) = \mathbb{E}[\epsilon - x_0 \mid x_t = x]$ 。对 Gaussian 路径 $x_t = (1-t)x_0 + t\epsilon$, Tweedie 公式给出 $\mathbb{E}[\epsilon \mid x_t = x] = -ts$ 和 $\mathbb{E}[x_0 \mid x_t = x] = \frac{x-t\mathbb{E}[\epsilon \mid x]}{1-t} = \frac{x+t^2s}{1-t}$ 。代入:

$$v = \mathbb{E}[\epsilon \mid x] - \mathbb{E}[x_0 \mid x] = -ts - \frac{x+t^2s}{1-t} = -\frac{x}{1-t} - s\left(t + \frac{t^2}{1-t}\right) = -\frac{x}{1-t} - \frac{t}{1-t}s. \quad \square$$

关键在于: 所有 teacher 共享同一 base scheduler, 故共享同一 $(A(t), B(t))$; 它们的差别全在各自的 score $s^{(k)} = \nabla \log p_t^{(k)}$ 。

4.2 Affine velocity 混合 $\equiv$ Score 求和 $\equiv$ Product-of-Experts

Proposition 2 (AND/共识语义). 设 $\sum_k \lambda_k = 1$ (affine 约束)。则混合速度

$$v_\lambda = \sum_k \lambda_k v^{(k)} = A(t)x \underbrace{\sum_k \lambda_k}_{=1} + B(t) \sum_k \lambda_k s^{(k)} = A(t)x + B(t)s_\lambda, \quad s_\lambda \triangleq \sum_k \lambda_k s^{(k)}, \quad (3)$$

即 v_λ 恰好是有效 score 为 $s_\lambda = \sum_k \lambda_k s^{(k)}$ 的速度场。而 score 的加权和正是

$$\sum_k \lambda_k s^{(k)} = \nabla_x \log \prod_k (p^{(k)}(x))^{\lambda_k}, \quad (4)$$

即 (未归一化的) **Product-of-Experts** / 几何池化 $p_\lambda^{\text{PoE}} \propto \prod_k (p^{(k)})^{\lambda_k}$ 的 score。

Proof. (3) 由 Lemma 1 逐项代入 + $\sum_k \lambda_k = 1$ 保住 $A(t)x$ 项不被缩放。score 求和等于对数密度求和的梯度, 即乘积分布的 score。 $\square$

Remark 2 ($\sum \lambda = 1$ 的几何意义). 若 $\sum_k \lambda_k = c \neq 1$, 则 x 项变成 $A(t)cx$ ——速度场被整体缩放, 等价于时间重参数化, 把样本推离 marginal path。这与 `mof_notes.tex` Remark affine_vs_convex 的连续性方程论证完全一致, 只是换到 score 空间看: **affine** 约束的本质是”只动 **score**、不动几何缩放项”。

4.3 Mixture 分布 (OR) 需要 responsibility-weighted velocity

Proposition 3 (OR/混合语义). 分布混合 $p_\lambda^{\text{mix}} = \sum_k \lambda_k p^{(k)}$ ($\lambda_k \geq 0, \sum \lambda_k = 1$) 的 score 是 responsibility-weighted 的:

$$s^{\text{mix}} = \sum_k r_k(x) s^{(k)}, \quad r_k(x) = \frac{\lambda_k p^{(k)}(x)}{\sum_j \lambda_j p^{(j)}(x)}, \quad (5)$$

对应速度场

$$\tilde{v}_\lambda = \sum_k r_k(x) v^{(k)}(x, t) \quad (\text{data-dependent weights } r_k(x)), \quad (6)$$

这正是 `mof_notes.tex` eq. density_weighted 的 $\tilde{v}_\lambda$ 。

Proof. $\nabla \log \sum_k \lambda_k p^{(k)} = \frac{\sum_k \lambda_k \nabla p^{(k)}}{\sum_k \lambda_k p^{(k)}} = \frac{\sum_k \lambda_k p^{(k)} s^{(k)}}{\sum_k \lambda_k p^{(k)}} = \sum_k r_k s^{(k)}$; 再用 Lemma 1 与 $\sum_k r_k = 1$ 得 (6)。□

核心对照：常权 vs 责任权

- **AND(product / 共识)**: $v_\lambda = \sum_k \lambda_k v^{(k)}$, 权重 λ_k 是常数 (不依赖 x)。语义: 采样同时被所有 teacher 视作高密度的区域 (交集)。这正是 **MoF** 现在做的。
- **OR(mixture / 并集)**: $\tilde{v}_\lambda = \sum_k r_k(x) v^{(k)}$, 权重 $r_k(x)$ 随 x 变化 (责任)。语义: 采样”时而像 A、时而像 B” (并集 / 多样性)。**MoF** 现在并未实现这个。

两者仅在 teacher 一致 ($p^{(k)}$ 重合, $r_k \rightarrow \lambda_k$) 时重合。

4.4 分布语义谱与结构性错配

Corollary 1 (三种 weight_normalization 的分布语义). 在共享 Gaussian 路径近似下:

- **none**(自由线性, $\sum \lambda$ 可漂): 一般破坏几何 (缩放 $A(t)x$ 项), 除非 **weight_sum_penalty** 把 $\sum \lambda$ 拉回 1, 此时退化为下一条;
- **affine**($\sum \lambda = 1$, 允许负/超一): 完整 **PoE / CFG**——可强化共识 (把某 teacher 权重抬过 1、别的压负), 正是”AND 的锐化”;
- **softmax**($\lambda \in \Delta^{K-1}$): 被限制在单纯形内的 受约束 **PoE**——只能”软选择 / 几何插值”, 无法外推。其行为介于纯 AND 与”软 OR-like 选择”之间, 但本质仍是常权, 不是责任权。

与 reward 无关的结构性错配

多技能合成 (”一张图同时构图对、文字准、好看”) 在语义上要的是 **AND / 共识** (乘积)——这与 **affine/none**(完整 PoE) 对齐, 而与 **softmax** 凸组合 (受约束、偏”软选择”) 不完全对齐。

反过来, 若目标是”覆盖多个域的并集 / 保多样性”(OR), 则需要 **responsibility-weighted** $\tilde{v}_\lambda$, 这当前根本没有实现——常权 **softmax** 永远给不出 data-dependent 的责任权。

无论哪种情况, 错配都是算子层面的, 先于任何 reward 调参。仅靠调 γ 、调温度、换 router 都无法修复”算子语义对错”的问题。

Remark 3 (对”naive averaging”失效的新解释). `mof_notes.tex` 用 Jensen 不等式解释 $\bar{v} = \frac{1}{K} \sum_k v^{(k)}$ 的 in-domain 退化。Proposition 2 给出另一个视角: 均匀平均其实是均匀 **PoE** $\prod_k (p^{(k)})^{1/K}$ 。当 teacher 分歧时, 乘积集中在它们的狭窄交集上, 并压低各自”高密度但不共享”的区域——in-domain 自然下降。这与 Jensen 解释互补, 且不依赖 reward。

4.5 适用边界

Lemma 1 用了共享路径 (A, B 同一); Proposition 2 的“ s_λ 是 PoE 的 score”在未归一化意义下严格成立 (采样 ODE 不需要归一化常数)。两条都在 shared marginals 下精确, 对 LoRA-finetuned teacher 是一阶近似 (误差随 teacher 间 marginal gap 增长)——与 `mof_notes.tex` Remark affine_vs_convex 的适用范围相同。因此本节结论应读作: 当 teacher 足够接近 (小 LoRA 扰动) 时, MoF 的 affine 混合在分布上就是 **Product-of-Experts**。

4.6 由此得到的第一个 reward-free 判据

Criterion 1 (语义目标距离). 对一批轨迹访问点 (x_t, t, c) , 同时计算

- 到 OR 目标的距离 $d_{\text{OR}} = \|v_\lambda - \tilde{v}_\lambda\|$ (责任权由 $r_k \propto \lambda_k p^{(k)}$ 给出; 实践用 §5.2 的可计算代理);
- 到 AND 目标的吻合度 (由构造, affine 模式下 v_λ 就是 PoE, 故度量”是否仍在凸包内 / 外推幅度” $\rho = \max_k(\lambda_k - 1)_+ + \max_k(-\lambda_k)_+$)。

用途: 在不看 reward 的前提下, 判定当前 λ 到底在逼近哪种分布语义、以及外推到凸包外多远。若你想要”共识”却发现 λ 停在单纯形内部 (softmax 的天花板), 说明算子选错了, 而非 reward 没调好。

5 本质视角二: 四个 Reward-Free 度量

把”好混合”从 reward 解耦, 真正的 ground truth 是数据分布, reward 只是它的有损代理。下列度量因果上独立于训练 reward, 且都可用本仓库已有能力估计 (teacher 经 `use_named_parameters` 取得, base 经 `use_ref_parameters` 取得)。

5.1 度量 A: 留出真实数据的 FM 残差 / 似然 (覆盖 + 有效性)

Criterion 2 (Held-out real-data FM residual). 取每个域一小批留出真实图像 $x_0 \sim \mathcal{D}_s^{\text{real}}$ 及其 prompt c 。采样 $t \sim U(0, 1), \epsilon \sim \mathcal{N}(0, I), x_t = (1 - t)x_0 + t\epsilon$, 定义

$$\text{FMres}(v_\lambda) = \mathbb{E}_{s, x_0, t, \epsilon} \|v_\lambda(x_t, t, c) - (\epsilon - x_0)\|_2^2. \quad (7)$$

越小说明 v_λ 越是真实数据并集的合法速度场。把 FMres 在以下三种 λ 上对比:

$$\delta_s^{\text{const}} \text{ (单 teacher)}, \quad \lambda = \frac{1}{K} \text{ (均匀)}, \quad \lambda^* \text{ (学到的)}.$$

若 λ^* 的 FMres 不优于最优单 teacher, 则”它更好”是 reward 错觉。

Remark 4 (精确似然 (更贵)). 若要分布层面的硬证据, 可用 probability-flow ODE + Hutchinson 迹估计计算 $\log p_\lambda(x_0)$ (瞬时变量替换)。好混合 = 对各域留出真实数据的 $\log p_\lambda$ 高于任何单 teacher。代价高于 FM 残差, 建议先用残差筛, 再对候选 λ 算似然。无配对真实图时, 可用该域的通用真实图集合近似覆盖性。

5.2 度量 B: Marginal 一致性 / Off-manifold 漂移

先讲清”manifold”和”off-manifold”。这里的”manifold(流形)”指真实/teacher 可信图像所在的低维区域——每个 teacher $v^{(k)}$ 都把噪声往自己学到的图像分布 $p_0^{(k)}$ 上推, 那个分布的支撑就是它的 manifold。”off-manifold”就是落到所有 teacher 的分布都没有支撑的区域 (没有真实图像长那样)。下面说明常权混合为什么会掉进去。

核心逻辑: 混合 **velocity** $\equiv$ 平均”预测的干净图”。代码里干净图预测与速度场的关系是 $\hat{x}_0 = x_t - \sigma v(\text{nft.py})$ 。故在某个 (x_t, t) , 每个 teacher 隐式预测一张干净图 $\hat{x}_0^{(k)} = x_t - \sigma v^{(k)}$; 而常权混合 (因 $\sum_k \lambda_k = 1$) 对应

$$\hat{x}_0^\lambda = x_t - \sigma v_\lambda = \sum_k \lambda_k \hat{x}_0^{(k)}, \quad (8)$$

即混合 **velocity** = 对各 **teacher**”想画的那张干净图”做加权平均。于是:

- teacher 一致 (都想画同一张图): 平均仍是那张图 $\Rightarrow$ 落在数据流形上, 安全;
- teacher 分歧 (想画不同的图): 不同图的平均 = 重影 / 双曝光 = 不是任何一张真实图 $\Rightarrow$ off-manifold。

采样是 ODE 积分: 一旦踩进 off-manifold 区域, teacher 在那里的预测都是外推 (从没见过这种输入), 误差在后续步里被放大 (butterfly effect), 最终出 artifact。(类比: 两条导航在岔路口一个说”左转”、一个说”右转”, 取平均 = 直冲中间的田。)

Criterion 3 (Teacher 分歧加权漂移). 上述风险的可计算代理, 是 teacher 速度 (等价地 $\hat{x}_0^{(k)}$) 围绕混合值的 加权方差:

$$D(x, t) = \sum_k \lambda_k \|v^{(k)}(x, t) - v_\lambda(x, t)\|_2^2. \quad (9)$$

$D \rightarrow 0$ teacher 一致 $v_\lambda \approx$ 每个 $v^{(k)}$ 在流形上; D 大 分歧 混合是”谁都不是”的折中 off-manifold 风险高。沿采样轨迹累计 D 得一个 **off-manifold** 风险分; 它只需已有的 teacher 速度, 零额外数据。

Remark 5 (为什么 D 能代理”到正确混合 $\tilde{v}_\lambda$ 的差距”). 分歧处正确的做法是 responsibility 权 $\tilde{v}_\lambda = \sum_k r_k(x) v^{(k)}$ (Prop. 3): 它选当前 x 实际靠近的那条 teacher 流形 ($r_k \rightarrow 1$, 其余 $\rightarrow 0$), 从而留在流形上; 常权 v_λ 则不管 x 靠近谁、一律盲混。利用 $\sum_k (\lambda_k - r_k) = 0$ 把两者之差改写并放缩:

$$v_\lambda - \tilde{v}_\lambda = \sum_k (\lambda_k - r_k) (v^{(k)} - v_\lambda) \Rightarrow \|v_\lambda - \tilde{v}_\lambda\| \leq \sum_k |\lambda_k - r_k| \|v^{(k)} - v_\lambda\|. \quad (10)$$

$D = 0$ (teacher 一致) 时该差距必为 0; 分歧越大、 $\|v^{(k)} - v_\lambda\|$ 越大, 差距上界越大。算 $\tilde{v}_\lambda$ 需要密度 $p^{(k)}$ (拿不到), 而 D 只用 teacher 速度——所以 D 是这个差距的廉价、*density-free* 代理。

Remark 6. D 还能定位” λ 在哪些 (t) 段做了高风险外推”——天然适合和 `mof_notes.tex` §temporal analysis 的 per-timestep λ 可视化叠加。

5.3 度量 C: Teacher Skill-Residual 干涉 (可组合性上限)

teacher 共享 base v_{base} , 贡献是残差 $\Delta v^{(k)} = v^{(k)} - v_{\text{base}}$ 。由 $\sum_k \lambda_k = 1$:

$$v_\lambda = v_{\text{base}} + \sum_k \lambda_k \Delta v^{(k)}, \quad (11)$$

即混合是 velocity 空间里的 **task arithmetic** (只作用在残差上)。

Criterion 4 (残差干涉). 在轨迹访问点上算两两 cosine $\cos \angle(\Delta v^{(j)}, \Delta v^{(k)})$:

- 近正交 $\Rightarrow$ 技能可叠加, 混合有希望 (可组合性高);
- 负相关 (破坏性干涉) $\Rightarrow$ 技能冲突, 任何 λ 都救不了——这是混合质量的硬上限, 与 reward 无关。

Remark 7 (与梯度消失的呼应). `mof_notes.tex` §Limitations 提到 LoRA 残差很小、softmax 均值消减让梯度 $\sim 10^{-10}$ 。Criterion 4 正是该现象的”健康检查”: 残差不仅要够大, 还要方向互补。两者都是 teacher 集合的内禀属性, 训练前即可测。

5.4 度量 D：多样性 / Precision-Recall(模式坍塌)

Criterion 5 (分布的保真与覆盖). 纯刷 reward(尤偏好类如 PickScore) 极易牺牲多样性。在特征空间 (如 DINO/CLIP) 上, 对 λ 生成集合算 improved precision-recall: precision = 保真 (样本落在真实流形内的比例), recall = 覆盖 (真实模式被覆盖的比例)。好混合应在不显著降低 **recall** 的前提下提升或维持 **precision**; 若 reward 升而 recall 掉, 即模式坍塌——一种典型 reward hacking。

6 若仍用 Reward：如何打破循环

有时仍需一个标量来排序候选 λ 。此时必须引入因果独立于训练 **reward** 的信号：

1. 独立裁判。训练用 reward 与评判用 reward/judge 必须不同 (留出 reward、更强 VLM、或人评)。判据：

$$\Delta_{\text{train}} = Q_{\text{train}}(\lambda^*) - Q_{\text{train}}(\delta_s^{\text{const}}), \quad \Delta_{\text{judge}} = Q_{\text{judge}}(\lambda^*) - Q_{\text{judge}}(\delta_s^{\text{const}}). \quad (12)$$

$\Delta_{\text{train}} > 0$ 而 $\Delta_{\text{judge}} \leq 0$ = **reward hacking**; 这个 gap 本身是一阶诊断量。

2. 跨 **reward** 一致性。好的共识混合应让多个独立 reward 同时不降; 只有单一 (尤其”万能”)reward 涨, 基本是在刷结构 (对应病理 2)。
3. **OOD baseline** 变硬约束。把 OOD 从软 bonus 改成约束 $\max_{\lambda} f_s(\lambda)$ s.t. $f_j(\lambda) \geq \rho_j^{(s), \text{const}} \forall j \neq s$ (mof_ood_guarantee_analysis.tex §8.3 open problem)。此时”好”不再是”复合分最高”, 而是”在不破坏任何单项的前提下取得共识”。

7 综合：把”Best Mixing”重新定义为分布层面目标

§4 表明”如何混合”在分布层面有多个精确目标, reward 这个标量 分辨不出它们。把”best mixing”重述为先选目标分布、再问算子能否表示它：

- **Mixture(OR)** $\sum_k \lambda_k p^{(k)}$: 要”覆盖并集 / 保多样性 / 时而像 A 时而像 B”。正确算子 = responsibility-weighted $\tilde{v}_{\lambda}$ (当前未实现; 需让 router 输出 data-dependent 责任权)。
- **Product / PoE(AND / 共识)** $\prod_k (p^{(k)})^{\lambda_k}$: 要”一张图 同时满足所有技能”。正确算子 = affine velocity 混合 (MoF 现在做的; 建议用 **affine/none** 而非 **softmax**, 以容许共识锐化)。
- **Barycenter(OT)**: 要 teacher 的”几何公平平均”(风格变体的居中)。需 Wasserstein barycenter, 既非简单 velocity 平均也非 PoE。

Reward-Free 判据清单 (选 λ / 选算子时)

1. 先验上限: Criterion 4(残差干涉)——若技能冲突, 停止, 任何混合都没用。
2. 语义对齐: Criterion 1——你要 AND 还是 OR? 当前算子 (softmax/affine/none) 能表示它吗?
3. 有效性: Criterion 3(off-manifold 漂移)—— λ 是否把轨迹推离所有 teacher 流形?
4. 覆盖与质量: Criterion 2(真实数据 FM 残差/似然) + Criterion 5(precision-recall)——分布是否真的变好。
5. (可选) 排序: §6 的独立裁判, 而非训练 reward。

”Best” = 在 1–4 全部健康的前提下, 逼近你显式选定的目标分布的那个 λ 。

8 与现有 docs 的关系 + 纯诊断实验顺序

8.1 与现有 docs 的关系

- `mof_notes.tex`: 给出混合构造、两阶段、affine 闭包与 density-weighted 真传输。本文用 Lemma 1 把”affine 平均 = PoE”点破, 并把其 density_weighted 公式重认成 OR 语义。
- `mof_reward_design.tex`: 讨论优化目标 (reward 怎么设); 本文讨论评价准则 (怎么不靠 reward 判好坏), 互补。
- `mof_ood_guarantee_analysis.tex`: reward 内部的可证性; 本文质疑 reward 本身作为 ground truth, 并给外部信号。§6 第 3 条直接沿用其 §8.3 open problem。
- `mof_per_set_analysis.tex`: in-domain Level-1 构造性保证; 本文的 Criterion 4 解释该保证的质量前提 (残差需互补)。

8.2 纯诊断实验顺序 (无需训练 student)

全部只需 forward teacher + base + 一小批留出真实数据:

1. 可组合性体检 (Criterion 4): 算 $\Delta v^{(k)}$ 两两 cosine 的 per-timestep 谱。先于一切——决定混合有没有希望。
2. 语义定位 (Criterion 1): 对 $\{\delta_s^{\text{const}}, 1/K, \lambda^*\}$ 测外推幅度 ρ 与 d_{OR} , 确认在逼近 AND 还是 OR。
3. 有效性 + 覆盖 (Criterion 3, 2): 沿轨迹累计 D ; 在留出真实数据上比 $\text{FMres}(\delta_s^{\text{const}})$ vs $\text{FMres}(\lambda^*)$ 。
4. 独立裁判抽检 (§6): 对少数 λ 快照用 held-out judge 交叉验证 Δ_{train} vs Δ_{judge} 。

只有当 1–3 通过后, Stage 1 / Stage 2 的 reward 数字才值得相信。

结语

一句话

别再问”哪个 λ 的 reward 最高”, 而问” v_λ 诱导的分布是不是我们要的那个”。这会暴露:(i) 一个与 reward 无关的算子错配——affine velocity 混合其实是 Product-of-Experts(AND), softmax 凸组合偏”软选择”, 而真正的 mixture(OR) 需要当前尚未实现的 responsibility-weighted velocity;(ii) 一组 **reward-free** 度量 (真实数据 FM 残差/似然、marginal 一致性、残差干涉、多样性), 它们以数据分布为 ground truth, 能真正打破”用 reward 造 teacher、又用 reward 评 teacher”的自循环。