

Mixture of Flows

Abstract

本文研究如下问题：将 K 个针对不同 reward objective 微调的 specialist 扩散 teacher $\{v^{(k)}\}_{k=1}^K$ 蒸馏到单个 student 中，使该 student 在每个 reward 上达到对应 teacher 水平的 in-domain 性能，同时在 OOD (out-of-distribution) reward 上获得跨目标增益。我们给出三点观察：

(i) 标准 On-Policy Distillation (OPD) 应用于扩散模型时可分解为 *path-wise* MSE 项与 *policy-gradient* (PG) 项；当 teacher 作为 target 时，PG 项的期望贡献为零，因此单纯的 *velocity MSE* 即足够。

(ii) 朴素多 teacher OPD 有两类自然失败模式：*route-by-source* 把 student 钉死在单 teacher 上限，无 OOD 增益；*averaging* 由 Jensen 不等式导致 in-domain 严格下降，OOD bonus 极小。

(iii) 我们有可能构造一个更好的 target：取可学习的凸组合 $v_\lambda = \sum_k \lambda_{k,t,s,c} v^{(k)}$ ，权重以 (teacher, time, source, prompt) 为条件。由于合法 flow-matching velocity field 的凸组合仍是合法 velocity field， v_λ 是合法 Flow-Matching 模型，可以在小型混合参数空间上用 RL (DiffusionNFT 或 Flow-GRPO) 调优。Student 通过纯 pathwise MSE 从 v_{λ^*} 蒸馏。

本框架给出一个构造性的 Level-1 in-domain 保证：student 在每个 in-domain dataset 上的期望 reward 至少不低于对应单 teacher。但我们也证明 OOD 严格超越在一般情况下无法保证。实验设置（三个 teacher 已训练到 GenEval=0.958, OCR=0.953, PickScore $\approx$ 24.13）以及初步实验观察到的失败模式清单。

Contents

1	引言	2
1.1	动机	2
1.2	已有方案的失败模式	2
1.3	我们的方法	2
1.4	贡献与文章结构	2
2	背景	3
2.1	Flow matching 与符号	3
2.2	OPD: pathwise vs. policy-gradient	3
2.3	Flow-matching velocity 的凸组合仍是 flow-matching velocity	3
2.4	多 teacher OPD 的失败模式	4
3	方法: Mixture of Flows	4
3.1	MoF 构造	4
3.2	二阶段流水线	5
3.3	算法选择	5
3.3.1	NFT vs. Flow-GRPO	5
3.3.2	LUT vs. Router	5
4	理论分析	5
4.1	Level-1 in-domain 保证（构造性）	6
4.2	Level-2 条件性 in-domain 严格超越	6
4.3	无通用 OOD 严格超越保证	6

4.4	NFT β -cancellation	7
4.5	蒸馏 gap	7
5	实验程序	7
5.1	Teacher 训练 (准备阶段, 已完成)	7
5.2	MoF 配置	8
5.3	评估	9
6	实证发现与消融计划	9
6.1	Pathwise vs. PG (验证命题 1)	9
6.2	朴素多 teacher OPD baseline (Step 2)	9
6.3	MoF 主实验: NFT vs. Flow-GRPO (Step 3)	9
6.4	λ^* 的时序分析	9
6.5	NN router 的 PickScore-dominance 失败模式	9
6.6	γ 消融	10
6.7	初始化消融	10
7	讨论	10
7.1	In-domain 与 OOD 的不对称性	10
7.2	何时用哪种架构	10
7.3	局限	11
8	结论	11
8.1	开放问题	11
A	支撑文档索引	11

1 引言

1.1 动机

现代文生图扩散模型的微调已成为多目标问题：人类偏好（如 PickScore）、组合准确性（如 GenEval）、文字渲染保真度（OCR）都是想要的能力，每个都有自己的 reward model 和训练集。RL 微调（Flow-GRPO, DiffusionDPO, DiffusionNFT）通常只优化单个 reward，所以实际流水线是分别训练 K 个专家 LoRA teacher $\{v^{(k)}\}_{k=1}^K$ ——单个 reward 上的 in-domain 表现强，但没有一个可部署的统一 artifact 在所有 reward 上都强。

接下来的自然问题：能否把这 K 个 teacher 蒸馏成一个 student，让该 student 既匹配每个 teacher 的 in-domain 强度，又能获得跨目标增益？我们约定：在 prompt set $\mathcal{P}_s$ 上评估 reward R_s 称为 **in-domain** 性能（ $v^{(s)}$ 是为该 set 训练的 teacher），在 $\mathcal{P}_s$ 上评估 reward R_j （ $j \neq s$ ）称为 **OOD** 性能。

1.2 已有方案的失败模式

两个由 OPD 派生的自然 baseline，以对称的方式失败：

- **Route-by-source**. 每个 prompt 路由到 source-matched teacher, student 只拟合该 teacher。Student 性能上界由对应单 teacher 决定；无 OOD 增益，因为 cross-teacher 信息从未进入梯度。
- **Averaging**. Student 拟合算术平均 $\bar{v} = \frac{1}{K} \sum_k v^{(k)}$ 。由 Jensen 不等式（结合 velocity-MSE 与 KL distillation 的等价关系），student 在每个 in-domain 配对 (s, s) 上严格退化于单 teacher baseline；OOD 往往略有提升但增益小且不必然成立。

两种模式共享同一根本约束：一旦 target 给定，student 的 velocity field 在每个 (x, t) 点上被刚性锁定。没有用于跨目标协同的余量——例如让某个 teacher 在早期 timestep 主导 R_s (layout)，另一个在晚期主导 R_j (texture)。

1.3 我们的方法

先构造一个更好的 **teacher** 再蒸馏。具体地，

$$v_\lambda(x, t, c) = \sum_{k=1}^K \lambda_k(t, s(c), c) v^{(k)}(x, t, c), \quad \sum_k \lambda_k = 1, \quad \lambda_k \geq 0, \quad (1)$$

其中 λ 同时依赖 teacher index k 、timestep t 、source label $s(c)$ 和（可选的）prompt embedding c 。我们仅优化这些 λ ，在 *velocity* 输出空间用 RL 在复合 reward 上调优，然后用纯 pathwise MSE 把最终的 v_{λ^*} 蒸馏成一个 student LoRA。

1.4 贡献与文章结构

1. 方法 (§3)：三阶段流水线——OPD pathwise sufficiency $\rightarrow$ MoF target construction by RL $\rightarrow$ on-policy distillation——把”找到好的凸权重”与”把它编码进单个 LoRA”解耦。混合搜索空间仅 $K \times T \times S \sim 10^2$ 个参数 (LUT) 或 $\sim 10^6$ (router)，相比 10^7 – 10^9 的 student 参数微不足道。
2. 理论 (§4)：构造性的 Level-1 in-domain 保证 (§4.1)；时间互补性下条件性的 Level-2 in-domain 严格超越 (§4.2)；关于 OOD 严格超越的负面定理 (§4.3)，揭示 in-domain 与 OOD 间的不对称性，附带三类充分条件；NFT 的 β 消去性质分析 (§4.4)；以及蒸馏 gap 抹消的讨论 (§4.5)。

3. 实验 (§5)：实验协议包含三个 Flow-DPPO teacher (GenEval/OCR/PickScore 分别达到 0.958/0.953/24.128)、四种混合模块变体 (LUT, LUT-SA, Time Router, adaLN/MLP Router)、两种 RL 选择 (DiffusionNFT, Flow-GRPO)，以及对 OOD bonus γ 与初始化的消融。我们报告了一个初步失败模式——*PickScore-dominance* 效应，神经 router 因 PickScore 的 `applicable_sources` 覆盖所有 source (其他是 domain-specific) 而非对称地放大其 PickScore 信号。

2 背景

2.1 Flow matching 与符号

设 $x_0 \sim p_{\text{data}}$, $x_1 \sim \mathcal{N}(0, I)$ 。Flow matching 参数化一个 velocity field $v_\theta(x, t, c)$ 使 ODE $\dot{x}_t = v_\theta(x_t, t, c)$ 把噪声分布运输到数据分布。标准训练 loss:

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{x_0, x_1, t} \left[\|v_\theta(x_t, t, c) - (x_1 - x_0)\|_2^2 \right], \quad x_t = (1 - t)x_0 + tx_1. \quad (2)$$

Teacher 是冻结的 $v^{(k)}$ (通常是 base flow model 上的 LoRA snapshot)。我们用 $k \in \{1, \dots, K\}$ 索引 teacher, $s \in \{1, \dots, S\}$ 索引 source (每个 source 有 in-domain reward R_s), $i \in \{0, \dots, T-1\}$ 索引 timestep, $\mathcal{P}_s$ 表示 per-source prompt set。记号 $f_j^{(s)}(\lambda) \triangleq \mathbb{E}_{p \sim \mathcal{P}_s} [R_j(\text{ODE}(v_\lambda; x_T, p))]$ 表示 mixing λ 在 prompt set $\mathcal{P}_s$ 上获得的 reward R_j 期望。

2.2 OPD: pathwise vs. policy-gradient

设目标是把 teacher v^{tgt} 蒸馏到 student v_θ 。设 q_θ 是 student 的轨迹分布, q_{tgt} 是 teacher 的。最小化 path-wise KL $\text{KL}(q_\theta \| q_{\text{tgt}})$ 有标准分解 (参考 OPD 文献):

$$\nabla_\theta \text{KL}(q_\theta \| q_{\text{tgt}}) = \underbrace{\mathbb{E}_{q_\theta} \left[\sum_i \frac{1}{2\sigma_i^2} \nabla_\theta \|\mu_\theta^i - \mu_{\text{tgt}}^i\|^2 \right]}_{\text{pathwise}} + \underbrace{\mathbb{E}_{q_\theta} \left[\sum_i (\log q_\theta - \log q_{\text{tgt}}) \nabla_\theta \log q_\theta \right]}_{\text{policy-gradient (REINFORCE)}}. \quad (3)$$

命题 1 (PG 项期望贡献为零). 在标准假设下 (密度光滑, 方差有限) 且 v_θ 的参数化使每个中间 step 满足 $\mathbb{E}_{q_\theta} [\nabla_\theta \log q_\theta] = 0$ (score-function identity), 则 (3) 中 policy-gradient 项在 pathwise 梯度已应用的条件下均值为零, 仅贡献方差。

证明草图. 定义 $r_i := \log q_\theta - \log q_{\text{tgt}}$, $g_i := \nabla_\theta \log q_\theta$ 。由 score-function identity $\mathbb{E}[g_i] = 0$ 。若在 q_θ 下 r_i, g_i 独立 (或弱相关), 则 $\mathbb{E}[r_i g_i] \approx \mathbb{E}[r_i] \mathbb{E}[g_i] = 0$ 。在扩散设定中, sampling 轨迹由 v_θ 生成, pathwise 项已经把 μ_θ^i 校正到 μ_{tgt}^i 方向, 所以剩下的 REINFORCE 信号是高方差噪声而非方向性偏置。经验上 (OPD 文献已确立): 单纯使用 pathwise 项训练与使用完整 KL 梯度训练收敛到同一不动点。□

实践推论: 本流水线中的 distillation 退化为纯 velocity MSE (无 log-prob、无 importance ratio、无 clipping)。这正是 `trainers/mof/distill.py` 的实现 (参见 `mof_two_stage_pipeline.tex`)。

2.3 Flow-matching velocity 的凸组合仍是 flow-matching velocity

命题 2 (FM 的凸闭性). 若 $v^{(1)}, \dots, v^{(K)}$ 都是合法 flow-matching velocity field (各自满足连续性方程 $\partial_t p_t + \nabla \cdot (p_t v^{(k)}) = 0$), 则对任意 $\lambda \in \Delta^{K-1}$:

$$v_\lambda = \sum_k \lambda_k v^{(k)} \quad (4)$$

也是合法 flow-matching velocity field。

Proof. 连续性方程关于 v 是线性的；解的凸组合仍是解（形式上，对应的 marginal density 是 teacher marginal 的凸组合）。□

这是 MoF 的关键结构性事实：任意 per-timestep 混合 v_λ 都定义一个合法扩散模型，其 ODE 是 well-posed 的，轨迹可被采样、打分、蒸馏。

2.4 多 teacher OPD 的失败模式

记 $f_j^{(s)}(\theta)$ 为蒸馏后 student 在 prompt set $\mathcal{P}_s$ 上的 reward R_j 期望。

Route-by-source. 训练 K 个独立 student，或一个根据 $s(p)$ 切换 teacher 的 student。最优 student velocity 为 $v_\theta^*(x, t | p \in \mathcal{P}_s) = v^{(s)}(x, t)$ ，故 $f_s^{(s)}(\theta^*) \approx f_s^{(s)}(v^{(s)})$ （in-domain 精确匹配 teacher，仅有蒸馏 gap），且 $f_j^{(s)}(\theta^*) \approx f_j^{(s)}(v^{(s)})$ （OOD 直接继承 teacher s 的 OOD 分数——无 cross-teacher transfer）。无 OOD 增益。

Averaging. 训练 student 拟合 $\bar{v} = \frac{1}{K} \sum_k v^{(k)}$ 。最优 student 是 $v_\theta^* = \bar{v}$ 。对足够“尖锐”的 reward 应用 Jensen 不等式， $f_s^{(s)}(\bar{v}) < f_s^{(s)}(v^{(s)})$ 对每个 in-domain 配对 (s, s) 成立（严格 in-domain 退化）。OOD 通常略有提升（因为 $\bar{v}$ 混合了 teacher 行为），但增益小且不一定成立。

两种失败模式共享同一结构性原因

Student 的最优 velocity 被 target 构造方式刚性锁定：route 选 teacher 凸包的一个顶点 ($v^{(s)}$)，averaging 选重心。两者都没用上命题 2 给出的 per-timestep 余量。要利用它，权重必须学出来，依据是 reward landscape 上真正能帮上忙的方向——这正是 MoF 的核心想法。

3 方法：Mixture of Flows

3.1 MoF 构造

$$v_\lambda(x, t, c) = \sum_{k=1}^K \lambda_k(t, s(c), c; \psi) v^{(k)}(x, t, c), \quad \lambda_k = \frac{\exp(\ell_k/\tau)}{\sum_{k'} \exp(\ell_{k'}/\tau)}. \quad (5)$$

其中 ψ 是可学习的混合参数的小集合（logits ℓ 经 softmax 归一化）。Teacher 全部冻结且 detached。

我们用五种表达力递增的方式实例化 λ ，每种由 `trainers/mof/common.py` 中的一个 `MoFMixingModule` 子类实现：

模块	ℓ 的形式	说明
LUT	$\ell \in \mathbb{R}^{K \times T \times S}$	Per-source & per-step 查表； $K \cdot T \cdot S \sim 10^2$ 参数。
LUT-SA	$\ell \in \mathbb{R}^{K \times T}$	源无关；按 S 维广播。诊断 baseline。
Time Router	$\ell = \text{MLP}(t)$	t 上连续；无 prompt conditioning。
adaLN Router	$\ell = \text{MLP}(\text{adaLN}(t, c))$	adaLN 融合（DiT 风格）。
MLP Router	$\ell = \text{MLP}([\text{TE}(t) \ c_{\text{pool}}])$	拼接后过 MLP。

我们统一用 ψ 表示参数集（无论是 $K \times T \times S$ logits 还是 router 网络权重）。 ψ 的参数量比 student 参数小至少四个数量级。

3.2 二阶段流水线

Stage 1 (在 ψ 上做 **RL**)。我们把 v_λ 当作 policy，用 RL 在复合 reward 上优化 ψ 。由命题 2， v_λ 是合法 FM，因此任何支持 flow-matching policy 的 RL 算法都适用。我们用 **DiffusionNFT** 作为主算法（基于 advantage 重权的 path-wise 重建 loss；细节见 §3.3.1 和 `mof_two_stage_pipeline.tex`）。备选：**Flow-GRPO** (PPO 风格 ratio + 随机 CPS scheduler) 作为消融对照。

Stage 2 (把 v_{λ^*} 蒸馏到 **student LoRA**)。Stage 1 完成后， ψ^* 冻结并定义 *router-induced teacher* $v^{\text{MoF}^*}(x, t, c) = \sum_k \lambda_k(t, s(c), c; \psi^*) v^{(k)}(x, t, c)$ 。我们用 on-policy MSE 训练单个 student LoRA θ ：

$$\mathcal{L}_{\text{dist}}(\theta) = \mathbb{E}_{(x_t, t, c) \sim q_\theta} \left[\|v^\theta(x_t, t, c) - v^{\text{MoF}^*}(x_t, t, c)\|_2^2 \right], \quad (6)$$

其中 q_θ 是 student 自己的轨迹分布（Stage 2 是 on-policy：student rollout 之后，在每个访问到的 (x_t, t) 上计算 teacher mixture 并匹配）。由命题 1 消去 PG 项，这个 MSE 就是完整的 distillation loss。

为什么要二阶段？Stage 1 用小批 RL 信号在小参数空间找到 ψ^* ；Stage 2 把 K -teacher 推理代价摊销进单个 LoRA 的一次 forward。部署时 student 的推理代价与任何单个 teacher 相同，但行为表现为已优化的凸组合。

3.3 算法选择

3.3.1 NFT vs. Flow-GRPO

DiffusionNFT 通过 reward-weighted self-normalized MSE on x_0 重建优化 ψ ：

$$\mathcal{L}_{\text{NFT}} = \frac{r \cdot \mathcal{M}(v^+) + (1 - r) \cdot \mathcal{M}(v^-)}{\beta} \cdot A_{\max}, \quad \mathcal{M}(v) = \frac{\|x_t - \sigma v - x_0\|^2}{\text{sg}(\|x_t - \sigma v - x_0\|_1/d)}, \quad (7)$$

其中 $r = \text{clip}(\frac{A}{2A_{\max}} + \frac{1}{2}, 0, 1)$ 是归一化 advantage， $v^+ = \beta v_{\text{new}} + (1 - \beta)v_{\text{old}}$ 和 $v^- = (1 + \beta)v_{\text{old}} - \beta v_{\text{new}}$ 是 positive/negative 插值速度， v_{old} 是 EMA-shadow 混合 (off-policy)。详细推导见 `mof_loss_gradient_analysis.tex`。

Flow-GRPO 则使用 PPO-clipped log-prob ratio $\rho = \exp(\log p_{\text{new}} - \log p_{\text{old}})$ ，需要随机 dynamics (CPS / Flow-SDE)，且严格意义上是 on-policy。

选择：默认用 NFT。在小参数 MoF 搜索上 NFT 经验上收敛更快（与其 self-normalized 加权一致：训练初期梯度信号大，随 $x_0^{\text{pred}} \rightarrow x_0$ 自动衰减）。NFT 也不需要 log-prob 计算，Stage 1 显存开销减半。

3.3.2 LUT vs. Router

LUT 风格模块给出 per-source per-timestep 的解耦权重 ($\Lambda_{k,t,s}$)，把优化 landscape 拆成 $T \cdot S$ 个独立 simplex 问题。Router 给出连续 t 的灵活性（解耦训练与推理 T ）和 prompt conditioning，但引入参数共享偏置（其陷阱见 §6）。

4 理论分析

我们在 per-set MoF 设定下工作：每个 $\mathcal{P}_s$ 有自己的 ψ_s （或它的切片 $\Lambda_{:,i,s}$ ），优化在 source 间完全解耦。

4.1 Level-1 in-domain 保证（构造性）

定理 1 (In-domain $\geq$ single teacher). 设 ψ_s^* 是 prompt set $\mathcal{P}_s$ 上 Stage-1 全局最优混合, 对应任何形如 $F^{(s)}(\lambda) = f_s^{(s)}(\lambda) + \gamma \sum_{j \neq s} f_j^{(s)}(\lambda)$ 的复合 reward ($\gamma \geq 0$)。则 δ_s^{const} (在所有 timestep 上把权重 1 全部赋给 teacher s) 是可行点, 且:

$$F^{(s)}(\psi_s^*) \geq F^{(s)}(\delta_s^{\text{const}}) \geq f_s^{(s)}(v^{(s)}) - \gamma \cdot |\Delta_{\text{OOD}}|, \quad (8)$$

即 $v_{\lambda_s^*}$ 的 in-domain reward 至少等于 teacher s 的 in-domain reward, 差一个小余量 $\gamma|\Delta_{\text{OOD}}|$, 该余量在 $\gamma \rightarrow 0$ 时消失。

Proof. $\delta_s^{\text{const}} \in (\Delta^{K-1})^T$ 在搜索空间内, 其诱导 velocity 正是 $v^{(s)}$, 所以 $f_s^{(s)}(\delta_s^{\text{const}}) = f_s^{(s)}(v^{(s)})$ 。不等式由 ψ_s^* 在 $F^{(s)}$ 上的最优性得到。□

这是 MoF 相对 OPD-Average 的关键优势: 最优策略永远不必降到单 teacher 的 in-domain 水平之下。

4.2 Level-2 条件性 in-domain 严格超越

定理 2 (时间互补性下的 in-domain 严格超越). 设存在某个 timestep i^* 和 teacher $k^* \neq s$ 使 $\partial f_s^{(s)} / \partial \lambda_{k^*, i^*} |_{\lambda = \delta_s^{\text{const}}} > 0$ (即在 step i^* 处加入 teacher k^* 的 velocity 对 R_s 有正贡献)。则 $(\Delta^{K-1})^T$ 中 δ_s^{const} 的某个邻域上, 存在正测度子集使 $f_s^{(s)}(\lambda) > f_s^{(s)}(\delta_s^{\text{const}})$, 因此 ψ_s^* 实现严格 in-domain 超越。

注 1. 这个条件——“在某个 timestep 上引入另一个 teacher 实际有助于 in-domain reward”——就是我们所说的时间互补性。它是 teacher 集合与 reward landscape 的经验性质, 而非 MoF 的结构性质。是否成立取决于 teacher 是否真在不同的去噪阶段各有专长。

4.3 无通用 OOD 严格超越保证

自然的后续问题: MoF 能否保证 student 在每个 OOD reward 上严格超越所有单 teacher?

定理 3 (无通用 OOD 保证). 存在合法 MoF 实例 $(K, T, \{v^{(k)}\}, \{R_j\}, \mathcal{P}_s, \gamma)$, 在任意最优 ψ_s^* 下, 某个 OOD reward R_j ($j \neq s$) 满足:

$$f_j^{(s)}(\psi_s^*) < \rho_j^{(s), \text{const}} \triangleq \max_k f_j^{(s)}(\delta_k^{\text{const}}). \quad (9)$$

因此, 仅靠 framework 本身 (不引入额外结构性假设) 的论证无法证明 OOD 严格超越。

三类形式化障碍。

1. **Vertex-maximum block** (顶点最大阻断)。若 $f_j^{(s)}$ 在 $(\Delta^{K-1})^T$ 上 quasi-concave 且最大值在某个常数顶点 $\delta_{k^*}^{\text{const}}$ 取到, 则任何凸组合都不能超过 $f_j^{(s)}(\delta_{k^*}^{\text{const}}) = \rho_j^{(s), \text{const}}$ 。
2. **Composite misalignment** (复合目标错位)。 $\psi_s^* = \arg \max F^{(s)}$ 一般满足 $\nabla f_j^{(s)}(\psi_s^*) \neq 0$, 所以 ψ_s^* 不是 $f_j^{(s)}$ 的临界点。复合最优解为了换取 $f_s + \sum_{j' \neq j} f_{j'}$ 的提升, 会牺牲一些 f_j 。
3. **Reward conflict** (reward 冲突)。若 $\nabla f_s^{(s)} \cdot \nabla f_j^{(s)} < 0$ 在 δ_s^{const} 附近成立, 复合最优解位于 Pareto 前沿上, 无法严格超过两端极点。

OOD 严格超越的充分条件。 满足以下任一条件可把负面定理强化为正面保证：

- (A) *OOD* 时间互补性：不同 timestep i 上，最大化 $\partial f_j^{(s)}/\partial \lambda_{k,i}$ 的 teacher 不同；且 Pareto-improving 区域 $\mathcal{Q}_j = \{\lambda : f_s^{(s)}(\lambda) \geq f_s^{(s)}(\delta_s^{\text{const}}) \text{ 且 } f_j^{(s)}(\lambda) > \rho_j^{(s),\text{const}}\}$ 非空；
- (B) 梯度对齐： $\nabla f_s^{(s)} \cdot \nabla f_j^{(s)} \geq 0$ 在 δ_s^{const} 附近成立（较弱；只保证 $f_j^{(s)}(\psi^*) \geq f_j^{(s)}(\delta_s^{\text{const}})$ ，并不等于 $\rho_j^{(s),\text{const}}$ ）；
- (C) *Pareto-improving* 区域： $\mathcal{Q}_j \neq \emptyset$ 且复合最优解落在其中。

完整证明、反例（monotonic OOD、vertex-max、distillation-gap）、以及与 Level-1 的深层不对称性见 `mof_ood_guarantee_analysis.tex`。不对称性的根源：Level-1 有 构造性 fall-back (δ_s^{const})，但 OOD 没有对称的 safe vertex—— $\delta_{k^*}^{\text{const}}$ 本应是 OOD 的 safe vertex，但它在 in-domain 项上分数差，所以复合优化会主动避开它。

4.4 NFT β -cancellation

定理 4 (β 消去). DiffusionNFT loss (7) 满足：

$$\frac{\partial \mathcal{L}_{\text{NFT}}}{\partial v_{\text{new}}} = A_{\text{max}} \left[r \frac{\partial \mathcal{M}(v^+)}{\partial v^+} - (1-r) \frac{\partial \mathcal{M}(v^-)}{\partial v^-} \right], \quad (10)$$

该表达不依赖 β 。因此 $\partial \mathcal{L}/\partial \psi$ 与 β 无关（ $\mathcal{L}_{\text{NFT}}$ 前因子中的 β 与 $\partial v^\pm/\partial v_{\text{new}}$ 链式法则中的 $\pm\beta$ 精确抵消）。仅 self-normalization weight $w^\pm = \text{sg}(\|x_t - \sigma v^\pm - x_0\|_1/d)$ 依赖 β ，但只作为二阶 *magnitude* 重缩放，不影响方向。

完整推导见 `nft_beta_analysis.tex`。实践含义： β 不是 MoF 的有意义超参；默认 $\beta = 1$ 即可。

4.5 蒸馏 gap

Stage 2 的 MSE (6) 在 q_θ 支撑集上的最小值出现在 $v^\theta = v^{\text{MoF}^*}$ 处。还有两类余量：

- 容量 **gap**。 v^{MoF^*} 可能不在 LoRA 参数化的函数类中。
- **On-policy** 分布偏移。 $q_\theta \neq q_{\text{MoF}^*}$ ；即使在 q_θ 上 pointwise 完美匹配 MSE，也不保证 trajectory-level reward 相等（ODE 积分会放大小的 velocity error）。

定理 5 (Erosion). 设 $\Delta_{\text{stage1}} = f_j^{(s)}(\psi_s^*) - \rho_j^{(s),\text{const}}$ 为 Stage-1 OOD margin, $\epsilon_{\text{distill}} = f_j^{(s)}(\psi_s^*) - f_j^{(s)}(\theta^*)$ 为蒸馏 gap。若 $\epsilon_{\text{distill}} > \Delta_{\text{stage1}}$ ，则 $f_j^{(s)}(\theta^*) < \rho_j^{(s),\text{const}}$ ，即 student 的 OOD 表现劣于最佳单 teacher，尽管 Stage 1 已实现严格 OOD 超越。

实践含义：小的 Stage-1 margin（RL 微调中的典型 regime）容易被 erosion 抹消。Stage-2 student 容量（LoRA rank、训练预算）必须够大以保证 $\epsilon_{\text{distill}} \ll \Delta_{\text{stage1}}$ 。

5 实验程序

5.1 Teacher 训练（准备阶段，已完成）

我们用 Flow-DPPO 在三个 reward objective 上训练了三个 teacher，全部基于同一 base flow model，无 classifier-free guidance：

Teacher	Reward	选定 ckpt	Step	Eval 分数
teacher_geneval	GenEval	checkpoint-600	1200	0.958
teacher_ocr	OCR	checkpoint-220	440	0.953
teacher_pickscore	PickScore (已 $\times 26$ rescale)	checkpoint-1500	3000	24.128

这些 checkpoint 在整个 MoF 实验中作为冻结的 $v^{(k)}$ 使用。每个 teacher 的训练曲线都在所示分数附近 plateau；进一步微调收益递减。我们选定的 checkpoint 略早于各曲线最高 reward 的位置——这是为了规避 DPPO 微调后期常见的 reward-hacking 伪迹（OCR 目标尤甚：reward 持续上升远超“清晰文字”饱和点）。图 1 展示了三个 teacher 的训练与评估 reward 轨迹。




Figure 1: Flow-DPPO teacher 训练曲线（无 CFG）。顶行（a-c）：held-out eval reward；底行（d-f）：on-policy 训练 batch reward。MoF 中作为冻结 $v^{(k)}$ 使用的选定 checkpoint 为：GenEval @ step 1200 ($R=0.958$, ckpt-600)，OCR @ step 440 ($R=0.953$, ckpt-220)，PickScore @ step 3000（rescaled 后 $R \approx 0.931$ ，对应 $\times 26$ 未 rescale 分数 24.128）。这些选择保守地早于图中 tooltip 显示的 peak-reward step；后期 checkpoint 的 reward 仍在攀升但出现质量退化（OCR 尤其会过拟合到文字检测启发式而牺牲整体图像质量）。三条曲线均已 plateau——单目标微调收益递减，正是多 teacher mixing 方案变得有吸引力的转折点。

5.2 MoF 配置

我们正交消融两个设计轴：

- 混合模块：lut, lut_simple (LUT-SA), time_router, adaln_router, mlp_router。
- RL 算法：DiffusionNFT（默认），Flow-GRPO。

Reward 配置遵循标准的 *per-set composite*：

$$A(x_b, s_b) = a_{R_{\text{in}}(s_b)}(x_b) + \gamma \cdot \frac{1}{|J_b|} \sum_{j \in J_b} a_j(x_b), \quad J_b = \{j : j \neq R_{\text{in}}(s_b), a_j(x_b) \neq \text{NaN}\}, \quad (11)$$

含三个 reward (GenEval, PickScore, OCR)、三个 source、以及 `applicable_sources: geneval → [geneval], pick_score → [geneval, pickscore, ocr] (universal), ocr → [ocr]`。默认 $\gamma = 0.2$ 。

5.3 评估

我们同时测量 in-domain 与 OOD 性能:

- In-domain: 每个 s 上的 $f_s^{(s)}(\theta^*)$, 与上表的 matched single teacher eval 分数对比。
- OOD: $j \neq s$ 时的 $f_j^{(s)}(\theta^*)$, 与每个 $f_j^{(s)}(v^{(k)})$ baseline 对比 (完整的 $K \times S$ 交叉表)。

6 实证发现与消融计划

6.1 Pathwise vs. PG (验证命题 1)

在三种模式下跑 Stage-2 蒸馏: `pathwise_only`, `pg_only`, `both`。假设: `pathwise_only` 与 `both` 最终 reward 持平; `pg_only` 不收敛或训练高方差。此 ablation 验证 Stage 2 是纯 regression 问题。

6.2 朴素多 teacher OPD baseline (Step 2)

两个针对 route-by-source 与 average-velocity baseline 的消融:

- **OPD-route**: target $v^{\text{tgt}}(x, t, p) = v^{(s(p))}(x, t, p)$ 。假设: in-domain 匹配 teacher (Level-1 平凡), 无 OOD 增益。
- **OPD-average**: target $v^{\text{tgt}} = \frac{1}{K} \sum_k v^{(k)}$ 。假设: 由 Jensen 不等式 in-domain 严格退化, OOD 略有提升。

两者作为 MoF 的下界参照点。

6.3 MoF 主实验: NFT vs. Flow-GRPO (Step 3)

在 LUT 与 adaLN-router 架构上分别用两种 RL 算法跑 MoF。假设: NFT 收敛更快, 最终 reward 接近; Flow-GRPO 需要更多样本但严格 on-policy。每种设定取 SOTA。

6.4 λ^* 的时序分析

Stage 1 收敛后, 对每个 source s 画 $\lambda_{k,i,s}$ 关于 timestep i 的曲线。基于已知扩散现象类比的假设:

- 早期 **timestep** (高噪声): GenEval-teacher 主导 (全局 layout / 物体放置)。
- 中期 **timestep**: OCR-teacher 贡献 (文字笔画形成)。
- 晚期 **timestep** (低噪声): PickScore-teacher 主导 (美学精修)。

6.5 NN router 的 PickScore-dominance 失败模式

观察: 在初步实验中, 神经 router (Time/adaLN/MLP) 学出的策略始终把所有样本路由到 `teacher_pickscore`, 即使在 PickScore-teacher in-domain 表现差的 OCR prompt 上也是如此。LUT 和 LUT-SA 不出现此失败。

机制 (完整推导见 `mof_pickscore_dominance_analysis.tex`)。因 PickScore 是唯一具有 `universal_applicable_sources` 的 reward, PickScore 信号进入每个样本的 advantage——一次作为 in-domain (pickscore 样本), 两次通过 OOD bonus (geneval / ocr 样本)。共享参数 θ 上的总信号覆盖率:

$$F_{\text{pick}} = \frac{1}{3} \cdot 1.0 + \frac{1}{3} \cdot \gamma + \frac{1}{3} \cdot \gamma = 0.467, \quad (12)$$

$$F_{\text{gen}} = \frac{1}{3} \cdot 1.0 = 0.333, \quad (13)$$

$$F_{\text{ocr}} = \frac{1}{3} \cdot 1.0 = 0.333, \quad (14)$$

所以共享参数 router 上的最优解约偏向 PickScore, 比例 $F_{\text{pick}}/F_{\text{ocr}} = 1.4$ 。LUT 按 source 解耦, 每列只看自己的 1.0:0.2 比例, 因此不发展出主导效应。

缓解 (按推荐优先级):

1. Router 实验中设 $\gamma = 0$ (完全放弃 OOD bonus);
2. 把 PickScore 改为 domain-specific (`applicable_sources:[pickscore]`);
3. 给 router 加 source-conditioning 输入, 使其内部能解耦;
4. 按反信号覆盖率重权 per-source advantage。

方案 1 是推荐的第一步。

6.6 γ 消融

在 adaLN-router 和 LUT 上 grid 扫描 $\gamma \in \{0, 0.05, 0.1, 0.2, 0.5\}$, 画 in-domain 与 OOD 分数。假设:

- LUT: 小 γ 改进在 Pareto-friendly range 内单调。
- Router: $\gamma = 0$ 恢复 OCR; $\gamma > 0$ 触发 PickScore-dominance。

此消融把架构因素与 reward 设计因素分离。

6.7 初始化消融

对比 `uniform`, `random`, `teacher_biased` (in-domain teacher 初始化偏置 $C=2$):

- `teacher_biased`: 从 Level-1-safe 顶点 δ_s^{const} 附近出发, 应该收敛最快, 训练早期 in-domain dip 最小。
- `uniform`: 从 $1/K$ 出发; 学习轨迹必须越过 OPD-Average 中点。
- `random`: 方差对照。

7 讨论

7.1 In-domain 与 OOD 的不对称性

本框架是根本不对称的: in-domain Level-1 是搜索空间的结构性性质 (safe vertex δ_s^{const} 始终存在且对复合目标友好), 而 OOD 严格超越需要额外的经验性结构 (时间互补性、梯度对齐、或非空 Pareto 区域)。从业者不应先验地承诺 OOD 改进; 应当 实测。

7.2 何时用哪种架构

简而言之:

- **LUT**: 适合小 T, S (如 $K=3, T=10, S=3$); 消融友好, 因为每个 source/timestep 切片相互独立。
- **LUT-SA**: 诊断 baseline; 用于判断 S 维是否真有用。
- **Time Router**: 连续 t 灵活性 (解耦训练与推理 T), 无 prompt conditioning; 推荐用于推理 step 消融。
- **adaLN/MLP Router**: prompt-conditioned 混合; 表达力最强, 但默认 γ 下继承 PickScore-dominance 陷阱。

决策树: 若 reward 配置中存在 *universal* reward (覆盖所有 source), 优先用 LUT 或在 router 上设 $\gamma = 0$ 。若所有 reward 都是 domain-specific 且需要 T -灵活性, Time Router 是理想折中。

7.3 局限

- LoRA-shared-base teacher 下, NFT 的梯度量级会变得非常小 ($\sim 10^{-10}$), 由 softmax mean-subtraction 导致 ($v^{(j)} - \bar{v}$ 是小 LoRA residual)。Solutions A–D (direct-reward, REINFORCE, residual-space, unnormalized) 目录见 `mof_per_set_analysis.tex` §13–14。
- Stage 2 蒸馏 gap 是 OOD 增益的主要实践风险; 小 margin 可能需要对 v^{MoF^*} 做多轮 self-distillation refresh。
- 所有理论都依赖完美优化 ($F^{(s)}$ 全局最大); 实际中小样本量 RL 可能收敛到局部最优, 甚至连 Level-1 fallback 都被违反。

8 结论

核心结论

1. Flow matching 框架下的 OPD 蒸馏退化为纯 velocity MSE, 因为 policy-gradient 项均值为零 (命题 1)。本工作中所有 distillation 都是 regression 问题。
2. 朴素多 teacher OPD 有两类失败模式 (route-by-source: 无 OOD 增益; averaging: in-domain 损失)。MoF 用可学习凸组合替代刚性 target——合法性由命题 2 保证, 可在小参数集上用 RL 优化。
3. 理论上 MoF 给出构造性的 Level-1 in-domain 保证 (定理 1)、条件性的 Level-2 严格超越 (定理 2)、以及无通用 OOD 严格超越保证 (定理 3); 不对称性源于缺少复合目标友好的 OOD safe vertex。
4. 二阶段流水线 (RL $\rightarrow$ distill) 解耦 target 优化与部署代价。NFT 优于 Flow-GRPO (小 mixing 搜索上收敛更快); β 由定理 4 不重要。
5. 实践上, 当存在 universal reward 时, 神经 router 会陷入 PickScore-dominance attractor; LUT 和 LUT-SA 通过 source-decoupling 逃脱该问题。设 $\gamma = 0$ 或限制 `applicable_sources` 缓解。

8.1 开放问题

1. 设计具有构造性 OOD fall-back 的 Stage-1 目标 (如 chance-constrained 形式 $\max f_s + \gamma \bar{f}_{\text{OOD}}$ s.t. $f_j \geq \rho_j^{(s), \text{const}}$)。
2. 比 q_θ 上 pointwise MSE 更紧的 trajectory-level distillation loss, 降低 Stage-2 erosion。
3. 找到 teacher 集合 (LoRA rank、训练数据集) 的必要充分条件, 使时间互补性可证成立。
4. 把 LUT 的鲁棒性与 router 的 T -灵活性结合的 source-conditioned router with explicit decoupling priors。

A 支撑文档索引

本 notes 文档整合了核心叙事; 技术推导分散在专题文档中:

主题	文件
NFT vs. GRPO loss / 梯度对比	mof_loss_gradient_analysis.tex
NFT 中的 β 消去	nft_beta_analysis.tex
Per-set λ 架构; 梯度消失分析; solutions A/B/C/D	mof_per_set_analysis.tex
Reward / advantage pipeline 设计	mof_reward_design.tex
连续 router 形式化	mof_continuous_weights.tex
架构数据流 (LUT, LUT-SA, Time Router, adaLN, MLP)	mof_router_architectures.tex
PickScore-dominance 失败模式分析	mof_pickscore_dominance_analysis.tex
OOD 严格超越 (负面定理; 充分条件)	mof_ood_guarantee_analysis.tex
端到端 Stage 1 + Stage 2 流水线; 代码索引	mof_two_stage_pipeline.tex

参考文献 (informal)

本 notes 把如下作品以纯文本方式行内引用; 将 notes 提升为正式 paper 时需补全完整 BibTeX:

- **Flow Matching** (Lipman et al., 2023)。
- **Flow-GRPO, DiffusionDPO, DiffusionNFT** (近期 RL 风格扩散微调工作)。
- **OPD** (on-policy distillation 系列工作, 包含 multi-teacher route-by-source 变体)。
- **Flow-DPPO** (用于训练三个 teacher 的算法)。