

MoF 的 OOD 严格超越保证：理论可证性分析

为什么“ $\text{OOD} > \text{best single teacher}$ ”在一般情况下不可证

Flow Factory

Abstract

现有 MoF 理论给出两条保证：(i) Level-1 in-domain 保证 ($\geq \text{single teacher}$) 是构造性的；(ii) Level-2 in-domain 严格超越是条件性的（依赖时间互补性）。本文系统分析第三条 **claim**：MoF 蒸馏后的 student 在 OOD reward 上是否一定严格超越最佳单 teacher 的 OOD baseline。

主要结论：在一般情况下无法理论保证 **OOD** 严格超越。我们形式化三类根本性障碍（vertex-maximum block、复合目标错位、reward conflict），给出三个反例证明负面结果，然后给出三类充分条件（temporal complementarity for OOD、non-conflicting gradients、Pareto-improving 区域非空）描述何时能证明严格超越。最后讨论蒸馏阶段引入的额外损失如何进一步削弱保证。

核心 insight：in-domain Level-1 的构造性保证依赖 δ_s 始终在搜索空间内（“退化到 single teacher s ”永远是 fallback）；OOD 没有对称的构造——“退化到 single teacher j ”（ $j \neq s$ ）会摧毁 in-domain，所以复合优化不会自发地落到那里。

Contents

1	引言与问题陈述	2
1.1	已有保证的回顾	2
1.2	本文要回答的问题	2
1.3	本文的主要贡献	2
2	形式化	2
2.1	符号与基本定义	2
2.2	Stage 1 的优化目标	3
2.3	Stage 2 蒸馏与 student	3
3	主结论：负面定理	3
3.1	定理与证明纲要	3
3.2	为什么这个结论是 unsurprising 的	4
4	三类形式化障碍	4
4.1	障碍 1: Vertex-Maximum Block	5
4.2	障碍 2: 复合目标错位	5
4.3	障碍 3: Reward Conflict	6
5	反例库	6
5.1	反例 1: 单调 OOD reward	6
5.2	反例 2: Vertex-Maximum 阻断	7
5.3	反例 3: 蒸馏 gap 抹消改进	7
5.4	反例总结	8

6	充分条件：何时 OOD 严格超越可证	8
6.1	条件 A: OOD 的时间互补性	8
6.2	条件 B: Non-Conflicting Reward Gradients	9
6.3	条件 C: Pareto-Improving 区域非空	9
6.4	三类充分条件的关系	10
7	In-domain Level-1 vs OOD 的根本不对称性	10
7.1	Search Space Geometry	10
7.2	Construction-Comparison Table	11
7.3	形式化的不对称性	11
8	蒸馏阶段的额外损失	11
8.1	Distillation Gap 的两个来源	11
8.2	蒸馏 gap 与 OOD 改进的相对大小	12
8.3	蒸馏削弱不可避免吗?	12
9	实践含义与设计建议	12
9.1	设计 takeaway	12
9.2	What we CAN claim safely	13
9.3	What we CANNOT claim	13
10	总结	14
10.1	核心结论	14
10.2	实质性 insight 总览	14
10.3	开放问题	14

1 引言与问题陈述

1.1 已有保证的回顾

记 prompt set $\mathcal{P}_s$ 、reward R_j ($j \in \{1, \dots, |\mathcal{R}|\}$)、teacher $v^{(k)}$ ($k \in \{1, \dots, K\}$)。Stage 1 的 per-set MoF (`mof_per_set_analysis.tex`) 已证明：

- **Level-1 (in-domain match)**:

$$\mathbb{E}_{p \in \mathcal{P}_s}[R_s(v_{\lambda_s^*})] \geq \mathbb{E}_{p \in \mathcal{P}_s}[R_s(v^{(s)})] \quad (1)$$

构造性证明： $\lambda_{k,i,s} = \delta_{k,s}$ （即恒用 teacher s ）在搜索空间 $(\Delta^K)^T$ 中，对应 $v_{\lambda_s} = v^{(s)}$ 。最优解不劣于此可行点。

- **Level-2 (in-domain strict)**：在时间互补性假设下，

$$\mathbb{E}_{p \in \mathcal{P}_s}[R_s(v_{\lambda_s^*})] > \mathbb{E}_{p \in \mathcal{P}_s}[R_s(v^{(s)})] \quad (2)$$

但时间互补性是经验条件而非定理。

1.2 本文要回答的问题

核心问题

能否在一般情况下理论证明：对任意 OOD reward R_j ($j \neq s$)，

$$\boxed{\mathbb{E}_{p \in \mathcal{P}_s}[R_j(v^{\theta^*})] > \max_{k \in \{1, \dots, K\}} \mathbb{E}_{p \in \mathcal{P}_s}[R_j(v^{(k)})] \quad ?} \quad (3)$$

其中 v^{θ^*} 是 Stage 2 蒸馏完成的 student。

1.3 本文的主要贡献

1. 负面定理：构造性反例证明 (3) 不可在一般情况下成立 (§3)。
2. 三类形式化障碍：vertex-maximum block、复合目标错位、reward conflict (§4)。
3. 三类充分条件：刻画何时 OOD 严格超越可证 (§6)。
4. **In-domain Level-1** 的不对称性：解释为什么 in-domain 有构造性保证而 OOD 没有 (§7)。
5. 蒸馏阶段的额外损失：finite-capacity 与 on-policy distribution shift 如何削弱保证 (§8)。

2 形式化

2.1 符号与基本定义

Definition 1 (Reward Functional on Mixing). 对 prompt set $\mathcal{P}_s$ 、reward R_j 、混合参数 $\lambda \in (\Delta^K)^T$ ，定义 **reward functional**：

$$f_j^{(s)}(\lambda) \triangleq \mathbb{E}_{p \sim \mathcal{P}_s, x_T \sim \mathcal{N}(0, I)}[R_j(\text{ODE}(v_\lambda; x_T, p))] \quad (4)$$

其中 $v_\lambda(x, t_i, p) = \sum_k \lambda_{k,i} v^{(k)}(x, t_i, p)$ ，ODE 表示从 x_T 出发用 v_λ 数值积分得到 x_0 。

注： $\lambda \in (\Delta^K)^T$ 省略了 s 下标——这里固定一个 prompt set $\mathcal{P}_s$ ，混合参数为该 set 专属的 $\lambda_{:, :, s}$ 。

Definition 2 (Single-Teacher OOD Baseline). 对 prompt set $\mathcal{P}_s$ 和 reward R_j , 定义两种 single-teacher baseline:

$$\rho_j^{(s),\text{const}} \triangleq \max_{k \in \{1, \dots, K\}} f_j^{(s)}(\delta_k^{\text{const}}) \quad (\text{constant single-teacher}) \quad (5)$$

$$\rho_j^{(s),\text{step}} \triangleq \max_{k: \{1, \dots, T\} \rightarrow \{1, \dots, K\}} f_j^{(s)}(\delta_{k(\cdot)}) \quad (\text{per-step single-teacher}) \quad (6)$$

其中:

- $\delta_k^{\text{const}} \in (\Delta^K)^T$: 对所有 i 都取 $\lambda_{:,i} = \mathbf{e}_k$ (恒用 teacher k)。
- $\delta_{k(\cdot)}$: 在 timestep i 上取 $\lambda_{:,i} = \mathbf{e}_{k(i)}$ (每步可选不同 teacher, 但每步只用一个 teacher)。

显然 $\rho_j^{(s),\text{const}} \leq \rho_j^{(s),\text{step}}$ 。

Definition 3 (OOD 严格超越 claim). 对 prompt set $\mathcal{P}_s$ 和 OOD reward R_j (j 不是 $\mathcal{P}_s$ 的 in-domain reward), 有以下三种由弱到强的 strict-improvement claim:

- (C1) **Match constant baseline:** $f_j^{(s)}(\lambda_s^*) \geq \rho_j^{(s),\text{const}}$
- (C2) **Strictly exceed constant baseline:** $f_j^{(s)}(\lambda_s^*) > \rho_j^{(s),\text{const}}$
- (C3) **Strictly exceed per-step baseline:** $f_j^{(s)}(\lambda_s^*) > \rho_j^{(s),\text{step}}$

部署期推理使用单一 LoRA (无 per-step 切换), 所以 实际可比的是 **constant baseline** ——(C2) 是用户所问的真正含义。

2.2 Stage 1 的优化目标

`common.py:prepare_feedback` 实现的复合 reward objective:

$$F^{(s)}(\lambda) \triangleq f_s^{(s)}(\lambda) + \gamma \cdot \frac{1}{|\mathcal{R}_{\text{OOD}}^{(s)}|} \sum_{j \in \mathcal{R}_{\text{OOD}}^{(s)}} f_j^{(s)}(\lambda) \quad (7)$$

(GDPO advantage normalization 不改变最优解的 argmax, 因此这里直接用 expected reward 表达。) Stage 1 的最优解:

$$\lambda_s^* \triangleq \arg \max_{\lambda \in (\Delta^K)^T} F^{(s)}(\lambda) \quad (8)$$

2.3 Stage 2 蒸馏与 student

Stage 2 训练 student velocity v^θ 拟合 router-induced teacher $v^{\text{MoF}^*} = v_{\lambda_s^*}$ 。设 θ^* 为蒸馏完成的 student。定义蒸馏 **gap**:

$$\epsilon_{\text{distill}}^{(s,j)} \triangleq f_j^{(s)}(\lambda_s^*) - f_j^{(s)}(\theta^*) \quad (9)$$

(注: 这里复用 $f_j^{(s)}$ 的定义, 对 student 而言 λ 退化为 student 的确定性 velocity 网络。) 一般 $\epsilon_{\text{distill}} \neq 0$, 可正可负。

3 主结论: 负面定理

3.1 定理与证明纲要

Theorem 1 (No General OOD Guarantee). 存在合法的 MoF 实例 $(K, T, \{v^{(k)}\}, \{R_j\}, \mathcal{P}_s, \gamma)$, 使得对某个 OOD reward R_j (j 不是 $\mathcal{P}_s$ 的 in-domain reward):

$$f_j^{(s)}(\lambda_s^*) < \rho_j^{(s),\text{const}} \quad (10)$$

即 Stage 1 的最优混合在 OOD 上严格劣于最佳 single-teacher baseline。进而, Stage 2 蒸馏后的 student 也无法保证 (3)。

Proof. 通过 Counter-example 1 (§5.1) 显式构造满足 (10) 的实例。Stage 2 部分通过 $\epsilon_{\text{distill}} \geq 0$ 的可能性进一步加强（详见 §8）。□

Corollary 1 (OOD claim 的不可证性). 不存在仅基于 MoF 框架的本身的 architectural / objective 性质（即不引入 OOD-specific 的额外假设）的形式化推导能保证 (3)。任何 OOD 严格超越的证明都必须引入：

1. OOD reward landscape 的结构假设（如 temporal complementarity for OOD），或
2. Stage 1 复合目标与 OOD 之间的几何对齐假设（non-conflicting gradients），或
3. Pareto-improving 区域非空假设。

这些都是经验性条件，不能从 MoF 的定义中推出。

3.2 为什么这个结论是 **unsurprising** 的

回顾 in-domain Level-1 的构造性证明：

$$\delta_s^{\text{const}} \in (\Delta^K)^T \Rightarrow v_\lambda = v^{(s)} \Rightarrow \max_\lambda F^{(s)}(\lambda) \geq F^{(s)}(\delta_s^{\text{const}}) \geq f_s^{(s)}(\delta_s^{\text{const}}) \quad (11)$$

这个推理严格依赖于 δ_s^{const} 的两个性质：

1. **Reachability**: δ_s^{const} 在搜索空间 $(\Delta^K)^T$ 内。
2. **Composite-friendly**: δ_s^{const} 在 $f_s^{(s)}$ 上是高分（因为 teacher s 是 R_s 的 in-domain teacher），所以即使 OOD 项不利，复合 $F^{(s)}$ 也至少接近 $f_s^{(s)}(\delta_s^{\text{const}})$ 。

OOD reward R_j ($j \neq s$) 则没有对应的“safe vertex”：

- δ_j^{const} 在 $f_j^{(s)}$ 上可能是高分（teacher j 是 R_j 专家），但在 $f_s^{(s)}$ 上分数很低（teacher j 不是 R_s 专家）。
- 因此 $F^{(s)}(\delta_j^{\text{const}}) = f_s^{(s)}(\delta_j^{\text{const}}) + \gamma f_j^{(s)}(\delta_j^{\text{const}})$ 通常远低于 $F^{(s)}(\delta_s^{\text{const}})$ （除非 γ 极大）。
- 复合优化不会自发地把 λ_s^* 推向 δ_j^{const} ，所以 $f_j^{(s)}(\lambda_s^*) \neq f_j^{(s)}(\delta_j^{\text{const}})$ 。

核心不对称性

In-domain Level-1 的本质：搜索空间总是包含“退化到 in-domain teacher s ”的可行点 δ_s^{const} ，且这个点在复合目标 $F^{(s)}$ 上也是相对优的，所以 Stage 1 的最优解不会比它差。

OOD 没有对称构造：搜索空间确实包含“退化到 OOD-reward 专家 j ”的可行点 δ_j^{const} ，但这个点在复合目标上不优——它牺牲了 in-domain。所以 Stage 1 不会主动选择它，即使它的 OOD 分数远高于 λ_s^* 。

4 三类形式化障碍

下面的三类障碍刻画“OOD 严格超越”为何在数学上面临根本困难。

4.1 障碍 1: Vertex-Maximum Block

Proposition 1 (Convex-Hull Bound on Constant Vertices). 设 $f_j^{(s)} : (\Delta^K)^T \rightarrow \mathbb{R}$ 在常数顶点子集 $\{\delta_k^{\text{const}} : k = 1, \dots, K\}$ 上的最大值为 $\rho_j^{(s), \text{const}}$ 。若 $f_j^{(s)}$ 是 **quasi-concave** (凹的更强), 且最大值在某个常数顶点 $\delta_{k^*}^{\text{const}}$ 取到, 则对所有 $\lambda \in (\Delta^K)^T$:

$$f_j^{(s)}(\lambda) \leq f_j^{(s)}(\delta_{k^*}^{\text{const}}) = \rho_j^{(s), \text{const}} \quad (12)$$

Proof. Quasi-concave 函数在凸紧集上的最大值唯一/必然在极点取到。 $(\Delta^K)^T$ 的极点是 $\{\delta_{k(\cdot)}\}$ (per-step single teacher), 若 $f_j^{(s)}$ 在某常数顶点 $\delta_{k^*}^{\text{const}}$ 取到全局最大, 则任何 $\lambda \in (\Delta^K)^T$ 不优于它。 $\square$

Remark 1 (何时 vertex-maximum 成立). $f_j^{(s)}$ 在常数顶点取最大的常见情形:

1. Teacher k^* 在所有 timestep 上对 R_j 都是 unique-best (典型情况: $R_j = R_{k^*}$, 且 k^* 完全特化于 R_{k^*})。
2. Teacher 之间的 LoRA residual 在 R_j reward landscape 上单调对齐 (即一种 teacher 总是在所有方向上都更好)。

此时 (C2) 不可达 (任何 mixing 都不严格超过 single-teacher constant)。

Remark 2 (何时可以绕过 vertex block). 1. $f_j^{(s)}$ 在非常数顶点 $\delta_{k(\cdot)}$ 取最大 (不同 timestep 最优 teacher 不同)。但这只支持 (C2), 不超过 (C3)。

2. $f_j^{(s)}$ 在 **interior** 取最大。这要求 mixing 真正产生新的 trajectory dynamics——理论上可能 (Proposition 1 of `mof_gradient_analysis.tex`), 经验上偶发。

4.2 障碍 2: 复合目标错位

Proposition 2 (Composite Misalignment). 设 $\lambda_s^* = \arg \max_{\lambda} F^{(s)}(\lambda)$ 为 Stage 1 复合最优。则在一般情况下:

$$\lambda_s^* \neq \arg \max_{\lambda} f_j^{(s)}(\lambda) \quad \text{for } j \neq s \quad (13)$$

特别地, 在 KKT 条件下:

$$\nabla F^{(s)}(\lambda_s^*) = 0 \Leftrightarrow \nabla f_s^{(s)}(\lambda_s^*) + \frac{\gamma}{|\mathcal{R}_{\text{OOD}}^{(s)}|} \sum_{j' \in \mathcal{R}_{\text{OOD}}^{(s)}} \nabla f_{j'}^{(s)}(\lambda_s^*) = 0 \quad (14)$$

对单个 $j \in \mathcal{R}_{\text{OOD}}^{(s)}$, $\nabla f_j^{(s)}(\lambda_s^*) = 0$ 当且仅当 所有 OOD rewards 在该点同向, 否则 λ_s^* 不是 $f_j^{(s)}$ 的临界点。

Remark 3 (γ 调整的局限). 直觉上”增大 γ 推动 λ_s^* 向 OOD 方向”看似可以解决问题, 但有两个限制:

1. γ 增大牺牲 in-domain。当 γ 大到使 in-domain 退化时, 违反 Level-1 保证。
2. 即使 $\gamma \rightarrow \infty$, λ_s^* 收敛到 $\arg \max \sum_{j \in \mathcal{R}_{\text{OOD}}^{(s)}} f_j^{(s)}(\lambda)$ ——所有 OOD rewards 的平均最优, 不是单个 R_j 的最优。若 OOD rewards 互相冲突, 单个 R_j 在该点仍可能不优。

4.3 障碍 3: Reward Conflict

Definition 4 (Reward Conflict at λ). 称 reward R_s 和 R_j 在 λ 处冲突, 若:

$$\nabla f_s^{(s)}(\lambda) \cdot \nabla f_j^{(s)}(\lambda) < 0 \quad (15)$$

(梯度点积为负)。

Proposition 3 (Conflict Reduces OOD Achievable). 若 R_s 和 R_j 在 δ_s^{const} 周围有 reward conflict (Definition 4), 则:

$$f_j^{(s)}(\lambda_s^*) \leq f_j^{(s)}(\lambda^{j,\text{free}}) \quad \text{严格不等当 } \gamma < \gamma_{\text{critical}} \quad (16)$$

其中 $\lambda^{j,\text{free}} = \arg \max f_j^{(s)}$ 是无约束 OOD 最优, $\gamma_{\text{critical}} = \frac{\nabla f_s \cdot \nabla f_j^\perp}{\|\nabla f_j\|^2}$ 是临界 OOD bonus 系数 (依赖于 conflict 强度)。

三类障碍的耦合关系

三类障碍并非独立——它们在 reward landscape 上相互作用:

- **Vertex-max + Conflict**: 最差情形。 $f_j^{(s)}$ 顶点最大且 R_s, R_j 冲突。 Mixing 既不能在 simplex 内找到改进, 也不能通过 γ 推到顶点 (顶点被 conflict 阻止)。
- **Vertex-max + Aligned**: $f_j^{(s)}$ 顶点最大但 R_s, R_j 对齐。 λ_s^* 接近 δ_s^{const} , OOD 接近 $f_j^{(s)}(\delta_s^{\text{const}})$, 可能略好但不严格超过最佳 single teacher (除非 δ_s^{const} 恰好是 R_j 的最佳 single teacher)。
- **Interior-max + Aligned**: 最佳情形。 Mixing 可严格超过任何 single teacher, 复合优化与 OOD 同向, λ_s^* 落在 interior 改进区。

5 反例库

5.1 反例 1: 单调 OOD reward

Example 1 (Monotonic OOD Block). 设 $K = 2, T = 1, S = 1, \lambda \in [0, 1]$ (Δ^2 退化为单点参数)。设 $\mathcal{P}_s$ 上的两个 reward 满足:

$$f_s^{(s)}(\lambda) = \lambda \quad (\text{in-domain reward, max at } \lambda = 1) \quad (17)$$

$$f_j^{(s)}(\lambda) = 1 - \lambda \quad (\text{OOD reward, max at } \lambda = 0) \quad (18)$$

即 teacher 1 是 R_s 专家, teacher 2 是 R_j 专家, 两个 reward 完全反相关。 Single-teacher OOD baseline: $\rho_j^{(s),\text{const}} = \max(f_j(0), f_j(1)) = 1$ 。

复合目标:

$$F^{(s)}(\lambda) = \lambda + \gamma(1 - \lambda) = (1 - \gamma)\lambda + \gamma \quad (19)$$

分析:

- 若 $\gamma < 1$: $\arg \max F^{(s)} = 1$ (teacher 1)。 $f_j^{(s)}(\lambda_s^*) = 0 < 1 = \rho_j^{(s),\text{const}}$ 。 **OOD 严格劣于 single teacher**。
- 若 $\gamma = 1$: $F^{(s)}$ 常数, optimum 不唯一。最差情况 $f_j^{(s)} = 0$ 。仍可能严格劣。
- 若 $\gamma > 1$: $\arg \max F^{(s)} = 0$ (teacher 2)。 $f_j^{(s)}(\lambda_s^*) = 1 = \rho_j^{(s),\text{const}}$ 。 OOD 匹配但不严格超过。

结论: 此例下 **OOD 严格超过 single teacher** 不可能 (任何 γ)。

Remark 4 (此例的现实意义)。许多实际场景接近此结构。例如 GenEval reward 与 PickScore reward 在某些 prompt 上可能近似反相关——精确的 object counting / spatial relations 与高度 aestheticized 渲染可能互斥 (前者要求清晰结构, 后者倾向 stylization)。

5.2 反例 2: Vertex-Maximum 阻断

Example 2 (Vertex Maximum Block in Multi-Teacher Setting). 设 $K = 3, T = 1$ (单 timestep, 简化), $\mathcal{P}_s$ 是 in-domain 为 R_s 的 prompt set ($s = 1$)。设:

$$f_1^{(s)}(\lambda) = \lambda_1 \quad (20)$$

$$f_2^{(s)}(\lambda) = \lambda_2 \quad (21)$$

$$f_3^{(s)}(\lambda) = \lambda_3 \quad (22)$$

即每个 reward 只由对应 teacher 的”权重份额”决定, 且这些 reward 都是线性于 λ (顶点最大)。约束 $\sum \lambda_k = 1$ 。

OOD 是 R_2, R_3 。Single-teacher baseline: $\rho_2^{(s), \text{const}} = f_2(\delta_2) = 1, \rho_3^{(s), \text{const}} = f_3(\delta_3) = 1$ 。

复合目标 ($|\mathcal{R}_{\text{OOD}}^{(s)}| = 2$):

$$F^{(s)}(\lambda) = \lambda_1 + \frac{\gamma}{2}(\lambda_2 + \lambda_3) = \lambda_1 + \frac{\gamma}{2}(1 - \lambda_1) = \left(1 - \frac{\gamma}{2}\right) \lambda_1 + \frac{\gamma}{2} \quad (23)$$

分析:

- 若 $\gamma < 2$: $\arg \max F^{(s)} = (1, 0, 0)$ 。 $f_2^{(s)}(\lambda_s^*) = 0 < 1$ 。 OOD 严格劣。
- 若 $\gamma = 2$: $F^{(s)}$ 常数, optimum 不唯一。任何 λ 都 optimal, OOD 任意。
- 若 $\gamma > 2$: $\arg \max F^{(s)}$ 是 $\lambda_1 = 0 +$ 任意 $\lambda_2, \lambda_3 \geq 0$ 满足 $\lambda_2 + \lambda_3 = 1$ 的子集 (由复合目标的 affine 结构决定)。依然没有严格超越 **single teacher**: $f_2 = \lambda_2 \leq 1$, 等号当 $\lambda_2 = 1$ (即 δ_2) 取得。

结论: 当 $f_j^{(s)}$ 是 λ 的线性函数 (顶点最大) 时, 对任意 γ 和任意 reward 组合, **OOD** 严格超越 **single teacher** 都不可能。

5.3 反例 3: 蒸馏 gap 抹消改进

Example 3 (Distillation Gap Erosion). 设 Stage 1 实现了微小的 OOD 改进:

$$f_j^{(s)}(\lambda_s^*) = \rho_j^{(s), \text{const}} + \Delta, \quad \Delta = 0.01 \quad (24)$$

但 Stage 2 的蒸馏 gap:

$$\epsilon_{\text{distill}}^{(s,j)} = f_j^{(s)}(\lambda_s^*) - f_j^{(s)}(\theta^*) = 0.05 > \Delta \quad (25)$$

则 student 的 OOD 表现:

$$f_j^{(s)}(\theta^*) = \rho_j^{(s), \text{const}} + 0.01 - 0.05 = \rho_j^{(s), \text{const}} - 0.04 < \rho_j^{(s), \text{const}} \quad (26)$$

严格劣于 **single teacher**, 尽管 Stage 1 的 mixing 严格优于。

蒸馏 gap 来源:

1. **Finite student capacity**: v^θ 是 LoRA 网络, 无法精确拟合任意 v^{MoF^*} 。
2. **On-policy distribution shift**: student trajectory $\{x_{t_i}^\theta\}$ 与 v^{MoF^*} 的 trajectory 不同; MSE 在 student trajectory 上 well-trained 不保证 reward 一致。
3. **Optimization underfit**: 有限训练 epoch、有限 sample number。

5.4 反例总结

反例	核心机制	结论
1: Monotonic OOD	f_j 在 simplex 顶点取最大 (线性反相关)	任何 γ 都无法严格超越
2: Vertex-Maximum Block	f_j 是 λ 线性函数	mixing 永不严格超过 vertex
3: Distillation Gap	Stage 2 拟合误差	即使 Stage 1 严格超过, student 也可能劣于 single teacher

6 充分条件：何时 OOD 严格超越可证

虽然没有通用保证，下面给出三类充分条件，描述何时能形式化推导 OOD 严格超越。

6.1 条件 A：OOD 的时间互补性

Definition 5 (Temporal Complementarity for OOD). 对 prompt set $\mathcal{P}_s$ 和 OOD reward R_j ($j \neq s$)，称 **OOD** 时间互补性成立，若存在 timestep $i_1 \neq i_2$ 和 teacher $k_1 \neq k_2$ 使得：

$$\arg \max_k \left. \frac{\partial f_j^{(s)}}{\partial \lambda_{k,i_1}} \right|_{\lambda=\lambda_0} = k_1 \quad \text{and} \quad \arg \max_k \left. \frac{\partial f_j^{(s)}}{\partial \lambda_{k,i_2}} \right|_{\lambda=\lambda_0} = k_2 \quad (27)$$

对某个 reference λ_0 (如 δ_s^{const})。

直观：在不同 timestep，对 OOD reward R_j 贡献最大的 teacher 是不同的。

Theorem 2 (OOD Strict Improvement under Temporal Complementarity + Pareto-Improving Region). 设：

(A1) OOD 时间互补性成立 (Definition 5)。

(A2) $f_s^{(s)}$ 和 $f_j^{(s)}$ 在 $(\Delta^K)^T$ 上 C^1 连续。

(A3) 存在 $\lambda^{\text{Pareto}} \in (\Delta^K)^T$ 满足：

$$f_s^{(s)}(\lambda^{\text{Pareto}}) \geq f_s^{(s)}(\delta_s^{\text{const}}) \quad \text{和} \quad f_j^{(s)}(\lambda^{\text{Pareto}}) > \rho_j^{(s),\text{const}} \quad (28)$$

(A4) $\gamma > 0$ 足以使 Stage 1 局部最优偏离 δ_s^{const} (具体阈值依赖于 reward landscape 曲率)。

则存在 γ 区间 $(\gamma_{\min}, \gamma_{\max})$ 使得 Stage 1 最优解 λ_s^* 满足 $f_j^{(s)}(\lambda_s^*) > \rho_j^{(s),\text{const}}$ 。

Proof Sketch. (A1) 保证 $f_j^{(s)}$ 不是常数顶点最大 (否则梯度在 i_1, i_2 上一致)。(A3) 保证 Pareto-improving 区域非空。(A4) 保证 $\lambda_s^* \neq \delta_s^{\text{const}}$ 且接近 (A3) 的区域。具体：

- γ 太小 ($\gamma < \gamma_{\min}$): λ_s^* 仍接近 δ_s^{const} ，OOD 不显著超过 $f_j^{(s)}(\delta_s^{\text{const}})$ (不一定超过 $\rho_j^{(s),\text{const}}$)。
- γ 太大 ($\gamma > \gamma_{\max}$): λ_s^* 偏离过多，in-domain 受损，可能离开 Pareto-improving 区域。
- 中间 γ : λ_s^* 落在 Pareto-improving 区域内，OOD 严格超越。

□

Remark 5 (条件 A1–A4 都需经验验证). 1. (A1) 时间互补性: 需在训练前/中通过 per-teacher per-timestep 的 OOD gradient probing 估计。

2. (A3) Pareto-improving 区域: 需 grid search 或随机采样 mixing 配置后评估 reward 来验证非空。

3. (A4) γ 区间: 依赖于 reward landscape, 需消融实验确定。
所以本定理是条件性的, 不是无条件的 OOD 保证。

6.2 条件 B: Non-Conflicting Reward Gradients

Theorem 3 (OOD Improvement under Aligned Gradients). 设 δ_s^{const} 处 $\nabla f_s^{(s)}$ 与 $\nabla f_j^{(s)}$ 之间的夹角 $\theta \in (-\pi/2, \pi/2)$ (即点积非负)。则对任意 $\gamma > 0$:

$$f_j^{(s)}(\lambda_s^*) \geq f_j^{(s)}(\delta_s^{\text{const}}) \quad (29)$$

即 OOD 至少不劣于 δ_s^{const} 处 (但不一定超过 $\rho_j^{(s), \text{const}}$)。

Proof. $\nabla F^{(s)} = \nabla f_s + \gamma \nabla f_{\text{OOD}}$ 。若 ∇f_s 与 ∇f_j 同向 (点积非负), 则 $\nabla F^{(s)}$ 与 ∇f_j 也大致同向。从 δ_s^{const} 沿 $\nabla F^{(s)}$ 上升时, f_j 也上升。 $\lambda_s^* \neq \delta_s^{\text{const}}$ (因 $\nabla F \neq 0$), 故 $f_j^{(s)}(\lambda_s^*) > f_j^{(s)}(\delta_s^{\text{const}})$ 。□

Remark 6 (此定理的局限). 保证 $f_j^{(s)}(\lambda_s^*) > f_j^{(s)}(\delta_s^{\text{const}})$, 但 δ_s^{const} 不一定是 $\rho_j^{(s), \text{const}}$ (最佳 single teacher)。例如 $\rho_j^{(s), \text{const}}$ 可能由 teacher j 实现: $\rho_j^{(s), \text{const}} = f_j^{(s)}(\delta_j^{\text{const}})$ 。所以这个 weaker improvement 不蕴含 (C2)。

6.3 条件 C: Pareto-Improving 区域非空

Theorem 4 (OOD Improvement via Pareto-Improving Set). 定义 Pareto-improving 集合:

$$\mathcal{Q}_j \triangleq \{\lambda \in (\Delta^K)^T : f_s^{(s)}(\lambda) \geq f_s^{(s)}(\delta_s^{\text{const}}) \text{ 且 } f_j^{(s)}(\lambda) > \rho_j^{(s), \text{const}}\} \quad (30)$$

设:

(C1) $\mathcal{Q}_j \neq \emptyset$

(C2) $F^{(s)}$ 在 $\mathcal{Q}_j$ 上某点取得 严格高于 $F^{(s)}(\delta_s^{\text{const}})$ 的值


(C3) 优化算法收敛到全局或足够好的局部最优

则 $f_j^{(s)}(\lambda_s^*) > \rho_j^{(s), \text{const}}$ 。

Remark 7 (条件 C 是无歧义的, 但极难验证). (C1) 是 OOD 改进的存在性前提。(C2)+(C3) 保证优化能到达。但:

- (C1) 的验证需要在 simplex interior 上做 reward evaluation——计算代价 $O((\Delta^K)^T \text{ 网格点} \times \text{trajectory cost})$, 非常大。
- (C3) 在非凸 reward landscape 下无法保证。MoF 的 reward landscape 通常是 highly non-convex (reward 来自 ODE 积分后的 nonlinear 函数)。

6.4 三类充分条件的关系



解读:

- Condition A (OOD 时间互补性) 配合 Pareto-region 假设是最自然的充分条件, 但需经验验证。
- Condition B (梯度对齐) 是弱保证 (只超过 $f_j(\delta_s)$, 不一定超过 $\rho_j^{(s),\text{const}}$)。
- Condition C (Pareto 区域非空 + 收敛) 是最强保证但最难验证。

7 In-domain Level-1 vs OOD 的根本不对称性

为什么 in-domain Level-1 有构造性证明, 而 OOD 没有? 这一节系统化这一不对称性。

7.1 Search Space Geometry

Proposition 4 (In-Domain Vertex Coverage). 对每个 prompt set $\mathcal{P}_s$, $\delta_s^{\text{const}} \in (\Delta^K)^T$ 始终是合法的可行点且对应的 *reward* 表现就是 single teacher s 在 $\mathcal{P}_s$ 上的 in-domain 表现:

$$v_{\delta_s^{\text{const}}} = v^{(s)} \Rightarrow f_s^{(s)}(\delta_s^{\text{const}}) = \mathbb{E}_{p \in \mathcal{P}_s} [R_s(v^{(s)})] \quad (31)$$

且此点是复合目标的”合理可行点”—— $f_s^{(s)}(\delta_s^{\text{const}})$ 是 in-domain 的最佳 single teacher 值 (通常假设 teacher s 是 R_s 的专家)。

Proposition 5 (OOD Lacks Symmetric Coverage). 对 OOD reward R_j ($j \neq s$) on $\mathcal{P}_s$, 最佳 single teacher baseline 由某个 $k^* = \arg \max_k f_j^{(s)}(\delta_k^{\text{const}})$ 实现。但:

1. $\delta_{k^*}^{\text{const}}$ 在搜索空间中 (与 in-domain 一样有 reachability),
2. 但 $\delta_{k^*}^{\text{const}}$ 在复合目标 $F^{(s)}$ 上不优 (除非 $k^* = s$):

$$F^{(s)}(\delta_{k^*}^{\text{const}}) = f_s^{(s)}(\delta_{k^*}^{\text{const}}) + \gamma \cdot \overline{f^{\text{OOD}}}(\delta_{k^*}^{\text{const}}) \quad (32)$$

其中 $f_s^{(s)}(\delta_{k^*}^{\text{const}}) \ll f_s^{(s)}(\delta_s^{\text{const}})$ 因为 teacher k^* 不是 R_s 专家。

3. 即使 γ 增大, $F^{(s)}(\delta_{k^*}^{\text{const}})$ 也不一定超过 $F^{(s)}(\delta_s^{\text{const}})$ 。

所以 Stage 1 不会自发地 fall back 到 $\delta_{k^*}^{\text{const}}$, OOD baseline 不被搜索空间中的”安全顶点”覆盖。

7.2 Construction-Comparison Table

	In-domain Level-1	OOD Strict Improvement
”Safe vertex” 是哪个?	δ_s^{const} (teacher s)	$\delta_{k^*}^{\text{const}}$ (best OOD teacher)
是否在搜索空间?	✓	✓
是否 composite-friendly?	✓ (teacher s 是 R_s 专家)	✗ (teacher k^* 不是 R_s 专家)
Stage 1 是否自然到达?	✓ (最差情形 fall back 到此)	✗ (fall back 会破坏 in-domain)
保证类型	构造性 (无需额外假设)	条件性 (依赖 (A)/(B)/(C))
失败模式	不存在	Counter-example 1, 2, 3

7.3 形式化的不对称性

Theorem 5 (Asymmetry Theorem). 对任意 MoF 实例和任意 $\gamma \geq 0$:

(I) (**In-domain Level-1 holds unconditionally**)

$$F^{(s)}(\lambda_s^*) \geq F^{(s)}(\delta_s^{\text{const}}) \Rightarrow f_s^{(s)}(\lambda_s^*) \geq f_s^{(s)}(\delta_s^{\text{const}}) - \gamma \cdot \Delta_{\text{OOD}} \quad (33)$$

当 γ 充分小, Δ_{OOD} 可控, 故 in-domain 至少弱保证。

(II) (**OOD Strict Improvement requires extra structure**) 对于 $f_j^{(s)}(\lambda_s^*) > \rho_j^{(s), \text{const}}$ 的成立, 存在反例 (Examples 1, 2) 使其失败。

不对称性的根源

”In-domain Level-1 has a fallback to single teacher s ” 这个性质是 **Stage 1** 复合目标设计的结构性偏好—— R_s 在复合中权重最大 (系数 1, OOD 系数 $\gamma/|\mathcal{R}_{\text{OOD}}|$), 所以单纯顶点 δ_s^{const} 总是相对优。
 OOD 则相反: 复合目标的设计本身抑制对 OOD 顶点的偏好。要逼出 OOD 改进, 必须依赖 mixing landscape 的额外结构 (temporal complementarity、Pareto-improving 区域等)——这些都是关于具体 reward / teacher / data 的偶然性质, 不是 MoF 框架的内禀保证。

8 蒸馏阶段的额外损失

即使 Stage 1 实现了 OOD 严格超越 ($f_j^{(s)}(\lambda_s^*) > \rho_j^{(s), \text{const}}$), Stage 2 蒸馏可能进一步削弱保证。

8.1 Distillation Gap 的两个来源

Proposition 6 (Capacity-Induced Gap). 设 student v^θ 是 LoRA 参数化的网络。若 $v^{\text{MoF}^*} = \sum_k \lambda_k^* v^{(k)}$ 不在 student 函数族 $\mathcal{F}_\theta = \{v^\theta : \theta \in \Theta\}$ 中, 则存在最小拟合误差:

$$\epsilon_{\text{cap}} = \inf_{\theta \in \Theta} \mathbb{E}_{(x,t,c) \sim \mathcal{D}_{\text{train}}} \|v^\theta(x, t, c) - v^{\text{MoF}^*}(x, t, c)\|_2^2 > 0 \quad (34)$$

Remark 8 (何时 $\epsilon_{\text{cap}} = 0$). 若 student LoRA rank 充分大且所有 K 个 teacher LoRA 的 column space 之和能被 student LoRA 表示, 理论上 $\epsilon_{\text{cap}} = 0$ 。但实践中 rank 有限且训练有限。

Proposition 7 (On-Policy Distribution Shift). 设 $\mathcal{D}_\theta$ 为 student trajectory 的 state distribution, $\mathcal{D}_{\text{MoF}^*}$ 为 MoF mixing 的 state distribution。一般 $\mathcal{D}_\theta \neq \mathcal{D}_{\text{MoF}^*}$ 。即使 θ 在 $\mathcal{D}_\theta$ 上完美匹配 v^{MoF^*} (pointwise MSE = 0), 也不保证 θ 的 *trajectory-level* reward 等于 v^{MoF^*} 的 *trajectory-level* reward。

具体:

$$f_j^{(s)}(\theta^*) - f_j^{(s)}(\lambda_s^*) = \underbrace{\int (R_j \circ \text{ODE})(v^\theta) - (R_j \circ \text{ODE})(v^{\text{MoF}^*}) d\mu(p, x_T)}_{\text{trajectory-level discrepancy}} \quad (35)$$

trajectory-level discrepancy 可以大于 pointwise gap, 因为 ODE 积分会放大小的 velocity error (butterfly effect)。

8.2 蒸馏 gap 与 OOD 改进的相对大小

Theorem 6 (Erosion Condition). 设 Stage 1 OOD 改进幅度为 $\Delta_{\text{Stage 1}} \triangleq f_j^{(s)}(\lambda_s^*) - \rho_j^{(s), \text{const}} > 0$ 。若蒸馏 gap $\epsilon_{\text{distill}}^{(s,j)} > \Delta_{\text{Stage 1}}$, 则:

$$f_j^{(s)}(\theta^*) < \rho_j^{(s), \text{const}} \quad (36)$$

即 student 的 OOD 反而劣于 single teacher。

实践含义: $\Delta_{\text{Stage 1}}$ 通常较小 (因为 reward improvement 在 RL 中本就 marginal), $\epsilon_{\text{distill}}$ 在 LoRA 容量有限 + 有限训练时也可能 marginal——两者数量级接近时, erosion 很容易发生。

8.3 蒸馏削弱不可避免吗?

Remark 9 (何时 $\epsilon_{\text{distill}}$ 接近 0). 1. Student LoRA rank $\geq$ 所有 teacher LoRA rank 之和。

2. Stage 2 训练 epochs 充足 (达到 fitting capacity)。

3. Student trajectory $\mathcal{D}_\theta$ 接近 $\mathcal{D}_{\text{MoF}^*}$ (这通常通过多轮 *self-distillation* 或 *trajectory matching* loss 实现)。

现实条件下三者通常不完全满足。

9 实践含义与设计建议

9.1 设计 takeaway

1. 不要做无条件的 **OOD** 承诺: MoF 框架不能保证 OOD 严格超过最佳 single teacher。任何论文 / 报告中的此类 claim 必须基于实证测量, 不能仅依赖 framework architecture。
2. 先实证验证 **(A)** 时间互补性: 在固定的 prompt set $\mathcal{P}_s$ 和 OOD reward R_j 上, 扫描 per-timestep "single teacher" 配置 $\delta_{k(\cdot)}$, 看 $f_j^{(s)}$ 是否在不同 $k(\cdot)$ 间显著变化。若不变化, OOD 改进无希望。
3. γ 调整的双刃剑:
 - γ 太小: 复合目标几乎只看 in-domain, λ_s^* 接近 δ_s^{const} , $\text{OOD} \approx f_j^{(s)}(\delta_s^{\text{const}})$ (不是 single-teacher baseline)。
 - γ 太大: in-domain 退化, 违反 Level-1 保证。
 - 中间 γ : 可能踩到 Pareto-improving 区域, 但需要消融实验 ($\gamma \in \{0, 0.1, 0.2, 0.3, 0.5\}$) 找出区域边界。

4. **Per-set λ** 至少给出 **in-domain Level-1**: 相比 global λ , per-set λ 的好处是 in-domain 不会被其他 set 的 optimization 干扰。但这是 in-domain 的好处, OOD 不直接受益。
5. **Stage 2 蒸馏 gap** 不容忽视:
 - Student LoRA rank 应足够大 (建议 $\geq$ teacher rank 总和的一半)。
 - 监控 trajectory-level reward 而非 pointwise MSE——后者低不蕴含前者达标。
 - 考虑 multi-round self-distillation: 把 Stage 2 student 当 teacher 重新跑 Stage 1 + Stage 2。

9.2 What we CAN claim safely

基于现有理论和实证条件, 可以安全主张的内容:

Safe Claims

1. **In-domain Level-1**: MoF 蒸馏后的 student 在 in-domain reward 上至少不显著低于 in-domain single teacher (受 distillation gap 限制)。
2. **Conditional in-domain Level-2**: 在时间互补性假设下, MoF 可能严格超越 in-domain single teacher (实证)。
3. **Composite reward improvement**: MoF 在复合目标 $F^{(s)} = f_s + \gamma f_{\text{OOD}}^-$ 上严格超过 $F^{(s)}(\delta_s^{\text{const}})$ (因为 δ_s^{const} 是可行点)——但这不蕴含单个 OOD reward 的改进。
4. **Empirical OOD improvement on validation**: 若实证看到 $f_j^{(s)}(\theta^*) > \rho_j^{(s), \text{const}}$, 可以报告, 但不能宣称”MoF 框架保证 OOD 改进”。

9.3 What we CANNOT claim

Unsafe Claims

1. “MoF guarantees student outperforms any single teacher on OOD reward.” – **FALSE in general** (Theorem 1).
2. “Increasing γ guarantees OOD improvement.” – **FALSE** (Examples 1, 2).
3. “Distillation preserves Stage 1’s OOD improvement.” – **NOT GUARANTEED** (Theorem 6).
4. “Per-set λ improves OOD over global λ unconditionally.” – **ARCHITECTURALLY GIVES MORE FLEXIBILITY, NOT GUARANTEED OOD GAIN.**

10 总结

10.1 核心结论

对用户问题的直接回答

用户问题：能否理论推导“OOD 部分的能力一定超过 single teacher”这个论断？

答案：✗ 在一般情况下不能。

理由：

1. Stage 1 的复合目标 $F^{(s)} = f_s + \gamma f_{\text{OOD}}^-$ 优化的不是单个 OOD reward R_j ，而是 in-domain 与 OOD 的加权和。其最优解 λ_s^* 一般不是 $f_j^{(s)}$ 的最优解。
2. 三类形式化障碍（vertex-maximum、composite misalignment、reward conflict）结构性地阻止 OOD 严格超越的成立。
3. 三个反例（Counter-examples 1, 2, 3）显式构造了 OOD 严格劣于 single teacher 的合法实例。
4. 蒸馏阶段进一步引入 capacity gap 和 distribution shift，可能抹消 Stage 1 的小幅改进。
5. In-domain Level-1 的构造性证明依赖 δ_s^{const} 这个“安全顶点”，OOD 没有对称的构造（Theorem 5）。

我们能保证什么：

- In-domain Level-1（构造性，无条件）。
- OOD 严格超越在三类额外条件（A/B/C, §6）下条件性可证，但条件本身需经验验证。

10.2 实质性 insight 总览

1. 时间互补性是经验条件，不是定理。它在 in-domain Level-2 上是 sufficient condition，在 OOD 上同样需要（但还不够——还需 Pareto-improving 区域非空假设）。
2. In-domain 与 OOD 的不对称性是 MoF 复合目标设计的内禀属性。 R_s 系数 1 让 in-domain 顶点 δ_s^{const} 是“safe fallback”；OOD 系数 $\gamma/|\mathcal{R}_{\text{OOD}}|$ 远小于 1 让 OOD 顶点 δ_k^{const} 不是“safe”。
3. Reward landscape 的几何决定 OOD 上限。当 $f_j^{(s)}$ 是 simplex 顶点最大（线性 / quasi-concave 单调），mixing 永远不严格超过 single teacher。当 $f_j^{(s)}$ 在 interior 取最大（mixing 产生新轨迹），mixing 才有可能严格超过。
4. 蒸馏 gap 与 Stage 1 改进幅度的相对大小决定最终结果。即使 Stage 1 严格超越 single teacher 几个百分点，distillation 也可能侵蚀更多。所以 Stage 1 的 OOD margin 必须足够大（远大于经验观察到的 distillation gap）才能在 student 上观察到改进。
5. 严肃论文应避免“MoF guarantees OOD improvement”类型的措辞。正确的表述：“MoF enables OOD improvement when 时间互补性 + Pareto-improving region 同时成立，empirically observed in our experiments.”

10.3 开放问题

1. 能否设计一个修改的 Stage 1 目标，使 OOD 严格超越成为构造性保证？例如：约束优化 $\max f_s + \gamma f_j$ s.t. $f_j \geq \rho_j^{(s), \text{const}}$ 。此时 OOD baseline 作为 hard constraint，但优化收敛性变

难。

2. 能否在 **shared-base LoRA setting** (teachers 都是同一 base 上的小 LoRA 扰动) 下证明更强的 OOD 保证? 此时 δ_k^{const} 之间的距离很小, 可能改变 landscape 几何。
3. 能否设计一个 distillation loss (替代 vanilla MSE) 来保留 **Stage 1** 的 **OOD margin**? 例如 reward-weighted MSE 或 trajectory matching。
4. 能否量化蒸馏 **gap** 的上界? 如 $\epsilon_{\text{distill}} \leq C \cdot \text{rank}_{\text{LoRA}}^{-1}$?

附录 A: 与现有 docs 的关系

- `mof_gradient_analysis.tex` 给出 MoF 框架的基础梯度分析; 本文沿用其符号但聚焦 OOD 可证性。
- `mof_per_set_analysis.tex` 证明了 in-domain Level-1 构造性保证; 本文揭示这一保证的 OOD 不对称性。
- `mof_reward_design.tex` 讨论 reward 设计但隐式假设 OOD improvement 是 architecture 的副产物; 本文澄清这是条件性成立。
- `mof_two_stage_pipeline.tex` 给出 Stage 1 + Stage 2 的算法描述; 本文是其理论限制的补充分析。

建议引用

- In-domain Level-1: `mof_per_set_analysis.tex` Theorem 2.
- OOD claims: 本文 Theorem 1 (负面) + §6 (条件性正面)。