

MoF 训练失败模式分析

神经路由器下的 PickScore-dominance 与 OCR 性能退化

Flow Factory

1 现象记录

1.1 实验设置

K=3 teachers (teacher_geneval, teacher_pickscore, teacher_ocr) 在三个 prompt sets 上训练 MoF:

- Sources: geneval, pickscore, ocr (每个对应一个 in-domain teacher)
- Rewards 配置:
 - geneval reward $\rightarrow$ applicable_sources: [geneval] (domain-specific)
 - pick_score reward $\rightarrow$ applicable_sources: [geneval, pickscore, ocr] (**universal**)
 - ocr reward $\rightarrow$ applicable_sources: [ocr] (domain-specific)
- OOD bonus 系数 $\gamma = 0.2$

1.2 观察到的训练表现

架构	GenEval reward	PickScore reward	OCR reward
LUT (uniform init)	达到 teacher 水平	达到 teacher 水平	达到 teacher 水平
LUT (biased init)	达到 teacher 水平	达到 teacher 水平	达到 teacher 水平
Time Router	平衡 (达到 teacher)	主导	下降
adaLN Router	平衡 (达到 teacher)	主导	下降
MLP Router	平衡 (达到 teacher)	主导	下降

核心异象:

1. **LUT** 不论何种初始化都能让所有三个 **reward** 达到对应 **teacher** 水平。
2. 所有神经路由器 (**Time** / **adaLN** / **MLP**) 都呈现 **PickScore teacher** 主导: 路由权重显著偏向 **teacher_pickscore**, OCR 的 in-domain 性能下降, 而 GenEval 看似仍达到 teacher 水平。

2 Reward / Advantage 公式回顾

每个 sample b (来自 source s_b) 的 advantage 通过 **prepare_feedback** 中的三步流程计算:

1. Per-reward, per-group z-score $\rightarrow a_j(x_b) \sim \mathcal{N}(0, 1)$, 对该 reward 不适用的样本设为 NaN。

2. Per-sample 聚合：

$$A(x_b, s_b) = a_{R_{\text{in}}(s_b)}(x_b) + \gamma \cdot \frac{1}{|J_b|} \sum_{j \in J_b} a_j(x_b) \quad (1)$$

其中 $J_b = \{j : j \neq R_{\text{in}}(s_b), a_j(x_b) \neq \text{NaN}\}$ 为该 sample 的 OOD reward 集合。

3. Global-std 归一化 + clipping。

2.1 展开三类样本的 advantage

由于 `pick_score` 是唯一在所有 source 上都 applicable 的 reward，OOD 集合 J_b 在三类样本上是不对称的：

样本类型	$R_{\text{in}}(s_b)$	J_b (OOD 集合)	advantage 公式
pickscore 样本	<code>pick_score</code>	$\emptyset$	$A_b = a_{\text{pick}}(x_b)$
geneval 样本	<code>geneval</code>	$\{\text{pick}\}$	$A_b = a_{\text{gen}}(x_b) + \gamma a_{\text{pick}}(x_b)$
ocr 样本	<code>ocr</code>	$\{\text{pick}\}$	$A_b = a_{\text{ocr}}(x_b) + \gamma a_{\text{pick}}(x_b)$


关键观察：

- PickScore 信号通过 OOD term 渗透到 *geneval* 和 *ocr* 样本的 advantage 中。
- GenEval 和 OCR 信号 互不渗透到对方（因 `applicable_sources` 限制使彼此 NaN）。
- GenEval 和 OCR 信号 完全不渗透到 *pickscore* 样本（同上）。

PickScore 信号是唯一双向流动的——它既驱动自己的 in-domain 优化，又通过 OOD 影响其他两个 source。

3 LUT 解耦 vs NN 参数共享

3.1 两种参数化方式对信号路由的影响



3.2 LUT：参数解耦

LUT 的可学习参数为 $\mathbf{\Lambda} \in \mathbb{R}^{K \times T \times S}$ 。对一个来自 source s 的样本 x_b ，它只对 $\mathbf{\Lambda}[:, t, s]$ 这一列产生梯度（per-sample 索引由 `set_ids` 决定）。

考察 ocr_set 列 ($s = \text{ocr}$) 的梯度积分:

$$\begin{aligned}\nabla_{\Lambda[:,t,\text{ocr}]} \mathcal{L} &= \mathbb{E}_{x \sim \text{ocr}} [A(x, \text{ocr}) \cdot \nabla_{\Lambda[:,t,\text{ocr}]} \log p(x|t)] \\ &= \mathbb{E}_{x \sim \text{ocr}} \left[\underbrace{a_{\text{ocr}}(x)}_{\text{权重1.0}} + \underbrace{\gamma \cdot a_{\text{pick}}(x)}_{\text{权重0.2}} \right] \cdot \nabla_{\Lambda[:,t,\text{ocr}]} \log p(x|t)\end{aligned}\quad (2)$$

关键比例: 在 ocr_set 列上, a_{ocr} 权重 1.0, a_{pick} 权重 $\gamma = 0.2$ 。OCR 信号在自己的列上享有 $5\times$ 优势, PickScore 主导效应被严格遏制在每列内部。

类似地, pickscore_set 列只接受 pickscore 样本梯度 ($A = a_{\text{pick}}$), geneval_set 列接受 geneval 样本梯度 ($A = a_{\text{gen}} + \gamma a_{\text{pick}}$)。各列之间无串扰。

3.3 NN Router: 参数共享

NN router 的可学习参数 θ 由所有样本梯度共享。每个 sample 的梯度都流入同一组 θ :

$$\nabla_{\theta} \mathcal{L} = \mathbb{E}_{(x,s)} [A(x, s) \cdot \nabla_{\theta} \log p_{\theta}(x|t, c)] \quad (3)$$

按 source 分解 (假设三类样本等频率 $\frac{1}{3}$):

$$\begin{aligned}\nabla_{\theta} \mathcal{L} &= \frac{1}{3} \left[\mathbb{E}_{x \sim \text{pick}} [a_{\text{pick}}(x) \cdot g(x; \theta)] \right. \\ &\quad + \mathbb{E}_{x \sim \text{gen}} [(a_{\text{gen}}(x) + \gamma a_{\text{pick}}(x)) \cdot g(x; \theta)] \\ &\quad \left. + \mathbb{E}_{x \sim \text{ocr}} [(a_{\text{ocr}}(x) + \gamma a_{\text{pick}}(x)) \cdot g(x; \theta)] \right]\end{aligned}\quad (4)$$

其中 $g(x; \theta) := \nabla_{\theta} \log p_{\theta}(x|t, c)$ 为 score function。

3.4 信号总强度对比表

把每个 reward 信号在整体梯度中的”覆盖率”列出 (频率 $\times$ 系数之和):

Reward 信号	LUT 在自己列上	NN 在共享 θ 上	相对差异
PickScore signal	1.0 (pickscore 列)	$\frac{1}{3} \cdot 1.0 + \frac{1}{3} \cdot \gamma + \frac{1}{3} \cdot \gamma = 0.467$	NN 上 PickScore 多 0.467
GenEval signal	1.0 (geneval 列)	$\frac{1}{3} \cdot 1.0 = 0.333$	NN 上 GenEval 仅 0.333
OCR signal	1.0 (ocr 列)	$\frac{1}{3} \cdot 1.0 = 0.333$	NN 上 OCR 仅 0.333

在 NN 路由器的共享参数 θ 上:

$$\frac{F_{\text{pick}}}{F_{\text{ocr}}} = \frac{0.467}{0.333} = 1.4 \quad (5)$$

PickScore 信号是 OCR 信号的 1.4 倍。LUT 上对应的比例是 $1.0/1.0 = 1.0$ (每列独占)。

4 为什么 NN 路由器收敛到 **PickScore-dominant** 解

4.1 平滑性归纳偏置放大不对称信号

NN router 输出的混合权重 $W(t, c; \theta)$ 关于输入是连续函数 (线性层 + SiLU 激活的 Lipschitz 性质)。这意味着:

- 相近的 (t, c) 输入 $\rightarrow$ 相近的 W 输出 (隐式平滑约束)。
- 在样本稀疏 (每 epoch 144 样本) 的 RL 设置下, NN 难以学到 prompt 内容的细粒度判别特征。
- 容易找到的局部最优是全局共享的 $W^*(t)$, 对所有 prompt 输出相近的混合权重。

4.2 在共享 W 上找最大化期望 **advantage** 的解

把 NN 路由器近似为输出全局共享的 $W \in \Delta^{K-1}$ (极简情况, 但反映平滑性偏置)。最优 W^* 满足:

$$\begin{aligned} W^* &= \arg \max_W \mathbb{E}_{(x,s)} [A(x,s) \cdot \log p_W(x)] \\ &\propto \arg \max_W [F_{\text{pick}} \cdot W_{\text{pick-aligned}} + F_{\text{gen}} \cdot W_{\text{gen-aligned}} + F_{\text{ocr}} \cdot W_{\text{ocr-aligned}}] \end{aligned} \quad (6)$$

其中 $W_{k\text{-aligned}}$ 表示朝 teacher_k 的对齐方向 (即 $W \rightarrow \mathbf{e}_k$ one-hot)。由 (5), $F_{\text{pick}} > F_{\text{gen}} = F_{\text{ocr}}$, 最优解偏向 **teacher_pickscore**。

形式上: 在 simplex Δ^{K-1} 上的”重心” (按 F_k 加权):

$$W_k^* \propto \frac{F_k}{\sum_{k'} F_{k'}} = \begin{cases} 0.467/1.133 \approx 0.412 & k = \text{pick} \\ 0.333/1.133 \approx 0.294 & k = \text{gen} \\ 0.333/1.133 \approx 0.294 & k = \text{ocr} \end{cases} \quad (7)$$

PickScore 占 41.2%, GenEval / OCR 各 29.4%。这是在最简平滑假设下的预测——实际 NN 可以在 prompt 维度上做有限分化, 缓解但不消除这个偏置。

4.3 实验观察与理论预测一致

观察到的”PickScore teacher 主导, OCR 性能下降”恰好对应:

- NN router 收敛到 (7) 附近 (PickScore 比重最高)。
- 路由策略对所有 prompt 类似 (平滑性偏置)。
- OCR 样本被路由到 $\text{teacher_pickscore} \rightarrow \text{OCR 性能下降}$ 。

5 为什么 GenEval 仍然平衡?

5.1 Teacher 间的”在 source 上的得分”矩阵

设 $R_{k,s}$ 表示 teacher k 单独 inference 时在 source s 上的 in-domain reward 期望。基于经验 Diffusion 训练观察, 矩阵大致结构:

$R_{k,s}$	geneval	pickscore	ocr
teacher_geneval	high	med	low
teacher_pickscore	med	high	low
teacher_ocr	low	low	high

关键不对称:

Teacher 性能不对称

- **teacher_pickscore** 在 **GenEval** 上得 **med**: 美学好的图像通常也包含基本的物体正确性, 所以 PickScore 偏好 (构图美观) 与 GenEval 偏好 (物体计数/属性) 有较高重合。
- **teacher_pickscore** 在 **OCR** 上得 **low**: OCR 是高度专业化的任务 (精确的文字渲染), 与美学偏好正交甚至冲突——美学训练倾向于”画面整体和谐”, 可能模糊文字细节。
- **teacher_ocr** 在 **OCR** 上得 **high**: 专业化训练带来 OCR 专属能力。

5.2 NN 收敛后的实际效果分析

NN router 收敛到 (7) 后的 student 性能:

$$R_{\text{student},s} \approx \sum_k W_k^* \cdot R_{k,s} \quad (8)$$

具体计算 (用 high=1.0, med=0.7, low=0.3 估算):

Source s	$W_{\text{gen}}^* \cdot R_{\text{gen},s}$	$W_{\text{pick}}^* \cdot R_{\text{pick},s}$	$W_{\text{ocr}}^* \cdot R_{\text{ocr},s}$	Student R
geneval	$0.294 \cdot 1.0 = 0.294$	$0.412 \cdot 0.7 = 0.288$	$0.294 \cdot 0.3 = 0.088$	0.670
pickscore	$0.294 \cdot 0.7 = 0.206$	$0.412 \cdot 1.0 = 0.412$	$0.294 \cdot 0.3 = 0.088$	0.706
ocr	$0.294 \cdot 0.3 = 0.088$	$0.412 \cdot 0.3 = 0.124$	$0.294 \cdot 1.0 = 0.294$	0.506

对比每个 source 上的”单一 teacher 上限” (即 $R_{s,s} = \text{high} = 1.0$):

Source	Single-teacher 上限	NN router 实际	相对差距
geneval	1.0	0.670	-33%
pickscore	1.0	0.706	-29%
ocr	1.0	0.506	-49%

OCR 上的相对损失最大, 因为:

1. teacher_pickscore (被 NN 偏好) 在 OCR 上几乎无贡献 ($R = 0.3$)。
2. teacher_geneval (次偏好) 在 OCR 上同样无贡献。
3. 只有 29.4% 权重给到唯一有 OCR 能力的 teacher_ocr。

GenEval 看起来”平衡” (达到 teacher 水平) 的解释:

- **teacher_pickscore** 在 **GenEval** 上不差 (med=0.7), 加上 teacher_geneval 的 29.4% 权重 (high=1.0), 合计达到约 0.67, 可能与某些 epoch 下 teacher_geneval 单独 inference 的水平接近 (特别是当 **single teacher** 性能本身在 **0.6–0.7** 区间时, 看起来”达到”了)。
- 关键: GenEval 的”达到 teacher 水平”是相对于 **teacher_geneval baseline** 的, 而非真正的 high-bar 水平。

6 为什么 LUT 没有这个问题

6.1 每列独立优化

LUT 的 ocr_set 列只看 OCR 样本 (in-domain a_{ocr} 权重 1.0 + OOD a_{pick} 权重 $\gamma = 0.2$)。其最优解:

$$\Lambda^*[:, t, \text{ocr}] = \arg \max_{\Lambda} \mathbb{E}_{x \sim \text{ocr}} [(a_{\text{ocr}}(x) + \gamma a_{\text{pick}}(x)) \cdot \log p_{\Lambda}(x|t)] \quad (9)$$

由于 $1.0 \gg \gamma$, 最优解高度偏向 **teacher_ocr** (在 OCR 上得 high), 略微偏向 **teacher_pickscore** (在 OCR 上得 low, 但 OOD 系数小)。

6.2 初始化不影响最终收敛

LUT 的关键性质: 每列独立、低维 ($K = 3$ 个参数), 损失景观简单 ($K-1$ 维 simplex 上的近似线性目标), uniform 和 biased 两种初始化都能在足够 epochs 下收敛到同一最优解。这解释了”两种初始化都能让所有 reward 达到 teacher 水平”。

7 缓解方案

按推荐优先级排序：

7.1 方案 1：减小 OOD bonus 系数 (推荐首选)

直接把 NN router 配置中的 `ood_bonus_gamma` 从 0.2 降到 0.0。

- 原理：完全切断 PickScore 信号通过 OOD 渗透到 GenEval/OCR 样本的路径。每个样本的 advantage 退化为纯 in-domain。
- 信号强度对比表变为 $F_{\text{pick}} : F_{\text{gen}} : F_{\text{ocr}} = 1 : 1 : 1$ (均衡)。
- 代价：失去 OOD bonus 的设计意图 (鼓励 cross-domain transfer)。但实测看，这个意图在当前 reward 配置下反而带来主导问题。
- 预期：OCR 性能恢复到 teacher 水平，PickScore 主导消失。
- 实现：仅改 config，无需代码改动。

7.2 方案 2：对称化 reward 应用范围

把 `pick_score` reward 的 `applicable_sources` 从 `[geneval, pickscore, ocr]` 改为 `[pickscore]` (domain-specific)。

- 原理：把 PickScore 也变成 domain-specific reward，与 GenEval/OCR 对称。所有样本的 OOD 集合 $J_b = \emptyset$ ，与方案 1 等效。
- 代价：失去 PickScore 作为通用美学锚点的作用——若你希望所有 prompt 的图都美观，这个改动不利。
- 效果：与方案 1 等价，但通过 reward 配置实现，更“语义清晰”。

7.3 方案 3：折中的不对称 OOD

保留 OOD 但对 PickScore 不对称处理：

- 不让 `pickscore` 出现在其他 source 的 OOD 中 (即对 `geneval/ocr` 样本， $J = \emptyset$)；
- 让 GenEval/OCR 出现在彼此的 OOD 中 (如果你想要这种 transfer 的话——但目前 `applicable_sources` 限制让它们已经互相 NaN 了，所以也是 $\emptyset$)。

当前 reward 配置下，方案 3 退化为方案 1 (因为 GenEval/OCR 已经互不渗透)。所以方案 1 和方案 2 是当前主要可选项。

7.4 方案 4：Source-conditioned NN router

修改 NN router 输入：在 (t, c) 之外，再喂入 source one-hot 嵌入 $\mathbf{e}_s \in \mathbb{R}^S$ 。即 $W = f(t, c, s; \theta)$ 。

- 原理：把 LUT 的 source-decoupling 性质带回到 NN，让 NN 可以学到 per-source 的 W 。
- 风险：推理时需要正确的 `source` 标签 (与现有 router 的“source-agnostic”卖点相违背)。
- 代码改动量：中等——给 `MoFAdaLNRouter` / `MoFMLPRouter` 加一个 source 嵌入分支。
- 适用情形：你认可 source 标签可在推理时获取，且希望保留 OOD bonus 的 cross-domain 潜力。

7.5 方案 5: Per-source advantage 重权

在 advantage 计算后, 按 source 频率倒数重权:

$$A'(x_b, s_b) = w_{s_b} \cdot A(x_b, s_b), \quad w_s = \frac{c}{F_s^{\text{eff}}} \quad (10)$$

其中 F_s^{eff} 是 source s 的 *effective signal coverage* (OCR 信号覆盖率 $0.333 \rightarrow w_{\text{ocr}} = 1.4$; PickScore $0.467 \rightarrow w_{\text{pick}} = 1.0$)。

- 原理: 对受 OOD 串扰削弱的 source 加大其样本权重, 回归 1:1:1。
- 代价: 理论依据较弱 (粗暴的频率倒数), 且需要额外超参。
- 适用情形: 方案 1 不可接受 (必须保留 OOD bonus), 方案 4 不可接受 (必须保留 source-agnostic)。

7.6 方案对比

方案	改动量	保留 OOD?	保留 source-agnostic?	风险
1. $\gamma = 0$	仅 config	形式 实质 部分		低
2. 对称化 applicable	仅 config			低
3. 不对称 γ	仅 config			低 (当前等价于 1)
4. Source-conditioned NN	中等代码			中 (推理时需 source 标签)
5. Per-source 重权	中等代码			中 (超参敏感)

8 推荐的诊断 / Ablation 实验

8.1 快速验证假设

实验 A: 在 `adaln_router` 配置上做 γ ablation, 固定其他超参:

- $\gamma \in \{0.0, 0.05, 0.1, 0.2\}$ (当前是 0.2)
- 监控 OCR training reward 与 OCR test 性能
- 预期: γ 越小, OCR 性能越好。 $\gamma = 0$ 应能恢复到 teacher 水平。
- 若实验结果与预期一致: 确认 OOD 串扰为主要原因。

实验 B: 在 `adaln_router` 配置上对称化 reward:

- 把 `pick_score` 的 `applicable_sources` 改成 `[pickscore]`。
- 等价于方案 2。
- 预期: 与实验 A($\gamma=0$) 类似的结果。

8.2 LUT-SA 关键对照

实验 C: 跑 `lut_simple` (源无关 LUT) 作为关键对照。

- LUT-SA 也是参数共享 + **source-agnostic mixing** (与 NN router 同性质), 但用离散查表参数化 (与 LUT 同性质)。
- 若 LUT-SA 也呈现 PickScore 主导 $\rightarrow$ 主因是参数共享 + **OOD 串扰** (与 NN 的平滑性偏置无关)。
- 若 LUT-SA 没有问题 $\rightarrow$ 主因是 **NN** 的平滑性归纳偏置对不对称信号的放大。
- 这个区分对方案选择有指导意义: 前者 $\rightarrow$ 方案 1 必要; 后者 $\rightarrow$ 方案 4 也有效。

8.3 细粒度日志

在所有实验中，wandb 上记录按 **source** 分别的：

- `train/{source}/router_W_{teacher}` (每个 source 的 sample 的平均混合权重)
- `train/{source}/raw_{reward}` (z-score 前的原始 reward)
- `train/{source}/advantage` (z-score 后归一化前的 advantage)

可视化诊断：若 NN router 在 OCR 样本上的 $W_{\text{teacher_pickscore}}$ 显著高于 LUT 在同等条件下的值 $\rightarrow$ 印证平滑性偏置假设。

9 结论

核心论断

PickScore 主导效应 = 通用 **reward** $\times$ **OOD bonus** $\times$ 参数共享三方耦合的产物。

- 通用 **reward**: PickScore 的 `applicable_sources` 涵盖所有 sources，使其成为唯一双向流动的信号。
- **OOD bonus** ($\gamma > 0$): 把 PickScore 信号渗透到 GenEval/OCR 样本的 advantage 中，放大其总信号强度。
- **NN 参数共享**: 让来自所有 source 的 PickScore 信号累积在同一组 θ 上；LUT 的列解耦把这种串扰局限在每个 set 内部，所以不受影响。

为什么 **OCR** 受影响最严重: `teacher_pickscore` 在 OCR 上几乎无贡献 (low score)，而在 GenEval 上“恰好不差” (med score) ——这是 task 间能力相关性的不对称。

为什么 **LUT** 不论何种初始化都成功: LUT 每列独立优化，损失景观局部线性、 $K-1$ 维 simplex，初始化对最终收敛位置不敏感。

推荐立即行动: 在 NN router 配置上设 $\gamma = 0$ (方案 1, 仅改 config) 作为基线，确认 OCR 性能恢复后再考虑是否值得为保留 OOD bonus 引入更复杂的方案 (4 或 5)。