

MoF Reward 设计分析

如何设计 Reward 以实现/超越 Single-Teacher Performance

Flow Factory

Abstract

本文分析 MoF 框架中 reward function 的设计策略。MoF 通过 DiffusionNFT 算法优化 per-timestep 的 teacher 混合权重 $\lambda_{k,i}$, reward 函数直接决定了优化方向和最终性能上界。我们分析三种 reward 设计方案: (1) 等权加权所有指标; (2) 基于 prompt 类型的条件 reward; (3) 多阶段自适应 reward。并给出理论分析和实践建议, 特别关注超越 single-teacher 的可能性。

Contents

1	问题定义	2
1.1	背景回顾	2
1.2	核心问题	2
1.3	目标层次	2
2	方案一: 等权加权 (Naive GDPO)	2
2.1	定义	2
2.2	梯度分析	3
2.3	问题分析	3
2.4	等权加权的理论最优解	3
3	方案二: Prompt-Conditional Reward	3
3.1	动机	3
3.2	定义	3
3.3	梯度分析	4
3.4	Level 1 目标的保证	4
3.5	问题	4
4	方案三: 分阶段自适应 Reward (推荐)	4
4.1	核心理念	4
4.2	分析	5
5	方案四: Per-Prompt-Set 独立 λ (最强理论保证)	5
5.1	扩展 MoF 架构	5
5.2	理论优势	5
5.3	Reward 设计	5
5.4	参数量与开销	6
6	理论分析: 哪种 Reward 设计最可能超越 Single Teacher	6
6.1	超越 Single Teacher 的必要条件	6
6.2	时间互补性的来源	6
6.3	Reward 设计对超越概率的影响	6

7	实践方案推荐	7
7.1	推荐方案: Per-Set Lambda + Dominant-Reward-with-OOD-Bonus	7
7.2	理论保证	7
7.3	备选方案 (全局 λ 不改架构)	7
8	Reward Scale Normalization	7
8.1	问题	7
8.2	推荐 Normalization	7
9	Reward Shaping for Timestep Discovery	8
9.1	动机	8
9.2	可选的 Timestep-Level Reward Shaping	8
10	总结: 方案对比与实验规划	8
10.1	建议的实验顺序	9

1 问题定义

1.1 背景回顾

我们有 $K = 3$ 个 teacher flow model:

- Teacher 1 (GenEval): 在 GenEval 评测集 (composition, counting, spatial relations) 上表现最优。
- Teacher 2 (PickScore): 在 PickScore 评测集 (overall aesthetics) 上表现最优。
- Teacher 3 (OCR): 在 OCR 评测集 (text rendering accuracy) 上表现最优。

三个评测集对应三个 prompt set:

- $\mathcal{P}_{\text{gen}}$: GenEval prompts (涉及数量、空间关系、颜色属性)
- $\mathcal{P}_{\text{pick}}$: PickScore prompts (通用美学 prompts)
- $\mathcal{P}_{\text{ocr}}$: OCR prompts (含文字渲染要求的 prompts)

三个 reward function:

$$R_{\text{gen}}(x) : \text{GenEval accuracy (per-image composition score)} \in [0, 1] \quad (1)$$

$$R_{\text{pick}}(x) : \text{PickScore} \in \mathbb{R} \quad (2)$$

$$R_{\text{ocr}}(x) : \text{OCR accuracy} \in [0, 1] \quad (3)$$

1.2 核心问题

MoF 优化的是:

$$\ell^* = \arg \max_{\ell \in \mathbb{R}^{K \times T}} \mathbb{E}_{p \sim \mathcal{D}} [R(\text{ODE}(v_\lambda; x_T, p))] \quad (4)$$

R 如何设计直接决定了 MoF 能否超越 single teacher。

1.3 目标层次

我们区分两个不同层次的目标:

Level 1 (保守目标): 在每个 prompt set 上至少达到对应 single teacher 的 in-domain performance, 同时提升 OOD performance。即:

$$R_j(v_\lambda | p \in \mathcal{P}_j) \geq R_j(v^{(j)} | p \in \mathcal{P}_j), \quad \forall j \quad (5)$$

Level 2 (雄心目标): 在某些 prompt set 上超越最优 single teacher。即:

$$\exists j : R_j(v_\lambda | p \in \mathcal{P}_j) > R_j(v^{(j)} | p \in \mathcal{P}_j) \quad (6)$$

2 方案一: 等权加权 (Naive GDPO)

2.1 定义

最直接的做法: 对所有 reward 等权平均:

$$R^{\text{equal}}(x, p) = \frac{1}{3} [R_{\text{gen}}(x) + R_{\text{pick}}(x) + R_{\text{ocr}}(x)] \quad (7)$$

在 GDPO (Grouped DPO-style advantage computation) 框架中, advantage 为:

$$\mathcal{A}(x, p) = R^{\text{equal}}(x, p) - \mathbb{E}_{x' \sim \pi_{\text{old}}(\cdot | p)} [R^{\text{equal}}(x', p)] \quad (8)$$

2.2 梯度分析

将 (7) 代入 MoF 的梯度公式 (Theorem 2.1 of mof_gradient_analysis.tex):

$$\frac{\partial \mathcal{L}_i}{\partial \ell_{k,i}} \propto \lambda_{k,i} [v_k - v^{\text{new}}]^\top \left(\text{error signal weighted by } \mathcal{A}^{\text{equal}} \right) \quad (9)$$

2.3 问题分析

Proposition 1 (等权加权的潜在问题). 等权 reward 存在以下问题:

1. **Scale** 不匹配: R_{pick} 的绝对值范围 ($\sim 0.8\text{--}0.95$) 与 R_{gen} ($\sim 0.6\text{--}0.95$) 和 R_{ocr} ($\sim 0.5\text{--}0.93$) 不同。直接等权平均导致 PickScore 的 variance 较小, 在 advantage 计算中贡献不足。
2. **Reward** 冲突的平滑效应: 当某个 sample 在一个 metric 上好但在另一个上差时, 等权 advantage 接近于零——无法给出明确的优化方向。
3. **Prompt-Type** 不敏感: 对 OCR prompt, R_{gen} 和 R_{pick} 的信号可能与 OCR accuracy 无关甚至矛盾 (美学好的文字渲染不一定 OCR 准确)。等权加权将无关 reward 的噪声引入了 advantage。

2.4 等权加权的理论最优解

Proposition 2 (等权最优解的性质). 在等权 reward 下, MoF 的最优 λ^* 最大化所有 prompt 上的平均综合 reward:

$$\lambda^* = \arg \max_{\lambda} \mathbb{E}_p \left[\frac{1}{3} \sum_j R_j(v_\lambda | p) \right] \quad (10)$$

这不保证在单个 metric 上超越对应 teacher——因为最优解是在三个 metric 之间做 trade-off。具体来说, 如果 teacher j 已经在 R_j 上接近最优, 等权优化可能牺牲 R_j 来提升 $R_{j'}$ ($j' \neq j$)。

Remark 1 (适用场景). 等权加权适合“不在乎单个 metric 的 in-domain 性能, 只要综合提升”的场景。对 Level 1 目标不理想。

3 方案二: Prompt-Conditional Reward

3.1 动机

核心观察: 每个 prompt 有其“主要关注的 reward 维度”。OCR prompt 最关心文字准确性; GenEval prompt 最关心 composition; 通用 prompt 最关心 aesthetics。

3.2 定义

Strategy 1 (Prompt-Conditional Reward). 定义 per-prompt reward 为:

$$R^{\text{cond}}(x, p) = \begin{cases} w_{\text{in}} R_{\text{gen}}(x) + w_{\text{ood}} [R_{\text{pick}}(x) + R_{\text{ocr}}(x)] & \text{if } p \in \mathcal{P}_{\text{gen}} \\ w_{\text{in}} R_{\text{pick}}(x) + w_{\text{ood}} [R_{\text{gen}}(x) + R_{\text{ocr}}(x)] & \text{if } p \in \mathcal{P}_{\text{pick}} \\ w_{\text{in}} R_{\text{ocr}}(x) + w_{\text{ood}} [R_{\text{gen}}(x) + R_{\text{pick}}(x)] & \text{if } p \in \mathcal{P}_{\text{ocr}} \end{cases} \quad (11)$$

其中 $w_{\text{in}} \gg w_{\text{ood}}$ (如 $w_{\text{in}} = 0.7$, $w_{\text{ood}} = 0.15$)。

3.3 梯度分析

Proposition 3 (Conditional Reward 的梯度方向). 在 prompt-conditional reward 下, 对 $p \in \mathcal{P}_j$:

$$\mathcal{A}(x, p \in \mathcal{P}_j) \approx w_{\text{in}} [R_j(x) - \bar{R}_j] + w_{\text{ood}} \sum_{j' \neq j} [R_{j'}(x) - \bar{R}_{j'}] \quad (12)$$

主导信号为 R_j : 在 prompt set $\mathcal{P}_j$ 上, 梯度主要由对应 reward R_j 驱动, 确保 in-domain performance 被优先优化。OOD reward 提供辅助信号但不干扰主方向。

3.4 Level 1 目标的保证

Theorem 1 (Conditional Reward 趋向 Level 1). 在 $w_{\text{in}} \rightarrow 1, w_{\text{ood}} \rightarrow 0$ 的极限下, prompt-conditional reward 退化为 “route_by_source” 的 reward 版本:

$$\lim_{w_{\text{ood}} \rightarrow 0} R^{\text{cond}}(x, p \in \mathcal{P}_j) = R_j(x) \quad (13)$$

此时 MoF 在每个 prompt set 上独立优化对应 reward, 最优解为:

$$\lambda_{k,i}^*(\mathcal{P}_j) = \begin{cases} 1 & \text{if teacher } k \text{ at timestep } i \text{ maximizes } R_j \\ 0 & \text{otherwise} \end{cases} \quad (14)$$

由于 teacher j 专门为 R_j 训练, 大概率 $\lambda_{j,i}^*(\mathcal{P}_j) \approx 1$ 对多数 i ——但不排除在某些 timestep 上其他 teacher 贡献更大 (实现 Level 2)。

3.5 问题

Remark 2 (Conditional Reward 的局限). 1. 需要 **prompt set** 标注: 必须知道每个 prompt 属于哪个 set。对混合 prompt (如 “a cat with the word ‘hello’ on a beautiful beach”) 归类模糊。

2. 共享 λ : 当前 MoF 实现使用全局共享的 $\lambda_{k,i}$ (不依赖 prompt), 因此 conditional reward 实际上要求 λ 在不同 prompt set 上做 weighted average——可能导致折衷。

关键洞察: 全局 λ 的限制

当前 MoF 的 $\lambda_{k,i}$ 对所有 prompt 共享。如果不同 prompt set 需要不同的 λ 分配 (如 OCR prompts 偏向 OCR teacher, GenEval prompts 偏向 GenEval teacher), 则单一 λ 无法同时满足所有 prompt set。

解决方案:

1. 扩展 λ 为 prompt-conditioned: $\lambda_{k,i}(p)$ (增加参数量但更灵活)
2. 或者: 接受全局 λ 的折衷, 设计 reward 使得全局最优 λ 恰好在每个 prompt set 上表现良好

4 方案三: 分阶段自适应 Reward (推荐)

4.1 核心理念

结合方案一和方案二的优点, 设计一个自适应的 reward 策略:

Strategy 2 (Two-Phase Adaptive Reward). 分两个阶段设计 reward:

Phase 1 (In-Domain Recovery, 前 N/2 epochs): 使用高 w_{in} 的 conditional reward, 优先确保 in-domain performance 不退化。

Phase 2 (OOD Enhancement, 后 N/2 epochs): 逐步降低 w_{in} 并提升 w_{ood} , 鼓励 OOD improvement。

具体 schedule:

$$w_{\text{in}}(t) = w_{\text{in}}^{\text{max}} - (w_{\text{in}}^{\text{max}} - w_{\text{in}}^{\text{min}}) \cdot \frac{\max(0, t - T_{\text{warmup}})}{T_{\text{total}} - T_{\text{warmup}}} \quad (15)$$

4.2 分析

Phase 1 确保 λ 首先学到“在 OCR set 上偏向 OCR teacher”等基础模式 (达到 Level 1)。Phase 2 在此基础上探索时间互补性, 寻找能同时提升多个 metric 的 λ 配置。

5 方案四: Per-Prompt-Set 独立 λ (最强理论保证)

5.1 扩展 MoF 架构

Strategy 3 (Per-Set Lambda). 将 logits 扩展为 $\ell \in \mathbb{R}^{K \times T \times S}$ (S = prompt set 数量), 每个 prompt set 有独立的 λ 配置:

$$v_{\lambda}(x, t_i, p \in \mathcal{P}_s) = \sum_k \lambda_{k,i,s} v_k(x, t_i), \quad \lambda_{k,i,s} = \text{softmax}_k(\ell_{:,i,s}/\tau) \quad (16)$$

5.2 理论优势

Theorem 2 (Per-Set Lambda 的 Level 1 保证). 在 per-set lambda 下, 对每个 prompt set $\mathcal{P}_s$:

$$\max_{\ell_{:,i,s}} \mathbb{E}_{p \in \mathcal{P}_s} [R_s(v_{\lambda_s})] \geq R_s(v_k), \quad \forall k \quad (17)$$

其中不等式至少弱成立 (因为 $\lambda_{k,i,s} = \delta_{k,s}$ 是可行解, 对应 teacher s 本身)。

Proof. Teacher s 对应的 $\lambda_{k,i,s} = \delta_{k,s}$ (第 s 个 teacher 恒取权重 1) 是搜索空间中的一个可行点。其 reward 恰为 $R_s(v_s)$ ——即 single teacher s 的 performance。优化只能找到不差于此的解。□

5.3 Reward 设计

在 per-set lambda 架构下, reward 设计大幅简化:

$$R^{\text{per-set}}(x, p \in \mathcal{P}_s) = R_s(x) + \gamma \sum_{j \neq s} R_j(x) \quad (18)$$

其中 $\gamma \geq 0$ 是 OOD bonus 系数 (推荐 $\gamma \in [0.1, 0.3]$)。

Remark 3 (为什么 $\gamma > 0$ 有助于超越 single teacher). 当 $\gamma = 0$ 时, 每个 prompt set 独立优化自己的 in-domain reward, 最优解就是对应 single teacher (或略好——如果时间互补性允许通过混合其他 teacher 在某些 timestep 上获得额外增益)。

当 $\gamma > 0$ 时, 优化会倾向于“在不显著损害 in-domain 的前提下提升 OOD”。这正是时间互补性发挥作用的场景: 如果在某些 timestep 上引入少量其他 teacher 权重能提升 OOD reward 而不损害 in-domain, optimizer 会找到这样的配置。

5.4 参数量与开销

方案	Learnable Parameters	Reward Evaluations/Sample
Global λ + equal reward	$K \times T = 3 \times 28 = 84$	3
Global λ + conditional reward	$K \times T = 84$	3
Per-set λ + per-set reward	$K \times T \times S = 84 \times 3 = 252$	3

即使是 per-set 方案，参数量也仅为 252——相比 model-weight training 微不足道。

6 理论分析：哪种 Reward 设计最可能超越 Single Teacher

6.1 超越 Single Teacher 的必要条件

Theorem 3 (超越的必要条件). v_λ 在 metric R_j 、prompt set $\mathcal{P}_j$ 上超越 teacher j ，当且仅当：

$$\exists \text{ timestep } i^* \text{ 和 teacher } k \neq j: \text{ 在 } t_{i^*} \text{ 处使用 teacher } k \text{ 的 velocity 能提升 } R_j \text{ 的最终输出} \quad (19)$$

Proof. 如果对所有 timestep，teacher j 都是 R_j 的最优选择，则 $\lambda_{j,i}^* = 1, \forall i$ 即为最优——等价于 teacher j 本身，无法超越。超越的必要条件是存在至少一个 timestep 上，某个其他 teacher 对 R_j 有正向贡献。 $\square$

6.2 时间互补性的来源

Proposition 4 (为什么其他 Teacher 可能在某些 Timestep 帮助 In-Domain). 考虑具体场景：

1. **GenEval teacher 帮助 OCR:** GenEval teacher 擅长空间布局 (positioning)，这对文字的正确放置有帮助。在早期 **timestep** (全局 layout 阶段)，GenEval teacher 的 velocity 可能比 OCR teacher 更好地确保文字区域的位置正确。
2. **PickScore teacher 帮助 GenEval:** PickScore teacher 学到了一般性的“图像质量”信号，这包括清晰度和对比度。在晚期 **timestep** (细化阶段)，清晰的渲染可能帮助 GenEval 的属性识别 (如颜色更准确)。
3. **OCR teacher 帮助 PickScore:** OCR teacher 在文字清晰度上有优势，而含文字的图像如果文字模糊反而会降低 aesthetics。在有文字的 prompt 上，OCR teacher 在中期 timestep 的贡献可能提升整体美感。

6.3 Reward 设计对超越概率的影响

Theorem 4 (Reward 与超越概率的关系). 设 $\lambda^*(R)$ 为 reward function R 下的 MoF 最优解。

1. **Equal reward** ($R = \frac{1}{3} \sum R_j$): λ^* 最大化综合 reward，对单个 R_j 无保证。可能在某些 R_j 上下降以换取综合提升。超越单 **teacher** 的概率低 (因为优化方向分散)。
2. **Per-set 独立 reward** ($R_s = R_s$, per-set λ): 每个 set 独立优化， λ_s^* 直接最大化 R_s 。由 Theorem 2，必然 $\geq$ **single teacher**。当时间互补性存在时，严格超越。
3. **Per-set + OOD bonus** ($R_s = R_s + \gamma \sum_{j \neq s} R_j$): 鼓励探索 OOD 方向的 λ 配置。由于 OOD bonus 的正向激励，optimizer 更倾向于“尝试在某些 timestep 引入其他 teacher”——如果这增加了总 reward，就会被保留。增大了发现时间互补性的概率。

7 实践方案推荐

7.1 推荐方案：Per-Set Lambda + Dominant-Reward-with-OOD-Bonus

推荐方案

架构：Per-set $\lambda \in \mathbb{R}^{K \times T \times S}$ ($S = 3$)

Reward for prompt set $\mathcal{P}_s$:

$$R_s(x) = R_s(x) + \gamma \cdot \frac{1}{K-1} \sum_{j \neq s} R_j(x), \quad \gamma = 0.2 \quad (20)$$

Advantage computation: GDPO within each prompt set independently.

训练：三组 λ 同时训练，每个 mini-batch 混合三个 prompt set 的 sample。

7.2 理论保证

Corollary 1 (推荐方案的性质). 1. **Level 1** 保证 ($\geq$ single teacher in-domain): 由 Theorem 2 直接得到。即使学到的 λ 退化为对应 teacher，也不会更差。

2. **Level 2** 可能性 ($>$ single teacher): 由 OOD bonus 的正向激励 + 时间互补性 (Proposition 4), optimizer 有动力探索混合配置。

3. 稳定性: $\gamma = 0.2$ 确保 in-domain reward 仍然是 dominant signal (R_s 的系数为 1, OOD 的总系数为 $\gamma = 0.2$), 不会因 OOD bonus 而牺牲 in-domain。

7.3 备选方案（全局 λ 不改架构）

如果不修改 MoF 架构（保持全局 $\lambda \in \mathbb{R}^{K \times T}$ ），推荐使用 conditional reward:

备选方案（全局 λ ）

$$R(x, p) = \begin{cases} R_{\text{gen}}(x) + 0.15[R_{\text{pick}}(x) + R_{\text{ocr}}(x)] & p \in \mathcal{P}_{\text{gen}} \\ R_{\text{pick}}(x) + 0.15[R_{\text{gen}}(x) + R_{\text{ocr}}(x)] & p \in \mathcal{P}_{\text{pick}} \\ R_{\text{ocr}}(x) + 0.15[R_{\text{gen}}(x) + R_{\text{pick}}(x)] & p \in \mathcal{P}_{\text{ocr}} \end{cases} \quad (21)$$

注意：全局 λ 下，optimizer 需要在三个 prompt set 之间做折衷。最终 λ 是三个 set 的“平均最优”——可能在某些 set 上略差于 single teacher。但由于 in-domain reward 权重 大 (1.0 vs 0.30)，退化幅度应该很小。

8 Reward Scale Normalization

8.1 问题

$R_{\text{gen}} \in [0, 1]$, $R_{\text{pick}} \sim [0.83, 0.95]$, $R_{\text{ocr}} \in [0, 1]$ 。Scale 和 range 不同导致 advantage 中各 reward 的有效贡献不均衡。

8.2 推荐 Normalization

Strategy 4 (Per-Reward Z-Score Normalization). 在 advantage 计算前，对每个 reward 做 running z-score normalization:

$$\tilde{R}_j(x) = \frac{R_j(x) - \mu_j}{\sigma_j + \epsilon} \quad (22)$$

其中 μ_j, σ_j 是 running mean/std (across recent batches)。

然后定义 normalized reward:

$$R_s(x) = \tilde{R}_s(x) + \gamma \cdot \frac{1}{K-1} \sum_{j \neq s} \tilde{R}_j(x) \quad (23)$$

Remark 4 (Z-score vs. Min-Max). Z-score 优于 min-max: (1) 不需要预设 range 边界; (2) 对 outlier 更鲁棒; (3) 在 RL 中 advantage 本身就是 centered 的, z-score 与 GDPO advantage 的结构兼容。

9 Reward Shaping for Timestep Discovery

9.1 动机

标准 DiffusionNFT 的 reward 是 trajectory-level 的: 只在最终 image 上评估。这给 λ 在每个 timestep 上的 credit assignment 带来困难——需要大量 sample 来发现“哪个 timestep 上哪个 teacher 好”。

9.2 可选的 Timestep-Level Reward Shaping

Strategy 5 (KL-based Shaping Bonus). 为每个 timestep 提供一个“与当前 dominant teacher 对齐”的 bonus:

$$R_{\text{shaped},i} = R_{\text{final}} - \alpha \sum_i \text{KL}(v_\lambda(\cdot, t_i) \| v_{\text{dominant}}(\cdot, t_i)) \quad (24)$$

其中 v_{dominant} 是 per-prompt-set 的 in-domain teacher velocity。

效果: 鼓励 λ 默认偏向 in-domain teacher (减小 KL), 只有在 final reward 明确优于时才偏离。相当于 reward shaping 的“conservative prior”。

Remark 5 (是否推荐). KL shaping 增加了计算开销 (需要额外的 per-timestep KL 计算), 且可能限制探索。在前期实验中不推荐使用——先用纯 final reward 看 MoF 的自然行为。如果发现 λ 收敛慢或 variance 大, 再考虑引入 shaping。

10 总结: 方案对比与实验规划

方案	Level 1 保证	Level 2 可能	需改架构	推荐优先级
等权加权	✗	低	✗	4 (对照组)
Conditional reward (global λ)	弱 [†]	中	✗	2
Per-set $\lambda + R_s$ only	✓	低	✓*	3
Per-set $\lambda + R_s + \gamma \sum R_j$	✓	高	✓*	1

[†] 弱保证: 全局 λ 做折衷, 可能略低于 single teacher。

* 架构改动极小: 仅将 ℓ 从 (K, T) 扩展为 (K, T, S) 。

核心结论

1. 不要使用等权加权作为最终方案——它无法保证 in-domain performance，且超越 single teacher 的概率低。可作为 baseline 对照。
2. **Per-set λ** 是理论最优架构——它解耦了不同 prompt set 的优化，给予每个 set 独立的“teacher 调度权”。
3. **OOD bonus** ($\gamma > 0$) 是发现时间互补性的关键——纯 in-domain reward 倾向于退化为 single teacher（因为这已经是一个很强的局部最优）。OOD bonus 提供了“探索”的激励。
4. **Reward normalization** (z-score) 是必要的前处理——确保不同 scale 的 reward 有公平的梯度贡献。
5. 分阶段（先 in-domain 恢复、后 OOD 探索）可以加速收敛，但如果用 per-set λ （有 Level 1 保证），则不是必须的。

10.1 建议的实验顺序

1. **Exp 1** (验证 MoF 基础): 等权 reward + global λ 。确认 MoF 训练正常运行， λ 有合理的变化趋势。
2. **Exp 2** (conditional reward): prompt-conditional reward + global λ 。对比 Exp 1，验证 conditional reward 是否更好。
3. **Exp 3** (per-set λ): per-set λ + per-set reward ($\gamma = 0$)。验证 Level 1 保证。
4. **Exp 4** (完整推荐方案): per-set λ + per-set reward with OOD bonus ($\gamma = 0.2$)。验证 Level 2 (超越 single teacher)。
5. **Exp 5** (消融): 调整 $\gamma \in \{0.1, 0.3, 0.5\}$ 观察 in-domain vs OOD 的 trade-off。