

MoF 路由网络架构数据流分析

LUT · adaLN Router · MLP Router

Flow Factory

1 概述


MoF (Mixture-of-Flow) 使用一个路由模块来预测每个 denoising step 中各 teacher 的混合权重。系统实现了五种路由架构，共享相同的外部接口：

架构	配置名	核心思想
离散查找表 (LUT)	lut	固定 (K, T, S) 参数，按 $\text{source} \times \text{timestep}$ 查表
源无关 LUT (LUT-SA)	lut_simple	固定 (K, T) 参数，仅按 timestep 查表
时间路由器 (Time Router)	time_router	连续 $t \rightarrow W$ 的小型 MLP，无文本输入
adaLN Router	adaln_router	时间调制文本，类 DiT 的 adaLN 模式
MLP Router	mlp_router	拼接时间 + 文本，简单 MLP 预测

统一输出：所有架构输出 $\mathbf{W} \in \mathbb{R}^{K \times B}$ ，其中 K = teacher 数量， B = batch size，每列归一化 $\sum_k W_{k,b} = 1$ 。

2 架构 1：离散查找表 (MoFMixingModule)

2.1 数据流图



2.2 张量维度详解

张量	形状	维度含义
$\mathbf{\Lambda}$ (logits)	(K, T, S)	K : teacher 数量 (e.g., 3) T : denoising 总步数 (e.g., 10) S : prompt source 集合数 (e.g., 3 for geneval/pickscore/ocr)
t_{idx}	scalar $\in [0, T-1]$	当前 denoising step 的整数索引
$\mathbf{s}$ (set_ids)	$(B,)$	每个样本对应的 source 集合 ID
$\mathbf{\Lambda}[:, t_{\text{idx}}, :]$	(K, S)	当前 step 下所有 teacher $\times$ 所有 source 的 logits
$\mathbf{\Lambda}[:, t_{\text{idx}}, \mathbf{s}]$	(K, B)	每样本取对应 source 的 logits (advanced indexing)
$\mathbf{W}$	(K, B)	softmax 归一化后的权重, $\sum_k W_{k,b} = 1$

2.3 计算逻辑

$$W_{k,b} = \frac{\exp(\Lambda_{k,t_{\text{idx}},s_b}/\tau)}{\sum_{k'=1}^K \exp(\Lambda_{k',t_{\text{idx}},s_b}/\tau)} \quad (1)$$

特点：无神经网络计算，纯查表 + softmax。 $K \times T \times S$ 个可学习参数。

3 架构 1B: 源无关 LUT (MoFMixingModuleSimple, “LUT-SA”)

3.1 动机


源无关 LUT (`lut_simple`) 是源感知 LUT 的简化版本：丢弃 S 轴，只保留 (K, T) 两个维度。

核心问题

若不同 **source** 的最优 **teacher** 混合相似，是否仍需要为每个 **source** 单独学一组 **logits**?

LUT-SA 用一个共享的 (K, T) 表回答这个问题：所有样本共享同一套 per-timestep 权重，但 **reward / advantage** 仍然按 **source** 路由 ($A_b = a_{\text{in}}(s_b) + \gamma \cdot \text{mean}(a_{\text{ood}})$)。这给出了一个干净的对照实验：若 LUT-SA 与 LUT 性能持平，说明 per-source 维度对当前问题冗余；若 LUT 显著更好，说明 teacher 间存在需要按 source 区分的专长边界。

3.2 数据流图



3.3 计算逻辑

$$W_{k,b} = W_k(t_{\text{idx}}) = \frac{\exp(\Lambda_{k,t_{\text{idx}}}/\tau)}{\sum_{k'=1}^K \exp(\Lambda_{k',t_{\text{idx}}}/\tau)}, \quad \forall b \in [1, B] \quad (2)$$

注意右侧不依赖 b （也不依赖 s_b 、 $\mathbf{c}_b$ ），所以 $\mathbf{W}$ 在 batch 内沿 B 轴常数广播。

3.4 API 兼容性：广播到 (K, T, S)

为了让下游代码（按 `set_ids` 高级索引）无需任何修改，`forward()` 输出形状仍为 (K, T, S) ，但所有 S 切片相等：

$$\mathbf{W}_{\text{out}}[k, t, s] = W_k(t), \quad \forall s \in [0, S-1] \quad (3)$$

这是一个零成本的 `expand` 视图（不复制内存），参数仍只有 $K \cdot T$ 个。

3.5 优化目标与梯度流

考虑学生在第 b 个样本上的 NFT/GRPO 损失，其优势 $A_b = A(x_b, s_b)$ 由 source-aware 的 advantage pipeline (in-domain + $\gamma \cdot \text{mean}(\text{ood})$) 给出。logits Λ 的梯度为：

$$\nabla_{\Lambda_{k,t}} \mathcal{L} = \mathbb{E}_{(x,s) \sim \mathcal{D}} [A(x, s) \cdot \nabla_{\Lambda_{k,t}} \log p_{\theta}(x | t)] \quad (4)$$

由于 $\Lambda_{k,t}$ 不依赖 s ，所有 source 的样本梯度都流入同一个 $\Lambda_{k,t}$ 参数。最优解满足：

$$\Lambda^*(\cdot, t) = \arg \max_{\Lambda(\cdot, t)} \mathbb{E}_{s \sim P(s)} \mathbb{E}_{x \sim p_{\Lambda}(\cdot | s, t)} [R_s(x) + \gamma \cdot \frac{1}{|J|} \sum_{j \in J} R_j(x)] \quad (5)$$

其中 $J = \{j : j \neq R_{\text{in}}(s)\}$ 为 OOD reward 集合， $P(s)$ 为训练时 source 的边际分布。换言之，LUT-SA 学到的是对 **source** 边际化 (marginalized over s) 后的最优混合策略。

3.6 与源感知 LUT 的关系

LUT-SA 是源感知 LUT 在等约束 $\Lambda_{k,t,1} = \Lambda_{k,t,2} = \dots = \Lambda_{k,t,S}$ 下的特殊解。从假设空间角度：

$$\mathcal{H}_{\text{LUT-SA}} \subsetneq \mathcal{H}_{\text{LUT}} \quad (6)$$

- **LUT** 能表达的，**LUT-SA** 不一定能：当不同 source 的最优 teacher 混合差异显著时（例如 OCR 偏好 teacher-ocr，GenEval 偏好 teacher-geneval），LUT-SA 必须做妥协。
- **LUT-SA** 能表达的，**LUT** 总能精确复现：将 LUT 的所有 S 切片设为相等即可。

因此 LUT-SA 与 LUT 的性能差距，定量衡量了 **per-source** 路由收益。

3.7 何时使用 LUT-SA

推荐使用	中性	不推荐
Teacher 互补但不专业化（如多个 LoRA 共享一个底座、风格相近）	$K=2$ 时（ S 维收益本就不明显）	Teacher 与 source 严格一一对应（hard-route 配置）
作为 ablation baseline, 定量评估 per-source 路由收益	样本量 N 较小时，参数减少有助于防止过拟合	不同 source 间 reward scale 差异大且 γ 较小
推理时希望 source 标签解耦（同 prompt 不同 source 标签得到相同输出）		OOD 比例极小（ $\gamma \rightarrow 0$ 时几乎退化为单 source 训练）

3.8 参数量对比

模块	形状	参数量 ($K=3, T=10, S=3$)	vs LUT
LUT (lut)	(K, T, S)	90	$1.0\times$
LUT-SA (lut_simple)	(K, T)	30	$1/S\times$
adaLN Router	神经网络	$\sim 790\text{K}$	$\sim 8800\times$
MLP Router	神经网络	$\sim 660\text{K}$	$\sim 7300\times$

参数量随 S 线性下降。当 S 较大（例如 $S=10$ 个 source 子集）时，LUT-SA 的参数节省更显著。

3.9 与 reward 路由的协同

关键不变量：mixing 模块源无关 $\nrightarrow$ reward 源无关。MoF 框架下二者解耦：

机制	Mixing weights	Reward / Advantage
LUT (lut)	源感知 ($\Lambda_{k,t,s}$)	源感知 ($A_b = a_{\text{in}}(s_b) + \gamma \text{mean}(a_{\text{ood}})$)
LUT-SA (lut_simple)	源无关 ($\Lambda_{k,t}$)	源感知 (同上)
Router	隐式源感知 (经 $\mathbf{c}_b$)	源感知 (同上)

LUT-SA 训练流程（以 NFT 为例）：

1. Sample: student 用当前 $W_k(t) = \text{softmax}_k(\Lambda_{k,t}/\tau)$ 混合 teacher 速度，rollout 整条轨迹。
2. Reward: 每个 reward R_j 在自己的 `applicable_sources` 子集上计算。
3. Advantage: 按 (4) 中的 $A(x, s)$ 公式计算 source-aware advantage。
4. Loss: 将 source-aware A_b 反传到 source-agnostic Λ ，每个 $\Lambda_{k,t}$ 累积所有 source 的梯度信号。

3.10 实现要点

1. **Logits** 形状：模块内部 $\Lambda \in \mathbb{R}^{K \times T}$ ，无 S 轴。
2. **Forward** 输出广播：`forward()` 返回 (K, T, S) ，由 `logits.unsqueeze(-1).expand(K, T, S)` 实现（视图，不占额外内存）。
3. 初始化：
 - **uniform**： $\Lambda = \mathbf{0}$ ，softmax 后每个 teacher $1/K$ 。
 - **teacher_biased**：因无 S 轴可独立偏置，将所有 source 的 in-domain teacher 偏置合并到统一的 Λ 行（多 source 同一 teacher 时偏置叠加）。
4. **ema**、**checkpoint**、**distill** 加载：与源感知 LUT 共用代码路径；distill 加载时若发现 `lambda_logits` 为 2D 张量，会自动 `unsqueeze(-1).expand` 到 (K, T, S) 后再过 softmax。

4 架构 1C：时间路由器 (MoFTimeRouter, “Time Router”)

4.1 动机：从离散查表到连续时间函数

LUT-SA 抹掉了 S 轴，但仍保留 T 轴的离散查表结构，这意味着：

- 训练与推理必须使用相同的 T （推理时第 i 步固定查 $\Lambda[:, i]$ ）。
- 相邻 timestep 的权重之间无显式连续性约束——网络可以学到任意跳跃的混合曲线。

时间路由器进一步把离散查表替换为关于 t 的连续函数 $W : \mathbb{R} \rightarrow \Delta^{K-1}$ ，但不引入文本条件：


核心问题

若混合策略只随 timestep 平滑变化，与 prompt 内容无关，能否用一个仅以 t 为输入的小型 MLP 替代离散 LUT？这种参数化能否在保持表达力的同时获得推理 T 灵活性？

设计定位：Time Router 是连续时间路由器中的最简变体——只有时间分支，没有文本分支。它在假设空间和参数效率上位于 LUT-SA 与全路由器之间：

模块	时间	文本/Source	时间平滑性	推理 T
LUT	离散查表	source-aware	任意（可跳跃）	绑定训练 T
LUT-SA	离散查表	无（边际化）	任意（可跳跃）	绑定训练 T
Time Router	连续 NN	无	隐式平滑	任意 T
adaLN Router	连续 NN	隐式经 prompt	隐式平滑	任意 T
MLP Router	连续 NN	隐式经 prompt	隐式平滑	任意 T

4.2 数据流图



关键观察：与 adaLN/MLP Router 相比，Time Router 完全删除了文本分支（c_proj, AttnPool）以及融合层（adaLN 调制或 concat）。前向路径只有时间分支 + 输出分类头。

4.3 张量维度详解

张量	形状	维度含义
— 输入 —		
$\mathbf{t}$	$(B,)$	每样本的 raw timestep 值（scheduler 原始尺度，e.g. 0–1000）
— Time Branch —		
$\text{SinusoidalEmb}(\mathbf{t})$	(B, d_t)	正弦位置编码（ $d_t=256$ ，复用 <code>mixing_d_time</code> ）
$\mathbf{h}_1 = \text{Linear}_1 + \text{SiLU}$	(B, d_h)	第一隐层（ $d_h=256$ ，复用 <code>mixing_hidden_dim</code> ）
$\mathbf{h}_2 = \text{Linear}_2 + \text{SiLU}$	(B, d_h)	第二隐层
— 输出 —		
$\ell = \text{Linear}_{\text{out}}(\mathbf{h}_2)$	(B, K)	未归一化 logits（输出层零初始化 → 起始权重 $1/K$ ）
$\mathbf{W}$	(K, B)	softmax + transpose, $\sum_k W_{k,b} = 1$

注：Time Router 不使用 `mixing_d_pool` 和 `mixing_d_seq`（无文本路径）。即使 config 中设置了这两个字段，模块也会忽略。

4.4 计算逻辑

$$\mathbf{e}_t = \text{SinusoidalPosEmb}_{d_t}(\mathbf{t}) \in \mathbb{R}^{B \times d_t} \quad (7)$$

$$\mathbf{h}_1 = \text{SiLU}(\text{Linear}_1(\mathbf{e}_t)) \in \mathbb{R}^{B \times d_h} \quad (8)$$

$$\mathbf{h}_2 = \text{SiLU}(\text{Linear}_2(\mathbf{h}_1)) \in \mathbb{R}^{B \times d_h} \quad (9)$$

$$\ell = \text{Linear}_{\text{out}}(\mathbf{h}_2) \in \mathbb{R}^{B \times K} \quad (\text{输出层零初始化}) \quad (10)$$

$$W_{k,b} = \text{softmax}(\ell_b / \tau)_k \quad (11)$$

关键性质：当 batch 内所有样本共享同一个 t_b 时（典型 MoF 推理与训练 timestep 采样模式）， $\mathbf{W}$ 的所有列相等。当 t_b 在 batch 内不同时（少见），网络自然给出 B 个不同的混合向量。

4.5 优化目标与梯度流

设训练 timestep 集合为 $\mathcal{T}_{\text{train}} = \{t_0, t_1, \dots, t_{T-1}\}$ 。Time Router 的优化目标：

$$\min_{\theta_{\text{TR}}} \mathbb{E}_{(x,s,t) \sim \mathcal{D}} [-A(x, s) \cdot \log p_{\theta_{\text{TR}}}(x | t)] \quad (12)$$

其中 $\theta_{\text{TR}} = \{\text{Linear}_1, \text{Linear}_2, \text{Linear}_{\text{out}}\}$ 为路由器权重， $p_{\theta_{\text{TR}}}(x|t)$ 表示用 $W_k(t; \theta_{\text{TR}})$ 混合 teacher 速度后的学生轨迹密度。

由于 W 完全由 θ_{TR} 控制（不依赖 s ），所有 source 的样本梯度通过同一组共享权重流动：

$$\nabla_{\theta_{\text{TR}}} \mathcal{L} = \mathbb{E}_{(x,s,t)} \left[A(x, s) \cdot \sum_{k=1}^K \frac{\partial \log p}{\partial W_k(t)} \cdot \nabla_{\theta_{\text{TR}}} W_k(t) \right] \quad (13)$$

注意 $\nabla_{\theta_{\text{TR}}} W_k(t)$ 只依赖 t ——这表明 Time Router 的所有参数更新对所有 t 同时生效（与 LUT-SA 中 $\Lambda(\cdot, t)$ 仅由对应 timestep 的样本更新形成对照）。

4.6 假设空间分析

4.6.1 在训练 timestep 上的等价性

形式上，Time Router 限制在训练 timestep 集合 $\mathcal{T}_{\text{train}}$ 上的输出空间满足：

$$\mathcal{H}_{\text{TR}}|_{\mathcal{T}_{\text{train}}} \subseteq \mathcal{H}_{\text{LUT-SA}} \quad (14)$$

LUT-SA 在 $\mathcal{T}_{\text{train}}$ 上有 $K \cdot T$ 个独立自由度；Time Router 受 NN 参数化约束，等效自由度更低（任何相邻 t_i 的输出都通过共享权重耦合）。

4.6.2 在连续时间上的扩展性

但在 $\mathcal{T}_{\text{train}}$ 之外（连续 $t \in \mathbb{R}$ ）：

$$\mathcal{H}_{\text{TR}}|_{\mathbb{R}} \not\subseteq \mathcal{H}_{\text{LUT-SA}} \quad (15)$$

LUT-SA 在 $\mathcal{T}_{\text{train}}$ 之外完全没有定义——它无法回答“ $t = 0.5(t_3 + t_4)$ 时的混合权重应该是多少”。Time Router 通过 NN 自然外推：

$$W_{\text{TR}}(t^*) = \text{softmax}(\text{MLP}_{\theta}(\text{SinusoidalEmb}(t^*))/\tau), \quad \forall t^* \in \mathbb{R} \quad (16)$$

这给了 Time Router 一个独有的优势：推理时可以使用任意数量的 **timestep**（即使训练时只用了 $T = 10$ ，推理可以用 $T = 20$ 或 $T = 50$ ，无需重训）。

4.6.3 平滑性的归纳偏置

由于 NN 的 Lipschitz 连续性（线性层 + SiLU 激活），Time Router 隐式地对 $W(t)$ 施加平滑性约束。这是一把双刃剑：

平滑性的好处	平滑性的代价
若最优混合策略本就随 t 平滑变化（典型情况），NN 的归纳偏置作为隐式正则化，在 RL 信号稀疏时（每 epoch 144 样本）抑制过拟合。	若最优策略在某些 t 处需要尖锐切换（e.g. 高 noise 区与低 noise 区使用完全不同的 teacher 集合），平滑 NN 在切换点附近的表达受限。
SinusoidalEmb 的多频率分量允许网络在需要时学到中等频率的振荡，缓解上述问题。	极端的不连续（阶跃函数）仍难以精确刻画。

4.7 何时使用 Time Router

推荐使用	中性	不推荐
推理需要灵活的 timestep 数量（训练 T_{train} ，推理 $T_{\text{infer}} \neq T_{\text{train}}$ ）	RL 训练样本稀疏，需要平滑性正则化	最优混合策略需要按 prompt 内容路由（e.g. teacher_geneval 仅适用于含计数/物体的 prompt）
作为简化对照测试 prompt 路由必要性：若与 adaLN/MLP Router 性能持平，说明 prompt 不影响路由决策	K 较大（5–10）时，连续参数化能在不大幅增加参数下提升表达力	最优策略在某些 t 处有尖锐切换且训练 T 足够密集（LUT-SA 此时更直接）
模型部署时不希望路由器依赖文本编码器输出（解耦推理 pipeline）		训练数据极少（平滑 NN 的 132K 参数仍可能过拟合）

4.8 参数量对比

模块	形状	参数量（ $K=3, T=10, S=3, d_h=256, d_t=256$ ）	vs LUT	vs
LUT (lut)	(K, T, S) logits	90	$1.0\times$	$\sim$
LUT-SA (lut_simple)	(K, T) logits	30	$1/3\times$	$\sim$
Time Router (time_router)	3 Linear	$\sim$ 132K	$\sim 1500\times$	$\sim$
adaLN Router	adaLN + 2 branches	$\sim 790K$	$\sim 8800\times$	$\sim$
MLP Router	concat + 3 Linear	$\sim 660K$	$\sim 7300\times$	$\sim$

具体计算（ $K=3, d_t=d_h=256$ ）：

$$\text{Linear}_1 : 256 \times 256 + 256 = 65,792 \quad (17)$$

$$\text{Linear}_2 : 256 \times 256 + 256 = 65,792 \quad (18)$$

$$\text{Linear}_{\text{out}} : 256 \times 3 + 3 = 771 \quad (19)$$

$$\text{Total} : 132,355 \approx 132K \quad (20)$$

参数节省主要来自删除了 c_proj（ $2048 \times 256 \approx 525K$ params）和 AttnPool（如使用，约 $4096 \times 256 \approx 1M$ params）。

4.9 与 reward 路由的协同

关键不变量：与 LUT-SA 一样，mixing 模块的源无关性不影响 reward / advantage 的源感知性。三种“源无关 mixing + 源感知 reward”的组合：

机制	Mixing 输入	时间 sharpness	推理 T
LUT-SA (<code>lut_simple</code>)	仅 t (整数索引)	任意	绑定训练 T
Time Router (<code>time_router</code>)	仅 t (连续)	隐式平滑	任意 T
adaLN/MLP Router	$t + \text{prompt content}$	隐式平滑	任意 T

不论选哪一种 mixing 模块，advantage 计算路径完全相同：

$$A(x_b, s_b) = a_{R_{\text{in}}(s_b)}(x_b) + \gamma \cdot \frac{1}{|J|} \sum_{j \in J} a_j(x_b) \quad (21)$$

Time Router 的训练流程：


1. Sample: student 用当前 $W_k(t; \theta_{\text{TR}})$ 混合 teacher 速度，rollout 整条轨迹。
2. Reward: 每个 reward 在自己的 `applicable_sources` 子集上计算。
3. Advantage: 按 source-aware 的 in-domain + $\cdot$ OOD 公式计算 A_b 。
4. Loss: source-aware A_b 反传到 source-agnostic θ_{TR} ，所有 timestep 的样本共享对路由器权重的更新。

4.10 实现要点

1. 类继承结构: 建议不继承自 `MoRouterBase`，因为后者在 `__init__` 中强制构建 `c_proj` (依赖 d_{pool})，会引入对 Time Router 不必要的字段依赖。直接继承 `nn.Module`，自包含 `SinusoidalPosEmb` + 时间 MLP + 输出头即可。
2. **Forward** 签名兼容: 为与现有路由器调用点兼容, 签名可设计为 `forward(t, prompt_embeds=None, pooled_prompt_embeds=None)` 但忽略后两个参数。这样 `patched_forward` 中的 `w_i = router(t, prompt_emb, pooled)` 调用无需修改。
3. 零初始化: `Linearout` 的 weight 和 bias 都初始化为零 $\rightarrow$ 训练初期所有 teacher 均匀加权 $1/K$ 。这与 adaLN/MLP Router 的零初始化策略一致。
4. 无需文本配置: 模块创建时只读取 `mixing_d_time` (默认 256) 和 `mixing_hidden_dim` (默认 256); 忽略 `mixing_d_pool` 和 `mixing_d_seq`。
5. **Checkpoint** 元数据: `router_arch` 字典中 `d_pool=None`, `d_seq=None`, 其余字段 (`K`, `d_hidden`, `d_time`, `tau`) 正常填写。Distill 加载时识别出 `d_pool=None` 即可重建 Time Router。
6. 推理时 **timestep** 灵活性: `num_inference_steps` 在训练和推理可不一致; 调度器在推理时间用任何 T_{infer} 离散化连续时间区间, 把每个采样到的 t 喂给 Time Router 即可获得对应混合权重。

5 架构 2: adaLN Router (MoFAdaLNRouter)

5.1 数据流图



5.2 张量维度详解

张量	形状	维度含义
— 输入 —		
$\mathbf{t}$	$(B,)$	每样本的 raw timestep 值 (e.g., 0–1000)
$\mathbf{H}$ (prompt_embeds)	(B, L, d_{text})	B : batch size L : token 序列长度 (e.g., 77–512) d_{text} : text encoder hidden dim (e.g., 4096)
$\mathbf{H}_{\text{pool}}$ (可选)	(B, d_{pool})	pooled text embedding (SD3: 2048)。若提供则跳过 AttnPool
— Time Branch —		
SinusoidalEmb($\mathbf{t}$)	(B, d_t)	正弦位置编码 ($d_t=256$)
$\mathbf{t}_h = \text{Linear} + \text{SiLU}$	(B, d_h)	时间隐表示 ($d_h=256$)
adaLN output	$(B, 2d_h)$	Linear 映射后的 γ, β 拼接
γ, β	各 (B, d_h)	adaLN 调制参数 (初始化为 0)
— Text Branch —		
$\mathbf{q}$ (attn_query)	$(1, 1, d_{\text{text}})$	Learnable attention query (初始化 $\sim \mathcal{N}(0, 0.02)$)
attn scores	$(B, 1, L)$	$\mathbf{q} \cdot \mathbf{H}^\top / \sqrt{d_{\text{text}}}$
attn weights	$(B, 1, L)$	softmax over L dimension
$\mathbf{c}_{\text{pooled}}$	(B, d_{text})	Weighted sum of tokens
$\mathbf{c} = \mathbf{c}_{\text{proj}}$	(B, d_h)	投射到隐层维度
— Fusion + Output —		
$\mathbf{h} = \gamma \odot \mathbf{c} + \beta$	(B, d_h)	时间调制后的融合表示
MLP output (logits)	(B, K)	K 个 teacher 的 unnormalized logits
$\mathbf{W}$ (output)	(K, B)	softmax 后 transpose, $\sum_k W_{k,b} = 1$

5.3 计算逻辑

$$\mathbf{t}_h = \text{SiLU}(\text{Linear}(\text{SinusoidalEmb}(\mathbf{t}))) \in \mathbb{R}^{B \times d_h} \quad (22)$$

$$(\gamma, \beta) = \text{chunk}(\text{Linear}_{\text{adaLN}}(\mathbf{t}_h), 2) \quad \text{各} \in \mathbb{R}^{B \times d_h} \quad (23)$$

$$\mathbf{c} = \text{Linear}_{\text{proj}}(\text{AttnPool}(\mathbf{H})) \in \mathbb{R}^{B \times d_h} \quad (24)$$

$$\mathbf{h} = \gamma \odot \mathbf{c} + \beta \in \mathbb{R}^{B \times d_h} \quad (25)$$


$$\boldsymbol{\ell} = \text{MLP}(\mathbf{h}) \in \mathbb{R}^{B \times K} \quad (26)$$

$$W_{k,b} = \text{softmax}(\boldsymbol{\ell}_b / \tau)_k \in \mathbb{R}^{K \times B} \quad (27)$$

关键特性: γ 和 β 初始化为 0 $\rightarrow$ 训练初期 $\mathbf{h} = \mathbf{0} \rightarrow$ 输出层也零初始化 $\rightarrow$ 初始权重均匀 $1/K$ 。

6 架构 3: MLP Router (MoFMLPRouter)

6.1 数据流图



6.2 张量维度详解

张量	形状	维度含义
— 输入 (与 <i>adaLN Router</i> 相同) —		
$\mathbf{t}$	$(B,)$	raw timestep
$\mathbf{H}$	(B, L, d_{text})	text token 序列
— 中间计算 —		
$\mathbf{t}_h$	(B, d_h)	时间隐表示 (SinusoidalEmb $\rightarrow$ Linear $\rightarrow$ SiLU)
$\mathbf{c}$	(B, d_h)	文本隐表示 (AttnPool $\rightarrow$ c_proj)
$[\mathbf{t}_h; \mathbf{c}]$	$(B, 2d_h)$	拼接 (dim=-1 上 concat)
— MLP (3 层) —		
Layer 1: Linear + SiLU	$(B, 2d_h) \rightarrow (B, d_h)$	压缩维度
Layer 2: Linear + SiLU	$(B, d_h) \rightarrow (B, d_h)$	非线性变换
Layer 3: Linear	$(B, d_h) \rightarrow (B, K)$	输出 logits (零初始化)
$\mathbf{W}$	(K, B)	softmax + transpose

6.3 计算逻辑

$$\mathbf{t}_h = \text{SiLU}(\text{Linear}(\text{SinusoidalEmb}(\mathbf{t}))) \in \mathbb{R}^{B \times d_h} \quad (28)$$

$$\mathbf{c} = \text{Linear}_{\text{proj}}(\text{AttnPool}(\mathbf{H})) \in \mathbb{R}^{B \times d_h} \quad (29)$$

$$\mathbf{h} = [\mathbf{t}_h \parallel \mathbf{c}] \in \mathbb{R}^{B \times 2d_h} \quad (30)$$

$$\boldsymbol{\ell} = \text{MLP}_{3\text{-layer}}(\mathbf{h}) \in \mathbb{R}^{B \times K} \quad (31)$$


$$W_{k,b} = \text{softmax}(\boldsymbol{\ell}_b / \tau)_k \in \mathbb{R}^{K \times B} \quad (32)$$

与 **adaLN** 的区别：时间和文本通过简单拼接而非乘法调制融合。交互能力完全依赖 MLP 隐式学习。

7 五种架构对比


	LUT	LUT-SA	Time Router	adaLN Router	MLP Router
输入	t_{idx}, s	t_{idx}	t	t, H	t, H
输出	(K, B)	(K, B)	(K, B)	(K, B)	(K, B)
参数量 (K=3, T=10, S=3)	90	30	~132K	~1.2M	~1.0M
时间-文本交互	无	无	无 (仅时间)	显式乘法调制	隐式 MLP
Per-source 路由 (mixing)	✓	(边际化)	(边际化)	隐式 (经 prompt)	隐式 (经 prompt)
Per-source 路由 (advantage)	✓	✓	✓	✓	✓
时间 sharpness	任意 (可跳跃)	任意 (可跳跃)	隐式平滑	隐式平滑	隐式平滑
初始化策略	uniform/biased	uniform/biased	零初始化输出	零初始化 + adaLN	零初始化输出
训练 vs 推理 T	必须相等	必须相等	可不同	可不同	可不同
per-prompt 适应	仅按 source 分组	全局共享	全局共享 (按 t)	每个 prompt 独立	每个 prompt 独立
依赖文本编码器	否	否	否	是	是
训练稳定性	极稳定	极稳定	稳定	稳定	稳定

7.1 设计决策树



8 共享组件：AttnPool 详解

adaLN Router 和 MLP Router 共享同一个 Attention Pooling 模块（继承自 **MoFRouterBase**）。其作用是将变长 token 序列压缩为固定维度向量：



Bypass 机制：若模型提供 `pooled_prompt_embeds`（如 SD3.5 的 CLIP pooled output），则跳过 `AttnPool` 直接使用，节省计算。

9 共享组件：Timestep Embedding 详解

两种 Router 共享同一套时间编码：

$$\mathbf{t}_h = \text{SiLU}(\text{Linear}_{d_t \rightarrow d_h}(\text{SinusoidalPosEmb}_{d_t}(\mathbf{t}))) \quad (33)$$

其中 `SinusoidalPosEmb` 使用 `diffusers.models.embeddings.Timesteps`：

$$\text{SinusoidalPosEmb}(t)_i = \begin{cases} \cos(t/10000^{2i/d_t}) & \text{if } i < d_t/2 \\ \sin(t/10000^{2(i-d_t/2)/d_t}) & \text{if } i \geq d_t/2 \end{cases} \quad (34)$$

输入 $\mathbf{t}$ 为 scheduler 原始值（e.g., 0-1000），编码器自动处理不同尺度。

10 输出使用：速度组合

无论使用哪种路由架构，输出权重 $\mathbf{W} \in \mathbb{R}^{K \times B}$ 以相同方式参与速度组合：

$$\bar{v}_b = \sum_{k=1}^K W_{k,b} \cdot v_k(\mathbf{x}_t, t, \mathbf{c})_b, \quad \forall b \in [1, B] \quad (35)$$

实现时通过广播展开：

$$\mathbf{W}_{\text{expanded}} = \text{reshape}(\mathbf{W}, (K, B, 1, 1, 1)) \quad \text{匹配 spatial dims} \quad (36)$$

$$\bar{\mathbf{v}} = \sum_{k=1}^K \mathbf{W}_{\text{expanded}}[k] \odot \mathbf{v}_k \quad \in \mathbb{R}^{B \times C \times H \times W} \quad (37)$$

11 中间维度 d_h 的设计分析

Router 的核心设计参数是中间隐藏维度 d_h 。当前实现选择 $d_h = 256$ ，本节从信息论、优化理论和工程实践三个角度系统分析这一选择的理由，并讨论替代方案。

11.1 问题定义：维度压缩的本质

Router 的计算路径是一个维度压缩流水线：

$$\underbrace{d_{\text{text}}}_{2048} \xrightarrow{\text{c_proj}} \underbrace{d_h}_{?} \xrightarrow{\text{fusion}} d_h \xrightarrow{\text{MLP}} \underbrace{K}_3 \quad (38)$$

输入空间维度为 $d_{\text{text}} = 2048$ (SD3.5 的 CLIP-L[768] $\oplus$ OpenCLIP-G[1280] pooled embedding)，输出仅为 $K = 3$ 个标量。因此 d_h 的选择本质上是在回答：

核心问题

从 2048 维的语义空间中，需要保留多少信息才能做出正确的 3-way 路由决策？

11.2 信息论分析

11.2.1 输出信息量的上界

Router 的输出是一个 K -维 simplex 上的概率向量 (w_1, w_2, w_3) ，其自由度仅为 $K - 1 = 2$ 。考虑 softmax 前的 logit 空间，实际输出的有效维度为 $K = 3$ 个标量（其中一个自由度被归一化消除）。

因此，从信息论角度，路由决策的内在维度极低——仅需区分 K 种 teacher 的相对强度。

11.2.2 条件信息需求

Router 的条件输入有两个维度：

- 时间 t ：编码为 $d_{\text{time}} = 256$ 维正弦向量。但有效信息量远低于此——denoising 过程中只有 10–50 个离散步，且相邻步间路由策略平滑变化。
- 文本 $\mathbf{c}$ ：原始 $d_{\text{text}} = 2048$ 维。但对路由决策有效的信息远小于全部语义信息。路由只需区分“该 prompt 更适合哪个 teacher”——这是一个粗粒度的分类决策，不需要保留细粒度的语义细节。

11.2.3 信息瓶颈视角

从 Information Bottleneck (Tishby et al., 2000) 的视角， d_h 控制了压缩表示 $\mathbf{h}$ 中保留的互信息量 $I(\mathbf{H}; \mathbf{h})$ 。最优的中间表示应当：

$$\min_{p(\mathbf{h}|\mathbf{H})} I(\mathbf{H}; \mathbf{h}) - \beta \cdot I(\mathbf{h}; \mathbf{W}) \quad (39)$$

即在保持对输出 $\mathbf{W}$ 预测能力的同时，最大程度地压缩输入。由于 $\mathbf{W}$ 仅有 2 个自由度，最优 $\mathbf{h}$ 的有效信息量应该很低。

11.3 参数量与过拟合风险分析

11.3.1 训练信号的稀疏性

MoF 的训练信号来源于 RL reward，具有以下特点：

- 每 epoch 仅 $N_{\text{samples}} = 144$ 个样本（典型配置）

- 每个样本提供一个标量 reward (经 advantage normalization 后)
 - 梯度信号经过 NFT/GRPO loss $\rightarrow$ ratio/ -interpolation $\rightarrow$ 多层链式法则, 信噪比较低
- 这意味着可用的有效训练信号约为 ~ 144 scalar/epoch。对比不同 d_h 下的参数量:

d_h	AdaLN 参数量	MLP 参数量	参数/样本比	过拟合风险
64	$\sim 162\text{K}$	$\sim 144\text{K}$	$\sim 1,125:1$	高
128	$\sim 347\text{K}$	$\sim 314\text{K}$	$\sim 2,410:1$	高
256	$\sim 790\text{K}$	$\sim 660\text{K}$	$\sim 5,486:1$	高 (但可控)
512	$\sim 1.97\text{M}$	$\sim 1.75\text{M}$	$\sim 13,680:1$	极高
1024	$\sim 5.5\text{M}$	$\sim 5.0\text{M}$	$\sim 38,200:1$	不可接受

注: 参数/样本比 (params-per-sample ratio) 越高, 过拟合风险越大。经典监督学习中, $\sim 10:1$ 是合理比例。RL 场景的信号更稀疏, 实际有效信息量更低。

11.3.2 为什么 256 仍然可行

尽管参数/样本比极高 ($\sim 5,500:1$), 以下因素使 $d_h = 256$ 仍然稳定:

1. 零初始化: adaLN 调制参数 (γ, β) 和输出层均初始化为零, 确保训练开始时所有 teacher 均匀加权 ($1/K$)。网络只需从 uniform baseline 做微小偏移。
2. **EMA** 平滑: Off-policy 训练使用 EMA 权重采样, 当前权重仅用于 loss 计算。EMA 的时间平均效应抑制了过拟合到单 batch 的噪声。
3. **softmax** 归一化: 输出经过 softmax ($\tau = 1.0$), 将 logit 空间的自由度约束到 simplex 上。即使 MLP 容量很大, 输出空间仍然是 $(K-1)$ -维的。
4. **Gradient clipping**: $\|\nabla\|_{\max} = 1.0$ 配合 $\text{lr} = 10^{-3}$, 每步参数更新幅度极小。
5. 低秩约束: c_proj 将 $2048 \rightarrow 256$ 是一个线性瓶颈, 天然限制了网络可学习的函数族——只能在 256 维子空间中做决策。

11.4 不同 d_h 选择的系统分析

11.4.1 方案 A: $d_h > d_{\text{text}}$ (如 4096, 8192)

含义: 将文本先投射到比原始空间更高的维度。

方面	分析
表达能力	极高。可学习任意复杂的时间-文本交互模式。
过拟合风险	极高 。参数量 $> 20\text{M}$, 远超有效训练信号。
计算开销	显著增加推理延迟。每个 denoising step 的 router forward pass 不可忽略。
适用场景	仅当训练数据极其充足 (如百万级有标签样本) 时才合理。在 RL 训练中完全不适用。

结论: 无实际意义——这相当于用 LLM 级别的网络来预测 3 个数字。

11.4.2 方案 B: $d_h \approx d_{\text{text}}$ (如 1024, 2048)

含义: 保留接近原始文本维度的信息量。

方面	分析
表达能力 过拟合风险 信息效率	充分保留文本语义。可以基于细粒度语义差异做路由。 很高 。 $d_h = 1024$ 时参数量 $\sim 5.5\text{M}$ 。 极低——保留了大量对路由决策无关的语义信息（如句法结构、同义词差异等）。
与 DiT 的对比	SD3/Flux 使用 1536-dim conditioning, 但它们驱动一个 2B 参数的 transformer 生成整幅图像。Router 仅输出 3 个标量——维度应与输出复杂度匹配, 而非输入复杂度。

结论: 对本问题过度参数化。适用于需要精细 prompt 理解的场景（如数百个 teacher 的 dense MoE），但 $K = 3$ 不需要。

11.4.3 方案 C: $d_h \in [384, 512]$ (中等瓶颈)

含义: $2\times-4\times$ 压缩, 保留较多文本信息。

方面	分析
表达能力	可区分较精细的文本类别（如 prompt 中的物体数量、场景复杂度、OCR 内容长度）。
参数量	$d_h = 512$: AdaLN $\sim 1.97\text{M}$, MLP $\sim 1.75\text{M}$ 。约为当前方案的 $2.5\times$ 。
过拟合风险	中高。可能在 144 samples/epoch 的 regime 下需要更强的正则化（dropout, weight decay, 更低 lr）。
学习率需求 潜在优势	可能需要降低到 $\sim 3 \times 10^{-4}$, 减缓训练速度。 若 teacher 专长的边界需要从 prompt 的细粒度语义推断（而非粗粒度类别），更高维度可能有帮助。

结论: 合理的 ablation 候选。当 teacher 数量增加（ $K \geq 5$ ）或 prompt 空间更复杂时值得考虑。

11.4.4 方案 D: $d_h = 256$ (当前选择)

含义: $\sim 8\times$ 压缩, 激进瓶颈。

方面	分析
表达能力	保留文本的粗粒度语义类别信息。可区分”关于物体组合的 prompt”vs”关于美学的 prompt”vs”关于文字的 prompt”。
参数量	AdaLN $\sim 790\text{K}$, MLP $\sim 660\text{K}$ 。训练高效, 单 GPU 可快速迭代。
过拟合风险	中等。零初始化 + EMA + gradient clipping 联合控制。
与 d_{time} 对齐	$d_h = d_{\text{time}} = 256$, 无需额外投射层。Time MLP 的输出直接作为 adaLN 的输入, 架构简洁。
信息效率	高——强制网络学习与路由决策相关的压缩表示, 忽略无关的语义细节。正则化效果类似于信息瓶颈中增大 β 惩罚。

结论: 在 $K = 3$, 144 samples/epoch 的 regime 下是最优平衡点。

11.4.5 方案 E: $d_h < 256$ (如 64, 128)


含义: $16 \times 32 \times$ 压缩。

方面	分析
表达能力	可能不足以表达时间-文本的非线性交互。 $d_h = 64$ 的 adaLN 调制仅有 64 个 (γ, β) 对, 限制了表达力。
欠拟合风险	中高 。若 optimal routing policy 需要 prompt 内容的细粒度区分 (e.g., 同为 OCR 但长短文本需要不同权重), 可能容量不足。
参数量	$d_h = 64$: AdaLN $\sim 162K$, MLP $\sim 144K$ 。接近 LUT 的参数效率。
退化为 LUT	极端情况下 ($d_h \rightarrow 1$), router 退化为“所有 prompt 得到相同权重”, 等价于去掉 per-prompt adaptation。
适用场景	若事前知道路由决策几乎只依赖时间 (所有 prompt 在同一 t 处使用相同权重), 则低 d_h 足矣。

结论: 参数效率最高, 但牺牲了 per-prompt 适应性——正是 router 相比 LUT 的核心优势。仅在 $K = 2$ 或路由策略极简单时考虑。

11.5 维度选择的决定性因素

综合分析, d_h 的选择取决于以下因素的平衡:



11.6 与相关工作中 gating dimension 的对比

系统	d_{input}	d_{hidden}	K	压缩比
MoF Router (ours)	2048	256	3	$8 \times$
Mixtral MoE gate	4096	—(single linear)	8	∞ (无隐层)
Switch Transformer gate	768	—(single linear)	16	∞ (无隐层)
DiT adaLN (SD3)	2048	1536	d_{model}	$1.3 \times$
PixArt- α cross-attn	4096	1152	d_{model}	$3.5 \times$

关键观察:

- **MoE gating** 通常使用单层线性 (无隐层), 因为它们有海量监督信号 (每个 token 都训练 gate) 和大 K (8–128 experts)。压缩通过单一矩阵完成。
- **DiT conditioning** 使用高维隐层 (1536), 因为输出不是 K 个标量, 而是调制整个 transformer block 的所有参数 ($\sim d_{\text{model}}$ 个 γ, β)。

- **MoF Router** 处于中间位置：输出仅 $K = 3$ （比 MoE 的 8–128 少），但需要非线性时间-文本交互（比单层 linear gate 更复杂）。 $d_h = 256$ 是该 regime 的合理折中。

11.7 scaling law 推导： d_h 应如何随 K 和 N 变化

基于以上分析，我们可以给出启发式 scaling 建议：

$$d_h^* \approx C \cdot \sqrt{K \cdot \log N} \quad (40)$$

其中 C 是常数（取决于任务复杂度）， N 为 effective sample size per epoch。

直觉：

- $\sqrt{K}$ 依赖：输出 simplex 维度为 $K-1$ ，但区分 K 个 teacher 需要 $O(\sqrt{K})$ 的表达力增长（类似 random projection 的 Johnson–Lindenstrauss 维度）。
- $\log N$ 依赖：可用样本量翻倍时，过拟合风险降低，可适度增加容量。但收益是对数级的——即使样本增加 10 倍， d_h 也只需微增。

对于当前设置（ $K = 3, N = 144$ ）：

$$d_h^* \approx C \cdot \sqrt{3 \cdot \log 144} \approx C \cdot \sqrt{3 \times 4.97} \approx 3.86 \cdot C \quad (41)$$

取 $C \approx 66$ （基于经验校准）得 $d_h^* \approx 256$ ，与我们的选择一致。

11.8 消融实验指导

基于以上分析，推荐以下消融方向：

实验	动机	预期结果
$d_h = 128$ vs 256 vs 512	验证瓶颈效应	128 可能略欠拟合（OCR 识别边界 case），512 可能训练不稳定
去掉 MLP 隐层（ $d_h \rightarrow K$ ）	测试是否需要非线性	类似 MoE linear gate。若性能接近则说明路由函数接近线性
$K = 5$ 时增大 d_h	验证 $\sqrt{K}$ scaling	K 从 3 增到 5 时， d_h 从 256 增到 ~ 330 应有帮助
增大 N (800 samples/epoch)	验证 $\log N$ scaling	更多样本应允许更大 d_h 而不过拟合

11.9 结论：为什么 $d_h = 256$ 是当前最优选择

设计总结

1. 输出复杂度匹配： $K = 3$ 个输出仅需极低的信息量， $d_h = 256$ 提供了充足但不冗余的中间表示容量。
2. 训练信号适配：144 samples/epoch 的稀疏 RL 信号无法支撑更大网络。 $\sim 790K$ 参数在零初始化 + EMA + grad clip 的约束下可稳定训练。
3. 架构对齐： $d_h = d_{\text{time}} = 256$ 使 time embedding 和 text projection 在同一维度空间，无需额外对齐层。
4. 计算效率：Router 在每个 denoising step 调用一次。 $d_h = 256$ 的 forward pass $< 0.1\text{ms}$ （单 GPU），相比 teacher forward（ $\sim 50\text{ms}$ ）可忽略。
5. 信息瓶颈正则化：激进的 $8\times$ 压缩迫使网络只保留与路由决策相关的信息，隐式实现了正则化效果。

推荐变更条件：

- 若 K 增加到 5–10：考虑 $d_h = 384$ –512。
- 若从 RL 切换到 supervised distillation（充足标签）：可增到 $d_h = 512$ –1024。
- 若 d_{text} 变化（如 T5-XXL 的 4096）：保持 $\sim 8\times$ – $16\times$ 压缩比，即 $d_h = 256$ –512。
- 若路由策略已知为几乎纯时间依赖（所有 prompt 类似）：可降至 $d_h = 128$ 或直接用 LUT。