

MoF 路由网络架构数据流分析

LUT · adaLN Router · MLP Router

Flow Factory

1 概述


MoF (Mixture-of-Flow) 使用一个路由模块来预测每个 denoising step 中各 teacher 的混合权重。系统实现了三种路由架构，共享相同的外部接口：

架构	配置名	核心思想
离散查找表 (LUT)	lut	固定 (K, T, S) 参数，按 index 查表
adaLN Router	adaln_router	时间调制文本，类 DiT 的 adaLN 模式
MLP Router	mlp_router	拼接时间 + 文本，简单 MLP 预测

统一输出：所有架构输出 $\mathbf{W} \in \mathbb{R}^{K \times B}$ ，其中 K = teacher 数量， B = batch size，每列归一化 $\sum_k W_{k,b} = 1$ 。

2 架构 1：离散查找表 (MoFMixingModule)

2.1 数据流图



2.2 张量维度详解

张量	形状	维度含义
$\mathbf{\Lambda}$ (logits)	(K, T, S)	K : teacher 数量 (e.g., 3) T : denoising 总步数 (e.g., 10) S : prompt source 集合数 (e.g., 3 for geneval/pickscore/ocr)
t_{idx}	scalar $\in [0, T-1]$	当前 denoising step 的整数索引
$\mathbf{s}$ (set_ids)	$(B,)$	每个样本对应的 source 集合 ID
$\mathbf{\Lambda}[:, t_{\text{idx}}, :]$	(K, S)	当前 step 下所有 teacher $\times$ 所有 source 的 logits
$\mathbf{\Lambda}[:, t_{\text{idx}}, \mathbf{s}]$	(K, B)	每样本取对应 source 的 logits (advanced indexing)
$\mathbf{W}$	(K, B)	softmax 归一化后的权重, $\sum_k W_{k,b} = 1$


2.3 计算逻辑

$$W_{k,b} = \frac{\exp(\Lambda_{k,t_{\text{idx}},s_b}/\tau)}{\sum_{k'=1}^K \exp(\Lambda_{k',t_{\text{idx}},s_b}/\tau)} \quad (1)$$

特点：无神经网络计算，纯查表 + softmax。 $K \times T \times S$ 个可学习参数。

3 架构 2: adaLN Router (MoFAdaLNRouter)

3.1 数据流图



3.2 张量维度详解

张量	形状	维度含义
— 输入 —		
$\mathbf{t}$	$(B,)$	每样本的 raw timestep 值 (e.g., 0–1000)
$\mathbf{H}$ (prompt_embeds)	(B, L, d_{text})	B : batch size L : token 序列长度 (e.g., 77–512) d_{text} : text encoder hidden dim (e.g., 4096)
$\mathbf{H}_{\text{pool}}$ (可选)	(B, d_{pool})	pooled text embedding (SD3: 2048)。若提供则跳过 AttnPool
— Time Branch —		
SinusoidalEmb($\mathbf{t}$)	(B, d_t)	正弦位置编码 ($d_t=256$)
$\mathbf{t}_h = \text{Linear} + \text{SiLU}$	(B, d_h)	时间隐表示 ($d_h=256$)
adaLN output	$(B, 2d_h)$	Linear 映射后的 γ, β 拼接
γ, β	各 (B, d_h)	adaLN 调制参数 (初始化为 0)
— Text Branch —		
$\mathbf{q}$ (attn_query)	$(1, 1, d_{\text{text}})$	Learnable attention query (初始化 $\sim \mathcal{N}(0, 0.02)$)
attn scores	$(B, 1, L)$	$\mathbf{q} \cdot \mathbf{H}^\top / \sqrt{d_{\text{text}}}$
attn weights	$(B, 1, L)$	softmax over L dimension
$\mathbf{c}_{\text{pooled}}$	(B, d_{text})	Weighted sum of tokens
$\mathbf{c} = \mathbf{c}_{\text{proj}}$	(B, d_h)	投射到隐层维度
— Fusion + Output —		
$\mathbf{h} = \gamma \odot \mathbf{c} + \beta$	(B, d_h)	时间调制后的融合表示
MLP output (logits)	(B, K)	K 个 teacher 的 unnormalized logits
$\mathbf{W}$ (output)	(K, B)	softmax 后 transpose, $\sum_k W_{k,b} = 1$

3.3 计算逻辑

$$\mathbf{t}_h = \text{SiLU}(\text{Linear}(\text{SinusoidalEmb}(\mathbf{t}))) \in \mathbb{R}^{B \times d_h} \quad (2)$$

$$(\gamma, \beta) = \text{chunk}(\text{Linear}_{\text{adaLN}}(\mathbf{t}_h), 2) \quad \text{各} \in \mathbb{R}^{B \times d_h} \quad (3)$$

$$\mathbf{c} = \text{Linear}_{\text{proj}}(\text{AttnPool}(\mathbf{H})) \in \mathbb{R}^{B \times d_h} \quad (4)$$

$$\mathbf{h} = \gamma \odot \mathbf{c} + \beta \in \mathbb{R}^{B \times d_h} \quad (5)$$


$$\boldsymbol{\ell} = \text{MLP}(\mathbf{h}) \in \mathbb{R}^{B \times K} \quad (6)$$

$$W_{k,b} = \text{softmax}(\boldsymbol{\ell}_b / \tau)_k \in \mathbb{R}^{K \times B} \quad (7)$$

关键特性: γ 和 β 初始化为 0 $\rightarrow$ 训练初期 $\mathbf{h} = \mathbf{0} \rightarrow$ 输出层也零初始化 $\rightarrow$ 初始权重均匀 $1/K$ 。

4 架构 3: MLP Router (MoFMLPRouter)

4.1 数据流图



4.2 张量维度详解

张量	形状	维度含义
— 输入 (与 <i>adaLN Router</i> 相同) —		
t	$(B,)$	raw timestep
H	(B, L, d_{text})	text token 序列
— 中间计算 —		
t_h	(B, d_h)	时间隐表示 (SinusoidalEmb → Linear → SiLU)
c	(B, d_h)	文本隐表示 (AttnPool → c_proj)
[t_h; c]	$(B, 2d_h)$	拼接 (dim=-1 上 concat)
— <i>MLP</i> (3 层) —		
Layer 1: Linear + SiLU	$(B, 2d_h) \rightarrow (B, d_h)$	压缩维度
Layer 2: Linear + SiLU	$(B, d_h) \rightarrow (B, d_h)$	非线性变换
Layer 3: Linear	$(B, d_h) \rightarrow (B, K)$	输出 logits (零初始化)
W	(K, B)	softmax + transpose

4.3 计算逻辑

$$\mathbf{t}_h = \text{SiLU}(\text{Linear}(\text{SinusoidalEmb}(\mathbf{t}))) \in \mathbb{R}^{B \times d_h} \quad (8)$$

$$\mathbf{c} = \text{Linear}_{\text{proj}}(\text{AttnPool}(\mathbf{H})) \in \mathbb{R}^{B \times d_h} \quad (9)$$

$$\mathbf{h} = [\mathbf{t}_h \parallel \mathbf{c}] \in \mathbb{R}^{B \times 2d_h} \quad (10)$$

$$\boldsymbol{\ell} = \text{MLP}_{3\text{-layer}}(\mathbf{h}) \in \mathbb{R}^{B \times K} \quad (11)$$

$$W_{k,b} = \text{softmax}(\boldsymbol{\ell}_b / \tau)_k \in \mathbb{R}^{K \times B} \quad (12)$$


与 **adaLN** 的区别：时间和文本通过简单拼接而非乘法调制融合。交互能力完全依赖 MLP 隐式学习。

5 三种架构对比

	LUT	adaLN Router	MLP Router
输入	$t_{\text{idx}}, \mathbf{s}$ (整数)	$\mathbf{t}, \mathbf{H}$ (连续)	$\mathbf{t}, \mathbf{H}$ (连续)
输出	(K, B)	(K, B)	(K, B)
参数量 (K=3, T=10, S=3)	90	~1.2M	~1.0M
时间-文本交互	无 (独立查表)	显式乘法调制	隐式 MLP
泛化能力	无 (仅记忆)	强 (连续插值)	中 (依赖 MLP 容量)
初始化策略	uniform/biased	零初始化输出 + adaLN	零初始化输出
推理步数依赖	绑定 T	任意步数	任意步数
per-prompt 适应	仅按 source 分组	每个 prompt 独立	每个 prompt 独立
训练稳定性	极稳定	稳定 (零初始化保证)	稳定

6 共享组件：AttnPool 详解

adaLN Router 和 MLP Router 共享同一个 Attention Pooling 模块 (继承自 **MoFRouterBase**)。其作用是将变长 token 序列压缩为固定维度向量：



Bypass 机制：若模型提供 `pooled_prompt_embeds` (如 SD3.5 的 CLIP pooled output)，则跳过 AttnPool 直接使用，节省计算。

7 共享组件：Timestep Embedding 详解

两种 Router 共享同一套时间编码：

$$\mathbf{t}_h = \text{SiLU}(\text{Linear}_{d_t \rightarrow d_h}(\text{SinusoidalPosEmb}_{d_t}(\mathbf{t}))) \quad (13)$$

其中 SinusoidalPosEmb 使用 `diffusers.models.embeddings.Timesteps`：

$$\text{SinusoidalPosEmb}(t)_i = \begin{cases} \cos(t/10000^{2i/d_t}) & \text{if } i < d_t/2 \\ \sin(t/10000^{2(i-d_t/2)/d_t}) & \text{if } i \geq d_t/2 \end{cases} \quad (14)$$

输入 $\mathbf{t}$ 为 scheduler 原始值 (e.g., 0–1000)，编码器自动处理不同尺度。

8 输出使用：速度组合

无论使用哪种路由架构，输出权重 $\mathbf{W} \in \mathbb{R}^{K \times B}$ 以相同方式参与速度组合：

$$\bar{v}_b = \sum_{k=1}^K W_{k,b} \cdot v_k(\mathbf{x}_t, t, \mathbf{c})_b, \quad \forall b \in [1, B] \quad (15)$$

实现时通过广播展开：

$$\mathbf{W}_{\text{expanded}} = \text{reshape}(\mathbf{W}, (K, B, 1, 1, 1)) \quad \text{匹配 spatial dims} \quad (16)$$

$$\bar{\mathbf{v}} = \sum_{k=1}^K \mathbf{W}_{\text{expanded}}[k] \odot \mathbf{v}_k \quad \in \mathbb{R}^{B \times C \times H \times W} \quad (17)$$