

MoF→Distill 与直接 Multi-Teacher OPD 的范式 Gap 分析

两种 Multi-Teacher 蒸馏路线的形式化对比与理论 Gap 推导

Flow Factory

Abstract

本文严格对比两种 Multi-Teacher 蒸馏范式：**Paradigm A** (MoF→Distill) 先用可学习的混合权重把 K 个 teacher 融合为单个虚拟 teacher v^{MoF^*} ，再把后者直接蒸馏到 student；**Paradigm B** (route-by-source OPD) 则在每个 data source 上用对应的 in-domain teacher 直接监督 student。两者最终都得到一个 student LoRA，但其最优 *target* 函数、搜索空间、*reward landscape* 均不同。本文给出：(1) 两个范式的形式化定义与最优解刻画；(2) target velocity field 的精确 gap 公式 $\Delta v = \sum_{k \neq s(c)} \lambda_k^* (v^{(k)} - v^{(s(c))})$ ；(3) 一阶 reward gap 推导（沿 ODE 轨迹的功能性导数）；(4) 搜索空间的严格包含关系 $\mathcal{T}_B \subsetneq \mathcal{T}_A$ ；(5) in-domain 与 OOD 上 gap 的符号分析（in-domain $A \geq B$ 由 Level-1 保证；OOD 符号由复合优化方向决定）；(6) 蒸馏 gap 的二阶差异（ T_A 在 c 上连续平滑、 T_B 在 source 边界处不连续）；(7) 三种边界情形（degenerate $\rightarrow A = B$ 、generic $\rightarrow A \neq B$ 、temporal complementarity $\rightarrow A > B$ ）的精确条件。

核心结论：Paradigm A 是 Paradigm B 的严格泛化——B 的 target 函数集合严格包含于 A 的 target 函数集合，所以 A 的 reward 上限不低于 B。但实际获得的 reward 取决于 Stage 1 RL 优化质量与 Stage 2 蒸馏 gap，存在三类型抹消情形。最有可能让 $A > B$ 严格成立的场景是 时间互补性（不同 timestep 上不同 teacher 各有所长）。

Contents

1	引言	2
1.1	两种范式的高层对比	2
1.2	本文的贡献结构	2
2	形式化	2
2.1	符号与 reward functional	2
2.2	Paradigm A 的形式化	3
2.3	Paradigm B 的形式化	3
2.4	对照表	3
3	Target Velocity Field 的精确 Gap	4
3.1	命题：target gap 公式	4
3.2	解读：gap 的几何意义	4
3.3	Δv 的范数估计	4
4	搜索空间的严格包含关系	5
4.1	两个范式可表达的 target 函数类	5
4.2	Reward 上界的对应包含	5
4.3	但 reward 上界 $\neq$ 实际获得的 reward	5

5	Reward Gap 的一阶推导	5
5.1	ODE 解关于 velocity 的功能性导数	5
5.2	主定理: reward gap 一阶展开	6
5.3	解读: gap 的三个因素	6
5.4	二次项与全局误差	6
5.5	Δv 与 Stage 1 KKT 条件的关联	6
6	In-domain vs. OOD 上 Gap 的差异化分析	7
6.1	In-domain: Level-1 保证下 $A \geq B$	7
6.2	OOD: 符号依赖于 Stage 1 优化方向	7
6.3	对比表: A vs. B 的预期 gap	7
7	蒸馏 Gap 的二阶差异	8
7.1	Target 函数的连续性差异	8
7.2	Capacity gap 的对比	8
7.3	两种典型情形分析	8
7.4	Distillation 残差对 reward 的影响	8
7.5	Erosion 风险对比	9
8	三种边界情形与精确条件	9
8.1	情形 I: $A = B$ (Stage 1 退化)	9
8.2	情形 II: $A \neq B$ 但 reward 持平 (generic 偏移)	9
8.3	情形 III: $A > B$ (时间互补性 + Stage 1 找到正向 mixing)	10
8.4	情形 IV: $A < B$ (罕见但可能)	10
9	综合 Gap 公式与决策树	10
9.1	综合 reward gap 公式	10
9.2	决策树: 何时选 A, 何时选 B	11
9.3	综合结论	11
9.4	开放问题	12
A	Adjoint Sensitivity 的精确计算	12
B	与已有 docs 的关系	12

1 引言

1.1 两种范式的高层对比

我们已有 K 个 specialized 扩散 teacher $\{v^{(k)}\}_{k=1}^K$ (典型如 GenEval / OCR / PickScore), 各自在自己的 prompt set $\mathcal{P}_s$ 上训练。目标是蒸馏出单个 student v^θ 。两种范式分别如下。

Paradigm A: MoF→Distill (本工作)

Stage 1: 在小型混合参数空间 ψ 上做 RL, 找出最优的混合权重 $\lambda_k(t, s, c; \psi^*)$, 构造 router-induced teacher

$$v^{\text{MoF}^*}(x, t, c) = \sum_{k=1}^K \lambda_k(t, s(c), c; \psi^*) v^{(k)}(x, t, c).$$

Stage 2: 用纯 pathwise MSE 把 v^{MoF^*} 蒸馏到 student v^θ 。

Paradigm B: 直接 multi-teacher OPD (route-by-source, OPDTrainer)

单阶段: 对每个 prompt $p \in \mathcal{P}_s$, 让 student 直接拟合对应 in-domain teacher $v^{(s)}$:

$$\mathcal{L}_B(\theta) = \sum_{s=1}^S \pi_s \mathbb{E}_{p \in \mathcal{P}_s, (x_t, t) \sim q_\theta} [\|v^\theta(x_t, t, c_p) - v^{(s)}(x_t, t, c_p)\|^2].$$

核心问题: 这两个范式得到的 student 在 in-domain / OOD reward 上能差多少? 这个 gap 由什么因素决定?

1.2 本文的贡献结构

1. §2: 两个范式的精确形式化与各自的最优解刻画。
2. §3: target velocity field 的精确 gap 公式 (命题 1)。
3. §4: 搜索空间的严格包含关系 $\mathcal{T}_B \subsetneq \mathcal{T}_A$ (命题 2)。
4. §5: reward gap 的一阶推导 (定理 1)。
5. §6: in-domain (A 不劣于 B) 与 OOD (符号依赖) 的差异化分析。
6. §7: 蒸馏 gap 的二阶差异 (连续平滑 vs. 源边界跳变)。
7. §8: 三种边界情形与 $A \gtrsim B$ 的精确条件。

2 形式化

2.1 符号与 reward functional

记 prompt set $\{\mathcal{P}_s\}_{s=1}^S$, source 频率 $\pi_s = \Pr(p \in \mathcal{P}_s)$, prompt p 的 source 标签 $s(p)$, prompt embedding c_p 。Teacher 集合 $\{v^{(k)}(x, t, c)\}_{k=1}^K$ 全部冻结。Reward 集合 $\{R_j\}_{j=1}^J$ 。

为简化 notation, 把 $f_j^{(s)}(\lambda)$ 定义为: 在使用混合参数 λ (关于 t, s, c 的函数) 生成轨迹时, prompt set $\mathcal{P}_s$ 上的 reward R_j 期望:

$$f_j^{(s)}(\lambda) \triangleq \mathbb{E}_{p \sim \mathcal{P}_s, x_T \sim \mathcal{N}(0, I)} [R_j(\text{ODE}(v_\lambda; x_T, p))]. \quad (1)$$

对单 teacher, $f_j^{(s)}(v^{(k)}) := \mathbb{E}_p [R_j(\text{ODE}(v^{(k)}; x_T, p))]$ 。

2.2 Paradigm A 的形式化

定义 1 (Paradigm A: MoF→Distill). **Stage 1** (在 mixing 参数 ψ 上优化复合 reward):

$$\psi^* = \arg \max_{\psi} \mathbb{E}_p \left[F^{(s(p))}(\lambda(\cdot; \psi)) \right], \quad F^{(s)}(\lambda) = f_s^{(s)}(\lambda) + \gamma \frac{1}{|\mathcal{R}_{\text{OOD}}^{(s)}|} \sum_{j \in \mathcal{R}_{\text{OOD}}^{(s)}} f_j^{(s)}(\lambda). \quad (2)$$

定义 **router-induced teacher**

$$T_A(x, t, c) \triangleq v^{\text{MoF}^*}(x, t, c) = \sum_{k=1}^K \lambda_k(t, s(c), c; \psi^*) v^{(k)}(x, t, c). \quad (3)$$

Stage 2 (直接 pathwise MSE 蒸馏):

$$\theta_A^* = \arg \min_{\theta} \mathbb{E}_{p, (x_t, t) \sim q_{\theta}} \left[\|v^{\theta}(x_t, t, c_p) - T_A(x_t, t, c_p)\|_2^2 \right]. \quad (4)$$

Stage 2 最优解 (在 student 容量足够、训练充分的理想假设下):

$$v^{\theta_A^*}(x, t, c) = T_A(x, t, c) - \xi_A(x, t, c), \quad (5)$$

其中 ξ_A 是蒸馏残差 (capacity gap + on-policy distribution shift), $\mathbb{E}_{q_{\theta}}[\|\xi_A\|^2]$ 在理想条件下趋零。

2.3 Paradigm B 的形式化

定义 2 (Paradigm B: route-by-source OPD). 单阶段优化:

$$\theta_B^* = \arg \min_{\theta} \sum_{s=1}^S \pi_s \mathbb{E}_{p \in \mathcal{P}_s, (x_t, t) \sim q_{\theta}} \left[\|v^{\theta}(x_t, t, c_p) - v^{(s)}(x_t, t, c_p)\|_2^2 \right]. \quad (6)$$

等价地, 定义 **routing target**

$$T_B(x, t, c) \triangleq v^{(s(c))}(x, t, c), \quad (7)$$

则 $\mathcal{L}_B(\theta) = \mathbb{E}_{(x_t, t, c)} [\|v^{\theta} - T_B\|^2]$, 最优解

$$v^{\theta_B^*}(x, t, c) = T_B(x, t, c) - \xi_B(x, t, c), \quad (8)$$

ξ_B 为对应的蒸馏残差。

2.4 对照表

维度	Paradigm A (MoF→Distill)	Paradigm B (route-by-source OPD)
阶段数	两阶段 (RL + 蒸馏)	单阶段 (仅蒸馏)
可学习参数	Stage 1: $\psi \in \mathbb{R}^{ \psi }$ ($\sim 10^2$ – 10^6) Stage 2: $\theta \in \mathbb{R}^{ \theta }$ (LoRA)	$\theta \in \mathbb{R}^{ \theta }$ (LoRA)
Target 函数 $T(x, t, c)$	$\sum_k \lambda_k^*(t, s(c), c) v^{(k)}$	$v^{(s(c))}$
Target 在 c 上连续性	平滑 (router 输出连续函数)	在 source 边界不连续
Target 关于 reward	Stage 1 优化得到	固定 (直接由 source 决定)
Reward 上界	$\sup_{\psi} F^{(s)}(\lambda(\psi))$	$f_s^{(s)}(v^{(s)})$
能否超越 single teacher	可以 (条件性, 见 §8)	不能

3 Target Velocity Field 的精确 Gap

3.1 命题：target gap 公式

命题 1 (Target velocity field gap). 对任意 (x, t, c) 三元组 (c 来自 source $s = s(c)$):

$$\Delta v(x, t, c) \triangleq T_A(x, t, c) - T_B(x, t, c) = \sum_{k \neq s} \lambda_k^*(t, s, c) [v^{(k)}(x, t, c) - v^{(s)}(x, t, c)]. \quad (9)$$

Proof.

$$\Delta v = T_A - T_B = \sum_{k=1}^K \lambda_k^* v^{(k)} - v^{(s)} \quad (10)$$

$$= \lambda_s^* v^{(s)} + \sum_{k \neq s} \lambda_k^* v^{(k)} - v^{(s)} \quad (11)$$

$$= (\lambda_s^* - 1) v^{(s)} + \sum_{k \neq s} \lambda_k^* v^{(k)} \quad (12)$$

$$\stackrel{(*)}{=} - \sum_{k \neq s} \lambda_k^* v^{(s)} + \sum_{k \neq s} \lambda_k^* v^{(k)} \quad (13)$$

$$= \sum_{k \neq s} \lambda_k^* (v^{(k)} - v^{(s)}), \quad (14)$$

其中 $(*)$ 用了归一化约束 $\sum_k \lambda_k^* = 1 \Rightarrow \lambda_s^* - 1 = - \sum_{k \neq s} \lambda_k^*$. □ □

3.2 解读：gap 的几何意义

- Δv 是 $K - 1$ 个”OOD 方向” $\{v^{(k)} - v^{(s)}\}_{k \neq s}$ 的非负加权和中，权重为 λ_k^* 。
- 当 $\lambda_s^*(t, s, c) = 1$ (即 mixing 退化为 in-domain teacher): $\Delta v = 0$, 两个范式 target 完全一致。
- 当 $\lambda_s^* < 1$ (mixing 引入了至少一个其他 teacher): Δv 沿”远离 in-domain teacher”的方向偏移。
- 偏移方向由 Stage 1 的复合 reward 优化决定——这是 A 与 B 的所有后续差异的根源。

LoRA-shared-base 简化: 若 teacher 都是同一 base 上的 LoRA ($v^{(k)} = v_{\text{base}} + \delta^{(k)}$), 则

$$\Delta v = \sum_{k \neq s} \lambda_k^* (\delta^{(k)} - \delta^{(s)}), \quad (15)$$

即 Δv 是 LoRA residual 之间 difference 的混合, v_{base} 被消去。

3.3 Δv 的范数估计

由 Cauchy-Schwarz:

$$\|\Delta v\| \leq \sum_{k \neq s} \lambda_k^* \|v^{(k)} - v^{(s)}\| \leq (1 - \lambda_s^*) \max_{k \neq s} \|v^{(k)} - v^{(s)}\|. \quad (16)$$

记 $D_s := \max_{k \neq s} \|v^{(k)} - v^{(s)}\|_{L^2(p_t \times c)}$ 为”在 source s 视角下, 其他 teacher 与 in-domain teacher 的最大距离”。则

$$\|\Delta v\|_{L^2} \leq (1 - \mathbb{E}[\lambda_s^*]) D_s. \quad (17)$$

含义: 当 $\lambda_s^* \rightarrow 1$ (mixing 几乎不偏离 in-domain teacher) 时, 两范式 target 几乎相同; 只有当 λ_s^* 显著小于 1 时, A 与 B 才有实质差异。

4 搜索空间的严格包含关系

4.1 两个范式可表达的 **target** 函数类

定义 3 (Paradigm B 的 target 函数类).

$$\mathcal{T}_B \triangleq \{T : T(x, t, c) = v^{(s(c))}(x, t, c)\}. \quad (18)$$

(仅一个函数, 由 source mapping 唯一确定.)

扩展 (允许任意 source-to-teacher 映射 $r : \{1, \dots, S\} \rightarrow \{1, \dots, K\}$):

$$\mathcal{T}_B^{\text{ext}} \triangleq \{T_r : T_r(x, t, c) = v^{(r(s(c)))}(x, t, c), r : \{1, \dots, S\} \rightarrow \{1, \dots, K\}\}. \quad (19)$$

$|\mathcal{T}_B^{\text{ext}}| = K^S$ (有限离散集)。

定义 4 (Paradigm A 的 target 函数类).

$$\mathcal{T}_A \triangleq \left\{T : T(x, t, c) = \sum_{k=1}^K \lambda_k(t, s(c), c) v^{(k)}(x, t, c), \lambda_k \geq 0, \sum_k \lambda_k = 1\right\}. \quad (20)$$

(每个时空-prompt 点上的混合系数都可独立选择, 是无穷大的函数空间。)

命题 2 (严格包含). $\mathcal{T}_B^{\text{ext}} \subsetneq \mathcal{T}_A$ 。

Proof. 对任意 $T_r \in \mathcal{T}_B^{\text{ext}}$, 取 $\lambda_k(t, s, c) = \mathbb{I}[k = r(s)]$ (单纯形顶点 one-hot), 即可得 $T_r \in \mathcal{T}_A$ 。反之, 对任意非 one-hot 的 λ (如 $\lambda = (1/K, \dots, 1/K)$), 对应的 $T \in \mathcal{T}_A \setminus \mathcal{T}_B^{\text{ext}}$ 。 $\square$ $\square$

4.2 Reward 上界的对应包含

推论 1 (Reward 上界包含). 对任意 prompt set $\mathcal{P}_s$ 和任意 reward R_j :

$$\sup_{T \in \mathcal{T}_A} f_j^{(s)}(T) \geq \sup_{T \in \mathcal{T}_B^{\text{ext}}} f_j^{(s)}(T) = \max_k f_j^{(s)}(v^{(k)}). \quad (21)$$

直接含义: A 的最优 target 在任意 reward 上至少不劣于 B 的 (best routing) 最优 target。这是 A 相对 B 的结构性优势的来源。

何时严格不等: 当存在某个 λ^{int} (interior 而非 vertex) 使 $f_j^{(s)}(\lambda^{\text{int}}) > \max_k f_j^{(s)}(v^{(k)})$ 时, 严格不等成立。这正是时间互补性假设 (`mof_ood_guarantee_analysis.tex` 条件 A)。

4.3 但 reward 上界 $\neq$ 实际获得的 reward

重要警告: Corollary 1 只说搜索空间扩大不会让上界变小, 但并不说 *Stage 1 RL* 优化必然能找到这个上界。Stage 1 优化的是复合 reward $F^{(s)} = f_s + \gamma \bar{f}_{\text{OOD}}$, 而非单一 reward R_j 。因此 ψ^* 给出的 T_A 在某个具体 OOD reward R_j 上可能劣于 $\max_k f_j^{(s)}(v^{(k)})$ (正是 `mof_ood_guarantee_analysis.tex` 的负面定理)。

5 Reward Gap 的一阶推导

5.1 ODE 解关于 velocity 的功能性导数

固定 prompt p 和 noise x_T 。记 $\phi_v(t)$ 为 velocity field v 下 ODE $\dot{x}(\tau) = v(x(\tau), \tau, c_p)$ 从 x_T 出发到时刻 t 的解。最终图像 $x_0 = \phi_v(0)$ 。Reward 函数 $R_j(x_0)$ 。

定义 **adjoint state** (reward 关于 velocity 的功能性导数):

$$G_j(\tau, x; v) \triangleq \left. \frac{\delta R_j(\phi_v(0))}{\delta v(\cdot, \tau, c_p)} \right|_{\phi_v(\tau)=x}. \quad (22)$$

由变分原理, 对 velocity 的小扰动 $v \rightarrow v + \epsilon \Delta v$:

$$R_j(\phi_{v+\epsilon \Delta v}(0)) - R_j(\phi_v(0)) = \epsilon \int_T^0 \langle G_j(\tau, \phi_v(\tau); v), \Delta v(\phi_v(\tau), \tau, c_p) \rangle d\tau + O(\epsilon^2). \quad (23)$$

5.2 主定理：reward gap 一阶展开

定理 1 (Reward Gap First-Order). 设 $T_A = T_B + \Delta v$, 其中 Δv 由命题 1 给出。在 $\|\Delta v\|$ 足够小的范围内,

$$R_j^{(s)}(T_A) - R_j^{(s)}(T_B) \approx \mathbb{E}_{p \in \mathcal{P}_s, x_T} \left[\int_T^0 \sum_{k \neq s} \lambda_k^*(\tau, s, c_p) \langle G_j(\tau, \phi_B(\tau); T_B), v^{(k)} - v^{(s)} \rangle d\tau \right], \quad (24)$$

其中 $\phi_B(\tau)$ 是 Paradigm B 在 prompt p 上的 ODE 轨迹。

Proof. 直接代入命题 1 的 $\Delta v = \sum_{k \neq s} \lambda_k^*(v^{(k)} - v^{(s)})$ 到 (23), 并取对 p 与 x_T 的期望即可。 $\square$

5.3 解读：gap 的三个因素

公式 (24) 中每个 (t, k) pair 的贡献由三因素决定:

1. 混合权重 $\lambda_k^*(\tau, s, c_p)$: Stage 1 优化决定。若 $\lambda_k^* = 0$, 该 teacher 完全不贡献到 gap。
2. **Reward sensitivity** $G_j(\tau, \phi_B(\tau); T_B)$: reward R_j 对 timestep τ 处 velocity 扰动的灵敏度 (adjoint)。
3. **Teacher** 偏移方向 $v^{(k)} - v^{(s)}$: teacher k 与 in-domain teacher 在 velocity 空间的差异方向。符号决定因素: 内积 $\langle G_j, v^{(k)} - v^{(s)} \rangle$ 的符号决定该 (t, k) pair 对 gap 的贡献是正是负。
 - 若 teacher k 的 velocity 偏移方向与”提升 R_j 的方向”对齐 ($\langle G_j, v^{(k)} - v^{(s)} \rangle > 0$): A 在 R_j 上比 B 好。
 - 若反向 ($\langle G_j, v^{(k)} - v^{(s)} \rangle < 0$): A 在 R_j 上比 B 差。
 - 若正交: 无贡献。

5.4 二次项与全局误差

定理 1 是一阶近似。完整 reward gap 为:

$$\Delta R_j^{(s)} = \underbrace{R_j^{(s)}(T_A) - R_j^{(s)}(T_B)}_{\text{linear}} + \underbrace{O(\|\Delta v\|^2)}_{\text{nonlinear}}. \quad (25)$$

二次项可能 dominant 当 $\|\Delta v\|$ 较大时。但由 (17), $\|\Delta v\| \leq (1 - \lambda_s^*)D_s$, 所以当 λ_s^* 接近 1 (A 几乎不偏离 B) 时, 一阶近似精确。

5.5 Δv 与 Stage 1 KKT 条件的关联

Stage 1 的 KKT 条件 ($\psi^* = \arg \max F^{(s)}$) 为:

$$\nabla_{\psi} f_s^{(s)}(\lambda(\psi^*)) + \frac{\gamma}{|\mathcal{R}_{\text{OOD}}^{(s)}|} \sum_{j \in \mathcal{R}_{\text{OOD}}^{(s)}} \nabla_{\psi} f_j^{(s)}(\lambda(\psi^*)) = 0. \quad (26)$$

利用功能性导数链式法则

$$\nabla_{\psi} f_j^{(s)} = \mathbb{E}_{p, \tau} [\langle G_j(\tau; v_{\psi}), \nabla_{\psi} v_{\psi}(\tau) \rangle], \quad (27)$$

代入 (26) 后整理可得:

$$\mathbb{E}_{p, \tau, k} \left[\nabla_{\psi} \lambda_k \left\{ \langle G_s, v^{(k)} - \bar{v} \rangle + \frac{\gamma}{|\mathcal{R}_{\text{OOD}}|} \sum_{j \in \mathcal{R}_{\text{OOD}}} \langle G_j, v^{(k)} - \bar{v} \rangle \right\} \right] = 0. \quad (28)$$

KKT 含义: 在 ψ^* 处, 每个 teacher 的 in-domain 投影 $\langle G_s, v^{(k)} - \bar{v} \rangle$ 与 OOD 投影 $\langle G_j, v^{(k)} - \bar{v} \rangle$ 按 γ 加权后总和为零 (在 $\nabla_{\psi} \lambda_k$ 的方向上)。这就是所有 reward 信号在 Stage 1 平衡的精确条件。

6 In-domain vs. OOD 上 Gap 的差异化分析

6.1 In-domain: Level-1 保证下 $A \geq B$

定理 2 (In-domain reward 不弱于 B). 对任意 source s ,

$$f_s^{(s)}(T_A) \geq f_s^{(s)}(T_B) - \gamma \cdot |\Delta_{\text{OOD}}|, \quad (29)$$

其中 $|\Delta_{\text{OOD}}|$ 是 OOD 项变化的有界量。当 $\gamma = 0$ (纯 in-domain reward): $f_s^{(s)}(T_A) \geq f_s^{(s)}(T_B)$ 。

Proof. $T_B = v^{(s)}$ 对应 mixing $\lambda = \delta_s^{\text{const}}$, 是 Stage 1 搜索空间内的可行点。Stage 1 最优 ψ^* 使 $F^{(s)}(\lambda^*) \geq F^{(s)}(\delta_s^{\text{const}}) = f_s^{(s)}(v^{(s)}) + \gamma \bar{f}_{\text{OOD}}^{(s)}(v^{(s)})$ 。变量分离后即得。 $\square$ $\square$

含义: 在合理 γ 下, A 的 in-domain reward 至少不显著劣于 B。这是 Paradigm A 的基本保证。

6.2 OOD: 符号依赖于 Stage 1 优化方向

将定理 1 应用到 OOD reward R_j ($j \neq s$):

$$\Delta R_j^{(s)} \approx \mathbb{E}_{p,\tau} \left[\sum_{k \neq s} \lambda_k^*(\tau, s, c_p) \langle G_j(\tau), v^{(k)} - v^{(s)} \rangle \right]. \quad (30)$$

由 Stage 1 KKT (28): λ_k^* 由 in-domain G_s 与 OOD 平均 $\bar{G}_{\text{OOD}}$ 的加权平衡决定。具体地:

命题 3 (OOD gap 符号分析). $\Delta R_j^{(s)}$ 的符号与下式一致 (局部一阶意义下):

$$\text{sign}(\Delta R_j^{(s)}) = \text{sign} \left(\mathbb{E}_{p,\tau,k \neq s} \left[\lambda_k^* \langle G_j(\tau), v^{(k)} - v^{(s)} \rangle \right] \right). \quad (31)$$

由 Stage 1 KKT 条件, $\lambda_k^* \neq 0$ 当且仅当 $\langle G_s + \gamma' \bar{G}_{\text{OOD}}, v^{(k)} - v^{(s)} \rangle$ 在 ψ^* 邻域有非平凡的方向性。

三种典型情形:

1. $\langle G_j, v^{(k)} - v^{(s)} \rangle$ 与 $\langle G_s, v^{(k)} - v^{(s)} \rangle$ 同号 (reward j 与 s 在 teacher k 偏移方向上协同): $\Delta R_j^{(s)} > 0$ 。
2. 异号且 γ 较小: Stage 1 主要受 G_s 主导, λ^* 选择让 $\langle G_s, v^{(k)} - v^{(s)} \rangle > 0$ 的 teacher, 可能让 $\langle G_j, v^{(k)} - v^{(s)} \rangle < 0$, 故 $\Delta R_j^{(s)} < 0$ 。
3. 异号但 γ 大: λ^* 倾向选择 $\langle G_j, v^{(k)} - v^{(s)} \rangle > 0$ 的 teacher, 但代价是 in-domain 退化。

核心 **insight**: 在 OOD 上, A 与 B 的 gap 符号无 *framework* 内的通用保证——它取决于 reward landscape 的几何 (G_j 与 G_s 的相对方向) 与 Stage 1 优化的 trade-off (γ 选择)。这与 `mof_ood_guarantee_analysis.tex` 的负面定理一致。

6.3 对比表: A vs. B 的预期 gap

Reward 类型	A 期望	B 期望	Gap 方向 (理论)	Gap 符号 conditional on
In-domain R_s on $\mathcal{P}_s$	$\geq f_s^{(s)}(v^{(s)})$	$= f_s^{(s)}(v^{(s)})$	$A \geq B$	γ 不太大 (Thm. 2)
OOD R_j on $\mathcal{P}_s, j \neq s$	取决于 λ^*	$= f_j^{(s)}(v^{(s)})$	符号未定	reward landscape 几何 (Prop. 3)
Best-OOD-teacher reward	通常 $< \max_k f_j^{(s)}(v^{(k)})$	$= f_j^{(s)}(v^{(s)}) \leq \max_k$	两者都未必达到顶点最大	非平凡
复合 reward $F^{(s)}$	$\sup_{\psi} F^{(s)}$	$F^{(s)}(\delta_s^{\text{const}})$	$A \geq B$ (构造性)	不依赖任何额外假设

7 蒸馏 Gap 的二阶差异

前面的分析假定 Stage 2 的蒸馏完美无损 ($\xi_A = 0, \xi_B = 0$)。本节讨论蒸馏残差 ξ_A, ξ_B 的差异及其对最终 reward 的影响。

7.1 Target 函数的连续性差异

- $T_A(x, t, c)$ 的 c -连续性: $T_A = \sum_k \lambda_k(t, s(c), c) v^{(k)}(x, t, c)$ 。当 router 用 c 的 embedding 输出连续 λ_k 时, T_A 在 c 上 Lipschitz 连续 (除了 source 标签 $s(c)$ 在 source 边界跳变这一点)。
- $T_B(x, t, c)$ 的 c -连续性: $T_B = v^{(s(c))}$ 。当 prompt c 跨越 source 边界时, target 函数从一个 LoRA 跳到另一个 LoRA, 不连续。

典型分布偏移: 在多 source mixture 数据集上训练 student, 每个 mini-batch 同时含多 source 样本。Paradigm B 的 target 在 batch 内出现 step jump, Paradigm A 的 target 在 batch 内 (除 source 标签外) 平滑。

7.2 Capacity gap 的对比

命题 4 (Capacity gap 的渐进比较). 对一阶 LoRA student ($v^\theta = v_{\text{base}} + \delta^\theta$, δ^θ 的 representation 函数族为 $\mathcal{F}_\theta$),

$$\epsilon_A^{\text{cap}} := \inf_{\theta} \mathbb{E}[\|v^\theta - T_A\|^2] = \inf_{\delta^\theta \in \mathcal{F}_\theta} \mathbb{E}\left[\left\|\delta^\theta - \sum_k \lambda_k^* \delta^{(k)}\right\|^2\right], \quad (32)$$

$$\epsilon_B^{\text{cap}} := \inf_{\theta} \mathbb{E}[\|v^\theta - T_B\|^2] = \inf_{\delta^\theta \in \mathcal{F}_\theta} \mathbb{E}\left[\left\|\delta^\theta - \delta^{(s(c))}\right\|^2\right]. \quad (33)$$

两者无统一大小关系, 依赖具体 $\mathcal{F}_\theta$ 与 $\{\delta^{(k)}, \lambda^*\}$ 几何。

7.3 两种典型情形分析

情形 1: $\mathcal{F}_\theta$ 表达力充足。若 student LoRA rank 足够, $\mathcal{F}_\theta$ 既能表达每个 $\delta^{(k)}$, 又能表达任意凸组合 $\sum_k \lambda_k \delta^{(k)}$ 。此时 $\epsilon_A^{\text{cap}} \approx \epsilon_B^{\text{cap}} \approx 0$, 两范式蒸馏 gap 均可忽略。

情形 2: $\mathcal{F}_\theta$ 受限 (小 LoRA rank)。

- **B** 的目标: 把 S 个不同的 LoRA $\delta^{(s)}$ 都嵌入到 $\mathcal{F}_\theta$ 中, 由 c 触发 source-aware switching。如果 $\mathcal{F}_\theta$ 容量小于 S 个 LoRA 的 column space 之和, 必然损失。
- **A** 的目标: 把 S 个不同的”混合 LoRA” $\sum_k \lambda_k^*(t, s, c) \delta^{(k)}$ 嵌入到 $\mathcal{F}_\theta$ 。由于 λ^* 在 (t, c) 上变化平滑, T_A 在 c -空间是 Lipschitz 平滑的, 对小容量函数族更友好。

粗略经验排序: 在小 LoRA rank regime 下, $\epsilon_A^{\text{cap}} \lesssim \epsilon_B^{\text{cap}}$, 因为:

- B 需要表达 S 个独立的 LoRA + 边界跳变;
- A 需要表达平滑过渡的 LoRA mixture, 函数复杂度更低。

7.4 Distillation 残差对 reward 的影响

把 (5)(8) 代入 reward:

$$R_j^{(s)}(\theta_A^*) \approx R_j^{(s)}(T_A) - \epsilon_A^{\text{distill}, j, s}, \quad (34)$$

$$R_j^{(s)}(\theta_B^*) \approx R_j^{(s)}(T_B) - \epsilon_B^{\text{distill}, j, s}, \quad (35)$$

其中 $\epsilon^{\text{distill},j,s}$ 是投影到 *reward* 空间的 distillation gap:

$$\epsilon^{\text{distill},j,s} \approx \mathbb{E} \left[\int \langle G_j(\tau), \xi(\tau) \rangle d\tau \right] + O(\|\xi\|^2). \quad (36)$$

最终 student-level reward gap:

$$\Delta R_j^{(s)}(\theta) = \underbrace{[R_j^{(s)}(T_A) - R_j^{(s)}(T_B)]}_{\text{target-level gap}} - \underbrace{[\epsilon_A^{\text{distill},j,s} - \epsilon_B^{\text{distill},j,s}]}_{\text{distillation 差异}}. \quad (37)$$

7.5 Erosion 风险对比

- Paradigm B 的 target 已经是 single teacher, 蒸馏几乎不会”超过”该 teacher 水平; distillation gap 主要来源是 $\mathcal{F}_\theta$ 容量不足。
- Paradigm A 的 target T_A 可能在 reward 上严格超过任何单 teacher (Level-2 in-domain 严格超越 / OOD 互补), 但这超越部分容易被 distillation gap 抹消 (参见 `mof_ood_guarantee_analysis.tex` 中关于 distillation gap erosion 的相关分析)。

8 三种边界情形与精确条件

下面给出 $A \gtrsim B$ 的精确条件, 按 Stage 1 收敛位置分类。

8.1 情形 I: $A = B$ (Stage 1 退化)

命题 5 (退化情形). 若 Stage 1 收敛到 $\lambda_s^*(t, s, c) = 1$ 对所有 (t, c) 成立 (即 in-domain teacher 在每个 timestep / prompt 上都最优), 则 $T_A = T_B$, 两范式 student 在 capacity 充足下行为一致: $\theta_A^* = \theta_B^*$ 。

发生条件:

- In-domain teacher 在所有 timestep 上对复合 reward 都最优 (无时间互补性, γ 不足以激励偏离 δ_s^{const});
- 或 Stage 1 优化未收敛 (局部最优陷在 δ_s^{const} 邻域);
- 或 OOD reward 与 in-domain reward 完全冲突 (γ 选不动 λ)。

含义: 当 Paradigm A 退化为 B 时, 两阶段流水线的 RL 阶段是”无效”的——但仍不劣于 B。

8.2 情形 II: $A \neq B$ 但 reward 持平 (generic 偏移)

命题 6 (Generic 偏移但 reward 持平). 若 $\lambda^* \neq \delta_s^{\text{const}}$ (A 引入了非平凡混合) 但 $\langle G_j(\tau), \sum_{k \neq s} \lambda_k^*(v^{(k)} - v^{(s)}) \rangle = 0$ (gap velocity 在 reward R_j 的灵敏度方向上正交), 则 $\Delta R_j^{(s)} \approx 0$ (一阶) 但 distillation gap 可能不同:

$$R_j^{(s)}(\theta_A^*) - R_j^{(s)}(\theta_B^*) \approx -[\epsilon_A^{\text{distill},j,s} - \epsilon_B^{\text{distill},j,s}]. \quad (38)$$

含义: 在该情形下, 差异完全由蒸馏精度主导。如果 A 的 target 更平滑 (导致 $\epsilon_A^{\text{cap}} < \epsilon_B^{\text{cap}}$), A 略胜; 反之 B 略胜。

8.3 情形 III: $A > B$ (时间互补性 + Stage 1 找到正向 mixing)

定理 3 (A 严格优于 B 的充分条件). $R_j^{(s)}(\theta_A^*) > R_j^{(s)}(\theta_B^*)$ 当以下条件同时满足:

- (C1) 时间互补性 (target-level): 存在 (τ^*, k^*) 使 $\lambda_{k^*}^*(\tau^*, s, c) > 0$ 且 $\langle G_j(\tau^*; T_B), v^{(k^*)} - v^{(s)} \rangle > 0$ 。
- (C2) **Reward** 协同 (Stage 1 复合优化方向): 满足 (C1) 的 (τ^*, k^*) 处 $\langle G_s, v^{(k^*)} - v^{(s)} \rangle$ 的负贡献小于其在 R_j 上的正贡献的 $1/\gamma'$ 倍 (γ' 是 Stage 1 OOD 系数)。
- (C3) 蒸馏不抹消: $\epsilon_A^{\text{distill}} - \epsilon_B^{\text{distill}} < R_j^{(s)}(T_A) - R_j^{(s)}(T_B)$ 。

解读:

- (C1) 是结构性条件 (teacher 之间确实存在跨 timestep 协同)。
- (C2) 是 Stage 1 优化能”发现”该 mixing 的条件 (KKT 平衡下 λ^* 不退化)。
- (C3) 是 Stage 2 不抹消该增益的条件。

三个条件全部满足时, A 在 OOD reward 上严格优于 B。任何一个不满足, A 都可能不优于 B。

8.4 情形 IV: $A < B$ (罕见但可能)

命题 7 (A 劣于 B 的情形). $R_j^{(s)}(\theta_A^*) < R_j^{(s)}(\theta_B^*)$ 当:

1. Stage 1 在复合优化中为提升其他 reward 而降低 R_j (trade-off on Pareto 前沿);
2. 且蒸馏 gap 不足以补偿。

具体地, 当 OOD reward R_j 与 in-domain R_s 在 mixing 方向上反相关 ($\langle G_j, v^{(k)} - v^{(s)} \rangle < 0$ 而 $\langle G_s, v^{(k)} - v^{(s)} \rangle > 0$) 时, Stage 1 选择 $\lambda_k^* > 0$ 提升 R_s , 但同时降低 R_j 。结果:

$$R_j^{(s)}(T_A) < R_j^{(s)}(T_B), \quad \text{即 A 在 } R_j \text{ 上劣于 B.} \quad (39)$$

警示: Paradigm A 不是”安全”选择——在某些 OOD reward 上可能比直接 OPD 更差。这与 `mof_ood_guarantee_analysis.tex` 的负面定理一致。

9 综合 Gap 公式与决策树

9.1 综合 reward gap 公式

把 (37) 与定理 1 合并:

$$\Delta R_j^{(s)}(\theta_A^*, \theta_B^*) \approx \mathbb{E}_{p, \tau, k} \left[\lambda_k^* \langle G_j(\tau), v^{(k)} - v^{(s)} \rangle \right] - [\epsilon_A^{\text{distill}, j, s} - \epsilon_B^{\text{distill}, j, s}]. \quad (40)$$

第一项 (target-level reward gap) 由 Stage 1 RL 优化决定, 符号依赖于 reward landscape 几何与 γ 选择。第二项 (distillation 差异) 依赖 student 容量与 target 平滑性。

9.2 决策树：何时选 A，何时选 B

选择 A (MoF→Distill) 的条件

- Teacher 之间在不同 timestep 上有可观察的互补性（早 / 中 / 晚 denoising 阶段各有所长）；
- 至少有一个 OOD reward 是优化目标，且 reward landscape 不强烈反相关；
- Student LoRA 容量充足，能拟合 router-induced mixture 的平滑过渡；
- 计算预算允许两阶段（Stage 1 + Stage 2）。

选择 B (route-by-source OPD) 的条件

- Teacher 高度专家化（每个 teacher 仅在自己的 source 上有意义）；
- 不关心 OOD reward 改进（仅要 in-domain match teacher）；
- 计算预算紧张（避免 Stage 1 RL 开销）；
- Student 容量足以表达 source-conditioned LoRA 切换。

9.3 综合结论

核心结论

1. 结构性优势： $\mathcal{T}_B^{\text{ext}} \subsetneq \mathcal{T}_A$ ，所以 A 的 reward 上界总不低于 B（Corollary 1）。但上界不等于实际获得，A 是否实际超过 B 取决于 Stage 1 优化。
2. **Target-level gap** 公式： $\Delta v = \sum_{k \neq s(c)} \lambda_k^* (v^{(k)} - v^{(s)})$ （命题 1），bound by $(1 - \lambda_s^*) D_s$ 。
3. **Reward gap** 一阶展开： $\Delta R_j^{(s)} \approx \mathbb{E}[\sum_{k \neq s} \lambda_k^* \langle G_j, v^{(k)} - v^{(s)} \rangle]$ （定理 1）。每个 (t, k) pair 的贡献符号由 *adjoint sensitivity* 与 *teacher* 偏移方向的内积决定。
4. **In-domain $\geq$ B**：定理 2 给出 A 在 in-domain 上不弱于 B（构造性，仅需 γ 不太大）。这是无条件保证。
5. **OOD 符号依赖**：A 在 OOD reward 上既可能优于、等于、也可能劣于 B（命题 3, 7）。framework 本身不提供 OOD 上 $A > B$ 的保证。
6. **蒸馏 gap 差异**：A 的 target 在 prompt 空间连续平滑、B 的 target 在 source 边界跳变。在小 student 容量下，A 通常更易拟合（ $\epsilon_A^{\text{cap}} \lesssim \epsilon_B^{\text{cap}}$ ）。
7. **综合公式**：student-level reward gap = target-level gap - distillation 差异。两者都需要实证测量。
8. 何时 $A > B$ 严格成立（定理 3）：需要时间互补性 + Stage 1 reward 协同 + 蒸馏 gap 不抹消，三个条件同时满足。
9. 何时 $A = B$ （命题 5）：Stage 1 退化到 $\lambda^* = \delta_s^{\text{const}}$ 。
10. 何时 $A < B$ （命题 7）：复合 reward trade-off 牺牲 OOD R_j 来提升其他项。

9.4 开放问题

1. 能否在 Stage 1 的复合 reward 中引入硬约束 $f_j^{(s)} \geq \rho_j^{(s),\text{const}}$, 使 OOD 严格不劣于 B 成为构造性保证? (约束优化 + Lagrangian 求解)
2. 能否设计 Stage 2 的蒸馏 loss (替代 vanilla MSE) 来保留 Stage 1 的 reward margin? 例如 reward-weighted MSE 或 trajectory matching.
3. 能否量化何时时间互补性会自然浮现? (teacher 训练数据集的相关性 / LoRA rank / base model 的稀疏激活模式)
4. Multi-round self-distillation: Paradigm A $\rightarrow$ student $\rightarrow$ 重新作 base training 新一组 teachers $\rightarrow$ 再做 Paradigm A, 能否 escape Stage 2 的 erosion?

A Adjoint Sensitivity 的精确计算

为了让定理 1 中的 $G_j(\tau)$ 可计算, 给出 adjoint ODE 形式。

ODE: $\dot{x}(\tau) = v(x(\tau), \tau, c)$, 逆向积分 $\tau : 1 \rightarrow 0$ 。设 $a(\tau) := \partial R_j(x(0))/\partial x(\tau)$ 为 adjoint state。由 chain rule, $a(\tau)$ 满足逆向 adjoint ODE:

$$\dot{a}(\tau) = -(\partial_x v(x(\tau), \tau, c))^\top a(\tau), \quad a(0) = \nabla_{x(0)} R_j. \quad (41)$$

Adjoint 变量与 functional derivative 的关系:

$$G_j(\tau, x; v) = a(\tau) \quad (\text{在轨迹 } x(\tau) \text{ 处}). \quad (42)$$

因此定理 1 中的 $\langle G_j, v^{(k)} - v^{(s)} \rangle$ 就是 adjoint state 与 teacher 偏移方向的内积, 可以通过反向 ODE 数值积分得到。

B 与已有 docs 的关系

- `mof_per_set_analysis.tex`: 给出 Paradigm A 的 Stage 1 理论 (Level-1 / Level-2 in-domain 保证)。本文复用其符号。
- `mof_ood_guarantee_analysis.tex`: 分析 Paradigm A 的 OOD 不保证; 本文从 A vs. B 对比角度复用了那里的反例与充分条件。
- `mof_two_stage_pipeline.tex`: 给出 Paradigm A 的算法实现; 本文是其相对 B 的理论 *gap* 补充。
- `mof_notes.tex`: 综合 notes; 本文是其 §2.4 与 §4.3 的更深推导。