

# Reward-Residual CFG Guidance

从单 Teacher 到 Mixture of Flows 的算子代数、交换律与适用边界

Jayce-Ping

2026 年 8 月 5 日

## Abstract

本文形式化一种 inference-time reward-residual guidance:

$$\mathbf{v}_\alpha = \mathbf{v}_{\text{base}} + \alpha(\mathbf{v}_{\text{RL}} - \mathbf{v}_{\text{base}}).$$

它与 classifier-free guidance (CFG) 具有相同的仿射形式, 但“形式同构”并不自动意味着“概率解释相同”。本文以 Flow-Factory 当前 Mixture of Flows (MoF) 为背景, 首先把 CFG 写成作用于 positive/negative 两个 branch 的线性算子, 再完整推导 {student 无 CFG, student 有 CFG}  $\times$  {teacher 无 CFG, teacher 有 CFG} 四种 single-teacher 组合。随后比较“先 CFG、后 reward guidance”与“先 branch-wise reward guidance、后 CFG”, 给出二者的精确交换子、等价条件和不可恢复情形。最后把结论推广到 multi-teacher MoF、多个独立 reward residual、softmax/affine/free 三类权重区域, 并区分三种不同陈述: 可积分的合成 *ODE field*、精确 *density-mixture velocity* 和指数倾斜下的 *score guidance*。核心结果是: 同一 CFG scale、branch-independent 混合权重与同一 residual strength 下, CFG 和 reward residual 严格交换; 一旦 student/teacher scale 不同、positive/negative 路由不同, 或 negative branch 从未计算, 该交换律即失效。

## Contents

|                                        |          |
|----------------------------------------|----------|
| <b>1 问题、角色与现有 MoF</b>                  | <b>3</b> |
| 1.1 本文中的 student 与 teacher             | 3        |
| 1.2 Flow-Factory 当前 MoF 的算子            | 3        |
| <b>2 两个基本算子</b>                        | <b>4</b> |
| 2.1 CFG 算子                             | 4        |
| 2.2 Reward-residual 算子                 | 4        |
| <b>3 Single-teacher: 四种 CFG 组合</b>     | <b>5</b> |
| 3.1 统一公式                               | 5        |
| 3.2 四个 case                            | 5        |
| 3.3 四种组合的两个实践结论                        | 5        |
| <b>4 CFG 在 reward guidance 之前与之后</b>   | <b>6</b> |
| 4.1 两个顺序的严格定义                          | 6        |
| 4.2 交换子与等价条件                           | 6        |
| 4.3 四种组合在“CFG 后置”语义下能否复现               | 7        |
| 4.4 数学上的 no-CFG 与工程上的 branch 缺失        | 7        |
| <b>5 Multi-teacher reward residual</b> | <b>8</b> |
| 5.1 先形成 MoF teacher, 再以 base 为锚        | 8        |
| 5.2 多个独立 reward residual 直接叠加          | 9        |
| 5.3 Multi-teacher 的 CFG 顺序             | 9        |
| 5.4 Positive/negative 使用不同 router      | 9        |

|          |                                                          |           |
|----------|----------------------------------------------------------|-----------|
| <b>6</b> | <b>理论解释的边界</b>                                           | <b>10</b> |
| 6.1      | Score 层: 指数倾斜下的严格结论 . . . . .                            | 10        |
| 6.2      | Noisy marginal: 不是直接的 $\nabla R(x_t)$ . . . . .          | 10        |
| 6.3      | Velocity 层: 形式同构不等于分布等价 . . . . .                        | 11        |
| 6.4      | 精确 density mixture 需要 posterior responsibility . . . . . | 11        |
| <b>7</b> | <b>实现映射与推理协议</b>                                         | <b>12</b> |
| 7.1      | 当前代码对应关系 . . . . .                                       | 12        |
| 7.2      | 最低成本的推理消融 . . . . .                                      | 12        |
| 7.3      | 安全与数值约束 . . . . .                                        | 12        |
| <b>8</b> | <b>结论</b>                                                | <b>13</b> |

# 1 问题、角色与现有 MoF

## 1.1 本文中的 student 与 teacher

本文固定以下角色，避免与二阶段 MoF 蒸馏中的“最终 student”混淆：

- S: pretrained base, 亦即部署时希望保留其质量与多样性的 *anchor model*;
- T: 从同一 base 出发, 经某个 reward objective 做 RL 微调得到的 *specialist*;
- $\mathbf{v}_M^+, \mathbf{v}_M^-$ : 模型  $M \in \{S, T\}$  在 positive 与 negative/unconditional conditioning 下的原始 velocity prediction;
- $\alpha$ : reward-residual strength;  $\gamma$ : CFG scale。

因此本文的基本目标是

$$\mathbf{v}_{\text{RRG}} = (1 - \alpha)\mathbf{v}_S + \alpha\mathbf{v}_T = \mathbf{v}_S + \alpha(\mathbf{v}_T - \mathbf{v}_S). \quad (1)$$

RRG 是 reward-residual guidance 的缩写。它在推理时不再调用 reward model, 但仍依赖由 RL checkpoint pair 编码的 implicit preference; 更准确的描述是 *reward-model-free at inference*, 而不是无 reward。

## 1.2 Flow-Factory 当前 MoF 的算子

Flow-Factory 中的 MoF 在每个 denoising step 查询  $K$  个冻结 teacher, 并在输出 velocity 空间组合:

$$\mathbf{v}_{\text{MoF}}(x, t, c) = \sum_{k=1}^K \lambda_k(t, s(c), c) \mathbf{v}_k(x, t, c). \quad (2)$$

当前 mixing module 支持:

$$\text{softmax}: \lambda_k \geq 0, \quad \sum_k \lambda_k = 1, \quad (3)$$

$$\text{affine}: \lambda_k \in \mathbb{R}, \quad \sum_k \lambda_k = 1, \quad (4)$$

$$\text{none}: \lambda_k \in \mathbb{R}, \quad \sum_k \lambda_k \text{ 不受约束}. \quad (5)$$

实现分别落在三个位置:

- `trainers/mof/common.py`: patched inference forward 与 `_combine_velocities_per_sample` 执行 (2);
- `trainers/mof/utils.py`: `apply_weight_normalization` 实现 (3)–(5);
- `trainers/mof/distill.py`: 用 on-policy velocity MSE 将固定 MoF target 蒸馏到部署 student。

### 本文与现有 MoF 的关系

现有 MoF 主要研究 teacher 之间如何组合; 本文额外保留 pretrained base S 作为显式 anchor, 并研究  $S + \alpha(T - S)$  型外推与 CFG 的组合。Single-teacher 是  $K = 1$ ; multi-teacher 则可以先形成  $\mathbf{v}_{\text{MoF}}$ , 再把它视为一个 composite RL teacher。

## 2 两个基本算子

### 2.1 CFG 算子

**定义 2.1** (CFG direction 与 CFG 算子). 对具有显式 positive/negative 两个 branch、且以线性方式合成 CFG 的模型  $M$ ，定义 conditional direction

$$\mathbf{d}_M := \mathbf{v}_M^+ - \mathbf{v}_M^- \quad (6)$$

CFG 算子为

$$\mathcal{C}_\gamma[M] := \mathbf{v}_M^- + \gamma(\mathbf{v}_M^+ - \mathbf{v}_M^-) = \mathbf{v}_M^+ + (\gamma - 1)\mathbf{d}_M \quad (7)$$

本文主体采用 SD3.5/Wan 等显式双 branch adapter 的 scale convention:

$$\gamma = 1 \implies \mathcal{C}_1[M] = \mathbf{v}_M^+ \quad (8)$$

所以“无 CFG”指仅使用 positive conditional prediction，不是使用  $\mathbf{v}_M^-$ 。当  $\gamma > 1$  时，模型从 positive branch 沿  $\mathbf{d}_M$  继续外推。

#### Adapter 适用范围

式 (7) 不是 Flow-Factory 所有模型的统一实现接口。Z-Image 使用  $\mathbf{v}^+ + g(\mathbf{v}^+ - \mathbf{v}^-)$ ，在关闭 CFG normalization 且固定 truncation mask 时，可通过  $\gamma = 1 + g$  换元为本文记号；其无 CFG 对应  $g = 0$ 。FLUX.1/FLUX.2 则把 guidance scalar 作为 transformer 输入，没有可直接观测的 positive/negative CFG branch，不能直接套用本文四组合与交换子。若存在 norm matching、rescale、动态 truncation 等非线性后处理，CFG 也不再是线性算子，后文交换律需逐项重新推导。

### 2.2 Reward-residual 算子

**定义 2.2** (Base-anchored reward-residual 算子). 对两个处在相同 latent coordinate、相同时间方向、相同 prediction parameterization 的 field  $A, B$ ，定义

$$\mathcal{G}_\alpha[A, B] := A + \alpha(B - A) = (1 - \alpha)A + \alpha B \quad (9)$$

系数区间决定几何意义：

| $\alpha$ | 几何位置         | 解释                                |
|----------|--------------|-----------------------------------|
| 0        | anchor S     | 纯 pretrained base                 |
| (0, 1)   | S 与 T 之间     | 插值，通常更保守                          |
| 1        | RL teacher T | 纯 specialist                      |
| > 1      | 越过 T         | 放大 RL-induced residual            |
| < 0      | 远离 T         | 反向 preference / negative guidance |




Figure 1: Reward residual 是以 pretrained base 为锚点的仿射直线。只有  $\alpha \in [0, 1]$  是凸插值； $\alpha < 0$  或  $\alpha > 1$  是外推。

### 3 Single-teacher: 四种 CFG 组合

#### 3.1 统一公式

令  $I_S, I_T \in \{0, 1\}$  分别表示 student/teacher 是否启用 CFG。若不启用，将对应 scale 视为 1。先分别合成 student 与 teacher，再做 reward guidance，可统一写成

$$\mathbf{v}_{I_S I_T}^{\text{CFG} \rightarrow \text{R}} = (1 - \alpha) [\mathbf{v}_S^+ + I_S(\gamma_S - 1)\mathbf{d}_S] + \alpha [\mathbf{v}_T^+ + I_T(\gamma_T - 1)\mathbf{d}_T]. \quad (10)$$

上式把输出拆成两个互相可审计的部分：

$$\mathbf{v}_{I_S I_T}^{\text{CFG} \rightarrow \text{R}} = \underbrace{(1 - \alpha)\mathbf{v}_S^+ + \alpha\mathbf{v}_T^+}_{\text{positive-branch reward residual}} + \underbrace{(1 - \alpha)I_S(\gamma_S - 1)\mathbf{d}_S + \alpha I_T(\gamma_T - 1)\mathbf{d}_T}_{\text{CFG contribution}}. \quad (11)$$

#### 3.2 四个 case

**Case 00: student 无 CFG, teacher 无 CFG。**

$$\mathbf{v}_{00} = (1 - \alpha)\mathbf{v}_S^+ + \alpha\mathbf{v}_T^+ = \mathbf{v}_S^+ + \alpha(\mathbf{v}_T^+ - \mathbf{v}_S^+). \quad (12)$$

这是最纯粹的 reward residual；只需两个 positive forward。

**Case 10: student 有 CFG, teacher 无 CFG。**

$$\mathbf{v}_{10} = (1 - \alpha)\mathcal{C}_{\gamma_S}[\mathbf{S}] + \alpha\mathbf{v}_T^+ = \mathbf{v}_{00} + (1 - \alpha)(\gamma_S - 1)\mathbf{d}_S. \quad (13)$$

CFG 增量被 anchor coefficient  $(1 - \alpha)$  缩放。当  $\alpha = 1$  时，student CFG 完全消失；这是先合成、后插值的直接结果。

**Case 01: student 无 CFG, teacher 有 CFG。**

$$\mathbf{v}_{01} = (1 - \alpha)\mathbf{v}_S^+ + \alpha\mathcal{C}_{\gamma_T}[\mathbf{T}] = \mathbf{v}_{00} + \alpha(\gamma_T - 1)\mathbf{d}_T. \quad (14)$$

teacher CFG 增量被 reward strength  $\alpha$  缩放。若同时增大  $\alpha$  与  $\gamma_T$ ，两个外推强度会相乘，容易产生 double extrapolation。

**Case 11: student 有 CFG, teacher 有 CFG。**

$$\begin{aligned} \mathbf{v}_{11} &= (1 - \alpha)\mathcal{C}_{\gamma_S}[\mathbf{S}] + \alpha\mathcal{C}_{\gamma_T}[\mathbf{T}] \\ &= \mathbf{v}_{00} + (1 - \alpha)(\gamma_S - 1)\mathbf{d}_S + \alpha(\gamma_T - 1)\mathbf{d}_T. \end{aligned} \quad (15)$$

这是最一般的 single-teacher 先-CFG 形式。

#### 3.3 四种组合的两个实践结论

**命题 3.1** (CFG 增量的有效系数). 在先 CFG 后 reward guidance 的语义下，student 与 teacher CFG direction 的有效系数分别是

$$a_S^{\text{cfg}} = (1 - \alpha)(\gamma_S - 1), \quad a_T^{\text{cfg}} = \alpha(\gamma_T - 1). \quad (16)$$

因此只报告  $(\alpha, \gamma_S, \gamma_T)$  不如同时报告 (16) 透明。特别地， $\alpha > 1$  时  $1 - \alpha < 0$ ，student CFG direction 被反向加入；此时 Case 10/11 不能解释成“保留一点 base CFG”。

**注 3.2** (相同数值 scale 不保证相同物理强度). 即使  $\gamma_S = \gamma_T$ ，也通常有  $\mathbf{d}_S \neq \mathbf{d}_T$ 。相同 CFG scale 只保证算子系数相同，不保证两个模型的 branch gap、RMS 或语义强度相同。




Figure 2: Single-teacher 的  $2 \times 2$  CFG 组合。四式仅相差 student/teacher conditional direction 的加权项。

## 4 CFG 在 reward guidance 之前与之后

### 4.1 两个顺序的严格定义

顺序 A: 先 CFG, 后 reward guidance。

$$\mathbf{v}_A := \mathcal{G}_\alpha[\mathcal{C}_{\gamma_S}[\mathbf{S}], \mathcal{C}_{\gamma_T}[\mathbf{T}]]. \quad (17)$$

它允许 student 与 teacher 使用不同 CFG scale。

顺序 B: 先 branch-wise reward guidance, 后 CFG。先构造一个拥有两个 branch 的 virtual guided model:

$$\mathbf{v}_R^+ := (1 - \alpha)\mathbf{v}_S^+ + \alpha\mathbf{v}_T^+, \quad \mathbf{v}_R^- := (1 - \alpha)\mathbf{v}_S^- + \alpha\mathbf{v}_T^-. \quad (18)$$

再用单一 scale  $\gamma_R$  做 CFG:

$$\mathbf{v}_B := \mathcal{C}_{\gamma_R}[\mathbf{R}] = (1 - \alpha)\mathcal{C}_{\gamma_R}[\mathbf{S}] + \alpha\mathcal{C}_{\gamma_R}[\mathbf{T}]. \quad (19)$$

最后一个等号来自 CFG 对 branch pair 的线性性。

### 4.2 交换子与等价条件

定理 4.1 (Single-teacher CFG-RRG 交换子). 顺序 A 与 B 的差为

$$\mathbf{v}_A - \mathbf{v}_B = (1 - \alpha)(\gamma_S - \gamma_R)\mathbf{d}_S + \alpha(\gamma_T - \gamma_R)\mathbf{d}_T. \quad (20)$$

*Proof.* 将 (7) 分别代入 (17) 和 (19)。两式的 positive-branch residual 相消, 只剩 conditional direction 系数之差。□

推论 4.2 (同 scale 时严格交换). 若

$$\gamma_S = \gamma_T = \gamma_R = \gamma, \quad (21)$$

则

$$\mathcal{G}_\alpha[\mathcal{C}_\gamma[\mathbf{S}], \mathcal{C}_\gamma[\mathbf{T}]] = \mathcal{C}_\gamma[\mathbf{R}], \quad \mathbf{v}_R^b = \mathcal{G}_\alpha[\mathbf{v}_S^b, \mathbf{v}_T^b], \quad b \in \{+, -\}. \quad (22)$$

即 CFG 与 branch-wise reward residual 严格交换。

**推论 4.3** (一般必要条件). 当  $0 < \alpha < 1$  且  $\mathbf{d}_S, \mathbf{d}_T$  线性无关时,  $\mathbf{v}_A = \mathbf{v}_B$  当且仅当

$$\gamma_S = \gamma_T = \gamma_R. \quad (23)$$

若两个 *direction* 共线, 则不同 *scale* 可能偶然抵消; 这种等价依赖当前  $(x, t, c)$ , 不构成全局算子恒等式。




Figure 3: CFG 与 reward residual 的两条路径。交换律要求比较 branch pair, 而不是只比较两个已合成的 velocity。

### 4.3 四种组合在“CFG 后置”语义下能否复现

顺序 B 只有一个  $\gamma_R$ 。由 (20):

- Case 00 可取  $\gamma_R = 1$  精确复现;
- Case 11 在  $\gamma_S = \gamma_T$  时可精确复现;
- Case 10/01 一般不能由单一后置 CFG 精确复现, 因为它要求同一个  $\gamma_R$  同时对两个不同 direction 施加不同 scale;
- 只有当  $\mathbf{d}_S, \mathbf{d}_T$  共线并满足 (20) 的抵消关系时, Case 10/01 才可能在某个状态偶然等价。

### 4.4 数学上的 no-CFG 与工程上的 branch 缺失

#### 不可恢复性

数学上“无 CFG”可写成  $\gamma = 1$ , 但仍可把  $(\mathbf{v}^+, \mathbf{v}^-)$  视为潜在可查询的 branch pair。工程上, Flow-Factory adapter 在 `guidance_scale`  $\leq 1$  时通常只执行 positive forward; negative embeddings 甚至不会进入 preprocessing cache。如果只保存了  $\mathbf{v}^+$  或某个 composed  $\mathcal{C}_\gamma[M]$ , 就无法唯一恢复  $\mathbf{v}^-$  与  $\mathbf{d}_M$ 。因此“先无 CFG forward, 之后再补 CFG”不是代数重排, 而是缺少一次模型查询。

只保存 composed field 还有更一般的不可辨识性: 对任意扰动  $\mathbf{e}$ ,

$$\mathbf{v}^+ \leftarrow \mathbf{v}^+ + \frac{\gamma - 1}{\gamma} \mathbf{e}, \quad \mathbf{v}^- \leftarrow \mathbf{v}^- + \mathbf{e} \quad (24)$$

保持  $\mathcal{C}_\gamma[M]$  不变。此 null space 正是只监督一个 CFG-composed target 无法保证其他 inference scale 的原因; Flow-Factory 的 branch-aware PDM 文档对此给出了 positive-direction matching 的处理方式。

## 5 Multi-teacher reward residual

### 5.1 先形成 MoF teacher, 再以 base 为锚

对每个 branch  $b \in \{+, -\}$ , 定义

$$\mathbf{v}_{\text{MoF}}^b := \sum_{k=1}^K \lambda_k \mathbf{v}_k^b. \quad (25)$$

若 positive/negative 两个 branch 共用同一组  $\lambda_k$ , 则 composite teacher 的 conditional direction 为

$$\mathbf{d}_{\text{MoF}} = \mathbf{v}_{\text{MoF}}^+ - \mathbf{v}_{\text{MoF}}^- = \sum_{k=1}^K \lambda_k \mathbf{d}_k. \quad (26)$$

Base-anchored MoF reward residual 为

$$\mathbf{v}_{\alpha, \lambda} = (1 - \alpha) \mathbf{v}_S + \alpha \sum_{k=1}^K \lambda_k \mathbf{v}_k. \quad (27)$$

在  $\sum_k \lambda_k = 1$  时, 总系数恒满足

$$(1 - \alpha) + \sum_k \alpha \lambda_k = 1. \quad (28)$$

**命题 5.1** (系数区域). 对 (27):

1. 若  $\lambda \in \Delta^{K-1}$  且  $\alpha \in [0, 1]$ , 则  $(1 - \alpha, \alpha \lambda_1, \dots, \alpha \lambda_K)$  位于  $\{S, T_1, \dots, T_K\}$  的凸包;
2. 若  $\lambda \in \Delta^{K-1}$  且  $\alpha \notin [0, 1]$ , 则沿  $S \leftrightarrow \mathbf{v}_{\text{MoF}}$  直线做外推;
3. 若  $\sum_k \lambda_k = 1$  但允许负权重, 则整体仍是 *affine combination*, 可以沿多个 *teacher residual* 方向离开凸包;
4. 若  $\sum_k \lambda_k \neq 1$ , 总系数为  $1 + \alpha(\sum_k \lambda_k - 1)$ , 不再保持 *affine constraint*; *field magnitude* 可整体漂移, 同时失去 *affine* 几何解释与对共同 *field offset* 的平移等变性。只有当合成 *field* 恰为某个参考 *field* 的纯时间标量倍数时, 才可进一步解释为 *time reparameterization*。




Figure 4: 两个 RL teacher 与 base anchor 的几何区域。Softmax MoF 位于 teacher 边上; 外层  $\alpha$  决定从 base 朝该点插值或外推。Affine teacher 权重还能沿 teacher 边方向继续外推。



## 5.2 多个独立 reward residual 直接叠加

若每个 teacher  $k$  都从同一 base  $S$  独立 RL 得到，可以直接写

$$\mathbf{v}_\beta = \mathbf{v}_S + \sum_{k=1}^K \beta_k (\mathbf{v}_k - \mathbf{v}_S) = \left(1 - \sum_k \beta_k\right) \mathbf{v}_S + \sum_k \beta_k \mathbf{v}_k. \quad (29)$$

令  $a = \sum_k \beta_k$ 。当  $a \neq 0$  时，取

$$\alpha = a, \quad \lambda_k = \frac{\beta_k}{a}, \quad (30)$$

即可把 (29) 写成 (27)。因此在  $\sum_k \beta_k \neq 0$  的区域，两种写法代数等价，但参数语义不同：

- outer-MoF 写法把 “teacher 内部 trade-off”  $\lambda$  与 “离 base 多远”  $\alpha$  分离；
- direct residual 写法让每个 reward direction 拥有独立 strength  $\beta_k$ ；
- 若  $\beta_k$  有正有负，则归一化后的  $\lambda_k$  一般不在概率单纯形内，所以这属于 affine preference composition，而不是 convex MoF。

若  $\sum_k \beta_k = 0$  但  $\beta \neq \mathbf{0}$ ，(29) 表示 teacher 之间的非零 zero-sum affine direction；outer-MoF 参数化要求  $\alpha = 0$  才能保持 student 系数为 1，继而无法保留这些 teacher 项。因此这是 (27) 的退化盲区；当系数依赖  $(x, t, c)$  时，式 (30) 还会在  $a = 0$  的状态产生奇点。

## 5.3 Multi-teacher 的 CFG 顺序

先允许 student scale 为  $\gamma_S$ ，第  $k$  个 teacher scale 为  $\gamma_k$ 。“先 CFG 后 RRG” 为

$$\mathbf{v}_A^{(K)} = (1 - \alpha) \mathcal{C}_{\gamma_S}[\mathbf{S}] + \alpha \sum_{k=1}^K \lambda_k \mathcal{C}_{\gamma_k}[\mathbf{T}_k]. \quad (31)$$

若所有 branch 共用同一  $\lambda$ ，先按 branch 做 (25) 与 (27)，再用单一  $\gamma_R$  做 CFG，得到

$$\mathbf{v}_B^{(K)} = (1 - \alpha) \mathcal{C}_{\gamma_R}[\mathbf{S}] + \alpha \sum_{k=1}^K \lambda_k \mathcal{C}_{\gamma_R}[\mathbf{T}_k]. \quad (32)$$

**定理 5.2** (Multi-teacher CFG-RRG 交换子).

$$\boxed{\mathbf{v}_A^{(K)} - \mathbf{v}_B^{(K)} = (1 - \alpha)(\gamma_S - \gamma_R) \mathbf{d}_S + \alpha \sum_{k=1}^K \lambda_k (\gamma_k - \gamma_R) \mathbf{d}_k.} \quad (33)$$

特别地，若  $\gamma_S = \gamma_1 = \dots = \gamma_K = \gamma_R$ ，则 CFG 与 MoF、外层 reward residual 都严格交换。这个结果不要求  $\lambda_k \geq 0$ ，甚至不要求  $\sum_k \lambda_k = 1$ ；它只使用线性性。权重约束影响概率/几何解释，不影响该代数恒等式。

## 5.4 Positive/negative 使用不同 router

若两个 branch 使用不同权重  $\lambda_k^+, \lambda_k^-$ ，则

$$\mathbf{v}_{\text{MoF}}^+ = \sum_k \lambda_k^+ \mathbf{v}_k^+, \quad \mathbf{v}_{\text{MoF}}^- = \sum_k \lambda_k^- \mathbf{v}_k^-, \quad (34)$$

$$\mathbf{d}_{\text{MoF}} = \sum_k \lambda_k^+ \mathbf{d}_k + \sum_k (\lambda_k^+ - \lambda_k^-) \mathbf{v}_k^-. \quad (35)$$

第二项是 *routing shift*。此时后置 CFG 放大的不仅是每个 teacher 的 conditional direction，还包括 positive/negative router 改变 teacher composition 所产生的差异。把它误写成  $\sum_k \lambda_k \mathbf{d}_k$  会漏项。

**命题 5.3** (Branch-dependent router 的广义交换子). 明确采用如下 “先 CFG 后 route” 约定:

$$\tilde{\mathbf{v}}_A^{(K)} := (1 - \alpha)\mathcal{C}_{\gamma_S}[\mathbf{S}] + \alpha \sum_k \lambda_k^+ \mathcal{C}_{\gamma_k}[\mathbf{T}_k], \quad (36)$$

即 *composed teacher* 使用 *positive router*; 而后置 CFG 路径先以 (34) 构造两个 *branch*, 再施加  $\mathcal{C}_{\gamma_R}$ 。两条路径之差为

$$\begin{aligned} \tilde{\mathbf{v}}_A^{(K)} - \tilde{\mathbf{v}}_B^{(K)} &= (1 - \alpha)(\gamma_S - \gamma_R)\mathbf{d}_S \\ &\quad + \alpha \sum_k \lambda_k^+ (\gamma_k - \gamma_R)\mathbf{d}_k \\ &\quad - \alpha(\gamma_R - 1) \sum_k (\lambda_k^+ - \lambda_k^-) \mathbf{v}_k^-. \end{aligned} \quad (37)$$

最后一行是 router commutator。即使所有 CFG scale 相同, 只要  $\lambda^+ \neq \lambda^-$  且  $\gamma_R \neq 1$ , 两种顺序通常仍不交换。令  $\lambda^+ = \lambda^-$  即恢复式 (33)。

当前 Flow-Factory MoF router 由 timestep、source 与 prompt representation 产生一组 shared teacher weights, 然后组合 adapter 已经返回的 prediction; 它不是显式的 dual-branch router。因此只要所有 teacher forward 使用相同 guidance scale, 当前路径落在交换律成立的 shared- $\lambda$  情形。若未来暴露原始 branches 并让 router 读取 negative conditioning, 则必须明确采用 shared router 还是 branch-dependent router。

## 6 理论解释的边界

### 6.1 Score 层: 指数倾斜下的严格结论

假设 endpoint RL distribution 真正满足 KL-regularized exponential tilt:

$$p_T(x) = \frac{1}{Z_\beta} p_S(x) e^{\beta R(x)}, \quad 0 < Z_\beta < \infty. \quad (38)$$

则 endpoint score 严格满足

$$\mathbf{s}_T(x) - \mathbf{s}_S(x) = \beta \nabla_x R(x). \quad (39)$$

因此 score residual

$$\mathbf{s}_\alpha = (1 - \alpha)\mathbf{s}_S + \alpha\mathbf{s}_T \quad (40)$$

是密度

$$p_\alpha(x) \propto p_S(x)^{1-\alpha} p_T(x)^\alpha \propto p_S(x) e^{\alpha\beta R(x)} \quad (41)$$

的 score, 前提是新的 normalizer 有限。这个结论是 reward residual 与 CFG 概率类比最严格的部分。

### 6.2 Noisy marginal: 不是直接的 $\nabla R(x_t)$

若 base 与 RL endpoint 经相同 forward noising kernel  $q_t(x_t | x_0)$ , 则

$$p_{T,t}(x_t) = \frac{p_{S,t}(x_t)}{Z_\beta} \mathbb{E}_S \left[ e^{\beta R(X_0)} \mid X_t = x_t \right]. \quad (42)$$

记

$$h_t(x_t) := \mathbb{E}_S \left[ e^{\beta R(X_0)} \mid X_t = x_t \right], \quad (43)$$

则

$$\mathbf{s}_{T,t} - \mathbf{s}_{S,t} = \nabla_{x_t} \log h_t(x_t), \quad (44)$$

而不是一般意义下的  $\beta \nabla_{x_t} R(x_t)$ 。小  $\beta$  时,  $\log h_t = \beta \mathbb{E}[R(X_0) \mid X_t] + \mathcal{O}(\beta^2)$ , 所以 residual 更接近 denoising posterior 上的 soft reward-to-go gradient。

### 6.3 Velocity 层：形式同构不等于分布等价

一般 flow-matching velocity 只满足连续性方程

$$\partial_t p_t + \nabla \cdot (p_t \mathbf{v}_t) = 0. \quad (45)$$

局部的  $\mathbf{v}_t(x)$  不是  $\nabla \log p_t(x)$ ; endpoint tilt 也不唯一决定整条 probability path。因此

$$\mathbf{v}_T - \mathbf{v}_S \stackrel{\text{一般情形}}{\neq} \beta \nabla R. \quad (46)$$

Velocity residual 可获得局部严格概率解释的常见条件包括：

1. student/teacher 共享 diffusion schedule, 且 probability-flow velocity 是 score 的同一个 affine-linear map; 此时 score residual 到 velocity residual 的映射在每个  $(x, t)$  上严格成立;
2. 单步 stochastic transition 是共享协方差高斯, velocity 到 transition mean 的映射相同, 此时 mean residual 对应精确的单步 conditional log-density-ratio tilt;
3. 明确把 (1) 仅定义为一个新的 ODE control field, 不宣称它精确实现 endpoint exponential tilt。

前两项仍不足以自动保证  $p_{S,t}^{1-\alpha} p_{T,t}^\alpha$  在所有  $t$  上构成同一条 Fokker-Planck/continuity-equation path。完整 density-path 等价还要求额外的 path-consistency 条件, 或加入相应 dynamic/Doob corrector。

#### 推荐表述

“Reward residual 与线性双 branch CFG 在 velocity 输出空间具有相同的仿射算子结构; 共享 score-velocity 映射或共享协方差 transition 可以给出严格的局部 density-ratio 解释。完整 path-level KL tilt 还需独立的 path-consistency 条件; 否则该算子仍定义了可测试的 inference-time control field, 但不是 reward gradient 或目标分布路径的严格恢复。”

### 6.4 精确 density mixture 需要 posterior responsibility

给定 teacher path densities  $p_{k,t}$  与其合法 velocities  $\mathbf{v}_{k,t}$ , 若目标密度是

$$p_{mix,t}(x) = \sum_{k=1}^K \pi_k p_{k,t}(x), \quad \pi_k \geq 0, \quad \sum_k \pi_k = 1, \quad (47)$$

则一个精确 mixture marginal velocity 是

$$\mathbf{v}_{mix,t}(x) = \sum_{k=1}^K r_k(x, t) \mathbf{v}_{k,t}(x), \quad r_k(x, t) = \frac{\pi_k p_{k,t}(x)}{\sum_j \pi_j p_{j,t}(x)}. \quad (48)$$

这里  $r_k$  是 state-dependent posterior responsibility, 而不是固定 prior  $\pi_k$ 。因此“连续性方程对 velocity 线性”不能单独证明任意常数  $\lambda_k$  的 teacher velocity 平均等于 density mixture flow; 不同 teacher 通常携带不同  $p_{k,t}$ 。

另一方面, 只要  $\sum_k \lambda_k \mathbf{v}_k$  足够正则, 它仍然定义一个可积分 ODE, 并从共同初始噪声诱导某个分布。正确区分是：

$$\begin{aligned} \text{regular field} &\implies \text{可采样的 ODE,} \\ \text{posterior-responsibility field} &\implies \text{指定 density mixture 的精确 marginal flow.} \end{aligned} \quad (49)$$

Flow-Factory 当前 MoF 的 time/source/prompt router 一般不读取 latent state  $x_t$ , 所以它应被描述为 learnable composite field; 除非额外证明其权重等于 (48), 不应自动称为 teacher density mixture。

## 7 实现映射与推理协议

### 7.1 当前代码对应关系

| 理论对象                                                          | 当前实现                                                                                                        | 含义/限制                                                                                             |
|---------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------|
| $\sum_k \lambda_k \mathbf{v}_k$                               | <code>trainers/mof/common.py</code>                                                                         | 逐 teacher weight swap、stack 后在 velocity 输出空间求和；teacher forward 共享传入的 CFG kwargs。                  |
| softmax/affine/free 区域                                        | <code>trainers/mof/utils.py</code>                                                                          | <code>apply_weight_normalization</code> 分别对应 (3)–(5)。                                             |
| MoF target 蒸馏                                                 | <code>trainers/mof/distill.py</code>                                                                        | 先缓存 teacher mixture，再以 student on-policy states 做 velocity MSE。                                   |
| $\mathcal{C}_\gamma[M]$                                       | <code>models/stable_diffusion/sd3_5.py</code> 与部分显式双 branch adapter                                         | 存在 negative embeddings 且 $\gamma > 1$ 时运行两 branch，再返回 composed prediction；通常不暴露原始 branches。       |
| 其他 guidance 语义                                                | <code>models/z_image/z_image.py</code> ； <code>models/flux/</code>                                          | Z-Image 需用 $\gamma = 1 + g$ 换元且关闭 nonlinear normalization；FLUX.1/2 guidance 是模型输入，无显式 CFG branch。 |
| branch 不可辨识性<br><code>branch_aware_cfg_distillation.md</code> | <code>docs/xopd/core/cfg/</code><br>PDM 用 positive prediction 与 conditional direction 分别监督；当前文档明确不自动改变 MoF。 |                                                                                                   |

### 7.2 最低成本的推理消融

对 single-teacher，建议使用 matched seed、相同 scheduler、相同 latent state，扫以下最小集合：

$$\alpha \in \{0, 0.5, 1, 1.5, 2\}, \quad (\gamma_S, \gamma_T) \in \{(1, 1), (\gamma, 1), (1, \gamma), (\gamma, \gamma)\}. \quad (50)$$

每个点同时记录：

$$\begin{aligned} & \text{RMS}(\mathbf{v}_T^+ - \mathbf{v}_S^+), \quad \text{RMS}(\mathbf{d}_S), \quad \text{RMS}(\mathbf{d}_T), \\ & \cos(\mathbf{v}_T^+ - \mathbf{v}_S^+, \mathbf{d}_S), \quad \cos(\mathbf{v}_T^+ - \mathbf{v}_S^+, \mathbf{d}_T). \end{aligned} \quad (51)$$

这些量可以区分 reward residual 与 CFG direction 是协同、正交还是冲突。

对 multi-teacher，先固定 shared  $\gamma$  验证交换律，再逐项引入 teacher-specific  $\gamma_k$ 。否则 reward routing、CFG scale 与 outer  $\alpha$  三者同时变化，无法归因。

### 7.3 安全与数值约束

1. 所有模型必须使用同一 latent coordinate、prediction parameterization、scheduler time convention 与 tensor scaling 后才能直接相减；
2. teacher weight swap 循环必须遵守现有 autocast-cache disable 与 inference-mode DDP bypass 约束；
3. residual subtraction 建议以 fp32 完成，并监控 per-timestep RMS；
4.  $\alpha > 1$  与  $\gamma > 1$  同时使用时，优先约束有效系数 (16)，而不是分别给两个看似温和的上界；

5. free teacher weights 的  $\sum_k \lambda_k$  漂移与 outer  $\alpha$  会相乘，应显式记录总 field coefficient  $1 + \alpha(\sum_k \lambda_k - 1)$ ;
6. 任何“严格 reward gradient”声明都应说明采用的是 score、shared-covariance transition mean，还是仅作为 ODE field heuristic。

## 8 结论

Reward-residual guidance 与 CFG 的共同核心是

$$\text{anchor} + \text{scale} \times \text{direction}. \quad (52)$$

这个共同模板带来一组简单但有约束的结论：

1. Single-teacher 四种 CFG 组合由 (10) 统一；差别仅是  $\mathbf{d}_S, \mathbf{d}_T$  的有效系数；
2. 同一 scale、shared branches 与同一 residual strength 下，CFG 与 branch-wise reward residual 严格交换；
3. student/teacher scale 不同时，交换误差由 (20) 精确给出；multi-teacher 情形由 (33) 给出；
4. 数学上的  $\gamma = 1$  不代表 negative branch 已被计算；后置 CFG 需要原始 branch pair，不能从单个 composed output 唯一恢复；
5. 当  $\sum_k \beta_k \neq 0$  时，Multi-teacher 的 outer-MoF 与 direct residual sum 可以互换参数化；非零 zero-sum residual 是 outer-MoF 的退化盲区；
6. Score exponential tilt 提供严格概率解释；一般 flow velocity arithmetic 只提供一个新的 control field，除非额外满足 shared-path 条件；
7. 精确 teacher density mixture 需要 state-dependent posterior responsibility，不能由任意固定凸权重的 velocity 平均自动推出。

因此，最稳健的研究顺序是：先把 (1) 作为 zero-training inference oracle，使用 shared CFG scale 验证 residual 是否改善 reward-quality Pareto frontier；再测试不同 student/teacher CFG 组合；最后才引入 multi-teacher routing 与 affine extrapolation。这样每一步都对应本文中的一个可验证算子，而不会把 CFG、reward residual 与 teacher routing 的效应混在一起。

## References

- [1] Jonathan Ho and Tim Salimans. Classifier-Free Diffusion Guidance. *NeurIPS 2021 Workshop on Deep Generative Models and Downstream Applications*, 2021. <https://arxiv.org/abs/2207.12598>.
- [2] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow Matching for Generative Modeling. *International Conference on Learning Representations*, 2023. <https://arxiv.org/abs/2210.02747>.
- [3] Quanhao Li, Junqiu Yu, Kaixun Jiang, et al. DiffusionOPD: A Unified Perspective of On-Policy Distillation in Diffusion Models. 2026. <https://arxiv.org/abs/2605.15055>.
- [4] Rethinking Classifier-Free Guidance in On-Policy Diffusion Distillation. 2026. <https://arxiv.org/abs/2607.24731>.