

Ensemble Blend Modes: Definitions and Theory

ensemble-eval 多 teacher 聚合算法 (weighted / PCGrad 家族 / TIES) 的含义与理论分析

Flow Factory

Abstract

本文系统给出 ensemble-eval trainer 在每个去噪步对 K 个 LoRA checkpoint 的 `noise_pred` 进行融合时所用的全部聚合算法 (`ensemble_blend_mode`) 的严格定义与理论分析, 并解释 `scripts/compare_ensemble_methods.py` 默认对比的那一组方法为何如此选择。核心结论:

1. 无冲突即退化 (命题 1): 任意 PCGrad 投影 (global / channelwise / normalized) 在没有符号冲突时都退化为加权和 `weighted`。单 checkpoint 时三者恒等于 `weighted`。
2. 全速度坍塌 (命题 2): teacher 的 full velocity v_i 被共享的 base 方向主导 (近平行), 冲突率趋零, 故 `pcgrad/pcgrad_channelwise/pcgrad_normalized` 与 `weighted` 数值上几乎相同。
3. **base** 锚定暴露冲突 (命题 3): 在残差 $\tau_i = v_i - v_{\text{base}}$ 上操作移除了共享共模分量, task delta 之间冲突频繁, 故 `pcgrad_residual` 系列与 `ties` 才与基线实质不同。
4. **TIES** 的退化与去毒 (命题 4): 无符号分歧时 TIES 退化为加权平均; 有分歧时通过 sign election 丢弃逆向 teacher, 等价于一种逐元素的鲁棒聚合。

据此, 默认对比集合 = $\{\text{weighted (基线)}\} \cup \{\text{pcgrad_residual 系列} + \text{ties}\} \cup \{\text{KL/1/KL 动态加权}\}$, 外加 base 与各 teacher 的单独 baseline。

Contents

1 设定与符号	2
2 Weighted : 线性基线	2
3 PCGrad 家族: 冲突投影	2
3.1 Global PCGrad	2
3.2 Channelwise PCGrad	3
3.3 Normalized PCGrad	3
3.4 Residual (base-anchored) 变体	3
4 TIES : 符号选举 + 不相交合并	3
5 Weight Merge : 权重空间融合 (model soup)	4
6 核心理论: 退化关系与 base 锚定的必要性	4
6.1 为何全速度 PCGrad 坍塌到 <code>weighted</code>	5
6.2 为何 base 锚定 (残差) 才有效	5
6.3 TIES 的退化与鲁棒性	5
7 动态加权: KL / inverse-KL	6
8 速查表	6
9 结论	7

1 设定与符号

ensemble-eval trainer (`src/flow_factory/trainers/ensemble_eval/`) 在每个去噪步把 K 个 checkpoint 的 `noise_pred` 融合为单个 v_{fused} ，再做一次 `scheduler.step`。输出空间融合算子的入口是 `ensemble_forward_step` (`common.py`)，其分发逻辑为：

$$\text{vector} \in \left\{ \underbrace{v_i}_{\text{full velocity}}, \underbrace{\tau_i = v_i - v_{\text{base}}}_{\text{residual delta}} \right\} \times \text{projection} \in \{\text{global}, \text{channelwise}, \text{normalized}\} \cup \{\text{weighted}, \text{ties}\}.$$

此外 `weight_merge` (§5) 在 参数空间一次性融合（不经 per-step 路径），作为 model-soup baseline。

符号约定。 所有量均为 *per-sample*（固定 batch 样本 b 与时间步 k ，省略上下标）：

符号	含义
K	ensemble 中 checkpoint (teacher) 数
$d = C \times H \times W$	latent 维度
v_{base}	base (pretrained, LoRA 关闭) 的 velocity (<code>use_ref_parameters</code>)
v_i	teacher i 的 velocity (<code>noise_pred</code> , <code>use_named_parameters</code>)
$\tau_i = v_i - v_{\text{base}}$	teacher i 的 task vector (residual delta)
$\pi_i \geq 0, \sum_i \pi_i = 1$	静态 checkpoint 权重 (<code>checkpoint_weights</code> , 默认均匀 $1/K$)
$w_i \geq 0$	实际融合权重 (静态或 per-sample 动态, §7)
ε	<code>pcgrad_eps</code> , 数值下限 (默认 10^{-8})

投影记号：对向量 a 在 b 方向的投影 $\text{proj}_b(a) = \frac{\langle a, b \rangle}{\|b\|^2} b$ 。

2 Weighted: 线性基线

Definition 1 (weighted). 线性加权和 (`common.py`, full-velocity 分支)：

$$v_{\text{fused}}^{\text{wsum}} = \sum_{i=1}^K w_i v_i. \quad (1)$$

这是最简单的聚合：各 teacher 速度的凸组合 (w_i 归一化时)。它不做任何冲突检测，是其余所有方法的参照系；下文反复出现的结论是“某模式在某条件下退化为 (1)”。从 RL/蒸馏视角，(1) 等价于把各 teacher 的转移均值做加权平均（见 `teacher_aggregation_loss_formulations.tex`），即 `average/sum` 聚合的推理期对应物。

3 PCGrad 家族：冲突投影

PCGrad (Projecting Conflicting Gradients, Yu et al. 2020) 原用于多任务梯度去冲突。这里把“梯度”换成 teacher 的速度/残差向量。

3.1 Global PCGrad

Definition 2 (pcgrad, global). 输入 $\{g_i\}$ (full 模式 $g_i = w_i v_i$ ，残差模式 $g_i = w_i \tau_i$ ，见 `_blend_velocity_set`)。初始化 $\text{pc}_i \leftarrow g_i$ ；对每个 i ，按固定（含可复现随机）顺序遍历 $j \neq i$ ：

$$\text{若 } \langle \text{pc}_i, g_j \rangle < 0: \quad \text{pc}_i \leftarrow \text{pc}_i - \frac{\langle \text{pc}_i, g_j \rangle}{\|g_j\|^2} g_j = \text{pc}_i - \text{proj}_{g_j}(\text{pc}_i), \quad (2)$$

投影方向始终用 原始 g_j 。输出 $v_{\text{fused}} = \sum_i \text{pc}_i$ 。冲突判定 $\langle \cdot, \cdot \rangle < 0$ 在全部 d 维上做一次内积。

几何含义：当 teacher i 与 j 方向相悖（夹角 $> 90^\circ$ ）时，把 i 中与 j 相抵的分量减去，只保留非冲突部分，再求和。其作用是抑制相互抵消，让融合方向更“协调”。

3.2 Channelwise PCGrad

Definition 3 (`pcgrad_channelwise`). 与 (2) 相同, 但内积与冲突判定在更细粒度上独立进行 (`pcgrad_blend_noise_preds_channelwise`):

- 4D (B, C, H, W): 逐 *channel*, 内积在 $H \times W$ 上, 每个 *channel* 独立决定是否投影;
- 3D ($B, \text{seq}, \text{feat}$): 逐 *token*, 内积在 *feat* 上。

直觉: *global* 用一个标量内积概括整张图的冲突, 可能”一票否决”; *channelwise* 允许部分 *channel/token* 冲突、部分不冲突, 去冲突更局部、更激进 (冲突触发面更大)。

3.3 Normalized PCGrad

Definition 4 (`pcgrad_normalized`). 把每个向量拆成幅度 $n_i = \|v_i\|$ 与单位方向 $u_i = v_i/n_i$ (`pcgrad_blend_noise_preds_normalized`)。PCGrad 在单位方向 $\{u_i\}$ 上运行 (2) 得投影方向 p_i , 再恢复幅度与权重重组:

$$v_{\text{fused}} = \sum_{i=1}^K w_i n_i p_i. \quad (3)$$

动机: *global* 的投影系数 $\langle p_i, g_j \rangle / \|g_j\|^2$ 受 g_j 幅度影响, 高范数 *teacher* 会主导投影。归一化后冲突几何 $\langle u_i, u_j \rangle$ (即 *cosine*) 幅度无关, 避免”大嗓门”*teacher* 支配方向; 幅度只在最后线性重组时加回。

3.4 Residual (base-anchored) 变体

Definition 5 (`pcgrad_residual` 系列). 先做一次 *base* 前向得 v_{base} (`use_ref_parameters`), 各 *teacher* 残差 $\tau_i = v_i - v_{\text{base}}$; 对 $\{\tau_i\}$ (而非 $\{v_i\}$) 施加上述三种投影之一得 $\{\tau_i^{\text{PCGrad}}\}$, 再加回基线 (`_pcgrad_residual_blend`):

$$v_{\text{fused}} = v_{\text{base}} + \underbrace{\sum_i w_i \tau_i^{\text{PCGrad}}}_{\text{combined delta}}. \quad (4)$$

对应 `pcgrad_residual (global) / _channelwise / _normalized`。代价: 每步多一次 *base* 前向。

4 TIES: 符号选举 + 不相交合并

Definition 6 (`ties`). *base-anchored*。在 task vectors $\{\tau_i\}$ 上做 TIES-merging (Yadav et al. 2023) 的两步 (`ties_blend_deltas`):

1. (可选) **trim**: 每个 τ_i 按幅度保留 *top- ρ* 比例的元素 (`ties_density`= ρ , 默认 1.0 不裁剪), 其余置零;
2. **sign election**: 逐元素选举主导符号

$$\gamma = \text{sign}\left(\sum_i w_i \tau_i\right) \in \{-1, 0, +1\}^d; \quad (5)$$

3. **disjoint merge**: 仅对与 γ 同号的 *teacher* 做加权平均

$$\tau_{\text{merged}} = \frac{\sum_i w_i \tau_i \mathbf{1}[\text{sign}(\tau_i) = \gamma]}{\sum_i w_i \mathbf{1}[\text{sign}(\tau_i) = \gamma]} \quad (\text{分母为0 处取0}), \quad (6)$$

返回 $v_{\text{fused}} = v_{\text{base}} + \tau_{\text{merged}}$ 。

直觉: 逐元素地”投票”决定该坐标应往哪个方向修正, 再只让赞成方贡献, 逆向 *teacher* 被直接剔除 (而非像 PCGrad 那样按投影削减)。这是一种比 PCGrad 更”硬”的冲突消解。

5 Weight Merge: 权重空间融合 (model soup)

上述所有模式都在 输出空间 (per-step velocity) 上融合, 每步需 K 次 (residual/ties 为 $K+1$ 次) 前向。weight_merge 则在 参数空间上融合, 且只融合一次。

Definition 7 (weight_merge). 设 teacher i 的 LoRA 参数为 θ_i (与 base 架构对齐的张量列表)。一次性做权重空间加权平均, 得到单个合并 LoRA:

$$\theta_{\text{merged}} = \sum_{i=1}^K w_i \theta_i, \quad w_i = \pi_i \text{ (静态 checkpoint_weights, 默认 } 1/K), \quad (7)$$

随后用 θ_{merged} 做 普通单模型推理 (每步仅 1 次前向, 无 per-step blend、无 v_{base})。实现见 build_merged_lora_snapshot: 对齐的 teacher 快照逐槽 fp32 加权求和, 写入合并快照后经 use_named_parameters 单模型推理。

Remark 1 (LoRA 双线性: 近似而非精确 delta merge). LoRA 的有效增量为 $\Delta W_i = B_i A_i$ (双线性)。(7) 对 A_i, B_i 分别平均, 故

$$\left(\sum_i w_i B_i \right) \left(\sum_i w_i A_i \right) \neq \sum_i w_i B_i A_i$$

即 weight_merge 复现的是左式 (廉价的 LoRA soup), 不等于右式的精确 task-arithmetic delta merge。这是有意为之的简单基线。又因无 per-step v_{base} , KL 动态加权不适用, ensemble_blend_weighting 必须为 uniform。

Remark 2 (系数性质与成本). 权重 θ_{merged} 是 teacher 参数的凸组合 ($w_i \geq 0, \sum w_i = 1$), 但由于扩散映射对参数高度非线性, 输出 v_{fused} 一般不是各 teacher 输出 v_i 的凸组合 (与 weighted 的输出空间凸组合不同)。成本上最省: 合并一次后每步单前向, 远低于 PCGrad/TIES 的 $K/K+1$ 次。

6 核心理论: 退化关系与 base 锚定的必要性

本节给出”为何默认对比只保留 weighted + residual 系列 + ties”的严格依据。

Lemma 1 (投影对正缩放的齐次性). 固定遍历顺序与冲突判定, (2) 对输入正缩放齐次: 若 $g_i \mapsto c g_i$ ($c > 0$ 对所有 i 相同), 则 $\text{pc}_i \mapsto c \text{pc}_i$ 。

Proof. 归纳。内积 $\langle c \text{pc}_i, c g_j \rangle = c^2 \langle \text{pc}_i, g_j \rangle$ 符号不变, 故冲突判定一致; 投影 $\text{proj}_{c g_j}(c \text{pc}_i) = c \text{proj}_{g_j}(\text{pc}_i)$, 更新两边同乘 c 。□

Proposition 1 (无冲突即退化为 weighted). 若在某样本上 PCGrad 内层循环 未触发任何投影 (所有判定 $\langle \cdot, \cdot \rangle \geq 0$), 则

- *global / channelwise*: $\text{pc}_i = g_i = w_i v_i$ (或 $w_i \tau_i$), 故 $v_{\text{fused}} = \sum_i w_i v_i$, 即 *weighted* (残差模式为 $v_{\text{base}} + \sum_i w_i \tau_i$);
- *normalized*: $p_i = u_i$, 重组 $\sum_i w_i n_i u_i = \sum_i w_i v_i$, 代数上 亦等于 *weighted*。

特别地, $K = 1$ 时不存在 $j \neq i$, 三种投影 恒 退化为 $w_1 v_1$ 。

Proof. 无投影时 pc_i 保持初值; global/channelwise 初值即 g_i 。normalized 初值 $p_i = u_i$, 代入 (3) 得 $\sum_i w_i n_i u_i = \sum_i w_i v_i$ 。 $K = 1$ 见定义中的单元短路分支。□

Remark 3. 命题 1 解释了脚本中”单 teacher baseline”为何直接用 blend_mode=weighted 配单 checkpoint: 由短路分支它就是该 teacher 自身的 v_1 。

6.1 为何全速度 PCGrad 坍缩到 weighted

Proposition 2 (full-velocity 坍缩). 设各 *teacher* 由同一 *base* 微调, 故 $v_i = v_{\text{base}} + \tau_i$ 且 $\|\tau_i\| \ll \|v_{\text{base}}\|$ (残差远小于共享分量)。则任意两 *teacher* 的 *full velocity* 夹角余弦

$$\cos \angle(v_i, v_j) = \frac{\langle v_{\text{base}} + \tau_i, v_{\text{base}} + \tau_j \rangle}{\|v_{\text{base}} + \tau_i\| \|v_{\text{base}} + \tau_j\|} = 1 - O\left(\frac{\|\tau\|^2}{\|v_{\text{base}}\|^2}\right) \rightarrow 1, \quad (8)$$

即 v_i 近平行、内积恒正。于是 *global PCGrad* 几乎不触发投影, 由命题 1 数值上 $\approx$ *weighted*; *normalized* 同理 (单位方向近重合)。

Proof. 展开 $\langle v_{\text{base}} + \tau_i, v_{\text{base}} + \tau_j \rangle = \|v_{\text{base}}\|^2 + \langle v_{\text{base}}, \tau_i + \tau_j \rangle + \langle \tau_i, \tau_j \rangle$, 分母 $\|v_{\text{base}} + \tau_i\| = \|v_{\text{base}}\| \sqrt{1 + 2\langle v_{\text{base}}, \tau_i \rangle / \|v_{\text{base}}\|^2 + O(\|\tau\|^2 / \|v_{\text{base}}\|^2)}$ 。令 $\delta = \|\tau\| / \|v_{\text{base}}\| \rightarrow 0$, 逐阶展开即得 $\cos = 1 - O(\delta^2)$ 。正内积 $\Rightarrow$ 冲突判定 $\langle \cdot, \cdot \rangle < 0$ 几乎不成立。□

Corollary 1. *pcgrad*, *pcgrad_channelwise*, *pcgrad_normalized* 在 *fine-tuned ensemble* 上与 *weighted* 数值近乎一致, 对比中信息冗余, 故默认对比集合将其剔除 (仅保留 *weighted* 作为这一族的代表基线)。*channelwise* 因逐 *channel* 判定冲突面更大, 可能略有偏离, 但共模主导对每个 *channel* 同样成立, 定性不变。

6.2 为何 base 锚定 (残差) 才有效

Proposition 3 (残差移除共模、暴露冲突). 在残差空间, 融合对象是 $\tau_i = v_i - v_{\text{base}}$, 共享分量 v_{base} 被精确减去。*task delta* 之间无共模约束, 夹角可自由分布于 $[0, \pi]$; 当 *teacher* 专精不同目标时, $\langle \tau_i, \tau_j \rangle < 0$ (方向相悖) 频繁出现。因此 *residual PCGrad/ties* 的投影/选举真正触发, 融合结果与 *weighted* (残差) $v_{\text{base}} + \sum_i w_i \tau_i$ 实质不同。

Proof. 由构造 τ_i 不含 v_{base} 方向的强制正分量; 命题 2 的 $\cos \rightarrow 1$ 论证不再适用。冲突率由 $\{\tau_i\}$ 的真实几何决定, 可显著 > 0 (经验上由 PCGradStats 的 conflict 率证实: full 模式 ≈ 0 , residual 模式显著为正)。□

为何默认对比是这一组

- **weighted**: 线性基线 (也代表整族 full-velocity, 命题 2)。
- **pcgrad_residual / _channelwise / _normalized**: 唯一与基线实质不同的 PCGrad (命题 3)。
- **ties**: base-anchored 的硬冲突消解, 独立于 PCGrad 的一类。
- **pcgrad_residual_kl / _kl_inv**: 在 residual 上叠加 per-sample 动态加权 (§7)。
- **baseline**: **base** (v_{base}) 与各 *teacher* 单独 (v_i), 给出融合的下界参照。

被剔除: *pcgrad* / *pcgrad_channelwise* / *pcgrad_normalized* (坍缩到 *weighted*)。

6.3 TIES 的退化与鲁棒性

Proposition 4 (TIES 退化为加权平均). 若所有 *teacher* 在某元素上符号一致 (无分歧), 则 (6) 的指示函数恒为 1,

$$\tau_{\text{merged}} = \frac{\sum_i w_i \tau_i}{\sum_i w_i} = \sum_i \tilde{w}_i \tau_i, \quad \tilde{w}_i = w_i / \sum_j w_j,$$

即归一化加权平均 ($\rho = 1$ 时)。存在分歧时, 逆向 (与 γ 异号) *teacher* 在该元素被剔除, 等价于逐元素的 *sign-trimmed* 加权平均——对”少数派强烈反向”具有鲁棒性。

Proof. 指示函数恒 1 时分子分母同为 $\sum_i w_i(\cdot)$, 直接化简。分歧时异号项被乘零剔除, 仅同号项进入加权平均。□

Remark 4 (与 PCGrad 的对比). PCGrad 对冲突做连续的投影削减 (保留正交分量); TIES 做离散的符号剔除 (整项丢弃)。前者温和、保几何; 后者激进、保符号一致性。二者都需 base 锚定才有意义 (命题 3)。

7 动态加权: KL / inverse-KL

权重 w_i 可为静态 π_i (**uniform**) 或 per-sample 动态。动态族以 teacher-base 的 per-step KL (在 flow matching 下 = velocity-MSE) $D_i = \|\tau_i\|^2$ 的幂为权:

$$w_i(\alpha) = \frac{\pi_i D_i^\alpha}{\sum_j \pi_j D_j^\alpha}, \quad \begin{cases} \alpha = 0 & \text{uniform} \\ \alpha = +1 & \text{kl (放大偏离最大的 specialist, 软路由)} \\ \alpha = -1 & \text{kl_inv (inverse-variance, 压制偏离大者)}. \end{cases} \quad (9)$$

因需要 $v_{\text{base,kl/kl_inv}}$ 仅对 base-anchored 模式(residual 系列与 **ties**)有效(`_resolve_blend_weights` / `_dynamic_kl_weights`, 否则显式报错)。

Theorem 1 (加权与 global/channelwise 投影可交换). 对 *global/channelwise PCGrad*, 引入 *per-sample* 标量 $w_i > 0$ 等价于先用 未加权 $\{\tau_j\}$ 投影、再加权重组: $\text{pc}_i = w_i \tau_i^{\text{PCGrad}}$, 从而 $v_{\text{fused}} = v_{\text{base}} + \sum_i w_i \tau_i^{\text{PCGrad}}$ 。即动态加权只改变最终线性重组, 不改变冲突结构。

Proof. 即引理 1 的逐 teacher 推广 (不同 w_i): 内积 $\langle w_i \text{pc}_i, w_j \tau_j \rangle = w_i w_j \langle \text{pc}_i, \tau_j \rangle$, $w_i w_j > 0$ 符号不变; 投影中 w_j 于分子分母相消, 更新保持 $\text{pc}_i = w_i \tau_i^{(s)}$ 。详见 `kl_weighted_teacher_fusion.tex` 定理 1。□

normalized 与 **ties** 不满足可交换 (前者把幅度剥离、 $w_i \propto \|\tau_i\|^{2\alpha}$ 改变等效幂; 后者 sign election 显式用 w_i)。ensemble-eval 的 OCR/PickScore/GenEval 属 specialist 制度, 理论预测 $\alpha > 0$ (**kl**) $\gg$ **uniform** $\gg$ $\alpha < 0$ (**kl_inv**)。完整推导见 `kl_weighted_teacher_fusion.tex`。

8 速查表

mode	融合公式	冲突处理	base 前向
weighted	$\sum_i w_i v_i$	无	✗
pcgrad	$\sum_i \text{pc}_i(\{w_j v_j\})$	global 投影	✗
pcgrad_channelwise	同上, 逐 channel/token	细粒度投影	✗
pcgrad_normalized	$\sum_i w_i n_i p_i$	单位方向投影	✗
pcgrad_residual	$v_{\text{base}} + \sum_i w_i \tau_i^{\text{PCGrad}}$	global 投影 (残差)	✓
pcgrad_residual_channelwise	同上, 逐 channel	细粒度 (残差)	✓
pcgrad_residual_normalized	$v_{\text{base}} + \sum_i w_i n_i^T p_i^T$	单位方向 (残差)	✓
ties	$v_{\text{base}} + \tau_{\text{merged}}$	符号选举 + 剔除	✓
weight_merge	单模型 $f(\theta_{\text{merged}})$, $\theta_{\text{merged}} = \sum_i w_i \theta_i$	无 (参数空间)	✗

加权选项 `ensemble_blend_weighting` $\in \{\text{uniform, kl, kl_inv}\}$ 仅对带 ✓ (base-anchored) 的行有效; `weight_merge` 仅支持 **uniform** (无 per-step v_{base})。注意 `weight_merge` 在 参数空间 融合、每步仅 1 次前向, 其余模式在 输出空间 融合。

模式	与 weighted 关系	默认对比
pcgrad/_channelwise/_normalized	近似相等 (命题 2)	剔除
weighted	—	保留 (基线)
pcgrad_residual 系列	实质不同 (命题 3)	保留
ties	实质不同	保留
*_kl / *_kl_inv	残差 + 动态重组	保留
weight_merge	参数空间 (非输出空间)	保留 (baseline)

9 结论

1. 所有 PCGrad 投影在无冲突时退化为 **weighted** (命题 1); 单 checkpoint 时恒等。
2. full-velocity 被共享 base 方向主导, 冲突率趋零, pcgrad/_channelwise/_normalized 坍缩到 **weighted** (命题 2), 故默认对比剔除之。
3. base 锚定 (残差) 移除共模、暴露真实冲突, 是 PCGrad/ties 产生非平凡效果的前提 (命题 3)。
4. TIES 无分歧时退化为加权平均, 有分歧时硬剔除逆向 teacher (命题 4), 与 PCGrad 的软投影互补。
5. 动态 KL 加权与 global/channelwise 投影可交换 (定理 1), 是低成本、可叠加的正交改进; 符号 α 由 ensemble 制度决定。

一句话总结。在”各 teacher 由同一 base 微调”的 **ensemble-eval** 设定下, 唯有在残差 $\tau_i = v_i - v_{\text{base}}$ 上做冲突消解 (pcgrad_residual 系列、ties) 才与简单加权和不同; 全速度版本因共模主导而退化。默认对比因此聚焦于 **weighted** 基线、residual 冲突消解族、动态加权变体, 以及 base/teacher 单独 baseline。

相关文档。kl_weighted_teacher_fusion.tex (KL 动态加权的完整理论)、pcgrad_gradient_vs_velocity_a (gradient-space vs velocity-space PCGrad)、teacher_aggregation_loss_formulations.tex (训练期 teacher aggregation)。