

KL-Weighted Teacher Fusion for Ensemble Evaluation

基于 teacher-base KL (velocity-MSE) 的动态加权 PCGrad 理论分析

Flow Factory

Abstract

本文分析在 multi-checkpoint ensemble 融合 (**ensemble-eval** trainer) 中, 用每个 teacher 相对 base model 的 per-step KL (在 flow matching 下等价于 velocity-MSE) $D_i = \|v_i - v_{\text{base}}\|^2$ 的幂 D_i^α 作为 *per-sample* 动态权重的理论效果。主要结论:

1. 加权-投影可交换 (定理 1): 对 PCGrad 的每个 task 施加正的 per-sample 标量权重 w_i , 等价于先用 未加权残差做投影、再对投影结果做 加权求和。权重不改变冲突检测与投影方向, 只改变最终线性重组。
2. 因此“KL 加权是否有效”归结为“加权重组 $\sum_i w_i \tau_i^{\text{PCGrad}}$ 是否优于均匀重组”, 与是否使用 PCGrad 无关。
3. 在 *specialist ensemble* (各 teacher 专精不同目标) 下, 正幂 $\alpha > 0$ (KL 加权) 实现 per-sample 软路由 (命题 2): 可恢复相关 teacher 的修正; uniform 会按 $1/K$ 稀释; 反幂 $\alpha < 0$ ($1/\text{KL}$ 加权) 会主动压制相关 teacher。
4. 反幂 $\alpha < 0$ 仅在“共享目标 + 异方差噪声”假设下 (inverse-variance / BLUE) 才最优 (命题 3)。 α 的符号本质上编码了“偏离 base 的幅度”与“可靠性”之间的先验关系。

对 OCR/PickScore/GenEval 三专家 ensemble, 理论预测 $\alpha > 0 \gg \text{uniform} \gg \alpha < 0$, 推荐以温度可调的正幂 (或 softmax-over-KL) 作为默认, 并给出失败模式与实现接口。

Contents

1 背景与问题设定	2
2 Per-Step KL 等价于 Velocity-MSE	2
3 KL 加权族与温度	3
4 核心结果: KL 加权与 PCGrad 投影可交换	3
5 加权重组的几何: $\alpha > 0$ 放大”活跃”teacher	4
6 何时 $\alpha > 0$ 最优: Specialist Routing	5
7 何时 $\alpha < 0$ 最优: 共享目标 + 异方差噪声	5
8 失败模式与偏差-方差权衡	6
9 算法与实现接口	6
10 结论与预测	7

1 背景与问题设定

`ensemble-eval` trainer 在每个去噪步把 K 个 LoRA checkpoint 的 `noise_pred` 融合后再做一次 `scheduler.step`。当前已实现的 PCGrad 家族为

$$\text{vector} \in \{\text{full velocity, residual delta}\} \times \text{projection} \in \{\text{global, channelwise, normalized}\},$$

外加 `weighted` 与 `ties` (见 `src/flow_factory/trainers/ensemble_eval/common.py`)。在所有 PCGrad 模式里, per-checkpoint 权重 w_i 默认 均匀 (或由静态的 `checkpoint_weights` 给定), 且作用在 velocity 本身上。

想法。既然每个 teacher 都是从同一 base model 微调而来, "teacher i 相对 base 偏离多少" 本身就携带信息: 它度量了该 teacher 在当前 (x_t, t, prompt) 上"想说多少话"。一个自然的提议是用 teacher-base 的 per-step KL

$$D_i = \text{KL}(p_{\phi_i}(\cdot|x_t) \| p_{\text{base}}(\cdot|x_t))$$

(下一节将证明 $D_i \propto \|v_i - v_{\text{base}}\|^2$, 即 velocity-MSE) 作为动态权重: 用 D_i 或其倒数 $1/D_i$ 去加权融合。本文回答: 这是否合理、在什么假设下有效、以及它如何与 PCGrad 相互作用。

符号约定。沿用 `teacher_aggregation_loss_formulations.tex` 与 `pcgrad_gradient_vs_velocity_analy` 的记号。所有量均为 *per-sample* (固定某个 batch 样本 b 与时间步 k , 省略上标):

符号	含义
K	ensemble 中 checkpoint (teacher) 数
$d = C \times H \times W$	latent 维度
v_{base}	base (pretrained, LoRA 关闭) 的 velocity
v_i	teacher i 的 velocity (<code>noise_pred</code>)
$\tau_i = v_i - v_{\text{base}}$	teacher i 的 task vector (residual delta)
$D_i = \ \tau_i\ ^2$	teacher-base 的 velocity-MSE ($\propto$ per-step KL)
$w_i \geq 0$	per-sample 融合权重
τ_i^{PCGrad}	对 未加权 $\{\tau_j\}$ 做 PCGrad 后的投影向量
α	加权指数: $w_i \propto D_i^\alpha$

2 Per-Step KL 等价于 Velocity-MSE

在 Flow-SDE / ODE 离散化下, 转移核是共享方差的条件高斯, 转移均值关于 velocity 仿射 (见 `teacher_aggregation_loss_formulations.tex` 式 (mu) 与代码 `flow_match_euler_discrete.py`):

$$\mu(v) = \beta_k x_{t_k} + \alpha_k v \Delta t_k, \quad \bar{\sigma}_k^2 = \sigma_{t_k}^2(-\Delta t_k), \quad (1)$$

其中 $\beta_k, \alpha_k, \bar{\sigma}_k^2$ 仅依赖 noise schedule 与时间步, 与具体模型无关。因此 teacher i 与 base 的均值差只保留 velocity 项:

$$\mu(v_i) - \mu(v_{\text{base}}) = \alpha_k \Delta t_k (v_i - v_{\text{base}}) = \alpha_k \Delta t_k \tau_i. \quad (2)$$

Proposition 1 (KL = velocity-MSE, 且 per-step 常数在归一化后抵消). 共享方差高斯的闭式 KL 给出

$$D_i = \text{KL}(\mathcal{N}(\mu(v_i), \bar{\sigma}_k^2 I) \| \mathcal{N}(\mu(v_{\text{base}}), \bar{\sigma}_k^2 I)) = \frac{\|\mu(v_i) - \mu(v_{\text{base}})\|^2}{2\bar{\sigma}_k^2} = c_k \|\tau_i\|^2, \quad (3)$$

其中 $c_k = \frac{\alpha_k^2 \Delta t_k^2}{2\bar{\sigma}_k^2} > 0$ 对所有 *teacher* 相同。在 *ODE eval* ($\bar{\sigma}_k \rightarrow 0$, 使用 *v-based* 约定) 下退化为纯 *velocity-MSE* $D_i = \|\tau_i\|^2$ 。无论哪种情形, 归一化权重

$$w_i(\alpha) = \frac{D_i^\alpha}{\sum_j D_j^\alpha} = \frac{\|\tau_i\|^{2\alpha}}{\sum_j \|\tau_j\|^{2\alpha}} \quad (4)$$

中的 c_k^α 完全抵消, 故”按 *KL* 加权”与”按 *velocity-MSE* 加权”严格等价。

Proof. (3) 是同方差高斯 *KL* 的标准结果, 代入 (2) 即得 $D_i = c_k \|\tau_i\|^2$ 。代入 (4), 分子分母同含因子 c_k^α 相消。□

Remark 1. 这正是代码中 `trainers/opd/sde.py:_compute_per_step_kl` 的量 (带 $1/(2\bar{\sigma}^2)$ 归一化或纯 *MSE*)。在 *residual PCGrad* 模式里 τ_i 已被计算 (`_pcgrad_residual_blend` 内的 `out.noise_pred - ref.noise_pred`), 故 $D_i = \|\tau_i\|^2$ 几乎零额外成本。

3 *KL* 加权族与温度

(4) 定义了一族以 α 为参数的权重:

- $\alpha = 0$: $w_i = 1/K$, 即当前的 **uniform** 加权。
- $\alpha = +1$: $w_i \propto D_i$, 即”按 *KL* 加权” (user 的提议之一)。
- $\alpha = -1$: $w_i \propto 1/D_i$, 即”按 $1/\text{KL}$ 加权” (user 的另一提议)。

等价地, $w_i = \text{softmax}_i(\alpha \log D_i)$, 即 α 是作用在 *log-KL* 上的温度。一个更”锐”的变体是直接对 *KL* 做 *softmax*: $w_i \propto \exp(\beta D_i)$ (在 *KL* 量纲上路由), $\beta \rightarrow \infty$ 时退化为 *hard routing* (只选 *KL* 最大的 *teacher*)。下文以幂族 (4) 为主 (贴合 user 提议), 必要处对照指数族。

4 核心结果: *KL* 加权与 *PCGrad* 投影可交换

实现里 *PCGrad* (`pcgrad_blend_noise_preds` 及其 *channelwise* 版本) 按如下方式操作输入 $\{g_i\}$: 对每个 i , 按固定 (可含随机但 两次运行一致的) 顺序遍历 $j \neq i$, 当 $\langle pc_i, g_j \rangle < 0$ 时

$$pc_i \leftarrow pc_i - \frac{\langle pc_i, g_j \rangle}{\|g_j\|^2} g_j \quad (\text{投影始终使用原始 } g_j), \quad (5)$$

最后输出 $\sum_i pc_i$ 。把 per-sample 标量权重 $w_i > 0$ 引入即令 $g_i = w_i \tau_i$ 。

Theorem 1 (加权-投影可交换). 设 $w_i > 0$ 为 per-sample 标量, $g_i = w_i \tau_i$ 。在 (5) 的 (*global* 或 *channelwise*) *PCGrad* 下, 对每个 i 有

$$\boxed{pc_i = w_i \tau_i^{\text{PCGrad}}} \quad (6)$$

其中 τ_i^{PCGrad} 是对 未加权 输入 $\{\tau_j\}$ 、以 相同顺序与相同冲突判定 运行 (5) 得到的投影向量。从而融合结果

$$\boxed{\sum_i pc_i = \sum_i w_i \tau_i^{\text{PCGrad}}} \quad (7)$$

即: **KL** 加权只作用在最终线性重组上, 不改变冲突检测、不改变投影方向。

Proof. 对 i 的投影序列做归纳。初始 $\text{pc}_i = g_i = w_i \tau_i = w_i \tau_i^{(0)}$, 其中 $\tau_i^{(0)} = \tau_i$ 为未加权初值。假设在某一步前 $\text{pc}_i = w_i \tau_i^{(s)}$ ($\tau_i^{(s)}$ 为未加权运行的对应中间量)。对下一个 j :

$$\langle \text{pc}_i, g_j \rangle = \langle w_i \tau_i^{(s)}, w_j \tau_j \rangle = w_i w_j \langle \tau_i^{(s)}, \tau_j \rangle.$$

由 $w_i, w_j > 0$, $\text{sign}\langle \text{pc}_i, g_j \rangle = \text{sign}\langle \tau_i^{(s)}, \tau_j \rangle$, 故 冲突判定与未加权运行完全一致。若判定冲突, 则

$$\text{pc}_i \leftarrow w_i \tau_i^{(s)} - \frac{w_i w_j \langle \tau_i^{(s)}, \tau_j \rangle}{w_j^2 \|\tau_j\|^2} w_j \tau_j = w_i \left(\tau_i^{(s)} - \frac{\langle \tau_i^{(s)}, \tau_j \rangle}{\|\tau_j\|^2} \tau_j \right) = w_i \tau_i^{(s+1)},$$

其中 w_j 在分子分母相消, 得到的正是未加权更新 $\tau_i^{(s+1)}$ 乘 w_i 。不冲突时两边同乘 w_i 也保持。归纳完成, 末态 $\text{pc}_i = w_i \tau_i^{\text{PCGrad}}$ 。channelwise 情形对每个 channel 独立重复同一论证 (w_i 是 per-sample 标量, 对所有 channel 相同), 结论不变。□

Corollary 1 (问题降维). 对 *pcgrad, pcgrad_channelwise, pcgrad_residual, pcgrad_residual_channelwise* 引入 *KL* 权重后的融合等于

$$v_{\text{fused}} = (v_{\text{base}} \text{ if residual else } 0) + \sum_i w_i \tau_i^{\text{PCGrad}} \quad (\text{full 模式中 } \tau_i^{\text{PCGrad}} \rightarrow v_i^{\text{PCGrad}}). \quad (8)$$

因此 “*KL* 加权对 *PCGrad* 是否有益” 与 “*KL* 加权对 (投影后的) 线性重组是否有益” 是 同一个问题; 是否开启 *PCGrad* 不改变这一判断的本质。下文据此聚焦于加权重组 $\bar{\tau}(\alpha) = \sum_i w_i(\alpha) \tau_i^{\text{PCGrad}}$ 。

Remark 2 (两个例外: *normalized* 与 *ties*). 定理 1 依赖 “投影对象按 w_i 线性缩放”。两个模式不满足该前提:

- **normalized:** 先把 τ_i 除以 $\|\tau_i\|$ 再投影, 重组为 $\sum_i w_i \|\tau_i\| p_i$ 。叠加 *KL* 权重 $w_i \propto \|\tau_i\|^{2\alpha}$ 后, 等效幅度变为 $\|\tau_i\|^{2\alpha+1}$ 。即 *normalized* 把 “幅度” 剥离后, *KL* 加权又以 $2\alpha+1$ 次幂把它部分加回—— $\alpha = -\frac{1}{2}$ 恰好回到纯方向 (完全剥离幅度), $\alpha = 0$ 回到原 *normalized* 行为。
- **ties:** sign 选举 $\gamma = \text{sign}(\sum_i w_i \tau_i)$ 与 *disjoint* 加权平均都显式用到 w_i , 故 *KL* 权重会改变选举与平均, 不可交换。

5 加权重组的几何: $\alpha > 0$ 放大” 活跃” teacher

由推论 1, 关键对象是 $\bar{\tau}(\alpha) = \sum_i w_i(\alpha) \tau_i^{\text{PCGrad}}$ 。先看无冲突的干净情形 ($\tau_i^{\text{PCGrad}} = \tau_i$), 则

$$\bar{\tau}(\alpha) = \frac{\sum_i \|\tau_i\|^{2\alpha} \tau_i}{\sum_j \|\tau_j\|^{2\alpha}}, \quad \|w_i(\alpha) \tau_i\| = \frac{\|\tau_i\|^{2\alpha+1}}{\sum_j \|\tau_j\|^{2\alpha}}. \quad (9)$$

单个 teacher 的贡献幅度 $\propto \|\tau_i\|^{2\alpha+1}$:

- $\alpha = 0$ (*uniform*): 贡献 $\propto \|\tau_i\|$, 简单平均。
- $\alpha = 1$ (*KL*): 贡献 $\propto \|\tau_i\|^3$, 立方放大偏离最大的 teacher。
- $\alpha = -1$ (*1/KL*): 贡献 $\propto \|\tau_i\|^{-1}$, 抑制偏离大的 teacher、放大近 base 的 teacher。

直观上, $\alpha > 0$ 把融合推向 “在当前样本上最活跃/最有主张” 的 teacher, $\alpha < 0$ 则相反。这是否可取, 取决于 “偏离大” 意味着 “相关” 还是 “噪声”——下两节用两个生成模型给出严格判别。

6 何时 $\alpha > 0$ 最优: Specialist Routing

Definition 1 (Disjoint-specialist 模型). 在 (x_t, t, prompt) 上存在唯一”相关 teacher” s : 其 task vector 为真实修正 $\tau_s = ru$ ($\|u\| = 1, r > 0$); 其余 off-domain teacher 近似沉默, $\|\tau_i\| = \epsilon_i \ll r$ ($i \neq s$), 方向任意。

Proposition 2 (KL 加权实现软路由). 在定义 1 下, 对无冲突情形 (或由定理 1, off-domain 很小不改变定性结论) 的加权融合 (9):

$$\alpha \rightarrow +\infty: \bar{\tau} \rightarrow \tau_s = ru \quad (\text{精确恢复相关修正}); \quad (10)$$

$$\alpha = 1: \bar{\tau} = \frac{r^3 u + \sum_{i \neq s} \epsilon_i^2 \tau_i}{r^2 + \sum_{i \neq s} \epsilon_i^2} = ru \left(1 + O(\epsilon^2/r^2)\right); \quad (11)$$

$$\alpha = 0: \bar{\tau} = \frac{1}{K} \left(ru + \sum_{i \neq s} \tau_i\right) \approx \frac{r}{K} u \quad (\text{方向被稀释、幅度欠修正 } 1/K); \quad (12)$$

$$\alpha = -1: \bar{\tau} = \frac{r^{-1}u + \sum_{i \neq s} \epsilon_i^{-2} \tau_i}{r^{-2} + \sum_{i \neq s} \epsilon_i^{-2}} \xrightarrow{\epsilon_i \ll r} \text{由 off-domain 噪声主导}. \quad (13)$$

即 $\alpha > 0$ 恢复相关 teacher 的修正; uniform 把信号按 $1/K$ 稀释且方向被 off-domain 污染; $\alpha < 0$ 主动压制相关 teacher、放大最不自信者。

Proof. 直接代入 (9)。 $\alpha \rightarrow +\infty$ 时 $w_s \rightarrow 1$ (r 严格最大)。 $\alpha = 1$: 分子 $r^2 \cdot ru = r^3 u$ 主导, 余项 $O(\epsilon^2) \cdot O(\epsilon) = O(\epsilon^3)$, 分母 $r^2 + O(\epsilon^2)$, 相除得 $ru(1 + O(\epsilon^2/r^2))$ 。 $\alpha = 0$: K 项平均, ru 被 $K - 1$ 个近零向量稀释为 $\approx ru/K$ 。 $\alpha = -1$: 权重 $\propto \epsilon_i^{-2} \gg r^{-2}$, 分母 $\approx \sum \epsilon_i^{-2}$, 分子相关项 $r^{-1}u$ 相对 $\sum \epsilon_i^{-2} \tau_i$ (量级 $\sum \epsilon_i^{-1}$) 可忽略。 $\square$

Remark 3 (与 PCGrad 的协同). 当 off-domain teacher 不仅沉默而且与 s 冲突时, PCGrad 会把 τ_s 沿冲突方向的分量投掉 (τ_s^{PCGrad}), 而 KL 权重保证最终重组仍以 s 为主——二者作用正交且互补: PCGrad 处理方向冲突, KL 权重处理”由谁主导”。这正是定理 1 的实际意义。

Remark 4 (ensemble-eval 即 specialist 制度). OCR / PickScore / GenEval 三个 teacher 在不同目标上专精。对一条 OCR prompt, OCR teacher 已学到文字渲染, $\|\tau_{\text{OCR}}\|$ 大; PickScore/GenEval teacher 多半接近 base (ϵ 小)。故本设定贴合定义 1, 理论预测 $\alpha > 0$ 显著优于 uniform, $\alpha < 0$ 最差。

7 何时 $\alpha < 0$ 最优: 共享目标 + 异方差噪声

反幂并非永远错——它在相反的生成假设下才是最优估计。

Definition 2 (Shared-target heteroscedastic 模型). 所有 teacher 估计同一真实修正 τ^* , 带独立零均值噪声: $\tau_i = \tau^* + \eta_i$, $\eta_i \sim \mathcal{N}(0, \sigma_i^2 I_d)$, 且偏离幅度随噪声单调, $\mathbb{E}\|\tau_i\|^2 = \|\tau^*\|^2 + d\sigma_i^2$ (”偏离大 = 更不可靠”)。

Proposition 3 (inverse-variance 最优). 在定义 2 下, 线性无偏估计 $\sum_i a_i \tau_i$ ($\sum a_i = 1$) 中方差最小者 (BLUE) 取 $a_i \propto 1/\sigma_i^2$ 。若以 $D_i = \|\tau_i\|^2$ 近似 $d\sigma_i^2$ (高维下 $\|\eta_i\|^2 \approx d\sigma_i^2$ 集中), 则 $w_i \propto 1/D_i$, 即 $\alpha = -1$, 且此时 $\bar{\tau}$ 是 τ^* 的最小方差无偏估计。

Proof. 独立高斯下 $\text{Var}(\sum a_i \tau_i) = \sum a_i^2 \sigma_i^2$, 在 $\sum a_i = 1$ 约束下用 Lagrange 乘子得 $a_i \propto 1/\sigma_i^2$ (标准 inverse-variance weighting)。高维集中 $\|\eta_i\|^2/d \rightarrow \sigma_i^2$ 给出 $D_i \approx \|\tau^*\|^2 + d\sigma_i^2$, 当 $\sigma_i^2 d \gg \|\tau^*\|^2$ 时 $D_i \approx d\sigma_i^2$, 故 $1/D_i \propto 1/\sigma_i^2$ 。 $\square$

判别准则： α 的符号编码先验

生成假设	” 偏离大 ” 含义	最优 α
Disjoint specialists (各 teacher 专精)	相关 / 信号	$\alpha > 0$ (KL 加权)
Shared target + 异方差噪声	噪声 / 不可靠	$\alpha < 0$ (1/KL 加权)
同质、等可靠	无信息	$\alpha = 0$ (uniform)

`ensemble-eval` (OCR/PickScore/GenEval) 属第一行 $\Rightarrow$ 预测 $\alpha > 0$ 。

8 失败模式与偏差-方差权衡

$\alpha > 0$ 的风险：自信但错误的 **teacher**。若某 off-domain teacher 在 out-of-domain 样本上自信地错 ($\|\tau_W\|$ 大但方向错)，则 $\alpha = 1$ 会按 $\|\tau_W\|^3$ 放大它。PCGrad 只能投掉与他人冲突的方向分量 (定理 1 表明权重不改变这一投影)，无法阻止其在重组中以大权重主导。因此 α 越大，偏差越低但对”自信错误”越敏感 (方差/鲁棒性变差) ——这是一个标准的偏差-方差/路由锐度权衡。

缓解。

1. 温度退火：取 $\alpha \in (0, 1]$ 而非直接 $+\infty$ ；或用 softmax-over-KL 加温度，限制单 teacher 权重上限。
2. 与 **normalized** 组合：normalized 把投影对象的幅度剥离 (注记 2)，可削弱”自信错误”在投影阶段的几何主导；KL 权重仍控制重组占比，二者可分别调。
3. **Clip** / 截断：对 w_i 设上限或对 D_i 做分位裁剪，避免极端样本的退化。
4. 诊断：训练/评测时记录 per-teacher per-domain 的 $\mathbb{E}\|\tau_i\|$ ，验证定义 1 的”on-domain 偏离最大”假设是否成立 (可复用现有 PCGrad 统计的日志通路)。

9 算法与实现接口

由定理 1，KL 加权 无需改动 PCGrad 内核：只需把现有 `_blend_velocity_set` 的 `weights` 由静态标量改为 *per-sample* 动态权重 $w_i(\alpha)$ (形状 $(B,)$)，其余复用残差路径已计算的 τ_i 。

已实现接口。本方案已落地为配置开关 `ensemble_blend_weighting` $\in \{\text{uniform, kl, kl_inv}\}$ (`kl` 即 $\alpha=+1$, `kl\_inv` 即 $\alpha=-1$, `uniform` 即静态权重)。per-sample 权重由 `_dynamic_kl_weights` 计算并经 `_resolve_blend_weights` 注入 `_pcgrad_residual_blend` / `_ties_blend`；因需要 v_{base} ，该开关仅对 base-anchored 模式 (`pcgrad_residual` 系列与 `ties`) 有效，其余模式会显式报错。per-teacher 平均权重会记入 `PCGradStats` / `TIESStats` 的 `summary` 以便核验路由。

Algorithm 1 KL-Weighted Residual Fusion (per denoising step, per sample)

```

1:  $v_{\text{base}} \leftarrow \text{base forward}(x_t, t)$  ▷ LoRA 关闭，残差模式已做
2: for  $i = 1, \dots, K$  do ▷ 各 teacher 前向
3:    $\tau_i \leftarrow v_i - v_{\text{base}}$ 
4:    $D_i \leftarrow \|\tau_i\|^2$  ▷ per-sample KL ( $\alpha$ )，免费复用
5: end for
6:  $w_i \leftarrow D_i^\alpha / \sum_j D_j^\alpha$  ▷  $\alpha > 0$  路由； $\alpha < 0$  inverse-variance；含 eps 防 0
7:  $\{\tau_i^{\text{PCGrad}}\} \leftarrow \text{PCGrad}(\{\tau_i\})$  ▷ 在未加权残差上投影 (可选 global/channelwise)
8: return  $v_{\text{base}} + \sum_i w_i \tau_i^{\text{PCGrad}}$  ▷ KL 加权重组

```

数值与一致性要点：

- D_i 加 **eps** 下限后再取幂，避免 $\alpha < 0$ 时除零；权重做归一化使 $\sum_i w_i = 1$ （保持 no-conflict $\Rightarrow$ weighted 的可比性）。
- per-step 常数 c_k 已由归一化抵消（命题 1），无需显式处理 $\bar{\sigma}_k, \Delta t_k$ 。
- 该加权与 global/channelwise 投影 严格可交换（定理 1）；与 normalized/ties 组合时行为见 注记 2，需单独验证。
- 静态 **checkpoint_weights** π_i 可与动态权重相乘： $w_i \propto \pi_i D_i^\alpha$ （先验 $\times$ per-sample 证据）。

10 结论与预测

1. **KL = velocity-MSE**: teacher-base 的 per-step KL 严格正比于 $\|v_i - v_{\text{base}}\|^2$ ，且 per-step 常数在归一化后抵消（命题 1）。
2. 加权与 **PCGrad** 可交换（定理 1）：对 global/channelwise，KL 加权只改变最终线性重组，不改变冲突结构。故“KL 加权 + PCGrad”=“PCGrad（未加权）后做 KL 加权求和”。
3. 符号由制度决定：specialist ensemble $\Rightarrow \alpha > 0$ （软路由，命题 2）；shared-target heteroscedastic $\Rightarrow \alpha < 0$ （inverse-variance，命题 3）。
4. 对 **ensemble-eval** 的预测：OCR/PickScore/GenEval 属 specialist 制度，预期

$$\alpha > 0 \text{ (KL 加权)} \gg \alpha = 0 \text{ (uniform)} \gg \alpha < 0 \text{ (1/KL 加权)}.$$

建议先验证 $\alpha = 1$ 于 **pcgrad_residual / weighted**（残差）之上，再以温度（ $\alpha \in [0.5, 2]$ 或 softmax-over-KL）扫描锐度，并监控“自信错误”失败模式。

一句话回答。 user 的提议在本 ensemble 设定下方向正确：按 KL（velocity-MSE）正向加权（而非取倒数）等价于按“每个 teacher 偏离 base 的程度”做 per-sample 软路由，理论上可恢复相关专家的修正、优于均匀融合；取倒数只有在“teacher 共享同一目标、偏离即噪声”时才合理，与本设定相悖。且由于 KL 加权与 PCGrad 投影可交换，它是一个低成本、可与现有任意 projection 叠加的正交改进。