

Gradient-Space vs. Velocity-Space PCGrad

Pathwise Loss 下的性质分析

Flow Factory

Abstract

本文在只保留 pathwise 项 ($\lambda_{\text{rf}} = 0$) 的设定下, 对 PCGrad 分别作用于 gradient space ($\mathbb{R}^P$) 和 velocity space ($\mathbb{R}^d$) 时的数学性质进行严格对比分析。重点阐明两者在冲突检测准则、投影算子、等价条件、以及 per-sample 粒度等方面的本质差异。

Contents

1	设定与符号	2
1.1	基础量	2
1.2	Per-Teacher Pathwise Loss	2
1.3	Per-Teacher Gradient (精确形式)	2
2	两种 PCGrad 的精确定义	2
2.1	Gradient-Space PCGrad (G-PCGrad)	2
2.2	Velocity-Space PCGrad (V-PCGrad)	2
3	冲突检测准则的本质差异	3
3.1	G-PCGrad: Fisher Metric 下的全局冲突	3
3.2	V-PCGrad: Euclidean Metric 下的 Per-Sample 冲突	3
3.3	对比: 何时两者检测到不同的冲突	4
4	投影算子的对比	4
4.1	单次投影的精确形式	4
4.2	投影系数的差异	5
5	精确等价条件	5
5.1	条件 1: 单样本 Batch (B=1) + 正交 Jacobian	5
5.2	条件 2: Batch-Homogeneous Jacobian	5
5.3	条件 3: 退化为 Sum 的边界	5
6	度量结构差异: $\mathbf{I}_d$ vs $\mathbf{J}\mathbf{J}^T$	6
6.1	G-PCGrad 隐含的 Mahalanobis 度量	6
6.2	V-PCGrad 使用的 Euclidean 度量	6
6.3	何时各向异性显著	6
7	Per-Sample 粒度的影响	6
7.1	G-PCGrad 的 Batch-Averaging 效应	6
7.2	形式化: V-PCGrad 的有效梯度分解	7
7.3	Per-Sample 粒度的代价	7

8	投影后的梯度结构对比	7
8.1	G-PCGrad 输出的线性结构	7
8.2	V-PCGrad 输出的非线性到参数空间映射	7
8.3	对比总结	8
9	近似误差的界	8
9.1	设定	8
9.2	单样本情形的误差	8
9.3	多样本情形的额外误差源	9
10	不动点与收敛性质	9
10.1	共同不动点	9
10.2	非零不动点的差异	9
11	计算复杂度与数值稳定性	10
12	总结与实践建议	11

1 设定与符号

只考虑 pathwise 项 ($\lambda_{\text{rf}} = 0$)，时间步索引 k 在本文中固定省略。

1.1 基础量

- Batch size B ，latent 维度 $d = C \times H \times W$ ，可训练参数维度 P 。
- Student 转移均值 (per-sample): $\mu_\theta^{(b)} \in \mathbb{R}^d$ ， $b = 1, \dots, B$ 。
- Teacher m 转移均值: $\mu_\phi^{(m),(b)} \in \mathbb{R}^d$ 。
- Velocity residual: $v_m^{(b)} = \mu_\phi^{(m),(b)} - \mu_\theta^{(b)} \in \mathbb{R}^d$ 。
- 误差向量: $\delta_m^{(b)} = \mu_\theta^{(b)} - \mu_\phi^{(m),(b)} = -v_m^{(b)}$ 。
- Per-sample Jacobian: $J^{(b)} = \nabla_\theta \mu_\theta^{(b)} \in \mathbb{R}^{d \times P}$ 。
- 常数因子: $c = \frac{\lambda_{\text{path}}}{\bar{\sigma}_k^2 d B}$ 。

1.2 Per-Teacher Pathwise Loss

$$\ell^{(m)}(\theta) = \frac{\lambda_{\text{path}}}{2\bar{\sigma}_k^2 d} \cdot \frac{1}{B} \sum_{b=1}^B \|\mu_\theta^{(b)} - \mu_\phi^{(m),(b)}\|^2 = \frac{c}{2} \sum_{b=1}^B \|\delta_m^{(b)}\|^2 \quad (1)$$

1.3 Per-Teacher Gradient (精确形式)

$$g_m = \nabla_\theta \ell^{(m)} = c \sum_{b=1}^B (\delta_m^{(b)})^\top J^{(b)} = -c \sum_{b=1}^B (v_m^{(b)})^\top J^{(b)} \in \mathbb{R}^P \quad (2)$$

2 两种 PCGrad 的精确定义

2.1 Gradient-Space PCGrad (G-PCGrad)

在参数空间 $\mathbb{R}^P$ 上操作。

冲突检测:

$$\langle g_i, g_j \rangle = c^2 \sum_{b=1}^B \sum_{b'=1}^B (v_i^{(b)})^\top J^{(b)} (J^{(b')})^\top v_j^{(b')} \quad (3)$$

投影: 若 $\langle g_i, g_j \rangle < 0$,

$$\tilde{g}_i \leftarrow \tilde{g}_i - \frac{\langle \tilde{g}_i, g_j \rangle}{\|g_j\|^2} g_j \quad (4)$$

输出:

$$g^G = \sum_{m=1}^M \tilde{g}_m \in \mathbb{R}^P \quad (5)$$

2.2 Velocity-Space PCGrad (V-PCGrad)

在 latent 空间 $\mathbb{R}^d$ 上 per-sample 独立操作。

冲突检测 (**per-sample**):

$$\langle v_i^{(b)}, v_j^{(b)} \rangle_d = \sum_{l=1}^d v_i^{(b,l)} v_j^{(b,l)} \in \mathbb{R}, \quad \forall b \quad (6)$$

投影 (**per-sample**): 若 $\langle v_i^{(b)}, v_j^{(b)} \rangle_d < 0$,

$$\tilde{v}_i^{(b)} \leftarrow \tilde{v}_i^{(b)} - \frac{\langle \tilde{v}_i^{(b)}, v_j^{(b)} \rangle_d}{\|v_j^{(b)}\|^2} v_j^{(b)} \quad (7)$$

Fused target & 有效梯度:

$$v^{\text{fused},(b)} = \sum_m \tilde{v}_m^{(b)}, \quad (8)$$

$$g^V = -c \sum_{b=1}^B (v^{\text{fused},(b)})^\top J^{(b)} = -c \sum_{b=1}^B \left(\sum_m \tilde{v}_m^{(b)} \right)^\top J^{(b)} \in \mathbb{R}^P \quad (9)$$

3 冲突检测准则的本质差异

3.1 G-PCGrad: Fisher Metric 下的全局冲突

将 (3) 展开并引入 Gram 矩阵:

Definition 1 (Empirical Neural Tangent Gram Matrix).

$$G^{(b,b')} = J^{(b)} (J^{(b')})^\top \in \mathbb{R}^{d \times d} \quad (10)$$

$G^{(b,b)}$ 是 per-sample 的 empirical Fisher (在输出空间中的 metric tensor)。

G-PCGrad 的冲突准则可写为:

$$\boxed{\langle g_i, g_j \rangle = c^2 \sum_{b,b'} (v_i^{(b)})^\top G^{(b,b')} v_j^{(b')} < 0} \quad (11)$$

这是一个全局准则: 它同时混合了:

1. 跨样本的交叉项: $b \neq b'$ 时 $G^{(b,b')} = J^{(b)} (J^{(b')})^\top$ 耦合不同样本。
2. 参数空间的 **metric** 结构: 通过 $J^\top J$ 引入了 neural tangent kernel 的几何。

3.2 V-PCGrad: Euclidean Metric 下的 Per-Sample 冲突

V-PCGrad 的冲突准则为:

$$\boxed{\langle v_i^{(b)}, v_j^{(b)} \rangle_d = (v_i^{(b)})^\top \mathbf{I}_d v_j^{(b)} < 0, \quad \forall b \text{ 独立判断}} \quad (12)$$

这是:

1. **Per-sample** 独立: 每个样本独立判断冲突, 无跨样本耦合。
2. **Euclidean metric**: 使用 $\mathbf{I}_d$ (恒等矩阵) 而非 $G^{(b,b)}$ 。

3.3 对比：何时两者检测到不同的冲突

Proposition 1 (冲突检测不一致). 存在以下情况使得 G-PCGrad 与 V-PCGrad 的冲突判断不同:

- (a) **Per-sample** 冲突但全局无冲突: 对某些样本 b , $\langle v_i^{(b)}, v_j^{(b)} \rangle_d < 0$ (V-PCGrad 检测到冲突), 但 $\langle g_i, g_j \rangle \geq 0$ (G-PCGrad 不检测为冲突), 因为其他样本的正贡献主导了全局内积。
- (b) 全局冲突但 **per-sample** 无冲突: 所有样本 $\langle v_i^{(b)}, v_j^{(b)} \rangle_d \geq 0$ (V-PCGrad 无冲突), 但 $\langle g_i, g_j \rangle < 0$ (G-PCGrad 检测到冲突), 因为跨样本交叉项 $G^{(b,b')}$ 的非对角结构引入了额外的负贡献。
- (c) **Metric** 导致的冲突翻转: 即使 $B = 1$, $\langle v_i, v_j \rangle_d > 0$ (V-PCGrad 无冲突), 但 $v_i^\top G v_j < 0$ (G-PCGrad 检测到冲突), 因为 $G = J J^\top$ 在某些方向上的 stretch 改变了角度关系。

构造示例 (c). 设 $d = 2$, $P = 2$, $B = 1$ 。取 $J = \begin{pmatrix} 1 & 0 \\ 0 & -2 \end{pmatrix}$, 则 $G = J J^\top = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix}$ 。

取 $v_i = (1, 1)^\top$, $v_j = (1, -0.3)^\top$ 。

- V-PCGrad: $\langle v_i, v_j \rangle_d = 1 - 0.3 = 0.7 > 0$, 无冲突。
- G-PCGrad: $v_i^\top G v_j = 1 \cdot 1 + 4 \cdot 1 \cdot (-0.3) = 1 - 1.2 = -0.2 < 0$, 有冲突。

G 在第二维度的放大 (因为 J 对第二维度梯度贡献更大) 使得 v_j 的负分量被放大, 导致在参数空间中产生了 latent 空间中不可见的冲突。□

4 投影算子的对比

4.1 单次投影的精确形式

假设只有 $M = 2$ 个 teacher 且检测到冲突。记投影后的结果。

G-PCGrad 投影:

$$\tilde{g}_1 = g_1 - \frac{\langle g_1, g_2 \rangle}{\|g_2\|^2} g_2 \quad (13)$$

代入 (2):

$$\tilde{g}_1 = -c \sum_b (v_1^{(b)})^\top J^{(b)} + \frac{\sum_{b,b'} (v_1^{(b)})^\top G^{(b,b')} v_2^{(b')}}{\sum_{b,b'} (v_2^{(b)})^\top G^{(b,b')} v_2^{(b')}} \cdot c \sum_{b''} (v_2^{(b'')})^\top J^{(b'')} \quad (14)$$

V-PCGrad 投影 (**per-sample**):

$$\tilde{v}_1^{(b)} = v_1^{(b)} - \frac{\langle v_1^{(b)}, v_2^{(b)} \rangle_d}{\|v_2^{(b)}\|_d^2} v_2^{(b)}, \quad \forall b \quad (15)$$

对应的有效梯度:

$$g^V = -c \sum_b (\tilde{v}_1^{(b)} + \tilde{v}_2^{(b)})^\top J^{(b)} \quad (16)$$

4.2 投影系数的差异

Definition 2 (投影系数). G-PCGrad 使用全局标量投影系数:

$$\alpha^G = \frac{\langle g_1, g_2 \rangle}{\|g_2\|^2} = \frac{\sum_{b,b'} (v_1^{(b)})^\top G^{(b,b')} v_2^{(b')}}{\sum_{b,b'} (v_2^{(b)})^\top G^{(b,b')} v_2^{(b')}} \in \mathbb{R} \quad (17)$$

V-PCGrad 使用 **per-sample** 标量投影系数:

$$\alpha^{V,(b)} = \frac{\langle v_1^{(b)}, v_2^{(b)} \rangle_d}{\|v_2^{(b)}\|_d^2} = \frac{(v_1^{(b)})^\top v_2^{(b)}}{(v_2^{(b)})^\top v_2^{(b)}} \in \mathbb{R}, \quad \forall b \quad (18)$$

Remark 1 (关键区别). α^G 是所有样本共享的单一系数 (batch-global), 而 $\alpha^{V,(b)}$ 是 per-sample 自适应的。这意味着 V-PCGrad 可以对不同样本施加不同强度的投影, 而 G-PCGrad 对所有样本统一“一刀切”。

5 精确等价条件

Proposition 2 (充分等价条件). G-PCGrad 与 V-PCGrad 产生完全相同的参数更新方向 ($g^G \propto g^V$), 当且仅当以下任一条件成立:

5.1 条件 1: 单样本 Batch (B=1) + 正交 Jacobian

当 $B = 1$ 时无跨样本混合。此时:

$$\alpha^G = \frac{v_1^\top (JJ^\top) v_2}{v_2^\top (JJ^\top) v_2}, \quad (19)$$

$$\alpha^V = \frac{v_1^\top v_2}{v_2^\top v_2}. \quad (20)$$

若 J 满足 $JJ^\top = \sigma^2 \mathbf{I}_d$ (各向同性, 即 J 的行向量正交等模), 则 $\alpha^G = \alpha^V$, 投影方向完全一致。

Corollary 1. 若 J 为正交矩阵 ($d \leq P$ 且行正交归一化), 则 $B = 1$ 时两者精确等价。

5.2 条件 2: Batch-Homogeneous Jacobian

Proposition 3. 若所有样本共享相同的 Jacobian $J^{(b)} = J$ (与输入无关), 则:

$$g_m = -c B \cdot \bar{v}_m^\top J, \quad \text{where } \bar{v}_m = \frac{1}{B} \sum_b v_m^{(b)} \quad (21)$$

G-PCGrad 简化为对 batch-averaged velocity $\bar{v}_m$ 在 $G = JJ^\top$ metric 下的投影:

$$\alpha^G = \frac{\bar{v}_1^\top G \bar{v}_2}{\bar{v}_2^\top G \bar{v}_2} \quad (22)$$

V-PCGrad 仍是 per-sample 的。两者等价要求额外满足 $G \propto \mathbf{I}_d$ 。

5.3 条件 3: 退化为 Sum 的边界

当所有 teacher 的 velocity 共线 ($v_m^{(b)} = c_m \cdot u^{(b)}$, $c_m > 0$), 无论哪种 PCGrad 都不触发投影 (内积恒正)。两者退化为等价的 sum 模式。

6 度量结构差异: $\mathbf{I}_d$ vs $\mathbf{J}\mathbf{J}^\top$

6.1 G-PCGrad 隐含的 Mahalanobis 度量

G-PCGrad 的冲突检测等价于在 latent 空间中使用 **Mahalanobis** 度量 $G = \mathbf{J}\mathbf{J}^\top$:

$$\text{G-PCGrad conflict} \Leftrightarrow v_i^\top (\mathbf{J}\mathbf{J}^\top) v_j < 0 \Leftrightarrow \langle v_i, v_j \rangle_G < 0 \quad (23)$$

Remark 2 (物理含义). $G = \mathbf{J}\mathbf{J}^\top$ 描述了“latent 空间中哪些方向更容易被参数变化改变”。 G 的大特征值方向对应“敏感方向”——参数的小变化即可引起该方向的大变化。G-PCGrad 在冲突检测时放大了敏感方向的权重，即更关注那些“参数空间中实际上会冲突”的方向。

6.2 V-PCGrad 使用的 Euclidean 度量

V-PCGrad 等价于假设 $G = \mathbf{I}_d$, 即:

$$\text{V-PCGrad conflict} \Leftrightarrow v_i^\top \mathbf{I}_d v_j < 0 \Leftrightarrow \langle v_i, v_j \rangle_{\text{Euclid}} < 0 \quad (24)$$

这忽略了 Jacobian 引入的各向异性。

6.3 何时各向异性显著

Proposition 4 (条件数的影响). 设 $G^{(b,b)} = J^{(b)}(J^{(b)})^\top$ 的条件数为 $\kappa(G)$ 。当 $\kappa(G) \gg 1$ 时 (Jacobian 高度各向异性), G-PCGrad 和 V-PCGrad 的冲突判断差异最大。具体地:

存在 velocity 对 (v_i, v_j) 使得两者冲突判断相反, 当且仅当

$$\kappa(G) > \frac{1 + |\cos \angle(v_i, v_j)|}{1 - |\cos \angle(v_i, v_j)|} \quad (25)$$

其中 $\angle(v_i, v_j)$ 是 Euclidean 度量下的夹角。

Remark 3 (实际网络中的 κ). 对于深度网络, $\mathbf{J}\mathbf{J}^\top$ 的谱通常高度不均匀 (少数方向 singular value 很大), $\kappa(G) \gg 1$ 是常态。这意味着 V-PCGrad 的近似在理论上可能遗漏 (或误报) 一些“参数空间中真正的冲突”。但在实践中, 由于 V-PCGrad 的 per-sample 粒度优势 (见第 7 节), 这一劣势可被部分补偿。

7 Per-Sample 粒度的影响

7.1 G-PCGrad 的 Batch-Averaging 效应

G-PCGrad 的冲突判据 (11) 是对整个 **batch** 的聚合。这意味着:

Example 1 (冲突被 averaging 掩盖). 设 $B = 2$, 两个 teacher。样本 1 严重冲突, 样本 2 强一致:

$$v_1^{(1)} = (1, 0)^\top, v_2^{(1)} = (-1, 0)^\top \Rightarrow \langle v_1^{(1)}, v_2^{(1)} \rangle = -1 \quad (26)$$

$$v_1^{(2)} = (0, 1)^\top, v_2^{(2)} = (0, 1)^\top \Rightarrow \langle v_1^{(2)}, v_2^{(2)} \rangle = +1 \quad (27)$$

假设 $J^{(1)} = J^{(2)} = \mathbf{I}$, 则:

$$\langle g_1, g_2 \rangle = \langle v_1^{(1)}, v_2^{(1)} \rangle + \langle v_1^{(2)}, v_2^{(2)} \rangle = -1 + 1 = 0 \quad (28)$$

G-PCGrad: 全局内积 = 0, 不触发投影。样本 1 的严重冲突被样本 2 的一致性完全抵消。

V-PCGrad: 对样本 1 检测到冲突并投影, 对样本 2 不投影。保留了 **per-sample** 的冲突解决能力。

7.2 形式化：V-PCGrad 的有效梯度分解

Proposition 5 (Per-sample 自适应性). V-PCGrad 的有效梯度可分解为：

$$g^V = -c \sum_{b=1}^B \left(\sum_m \tilde{v}_m^{(b)} \right)^\top J^{(b)} = -c \sum_{b=1}^B (v^{\text{fused},(b)})^\top J^{(b)} \quad (29)$$

其中 $v^{\text{fused},(b)}$ 是 **per-sample** 自适应的融合方向：

- 对冲突样本： $v^{\text{fused},(b)}$ 偏离了 $\sum_m v_m^{(b)}$ 的方向（去除了冲突分量）。
- 对一致样本： $v^{\text{fused},(b)} = \sum_m v_m^{(b)}$ （无投影发生）。

相比之下，G-PCGrad 的输出 $\tilde{g}_m$ 是“一刀切”的：对所有样本施加相同的投影系数 α^G 。

7.3 Per-Sample 粒度的代价

V-PCGrad 的 per-sample 操作在以下情况下可能过于“激进”：

Example 2 (噪声导致的虚假 per-sample 冲突). 如果 teacher 输出含噪声，个别样本可能因噪声出现 $\langle v_i^{(b)}, v_j^{(b)} \rangle < 0$ ，即使 teacher 在“population 层面”并无真实冲突。V-PCGrad 会对这些样本做投影，而 G-PCGrad 通过 batch averaging 天然地平滑了噪声。

8 投影后的梯度结构对比

8.1 G-PCGrad 输出的线性结构

G-PCGrad 的投影在 $\mathbb{R}^P$ 中是线性的（投影矩阵作用于梯度向量）：

$$\tilde{g}_1 = \left(\mathbf{I}_P - \frac{g_2 g_2^\top}{\|g_2\|^2} \right) g_1 = \Pi_{g_2^\perp} g_1 \quad (30)$$

其中 $\Pi_{g_2^\perp} = \mathbf{I}_P - \hat{g}_2 \hat{g}_2^\top$ 是到 $g_2^\perp$ 的正交投影。最终梯度：

$$g^G = \Pi_{g_2^\perp} g_1 + g_2 \quad (31)$$

Remark 4. 投影后 $\langle \tilde{g}_1, g_2 \rangle = 0$ ：teacher 1 的梯度被调整为与 teacher 2 正交（在 $\mathbb{R}^P$ 中）。

8.2 V-PCGrad 输出的非线性到参数空间映射

V-PCGrad 在 latent 空间做投影后映射回参数空间：

$$g^V = -c \sum_b \left(\Pi_{v_2^{(b)\perp}} v_1^{(b)} + v_2^{(b)} \right)^\top J^{(b)} \quad (32)$$

其中 $\Pi_{v_2^{(b)\perp}} = \mathbf{I}_d - \hat{v}_2^{(b)} (\hat{v}_2^{(b)})^\top$ 是在 $\mathbb{R}^d$ 中的正交投影。

Proposition 6 (V-PCGrad 不保证参数空间正交性). 一般而言：

$$\langle g_{\text{teacher 1 contribution}}^V, g_2 \rangle \neq 0 \quad (33)$$

即 V-PCGrad 投影后，teacher 1 的贡献在参数空间中不一定与 g_2 正交。正交性仅在 latent 空间中 per-sample 地成立： $\langle \tilde{v}_1^{(b)}, v_2^{(b)} \rangle_d = 0$ 。

Proof. 设 $B = 1$ ，投影后 $\tilde{v}_1 \perp v_2$ （在 $\mathbb{R}^d$ 中）。参数空间内积：

$$\tilde{v}_1^\top J \cdot J^\top v_2 = \tilde{v}_1^\top G v_2 \quad (34)$$

由于 $G \neq \mathbf{I}_d$ （一般情况）， $\tilde{v}_1 \perp v_2$ 并不保证 $\tilde{v}_1^\top G v_2 = 0$ 。□

8.3 对比总结

性质	G-PCGrad	V-PCGrad
投影后正交保证	$\tilde{g}_1 \perp g_2$ 在 $\mathbb{R}^P$ 中	$\tilde{v}_1^{(b)} \perp v_2^{(b)}$ 在 $\mathbb{R}^d$ 中
参数空间正交	✓ 精确	✗ 不保证
Per-sample 正交	✗ 不保证	✓ 精确

9 近似误差的界

9.1 设定

假设 $M = 2$, G-PCGrad 检测到冲突, 产出 g^G . V-PCGrad 在部分样本上检测到冲突, 产出 g^V . 定义近似误差:

$$\varepsilon = g^V - g^G \quad (35)$$

9.2 单样本情形的误差

当 $B = 1$ 时 (无跨样本差异), 误差纯粹来自度量差异:

$$g^G = -c \left(v_1 - \frac{v_1^\top G v_2}{v_2^\top G v_2} v_2 + v_2 \right)^\top J \quad (36)$$

$$g^V = -c \left(v_1 - \frac{v_1^\top v_2}{v_2^\top v_2} v_2 + v_2 \right)^\top J \quad (37)$$

$$\varepsilon = -c \left(\frac{v_1^\top G v_2}{v_2^\top G v_2} - \frac{v_1^\top v_2}{v_2^\top v_2} \right) v_2^\top J = -c \Delta\alpha \cdot v_2^\top J \quad (38)$$

其中投影系数差异为:

$$\Delta\alpha = \alpha^G - \alpha^V = \frac{v_1^\top G v_2}{v_2^\top G v_2} - \frac{v_1^\top v_2}{v_2^\top v_2} \quad (39)$$

Proposition 7 (投影系数差的上界). 设 G 的特征值为 $\lambda_1 \geq \dots \geq \lambda_d > 0$, 条件数 $\kappa = \lambda_1/\lambda_d$. 则:

$$|\Delta\alpha| \leq \frac{\kappa - 1}{\kappa + 1} \cdot \frac{\|v_1\|}{\|v_2\|} \quad (40)$$

当 $\kappa = 1$ (各向同性) 时 $\Delta\alpha = 0$ (精确等价)。

Proof. 设 $G = Q\Lambda Q^\top$ (特征分解), $u_i = Q^\top v_i$. 则:

$$\alpha^G = \frac{\sum_l \lambda_l u_{1l} u_{2l}}{\sum_l \lambda_l u_{2l}^2}, \quad \alpha^V = \frac{\sum_l u_{1l} u_{2l}}{\sum_l u_{2l}^2} \quad (41)$$

设 $w_l = u_{2l}^2 / \sum_{l'} u_{2l'}^2$ (归一化权重), 则 $\alpha^V = \sum_l w_l (u_{1l}/u_{2l}) \dots$ (略, 通过 Kantorovich 不等式得到上界)。

更直接地: $|\Delta\alpha| = |v_1^\top (G/\|Gv_2\|_*^2 - \mathbf{I}/\|v_2\|^2) v_2|$, 利用 Rayleigh quotient 的变化范围 $[\lambda_d, \lambda_1]$ 及 $\|v_1\|$ 的 Cauchy-Schwarz 界即得。□

9.3 多样本情形的额外误差源

当 $B > 1$ 时，除度量差异外还有粒度差异导致的误差：

- G-PCGrad 用单一 α^G 对所有样本统一投影。
- V-PCGrad 用 per-sample 的 $\alpha^{V,(b)}$ ，且可能仅对部分样本触发投影。

设冲突样本集 $\mathcal{C} = \{b : \langle v_1^{(b)}, v_2^{(b)} \rangle_d < 0\}$ ，非冲突集 $\mathcal{C}^c$ 。V-PCGrad 的有效梯度为：

$$g^V = -c \left[\sum_{b \in \mathcal{C}} (\tilde{v}_1^{(b)} + v_2^{(b)})^\top J^{(b)} + \sum_{b \in \mathcal{C}^c} (v_1^{(b)} + v_2^{(b)})^\top J^{(b)} \right] \quad (42)$$

而 G-PCGrad（若全局检测到冲突）对所有样本统一投影：

$$g^G = -c \sum_{b=1}^B (v_1^{(b)} + v_2^{(b)})^\top J^{(b)} + \alpha^G \cdot c \sum_{b=1}^B (v_2^{(b)})^\top J^{(b)} \quad (43)$$

两者在冲突不均匀分布的 batch 上差异最大。

10 不动点与收敛性质

10.1 共同不动点

Proposition 8 (零梯度不动点一致). 两种 PCGrad 在以下条件下均产出零梯度（不动点）：

$$\mu_\theta^{(b)} = \mu_\phi^{(m),(b)}, \quad \forall m, b \quad (44)$$

即 student 与所有 teacher 完美匹配。此时 $v_m^{(b)} = 0$ ， $g_m = 0$ ，无投影发生。

10.2 非零不动点的差异

当 teacher 之间存在不可调和的分歧（ $\sum_m v_m^{(b)} = 0$ 但各 $v_m \neq 0$ ），两者的行为不同：

Example 3 (对称冲突). $M = 2$ ， $v_1^{(b)} = -v_2^{(b)} = u^{(b)} \neq 0$ （完全对称冲突）。

V-PCGrad: $\langle v_1^{(b)}, v_2^{(b)} \rangle = -\|u\|^2 < 0$ ，投影后：

$$\tilde{v}_1^{(b)} = v_1^{(b)} - \frac{-\|u\|^2}{\|u\|^2} v_2^{(b)} = u + u = 2u, \quad \tilde{v}_2^{(b)} = v_2^{(b)} - \frac{-\|u\|^2}{\|u\|^2} v_1^{(b)} = -u - u = -2u \quad (45)$$

等等，这不对。让我重新计算。PCGrad 投影使用原始向量 v_j （非 $\tilde{v}_j$ ）：

$$\tilde{v}_1 = v_1 - \frac{\langle v_1, v_2 \rangle}{\|v_2\|^2} v_2 = u - \frac{-\|u\|^2}{\|u\|^2} (-u) = u - u = 0 \quad (46)$$

$$\tilde{v}_2 = v_2 - \frac{\langle v_2, v_1 \rangle}{\|v_1\|^2} v_1 = -u - \frac{-\|u\|^2}{\|u\|^2} (u) = -u + u = 0 \quad (47)$$

$v^{\text{fused}} = 0$ 。有效梯度为零：**student** 停止更新。

G-PCGrad: $g_1 = -c \sum_b u^{(b)\top} J^{(b)}$ ， $g_2 = c \sum_b u^{(b)\top} J^{(b)} = -g_1$ 。 $\langle g_1, g_2 \rangle = -\|g_1\|^2 < 0$ 。

$$\tilde{g}_1 = g_1 - \frac{-\|g_1\|^2}{\|g_1\|^2} g_2 = g_1 + g_2 = 0, \quad \tilde{g}_2 = g_2 - \frac{-\|g_2\|^2}{\|g_2\|^2} g_1 = g_2 + g_1 = 0 \quad (48)$$

$g^G = 0$ 。结论一致：完全对称冲突下两者均停止。

Example 4 (非对称冲突). $M = 2, B = 1, v_1 = (1, 0)^\top, v_2 = (-0.5, 1)^\top$ 。

V-PCGrad: $\langle v_1, v_2 \rangle = -0.5 < 0, \|v_2\|^2 = 1.25$ 。

$$\tilde{v}_1 = (1, 0) - \frac{-0.5}{1.25}(-0.5, 1) = (1, 0) - (0.2, -0.4) = (0.8, 0.4) \quad (49)$$

$$\langle v_2, v_1 \rangle = -0.5 < 0, \|v_1\|^2 = 1。$$

$$\tilde{v}_2 = (-0.5, 1) - \frac{-0.5}{1}(1, 0) = (-0.5, 1) + (0.5, 0) = (0, 1) \quad (50)$$

$v^{\text{fused}} = (0.8, 1.4)$ 。

G-PCGrad (设 $J = \mathbf{I}_2$, 使 $G = \mathbf{I}$): 与 V-PCGrad 等价, $g^G = g^V$ 。

G-PCGrad (设 $J = \text{diag}(2, 0.5)$, 使 $G = \text{diag}(4, 0.25)$):

$$\langle g_1, g_2 \rangle = v_1^\top G v_2 = 4 \cdot 1 \cdot (-0.5) + 0.25 \cdot 0 \cdot 1 = -2 < 0 \quad (51)$$

$$\|g_2\|^2 = v_2^\top G v_2 = 4(0.25) + 0.25(1) = 1.25。$$

$$\alpha^G = -2/1.25 = -1.6 \quad (52)$$

$$\tilde{g}_1 = g_1 - (-1.6) g_2 = g_1 + 1.6 g_2 \quad (53)$$

对比 V-PCGrad 的 $\alpha^V = -0.5/1.25 = -0.4$: G-PCGrad 的投影强度是 V-PCGrad 的 4 倍!

原因: G 放大了第一维度 ($\lambda_1 = 4$), 使得 v_1 和 v_2 在参数空间的冲突远比 latent 空间中看起来的严重。

11 计算复杂度与数值稳定性

	G-PCGrad	V-PCGrad
Backward passes / timestep	M	1
梯度存储	$O(M \cdot P)$	$O(M \cdot B \cdot d)$
投影计算	$O(M^2 \cdot P)$ dot products	$O(M^2 \cdot B \cdot d)$ dot products
冲突判断数	$\binom{M}{2}$ 次 (全局)	$\binom{M}{2} \times B$ 次 (per-sample)
数值条件	受 $\ g_m\ $ 尺度影响	受 $\ v_m^{(b)}\ $ 尺度影响
DeepSpeed ZeRO	✗	✓

数值稳定性注意:

- G-PCGrad 的 $\|g_m\|^2$ 可能非常小 (当 loss landscape 平坦时), 导致投影系数 α^G 发散。实践中需要 ϵ -clamp。
- V-PCGrad 的 $\|v_m^{(b)}\|^2$ 是 latent 空间的 ℓ^2 范数, 尺度通常更稳定 (与模型大小无关)。

12 总结与实践建议

核心差异总结

1. 度量: G-PCGrad 在 $JJ^\top$ (Fisher-like) 度量下检测冲突; V-PCGrad 在 Euclidean 度量下检测。前者感知参数空间结构, 后者不感知。
2. 粒度: G-PCGrad 是 batch-global 的 (一个投影系数对所有样本); V-PCGrad 是 per-sample 的 (每个样本独立投影)。
3. 正交保证: G-PCGrad 保证参数空间正交 ($\tilde{g}_i \perp g_j$ in $\mathbb{R}^P$); V-PCGrad 保证 latent 空间 per-sample 正交 ($\tilde{v}_i^{(b)} \perp v_j^{(b)}$ in $\mathbb{R}^d$)。
4. 近似误差: 当 Jacobian 各向异性大 ($\kappa(JJ^\top) \gg 1$) 时, V-PCGrad 的冲突检测与投影强度偏离真实参数空间几何。但 per-sample 粒度部分补偿了这一损失。
5. 成本: V-PCGrad 以 $1/M$ 的 backward 成本和 d/P 的存储比例实现了近似冲突解决。

实践建议

- 当 $\kappa(JJ^\top)$ 适中 (LoRA fine-tuning, 参数空间较低秩) 且 batch 中各样本冲突模式不一致时, **V-PCGrad** 的 **per-sample** 粒度优势大于度量损失——推荐使用。
- 当需要精确的参数空间冲突解决 (如调试 teacher 冲突、小 batch 精确训练) 且可承受 $M \times$ backward 成本时, 使用 **G-PCGrad**。
- 两者在完全一致/完全对称冲突的极端情况下行为一致; 差异主要体现在“部分冲突”的中间地带。