

Teacher Aggregation Loss Formulations

Mathematical Specification for OPDTrainer

Flow Factory

Abstract

本文档给出 OPDTrainer 中五种 `teacher_aggregation` 模式 (`round_robin`, `average`, `sum`, `pcgrad`, `v_pcgrad`) 的严格数学形式。核心 pathwise loss 本质上是对 teacher 转移均值的直接 KL regression (等价于 time-weighted MSE regression)，各模式的区别在于 teacher 信号在哪个空间上做 aggregation。

Contents

1	前置：符号与 Per-Step KL	2
1.1	符号表	2
1.2	SDE 离散化下的高斯转移核	2
1.3	Per-Step KL (单 Teacher)	2
1.4	Trajectory-Level Loss 与梯度分解	3
2	Round-Robin	3
2.1	Teacher 选择	3
2.2	Loss 公式	3
2.3	性质	3
3	Average (Prediction 空间均值)	3
3.1	Teacher Target 构造	4
3.2	Loss 公式	4
3.3	与 Per-Teacher KL 的关系	4
3.4	有效梯度	4
4	Sum (Loss 标量空间求和)	4
4.1	Loss 公式	4
4.2	梯度	4
4.3	与 Average 的恒等关系	5
5	PCGrad (Parameter/Gradient 空间投影)	5
5.1	Per-Teacher Loss	5
5.2	Per-Teacher 梯度	5
5.3	PCGrad 投影算法	5
5.4	数学形式	6
5.5	几何解释	6
5.6	计算复杂度	6

6	V-PCGrad (Velocity/Prediction 空间投影)	6
6.1	核心思想	6
6.2	Velocity Residual 定义	6
6.3	PCGrad 投影 (Velocity 空间)	7
6.4	Fused Teacher Target	7
6.5	Loss 公式	7
6.6	梯度形式	7
6.7	与 Gradient-Space PCGrad 的关系	8
6.8	计算复杂度对比	8
7	总结对比	8
7.1	有效 Target 与 Loss 形式	8
7.2	有效梯度方向	9
7.3	核心 Insight	9
8	Source Routing 扩展	9
8.1	Sum / PCGrad 模式	9
8.2	V-PCGrad 模式	9

1 前置：符号与 Per-Step KL

1.1 符号表

符号	含义
M	Teacher 总数
N (或 T)	离散化时间步数
d	Latent 空间维度 $= C \times H \times W$
B	Batch size
P	可训练参数总量
x_{t_k}	第 k 步的 latent state
$\Delta t_k = t_{k+1} - t_k < 0$	逆向时间步长
σ_{t_k}	Flow-SDE 扩散系数, $\sigma_t^2 = a^2 t / (1 - t)$
$v_\theta(x, t)$	Student velocity field
$v_\phi^{(m)}(x, t)$	第 m 个 teacher 的 velocity field
$\lambda_{\text{path}}, \lambda_{\text{rf}}$	Pathwise 与 REINFORCE 系数

1.2 SDE 离散化下的高斯转移核

在 Flow-SDE Euler-Maruyama 离散化下, student 与 teacher 共享相同方差的条件高斯:

$$p_\theta(x_{t_{k+1}}|x_{t_k}) = \mathcal{N}(\mu_\theta^k, \bar{\sigma}_k^2 \mathbf{I}), \quad (1)$$

$$p_{\phi^{(m)}}(x_{t_{k+1}}|x_{t_k}) = \mathcal{N}(\mu_\phi^{(m),k}, \bar{\sigma}_k^2 \mathbf{I}), \quad (2)$$

其中:

$$\mu_\theta^k = \beta_k x_{t_k} + \alpha_k v_\theta(x_{t_k}, t_k) \Delta t_k, \quad (3)$$

$$\mu_\phi^{(m),k} = \beta_k x_{t_k} + \alpha_k v_\phi^{(m)}(x_{t_k}, t_k) \Delta t_k, \quad (4)$$

$$\bar{\sigma}_k^2 = \sigma_{t_k}^2 (-\Delta t_k), \quad (5)$$

$$\alpha_k = 1 + \frac{\sigma_{t_k}^2 (1 - t_k)}{2t_k}, \quad \beta_k = 1 + \frac{\sigma_{t_k}^2}{2t_k} \Delta t_k.$$

Remark 1 (共享方差). $\bar{\sigma}_k^2$ 仅依赖于 noise schedule 和时间步, 与 θ 或 ϕ 无关。这一性质是闭式 KL 的关键。

1.3 Per-Step KL (单 Teacher)

Definition 1 (Per-Step KL).

$$D_k^{(m)}(\theta) = \text{KL}(p_\theta(\cdot|x_{t_k}) \parallel p_{\phi^{(m)}}(\cdot|x_{t_k})) = \frac{1}{2\bar{\sigma}_k^2} \|\mu_\theta^k - \mu_\phi^{(m),k}\|^2 \quad (6)$$

代码中的实际计算 (含空间均值归一化):

$$\tilde{D}_k^{(m)} = \frac{1}{d} \frac{\|\mu_\theta^k - \mu_\phi^{(m),k}\|^2}{2\bar{\sigma}_k^2} \quad (7)$$

后续统一使用 $D_k^{(m)}$ 表示 (7) 形式 (含 $1/d$ 因子)。

Remark 2 (ODE 模式). 当 $\sigma_t \equiv 0$ 时, $\bar{\sigma}_k^2 = 0$ 。此时退化为纯 MSE:

$$D_k^{(m)}|_{\text{ODE}} = \frac{1}{d} \|\mu_\theta^k - \mu_\phi^{(m),k}\|^2 \quad (8)$$

1.4 Trajectory-Level Loss 与梯度分解

完整 trajectory-level 逆 KL:

$$\mathcal{L}(\theta) = \sum_{k=0}^{N-1} \mathbb{E}_{\tau \sim q_{\theta}} [D_k(\tau, \theta)] \quad (9)$$

其梯度按 pathwise + REINFORCE 分解 (Rao-Blackwell):

$$\nabla_{\theta} \mathcal{L} = \mathbb{E}_{\tau} \left[\sum_{k=0}^{N-1} \underbrace{\nabla_{\theta} D_k}_{\text{pathwise}} + \underbrace{\bar{R}_{k+1} \nabla_{\theta} \log p_{\theta}(x_{t_{k+1}} | x_{t_k})}_{\text{REINFORCE}} \right] \quad (10)$$

其中 $\bar{R}_{k+1} = \sum_{j>k} D_j$ 是 cumulative future KL。

本文重点

以下各 aggregation 模式的区别完全体现在 **pathwise loss** D_k 的构造方式上。REINFORCE 项的结构类似, 仅 $\bar{R}_{k+1}$ 的来源 (由哪些 teacher 计算) 不同。

2 Round-Robin

Aggregation 空间: 无 (每个 micro-batch 仅使用单个 teacher)

2.1 Teacher 选择

每个 micro-batch 确定性地选取一个 teacher:

$$m^* = (\text{epoch} \times N_{\text{inner}} + \text{inner_epoch}) \times N_{\text{batches}} + \text{batch_idx} \pmod{M} \quad (11)$$

2.2 Loss 公式

$$\mathcal{L}_k^{\text{rr}}(\theta) = \lambda_{\text{path}} \cdot D_k^{(m^*)} + \lambda_{\text{rf}} \cdot \bar{R}_{k+1}^{(m^*)} \log p_{\theta}(x_{t_{k+1}} | x_{t_k}) \quad (12)$$

展开 pathwise 项:

$$\mathcal{L}_k^{\text{rr, path}}(\theta) = \frac{\lambda_{\text{path}}}{2\bar{\sigma}_k^2 d} \|\mu_{\theta}^k - \mu_{\phi}^{(m^*),k}\|^2 \quad (13)$$

2.3 性质

- 每步 1 次 teacher forward + 1 次 backward
- Teacher 间不存在任何 aggregation 或 conflict
- 确定性轮流保证各 teacher 均匀暴露
- 有效 target: $\mu_T^k = \mu_{\phi}^{(m^*),k}$

3 Average (Prediction 空间均值)

Aggregation 空间: **Prediction/latent** 空间—对所有 teacher 的转移均值 $\mu_{\phi}^{(m),k}$ 取算术平均

3.1 Teacher Target 构造

$$\bar{\mu}_\phi^k = \frac{1}{M} \sum_{m=1}^M \mu_\phi^{(m),k} \quad (14)$$

3.2 Loss 公式

$$\mathcal{L}_k^{\text{avg}}(\theta) = \frac{\lambda_{\text{path}}}{2\bar{\sigma}_k^2 d} \|\mu_\theta^k - \bar{\mu}_\phi^k\|^2 + \lambda_{\text{rf}} \cdot \bar{R}_{k+1} \log p_\theta(x_{t_{k+1}}|x_{t_k}) \quad (15)$$

其中 $\bar{R}_{k+1}$ 基于 averaged target $\bar{\mu}_\phi$ 计算。

3.3 与 Per-Teacher KL 的关系

Proposition 1 (Jensen 下界).

$$D_k^{\text{avg}} = \frac{1}{2\bar{\sigma}_k^2 d} \|\mu_\theta^k - \bar{\mu}_\phi^k\|^2 \leq \frac{1}{M} \sum_{m=1}^M D_k^{(m)} \quad (16)$$

即 average loss 是各 teacher per-step KL 均值的下界。等号成立当且仅当所有 teacher 预测一致。

Proof. 由 $\|a - \bar{b}\|^2 \leq \frac{1}{M} \sum_m \|a - b_m\|^2$ (Jensen 不等式应用于凸函数 $\|\cdot\|^2$)。 $\square$

3.4 有效梯度

$$\nabla_\theta \mathcal{L}_k^{\text{avg, path}} = \frac{\lambda_{\text{path}}}{\bar{\sigma}_k^2 d} (\mu_\theta^k - \bar{\mu}_\phi^k)^\top \nabla_\theta \mu_\theta^k = \frac{\lambda_{\text{path}}}{\bar{\sigma}_k^2 d} \left(\frac{1}{M} \sum_m \delta_m^k \right)^\top J_k \quad (17)$$

其中 $\delta_m^k = \mu_\theta^k - \mu_\phi^{(m),k}$, $J_k = \nabla_\theta \mu_\theta^k$ 。

Remark 3. Student 向所有 teacher 的“共识预测”做 MSE regression。等价于对 teacher 输出分布做一阶矩匹配 (moment matching)。

4 Sum (Loss 标量空间求和)

Aggregation 空间: Loss/scalar 空间—各 teacher 独立计算 per-step KL, 标量相加

4.1 Loss 公式

$$\mathcal{L}_k^{\text{sum}}(\theta) = \sum_{m=1}^M \left[\frac{\lambda_{\text{path}}}{2\bar{\sigma}_k^2 d} \|\mu_\theta^k - \mu_\phi^{(m),k}\|^2 + \lambda_{\text{rf}} \cdot \bar{R}_{k+1}^{(m)} \log p_\theta(x_{t_{k+1}}|x_{t_k}) \right] \quad (18)$$

Pathwise 项展开:

$$\mathcal{L}_k^{\text{sum, path}}(\theta) = \frac{\lambda_{\text{path}}}{2\bar{\sigma}_k^2 d} \sum_{m=1}^M \|\mu_\theta^k - \mu_\phi^{(m),k}\|^2 \quad (19)$$

4.2 梯度

$$\nabla_\theta \mathcal{L}_k^{\text{sum, path}} = \frac{\lambda_{\text{path}}}{\bar{\sigma}_k^2 d} \sum_{m=1}^M \delta_m^k{}^\top J_k = \frac{\lambda_{\text{path}}}{\bar{\sigma}_k^2 d} \left(\sum_m \delta_m^k \right)^\top J_k \quad (20)$$

各 teacher 梯度无条件叠加, 不做任何冲突处理。

4.3 与 Average 的恒等关系

Proposition 2 (Bias-Variance 分解).

$$\sum_{m=1}^M \|\mu_\theta^k - \mu_\phi^{(m),k}\|^2 = M \|\mu_\theta^k - \bar{\mu}_\phi^k\|^2 + \underbrace{\sum_{m=1}^M \|\mu_\phi^{(m),k} - \bar{\mu}_\phi^k\|^2}_{\text{const w.r.t. } \theta} \quad (21)$$

Proof. 展开 $\|\mu_\theta - \mu_\phi^{(m)}\|^2 = \|(\mu_\theta - \bar{\mu}_\phi) + (\bar{\mu}_\phi - \mu_\phi^{(m)})\|^2$, 交叉项求和为零。 $\square$

Remark 4 (Sum $\equiv$ Average 梯度等价). 由 (21), pathwise 项的梯度满足:

$$\nabla_\theta \mathcal{L}_k^{\text{sum, path}} = M \cdot \nabla_\theta \mathcal{L}_k^{\text{avg, path}} \quad (22)$$

因此 **sum** 与 **average** 在纯 pathwise loss 下梯度方向完全相同 (仅差常数倍 M)。但由于 REINFORCE 项中 $\bar{R}_{k+1}^{(m)}$ 是 per-teacher 的 (vs. average 使用共享的 $\bar{R}_{k+1}$), 总体梯度在 $\lambda_{\text{rf}} > 0$ 时并不完全等比。

5 PCGrad (Parameter/Gradient 空间投影)

Aggregation 空间: Full parameter space $\mathbb{R}^P$ — 计算每个 teacher 的完整参数梯度, 在梯度空间做冲突投影

5.1 Per-Teacher Loss

每个 teacher 独立定义一个标量 loss:

$$\ell_k^{(m)}(\theta) = \frac{\lambda_{\text{path}}}{2\bar{\sigma}_k^2 d} \|\mu_\theta^k - \mu_\phi^{(m),k}\|^2 + \lambda_{\text{rf}} \cdot \bar{R}_{k+1}^{(m)} \log p_\theta(x_{t_{k+1}}|x_{t_k}) \quad (23)$$

5.2 Per-Teacher 梯度

对每步 k , 通过 M 次独立 backward 获取:

$$g_m^k = \nabla_\theta \ell_k^{(m)} \in \mathbb{R}^P, \quad m = 1, \dots, M \quad (24)$$

5.3 PCGrad 投影算法

Algorithm 1 PCGrad Projection in Parameter Space

Require: M gradient vectors $\{g_1, \dots, g_M\} \subset \mathbb{R}^P$

Ensure: Projected blended gradient $g^{\text{blend}} \in \mathbb{R}^P$

1: $\tilde{g}_m \leftarrow g_m$ for all m

2: **for** $i = 1, \dots, M$ **do**

3: **for** $j \in \{1, \dots, M\} \setminus \{i\}$ **do**

4: **if** $\langle \tilde{g}_i, g_j \rangle < 0$ **then**

5: $\tilde{g}_i \leftarrow \tilde{g}_i - \frac{\langle \tilde{g}_i, g_j \rangle}{\|g_j\|^2} g_j$

6: **end if**

7: **end for**

8: **end for**

9: **return** $g^{\text{blend}} = \sum_{m=1}^M \tilde{g}_m$

▷ 冲突检测

▷ 投影去除冲突分量

5.4 数学形式

PCGrad 不显式定义一个标量 loss，而是直接定义有效梯度更新方向：

$$g_k^{\text{pcgrad}} = \sum_{m=1}^M \tilde{g}_m^k, \quad \text{where} \quad \tilde{g}_m^k = g_m^k - \sum_{\substack{j=1 \\ j \neq m}}^M \min(0, \langle g_m^k, g_j^k \rangle) \frac{g_j^k}{\|g_j^k\|^2} \quad (25)$$

跨时间步累积：

$$g^{\text{total}} = \frac{1}{T} \sum_{k=0}^{T-1} g_k^{\text{pcgrad}} \quad (26)$$

5.5 几何解释

对每对 (i, j) ：若 $g_i \cdot g_j < 0$ （两 teacher 梯度方向冲突），则将 g_i 投影到与 g_j 正交的子空间：

$$\tilde{g}_i = g_i - \text{proj}_{g_j}(g_i) = g_i - \frac{\langle g_i, g_j \rangle}{\|g_j\|^2} g_j \implies \langle \tilde{g}_i, g_j \rangle = 0 \quad (27)$$

5.6 计算复杂度

- 每 timestep 需要 M 次 backward pass (`retain_graph=True`)
- 内存： $O(M \times P)$ （存储 M 个梯度快照）
- 不兼容 DeepSpeed ZeRO（多次 backward 破坏 ZeRO gradient bucket 状态）

6 V-PCGrad (Velocity/Prediction 空间投影)

Aggregation 空间：Velocity (prediction residual) 空间 $\mathbb{R}^d$ —在 latent 预测残差方向上做冲突投影，然后融合为单一 target

6.1 核心理想

将 PCGrad 的冲突投影从高维参数空间 $\mathbb{R}^P$ 降维到低维 latent 空间 $\mathbb{R}^d$ ($d = C \times H \times W \ll P$)。

6.2 Velocity Residual 定义

Definition 2 (Per-Teacher Velocity Residual).

$$v_m^k = \mu_\phi^{(m),k} - \mu_\theta^k|_{\text{detach}} \in \mathbb{R}^{B \times C \times H \times W} \quad (28)$$

即 teacher m 相对于当前 student 预测的“拉力方向”（detach 断梯度）。

6.3 PCGrad 投影 (Velocity 空间)

Algorithm 2 PCGrad Projection in Velocity Space (per-sample)

Require: M velocity tensors $\{v_1, \dots, v_M\} \subset \mathbb{R}^{B \times d}$, tolerance ϵ

Ensure: Fused velocity $v^{\text{fused}} \in \mathbb{R}^{B \times d}$

```

1:  $\tilde{v}_m \leftarrow v_m$  for all  $m$ 
2:  $n_j \leftarrow \|v_j\|_{\text{spatial}}^2 = \sum_{c,h,w} (v_j)_{c,h,w}^2 \in \mathbb{R}^B$  for all  $j$ , clamped  $\geq \epsilon$ 
3: for  $i = 1, \dots, M$  do
4:   for  $j \in \{1, \dots, M\} \setminus \{i\}$  do
5:      $\text{dot}_{ij} \leftarrow \sum_{c,h,w} (\tilde{v}_i)_{c,h,w} \cdot (v_j)_{c,h,w} \in \mathbb{R}^B$  ▷ per-sample 内积
6:      $\tilde{v}_i \leftarrow \tilde{v}_i - \mathbb{I}[\text{dot}_{ij} < 0] \frac{\text{dot}_{ij}}{n_j} v_j$  ▷ per-sample 条件投影
7:   end for
8: end for
9: return  $v^{\text{fused}} = \sum_{m=1}^M \tilde{v}_m$ 

```

数学公式:

$$\tilde{v}_m^k = v_m^k - \sum_{\substack{j=1 \\ j \neq m}}^M \min\left(0, \frac{\langle v_m^k, v_j^k \rangle_{\text{sp}}}{\|v_j^k\|_{\text{sp}}^2}\right) v_j^k \quad (29)$$

其中内积和范数在空间维度上 per-sample 独立计算:

$$\langle v_m, v_j \rangle_{\text{sp}}^{(b)} = \sum_{c,h,w} v_m^{(b,c,h,w)} v_j^{(b,c,h,w)} \in \mathbb{R} \quad (30)$$

6.4 Fused Teacher Target

$$\mu_T^{\text{fused},k} = \mu_\theta^k|_{\text{detach}} + \sum_{m=1}^M \tilde{v}_m^k \quad (31)$$

6.5 Loss 公式

$$\mathcal{L}_k^{\text{v-pcgrad}}(\theta) = \frac{\lambda_{\text{path}}}{2\bar{\sigma}_k^2 d} \|\mu_\theta^k - \mu_T^{\text{fused},k}\|^2 + \lambda_{\text{rf}} \cdot \bar{R}_{k+1} \log p_\theta(x_{t_{k+1}}|x_{t_k})$$

(32)

其中 $\bar{R}_{k+1} = \frac{1}{M} \sum_{m=1}^M \bar{R}_{k+1}^{(m)}$.

6.6 梯度形式

由于 $\mu_T^{\text{fused},k}$ 相对于 θ 是 detached 的 (基于 $\mu_\theta|_{\text{detach}}$ 构造):

$$\nabla_\theta \mathcal{L}_k^{\text{v-pcgrad, path}} = \frac{\lambda_{\text{path}}}{\bar{\sigma}_k^2 d} (\mu_\theta^k - \mu_T^{\text{fused},k})^\top \nabla_\theta \mu_\theta^k \quad (33)$$

代入 (31):

$$\mu_\theta^k - \mu_T^{\text{fused},k} = \mu_\theta^k - \mu_\theta^k|_{\text{detach}} - \sum_m \tilde{v}_m^k = - \sum_m \tilde{v}_m^k \quad (\text{at evaluation point}) \quad (34)$$

因此:

$$\nabla_\theta \mathcal{L}_k^{\text{v-pcgrad, path}} = - \frac{\lambda_{\text{path}}}{\bar{\sigma}_k^2 d} \left(\sum_m \tilde{v}_m^k \right)^\top J_k = - \frac{\lambda_{\text{path}}}{\bar{\sigma}_k^2 d} (\text{PCGrad}(\{v_m^k\}_m))^\top J_k \quad (35)$$

6.7 与 Gradient-Space PCGrad 的关系

Proposition 3 (近似等价性). 设 $J_k = \nabla_{\theta} \mu_{\theta}^k \in \mathbb{R}^{d \times P}$ 为 student 的 Jacobian。Gradient-space PCGrad 中第 m 个 teacher 的 pathwise 梯度为：

$$g_m^k = -\frac{\lambda_{\text{path}}}{\bar{\sigma}_k^2 d} (v_m^k)^{\top} J_k \in \mathbb{R}^P \quad (36)$$

Gradient-space PCGrad 对 $\{g_m^k\}_m$ 投影：

$$g_k^{\text{pcgrad}} = \text{PCGrad}(\{(v_m^k)^{\top} J_k\}_m) \cdot \left(-\frac{\lambda_{\text{path}}}{\bar{\sigma}_k^2 d}\right) \quad (37)$$

V-PCGrad 的有效梯度为：

$$g_k^{\text{v-pcgrad}} = (\text{PCGrad}(\{v_m^k\}_m))^{\top} J_k \cdot \left(-\frac{\lambda_{\text{path}}}{\bar{\sigma}_k^2 d}\right) \quad (38)$$

两者的关系：

$$\boxed{\text{PCGrad}(\{v_m^{\top} J\}_m) \approx (\text{PCGrad}(\{v_m\}_m))^{\top} J} \quad (39)$$

等式成立条件： J 为正交矩阵（或所有 sample 共享相同的 J ）。当 Jacobian 在 batch 内变化较小时，近似精度较高。

6.8 计算复杂度对比

	PCGrad (gradient space)	V-PCGrad (velocity space)
投影空间维度	P (模型参数量)	$d = C \times H \times W$ (latent 维度)
Backward/timestep	M	1
梯度存储	$O(M \times P)$	$O(M \times d)$
DeepSpeed 兼容	✗	✓
精确性	精确	近似

7 总结对比

7.1 有效 Target 与 Loss 形式

模式	有效 Target μ_T^k	Pathwise Loss $\mathcal{L}_k^{\text{path}}$
round_robin	$\mu_{\phi}^{(m^*),k}$	$\frac{\lambda_{\text{path}}}{2\bar{\sigma}_k^2 d} \ \mu_{\theta}^k - \mu_{\phi}^{(m^*),k}\ ^2$
average	$\frac{1}{M} \sum_m \mu_{\phi}^{(m),k}$	$\frac{\lambda_{\text{path}}}{2\bar{\sigma}_k^2 d} \left\ \mu_{\theta}^k - \frac{1}{M} \sum_m \mu_{\phi}^{(m),k} \right\ ^2$
sum	各 $\mu_{\phi}^{(m),k}$ 独立	$\frac{\lambda_{\text{path}}}{2\bar{\sigma}_k^2 d} \sum_m \ \mu_{\theta}^k - \mu_{\phi}^{(m),k}\ ^2$
pcgrad	各 $\mu_{\phi}^{(m),k}$ 独立	无显式 loss; $g_k = \text{PCGrad}(\{\nabla_{\theta} \ell_k^{(m)}\}_m)$
v_pcgrad	$\mu_{\theta}^k _{\text{det}} + \sum_m \tilde{v}_m^k$	$\frac{\lambda_{\text{path}}}{2\bar{\sigma}_k^2 d} \ \mu_{\theta}^k - \mu_T^{\text{fused},k}\ ^2$

7.2 有效梯度方向

设 $J_k = \nabla_{\theta} \mu_{\theta}^k$, $\delta_m^k = \mu_{\theta}^k - \mu_{\phi}^{(m),k} = -v_m^k$:

模式	有效梯度 $\nabla_{\theta} \mathcal{L}_k^{\text{path}} \propto$	投影空间
round_robin	$(\delta_{m^*}^k)^{\top} J_k$	—
average	$(\frac{1}{M} \sum_m \delta_m^k)^{\top} J_k$	$\mathbb{R}^d$ (隐式均值)
sum	$(\sum_m \delta_m^k)^{\top} J_k$	— (无投影)
pcgrad	$\sum_m \text{PCGrad}(\delta_m^k)^{\top} J_k$	$\mathbb{R}^P$
v_pcgrad	$(\text{PCGrad}(\{-\delta_m^k\}_m))^{\top} J_k$	$\mathbb{R}^d$

7.3 核心 Insight

- 所有模式的 pathwise loss 本质上都是同方差高斯 **KL** (= time-weighted MSE), 区别仅在于如何构造 **regression target**。
- **sum** 与 **average** 在纯 pathwise loss 下梯度方向等价 (Bias-Variance 分解恒等式 (21))。
- **v_pcgrad** 是 **pcgrad** 的高效近似: 将冲突投影从 $\mathbb{R}^P$ 降维到 $\mathbb{R}^d$ ((39)), 代价是丢失 Jacobian 各向异性信息, 换来单次 backward + DeepSpeed 兼容。
- 从信息论角度: **average** 等价于对 teacher mixture 做 moment matching (一阶矩); **pcgrad/v_pcgrad** 则保留了 per-teacher 的“方向性”信息并显式处理冲突。

8 Source Routing 扩展

当 `teacher_route_by_source=True` 时, 每个 teacher m 仅对其适用的样本子集 $\mathcal{B}_m \subseteq \{1, \dots, B\}$ 有效。

8.1 Sum / PCGrad 模式

Loss 中只对 $b \in \mathcal{B}_m$ 的样本求均值:

$$\ell_k^{(m)} = \frac{\lambda_{\text{path}}}{2\bar{\sigma}_k^2 d} \frac{1}{|\mathcal{B}_m|} \sum_{b \in \mathcal{B}_m} \|\mu_{\theta}^{k,(b)} - \mu_{\phi}^{(m),k,(b)}\|^2 \quad (40)$$

8.2 V-PCGrad 模式

通过 mask 将不适用样本的 velocity 置零:

$$v_m^{k,(b)} = \begin{cases} \mu_{\phi}^{(m),k,(b)} - \mu_{\theta}^{k,(b)}|_{\text{det}} & \text{if } b \in \mathcal{B}_m \\ \mathbf{0} & \text{if } b \notin \mathcal{B}_m \end{cases} \quad (41)$$

零向量与任何向量的内积为 0, 因此不参与冲突检测, 也不被其他 teacher 投影影响。这实现了“不适用 teacher 被动退出”的语义。