

跨 VAE 隐空间的 Cross-Model On-Policy Distillation

XOPD with Heterogeneous Latent Spaces: 理论形式化与算法族

以 FLUX.2-dev (32B) $\rightarrow$ SD3.5 为参考实例

Flow Factory

Abstract

现有 XOPD 蒸馏器 (`trainers/xopd/trainer.py`) 建立在一个硬约束之上: teacher 与 student 共享同一个 VAE 隐空间(`load_teacher_transformer` 显式断言 `teacher.in_channels == student.in_channels`)。当我们希望把 FLUX.2-dev (其 VAE 隐空间 $\mathcal{Z}_T$) 蒸馏到 Stable Diffusion 3.5 (隐空间 $\mathcal{Z}_S$, 通道数/分辨率/统计均不同) 时, 这个约束被打破: teacher 的 velocity 场与 transition 分布都活在 $\mathcal{Z}_T$ 中, 而 student 的 rollout、loss、梯度都活在 $\mathcal{Z}_S$ 中。

本文把”跨 VAE 蒸馏”形式化为一个隐空间传输映射 (latent transport map) $\mathsf{T} : \mathcal{Z}_T \rightarrow \mathcal{Z}_S$ 的设计问题, 并给出一个统一框架: XOPD 的两个 loss (L0 velocity regression 与 L1 transition-KL) 分别对 T 提出不同强度的要求——L0 只需在干净样本上传输 (sample transport), 而 L1 需要传输整个 velocity 场 (vector-field pushforward), 后者只有当 T 是可逆光滑映射、且其 Jacobian 行为良好时才成立。由此我们得到一个关键结论: 仿射/线性传输是唯一能让 L0 与 L1 同时精确成立的传输类, 因为它的 Jacobian 是常数、且保持 flow matching 的插值路径结构。

在此框架下我们形式化并比较四类算法: (M1) pixel-space 桥接 (decode-encode), (M2) 学习式 latent projector (线性 / 仿射 / 非线性), (M3) CV-VAE 式重建对齐 (arXiv:2405.20279, 把对齐推到 VAE 训练阶段), 以及我们新提出的 (M4) 概率耦合 / 分布矩匹配、(M5) cycle-consistent 联合学习传输、(M6) shared-decoder 微调。对每种方法我们给出其对 L0/L1 的精确作用、有损性来源、可微性与梯度路径、训练开销, 并用一个统一的传输一致性误差 δ_{T} 给出 loss 偏差的上界。最后给出与 `trainers/xopd` 现有代码对齐的实现设计 (抽象出 `VAETransport`、放松 `in_channels` 断言、传输在 L0/L1 中的插入点、config 接口与实现优先级), 本文不写生产代码, 只做设计。

Contents

1	Motivation 与问题设定	3
1.1	XOPD 回顾: 共享隐空间假设	3
1.2	跨 VAE 问题	3
2	形式化: 隐空间传输映射	3
2.1	两种传输: 样本传输 vs. 速度场传输	3
2.2	速度场的推前 (pushforward)	4
2.3	为什么线性 / 仿射传输是”甜区”	5
2.4	传输一致性误差与 loss 偏差上界	5
3	传输对 L0 与 L1 的作用 (统一分析)	6
3.1	L0: 样本传输即可, 且优先于速度传输	6
3.2	L1: 必须传输速度场, 约束远强于 L0	6
4	算法族: 六种传输的形式化与对比	6
4.1	M1: Pixel-space 桥接 (decode-encode)	6
4.2	M2: 学习式 latent projector (线性 / 仿射 / 非线性)	7
4.3	M3: CV-VAE 式重建对齐 (把对齐推到 VAE 训练阶段)	7

4.4	M4 (新提出): 概率耦合 / 分布矩匹配	7
4.5	M5 (新提出): cycle-consistent 联合学习传输	8
4.6	M6 (新提出): shared-decoder 微调 (最小侵入的 M3)	8
4.7	横向对比	8
5	传输的初始化与 AdaLN 式可逆调制	8
5.1	初始化: 恒等不是好默认, 矩匹配才是”中性”初始化	8
5.2	ODE $\rightarrow$ SDE 与 AdaLN 式调制: 纠正前提, 保留机制	9
6	实现设计 (不写生产代码, 只做架构)	10
6.1	改动面	10
6.2	两阶段用不同传输 (呼应关键洞察 2)	10
6.3	先验证什么	11
7	结论	11

1 Motivation 与问题设定

1.1 XOPD 回顾：共享隐空间假设

设 student 是一个在隐空间 $\mathcal{Z}_S \subseteq \mathbb{R}^{d_S}$ 上的 flow-matching 模型，其 velocity 场为 $v_\theta(z, t)$ (θ 为可训练参数，实现中是 LoRA)。teacher 是一个冻结的大模型，velocity 场为 v_T 。XOPD 的两个 loss（见 `cross_opd_xopd.md`）为：

- **L0 (velocity regression, off-policy)**: teacher 先 rollout 出干净隐变量 z_0^T ，构造数据路径 $z_t = (1 - \sigma_t)z_0^T + \sigma_t \epsilon$ ，然后在同一个 z_t 上回归

$$\mathcal{L}_{L0} = \mathbb{E}_{t, \epsilon} \left[w(t) \|v_\theta(z_t, t) - v_T(z_t, t)\|^2 \right]. \quad (1)$$

- **L1 (transition matching, on-policy)**: student 自己 rollout 轨迹 $\{x_k\}$ ，对每个训练时间步计算 student / teacher 的转移高斯均值 $\mu_\theta(x_k), \mu_T(x_k)$ ，以闭式高斯 KL（即 D_k ）作为 pathwise loss：

$$D_k = \frac{\|\mu_\theta(x_k) - \mu_T(x_k)\|^2}{2\sigma_k^2}, \quad \mathcal{L}_{L1} = \mathbb{E} \left[\sum_k D_k \right] (+ \text{REINFORCE} + \text{KL anchor}). \quad (2)$$

(1) 与 (2) 的共同前提是 v_θ 与 v_T 定义在同一个隐空间：L0 在同一个 z_t 上比较两者，L1 在 student 访问到的状态 $x_k \in \mathcal{Z}_S$ 上查询 teacher 的均值 $\mu_T(x_k)$ 。代码用一行断言保证它：

flux2_klein.py:1363 的硬约束

```
student_in_channels = self.pipeline.transformer.config.in_channels
teacher_in_channels = teacher.config.in_channels
if teacher_in_channels != student_in_channels:
    raise ValueError("... shared-latent-space assumption is violated ...")
```

1.2 跨 VAE 问题

记 teacher VAE 为 $(\mathcal{E}_T, \mathcal{D}_T)$ 、隐空间 $\mathcal{Z}_T \subseteq \mathbb{R}^{d_T}$ ；student VAE 为 $(\mathcal{E}_S, \mathcal{D}_S)$ 、隐空间 $\mathcal{Z}_S \subseteq \mathbb{R}^{d_S}$ ；共享的像素空间为 $\mathcal{X}$ 。 $\mathcal{E}_T: \mathcal{X} \rightarrow \mathcal{Z}_T$ ， $\mathcal{D}_T: \mathcal{Z}_T \rightarrow \mathcal{X}$ ，student 同理。一般地

$$d_T \neq d_S, \quad \mathcal{Z}_T \not\cong \mathcal{Z}_S, \quad \mathcal{E}_T \neq \mathcal{E}_S,$$

通道数、空间下采样率、逐通道统计（FLUX.2 VAE 还带一个 BatchNorm 标准化层，见 `decode_latents`）都不同。直接把 v_T 代入 (1) 或把 $\mu_T(x_k)$ 用于 (2) 在类型上就不合法。

核心问题

我们需要一个隐空间传输映射 $\mathsf{T}: \mathcal{Z}_T \rightarrow \mathcal{Z}_S$ ，把 teacher 在 $\mathcal{Z}_T$ 中产生的信号（干净样本 z_0^T 、或整个 velocity 场 v_T ）搬运到 $\mathcal{Z}_S$ 中，使得 XOPD 的监督信号重新变得“类型合法且语义正确”。本文的全部内容就是： T 应满足什么性质、有哪些构造法、各自对 L0/L1 的作用与代价。

2 形式化：隐空间传输映射

2.1 两种传输：样本传输 vs. 速度场传输

跨 VAE 蒸馏的微妙之处在于：L0 与 L1 需要的不是同一种传输。

Definition 1 (语义一致性 / 像素锚定). 我们称 $\mathsf{T} : \mathcal{Z}_T \rightarrow \mathcal{Z}_S$ 是像素一致的, 若对 teacher 隐变量 $z \in \mathcal{Z}_T$, $\mathsf{T}(z)$ 解码出的图像与 z 解码出的图像一致:

$$\mathcal{D}_S(\mathsf{T}(z)) \approx \mathcal{D}_T(z), \quad \forall z \in \mathcal{Z}_T. \quad (3)$$

像素一致是所有合理传输的语义正确性判据: 两个隐变量”代表同一张图”。

Definition 2 (样本传输与速度场传输).

- 样本传输 (**sample transport**): 只要求把干净样本 z_0^T 搬到 $\mathcal{Z}_S$: $z_0^S = \mathsf{T}(z_0^T)$ 。L0 只需要这个。
- 速度场传输 (**vector-field pushforward**): 要求把整个 velocity 场 v_T 搬到 $\mathcal{Z}_S$ 上的一个场 $(\mathsf{T}_\# v_T)$, 使其在 $\mathcal{Z}_S$ 中生成的概率流与 teacher 在 $\mathcal{Z}_T$ 中的流经 T 推前后一致。L1 需要这个。

Remark 1 (隐变量不服从高斯分布——四个分布的辨析). 本文从不假设 latent 服从高斯分布, 这一点必须澄清, 因为 VAE 语境里至少有四个分布被经常混淆, 它们的高斯性截然不同:

- 逐图后验 $q(z | x) = \mathcal{N}(\mu_\phi(x), \text{diag } \sigma_\phi^2(x))$: 高斯 (reparameterization trick 构造使然, 单张图);
- 聚合后验/边际 $q(z) = \int q(z | x) p_{\text{data}}(x) dx$: 非高斯 (一张图一个分量的巨型混合, 多峰、携带全部图像结构);
- 干净隐变量 z_0 的分布: 非高斯 (= 上面的边际, 正是 flow 要去刻画的目标——若它高斯则生成平凡);
- 噪声端 $z_1 \sim \mathcal{N}(0, I)$: 高斯 (flow matching 的 prior 端, 定义)。

所以”干净图像/干净 latent 不服从高斯”是正确的: 非高斯的是边际 $q(z_0)$ 。唯一天然高斯的是逐图后验与噪声端。此外, 要让边际接近 $\mathcal{N}(0, I)$ 还需 KL 正则权重足够大且无 prior hole; 而 FLUX.2 / SD3.5 这类扩散用 VAE 的 KL 权重极小 ($\sim 10^{-6}$, 近乎纯自编码器以保重建保真度), 其边际比教科书 **VAE** 离高斯更远。FLUX.2 VAE 的 BatchNorm (`decode_latents` 中 $z \cdot \text{std} + \text{mean}$) 只标准化逐通道一阶/二阶矩, 标准化 $\neq$ 高斯化——通道内形状、跨通道/跨空间依赖仍非高斯。

对本文的影响: 偏好线性传输的真正依据是几何 (Prop. 2, 见其后的 Rem. 2), 不依赖任何分布假设; L1 的逐步高斯 KL (D_k) 匹配的是条件转移分布 $z_{k+1} | z_k$ (由 SDE 加性噪声构造, 本就高斯), 与 z_0 边际是否高斯无关。下面 M4 (§4) 只在边际恰好近高斯时才升级为全局最优; 一般情形它退化为矩匹配初始化。

2.2 速度场的推前 (pushforward)

Proposition 1 (ODE 流的推前). 设 $\mathsf{T} : \mathcal{Z}_T \rightarrow \mathcal{Z}_S$ 为 C^1 微分同胚, Jacobian 记为 $\mathbf{J}_\mathsf{T}(z) = \partial \mathsf{T} / \partial z$ 。若 $z^T(t)$ 满足 teacher 的概率流 ODE $\dot{z}^T = v_T(z^T, t)$, 令 $z^S(t) = \mathsf{T}(z^T(t))$, 则 $z^S(t)$ 满足

$$\dot{z}^S = \underbrace{\mathbf{J}_\mathsf{T}(\mathsf{T}^{-1}(z^S)) v_T(\mathsf{T}^{-1}(z^S), t)}_{=:(\mathsf{T}_\# v_T)(z^S, t)}. \quad (4)$$

即推前速度场 $\mathsf{T}_\# v_T$ 由链式法则 $\dot{z}^S = \mathbf{J}_\mathsf{T} \dot{z}^T$ 给出。

Proof. 链式法则 $\dot{z}^S = \mathbf{J}_\mathsf{T}(z^T) \dot{z}^T = \mathbf{J}_\mathsf{T}(z^T) v_T(z^T, t)$, 再代入 $z^T = \mathsf{T}^{-1}(z^S)$ 。□

Corollary 1 (L1 需要 Jacobian 与可逆性). L1 在 student 状态 $x_k \in \mathcal{Z}_S$ 上需要 teacher 的”意见” $(\mathsf{T}_\# v_T)(x_k, t)$ 。由 (4), 这要求: (i) T 可逆 (取 $\mathsf{T}^{-1}(x_k)$ 才能查询 teacher), (ii) T 可微且 Jacobian 可得。对一般非线性 T 这两点都昂贵; 对像素桥接 $\mathsf{T} = \mathcal{E}_S \circ \mathcal{D}_T$, T^{-1} 无解析式、Jacobian 需 VJP/JVP, 逐步代价极高。

2.3 为什么线性 / 仿射传输是”甜区”

Proposition 2 (仿射传输保持 flow-matching 路径与速度). 设 $T(z) = Az + b$ ($A \in \mathbb{R}^{d_S \times d_T}$). 则:

- (a) 保插值路径: teacher 的 flow-matching 路径 $z_t^T = (1 - \sigma_t)z_0^T + \sigma_t \epsilon^T$ 经 T 推前后仍是 student 空间里的一条 flow-matching 路径 $z_t^S = (1 - \sigma_t)T(z_0^T) + \sigma_t(A\epsilon^T)$, 端点为 $T(z_0^T)$ 与噪声 $A\epsilon^T$;
- (b) 速度常数倍传输: Jacobian $J_T \equiv A$ 为常数, 故 $(T_{\#}v_T)(z^S, t) = Av_T(A^+(z^S - b), t)$ (A^+ 为伪逆, A 行满秩可逆时为逆), 速度场的传输无需逐点 Jacobian 计算。

Proof. (a) 直接代入: $T(z_t^T) = A((1 - \sigma_t)z_0^T + \sigma_t \epsilon^T) + b = (1 - \sigma_t)(Az_0^T + b) + \sigma_t(A\epsilon^T) + [(1 - \sigma_t) + \sigma_t - 1]b$, 末项为 0。(b) 由 Prop. 1 及 $J_T \equiv A$ 。 $\square$

Remark 2 (偏好线性传输是几何结论, 不依赖分布假设). Prop. 2 的两条性质对任意干净隐变量 z_0^T 成立, 证明只用了仿射映射的代数性质 (T 与凸组合可交换、Jacobian 为常数), 完全没有用到 z_0^T 服从高斯或任何特定分布 (呼应 Rem. 1)。这才是本文偏好线性传输的真正理由: 它在计算上干净 (速度场推前 $= Av_T$, 无需逐点 Jacobian; 插值路径保结构), 与 latent 边际是否高斯无关。是否够用 (线性 δ_T 是否够小) 是关于”同一批图训出的两个 VAE 隐空间是否近似线性可通”的经验事实 (参见 relative-representation 一类工作的经验观察), 由 §2 的 δ_T 实测判定, 而非由高斯定理保证。

Remark 3 (非线性传输破坏路径结构). 若 T 非线性, 则 $T((1 - \sigma_t)z_0^T + \sigma_t \epsilon^T) \neq (1 - \sigma_t)T(z_0^T) + \sigma_t T(\epsilon^T)$, 即 teacher 的线性插值路径不映成 student 空间里的线性插值路径。于是 L0 中”在 z_t 上比较速度”这一构造对非线性 T 失去了 flow-matching 的解析靶子; 只能退化为样本传输 L0 (见 §3)。这与 CV-VAE 选择冻结 VAE、用重建 loss 把两个隐空间”对齐成近似可线性互通”的动机一致。

2.4 传输一致性误差与 loss 偏差上界

Definition 3 (传输一致性误差). 定义传输在像素空间的往返重建误差

$$\delta_T = \mathbb{E}_{z \sim p_T} \|\mathcal{D}_S(T(z)) - \mathcal{D}_T(z)\|, \quad (5)$$

其中 p_T 是 teacher 在相关时刻的隐变量分布。 $\delta_T = 0$ 即严格像素一致 (3)。

Proposition 3 (L0 样本传输的偏差被 δ_T 控制). 设 student VAE 编码器 $\mathcal{E}_S$ 在像素空间 L_E -Lipschitz。用样本传输构造 L0 的干净靶子 $z_0^S = T(z_0^T)$, 并与”理想靶子” $\bar{z}_0^S = \mathcal{E}_S(\mathcal{D}_T(z_0^T))$ (即真正像素一致的 student 隐变量) 相比, 则

$$\mathbb{E}\|z_0^S - \bar{z}_0^S\| \leq L_E \delta_T + \mathbb{E}\|\mathcal{E}_S(\mathcal{D}_T(z_0^T)) - \mathcal{E}_S(\mathcal{D}_S(T(z_0^T)))\|, \quad (6)$$

其中第二项在 T 像素一致 ((3) 成立) 时为 0。因此 L0 监督靶子的偏差由传输的像素往返误差 δ_T 线性控制。

Remark 4. Prop. 3 给出了一个干净的工程判据: 任何传输方法的”有损性”都可以用 δ_T (一个可离线测量的标量) 来量化与比较。这也是 §4 中各方法横向对比的统一坐标。

3 传输对 L0 与 L1 的作用（统一分析）

3.1 L0: 样本传输即可，且优先于速度传输

关键洞察 1: L0 用样本传输绕开 teacher 速度

跨 VAE 下，L0 的最自然形式不再回归 **teacher** 速度，而是：

1. teacher 在 $\mathcal{Z}_T$ 中 rollout 干净样本 z_0^T ;
2. 样本传输 $z_0^S = \mathsf{T}(z_0^T)$ (理想情形 $\mathsf{T} = \mathcal{E}_S \circ \mathcal{D}_T$);
3. 在 student 空间做标准 *flow matching*: $z_t^S = (1 - \sigma_t)z_0^S + \sigma_t\epsilon$, 回归到解析靶子

$$\mathcal{L}_{L0}^\times = \mathbb{E}_{t,\epsilon} \left[w(t) \| v_\theta(z_t^S, t) - (\epsilon - z_0^S) \|^2 \right]. \quad (7)$$

这只需要样本传输 (Def. 3 的 δ_T 控制其偏差, Prop. 3), 不需要 teacher 速度场、不需要 T 可逆或可微。代价: 丢失了 teacher 速度场在中间 t 上的”软”信息, 退化为”teacher 当数据生成器”。

(7) 与现有 (1) 的差别: 现有版本用 $v_T(z_t, t)$ 作软靶子 (teacher 在每个噪声水平上的意见); 跨 VAE 版本用解析 FM 靶子 $(\epsilon - z_0^S)$ 。当 T 像素一致时, 两者在 $\sigma_t \rightarrow 0$ 极限一致; 中间 t 的差异是”有损性”的来源之一。若坚持要软靶子, 则需 §4 的线性传输 (M2) 经 Prop. 2(b) 把 v_T 直接以 Av_T 搬运。

3.2 L1: 必须传输速度场, 约束远强于 L0

L1 要在 student 自己访问的状态 $x_k^S \in \mathcal{Z}_S$ 上得到 teacher 的转移均值。由 Cor. 1, 需要 $(\mathsf{T}_{\#} v_T)(x_k^S)$, 即可逆 + 可微 T 。三种可行度:

- 线性/仿射 $\mathsf{T} = Az + b$ (最干净): 由 Prop. 2(b), $\mu_T^S(x_k^S) = A\mu_T(A^+(x_k^S - b)) + b$ (转移均值同样以仿射搬运)。 A 行满秩可逆时无偏; $d_S \neq d_T$ 时用伪逆, 引入投影损失。
- 非线性 T (MLP, 可行但贵): 需要 T^{-1} (额外学一个逆网络或用可逆架构) 与 JVP (autograd 的 `jvp`) 来算 $\mathsf{J}_T v_T$ 。逐时间步代价 $\times$; 且 Rem. 3 的路径破坏使闭式高斯 KL 的”同方差”假设近似成立的条件变差。
- 像素桥接 $\mathsf{T} = \mathcal{E}_S \circ \mathcal{D}_T$ (L1 最差): T^{-1} 无解析式, Jacobian 需穿过两个 VAE 的 VJP, 逐步 decode+encode 代价 + 有损 + 不可逆, 实践上不适合 L1。

关键洞察 2: L0/L1 对传输的要求是分层的

L0 只需样本传输 (任何像素一致的 T 都行, 包括有损的像素桥接); **L1** 需要速度场传输 (实际上要求仿射 T 才干净)。因此一个自然的跨 VAE XOPD 方案是: 用便宜的像素桥接跑 *L0 warmup*, 用学习式线性传输跑 *L1*, 两阶段用不同的 T 。这直接复用了 XOPD 已有的”L0 warmup $\rightarrow$ L1”两阶段开关。

4 算法族: 六种传输的形式化与对比

4.1 M1: Pixel-space 桥接 (decode-encode)

$$\mathsf{T}_{\text{px}} = \mathcal{E}_S \circ \mathcal{D}_T, \quad z_0^S = \mathcal{E}_S(\mathcal{D}_T(z_0^T)). \quad (8)$$

性质: 无需训练; 像素一致性最好 (δ_T 仅由两个 VAE 各自的重建误差贡献)。用于 **L0**: 直接 (关键洞察 1)。用于 **L1**: 差 (Cor. 1, 不可逆 + 逐步 decode/encode 昂贵)。代价: 每个 teacher

样本一次 $\mathcal{D}_T$ + 一次 $\mathcal{E}_S$ (L0 中每 batch 一次, 可接受)。对应用户方法 1, 是有损但最简单的 baseline。

4.2 M2: 学习式 latent projector (线性 / 仿射 / 非线性)

学一个 $\mathsf{T}_\phi: \mathcal{Z}_T \rightarrow \mathcal{Z}_S$, 目标是像素一致:

$$\min_{\phi} \mathbb{E}_{z \sim p_T} \left[\left\| \mathcal{D}_S(\mathsf{T}_\phi(z)) - \mathcal{D}_T(z) \right\|^2 \right] \quad \left(= \delta_{\mathsf{T}_\phi}^2 \text{ 的经验版} \right), \quad (9)$$

或在配对数据上直接 latent-latent 回归 $\mathbb{E}_x \left\| \mathsf{T}_\phi(\mathcal{E}_T(x)) - \mathcal{E}_S(x) \right\|^2$ (更便宜, 无需逐步解码)。线性 $\mathsf{T}_\phi(z) = Az + b$: 由 Prop. 2, L0 和 L1 都干净 (速度 Av_T 、转移均值仿射搬运); 参数极少 ($d_S \times d_T$), 可闭式最小二乘初始化。非线性 **MLP**: δ 更小但 L1 需逆 +JVP (§3)。对应用户方法 2, 是本文推荐的 *L1* 主力。

4.3 M3: CV-VAE 式重建对齐 (把对齐推到 VAE 训练阶段)

参考 CV-VAE (Zhao et al., 2024): 与其在推理时传输 latent, 不如重训一个与 **teacher VAE** ”隐空间兼容” 的 **student VAE**。CV-VAE 冻结预训练 (image) VAE ($\mathcal{E}_i, \mathcal{D}_i$), 训练新 (video) VAE ($\mathcal{E}_v, \mathcal{D}_v$), 加两个像素重建正则:

$$\mathcal{L}_{\text{reg}}^{\text{dec}} = \left\| \psi(X) - \mathcal{D}_i(\mathcal{E}_v(X)) \right\|^2, \quad \mathcal{L}_{\text{reg}}^{\text{enc}} = \left\| X - \mathcal{D}_v(\mathcal{E}_i(\psi(X))) \right\|^2, \quad \mathcal{L} = \mathcal{L}_{\text{AE}} + \lambda_1 \mathcal{L}_{\text{reg}}^{\text{dec}} + \lambda_2 \mathcal{L}_{\text{reg}}^{\text{enc}}, \quad (10)$$

(ψ 是处理时序压缩的像素映射; 他们消融出 decoder-only $\lambda_1=1, \lambda_2=0$ 最好)。迁移到我们的设定: 把 teacher VAE 当”冻结的预训练 VAE”, 重训/微调 student VAE 使 $\mathcal{D}_T(\mathcal{E}_S(x)) \approx x$ 且 $\mathcal{D}_S(\mathcal{E}_T(x)) \approx x$, 则两个隐空间近似可互换 ($\mathsf{T} \approx \text{Id}$ 在通道对齐后), 从源头消除传输需求。代价: 要训一个 VAE 且会改变 student 的 decoder (影响最终采样质量); 属于”一次性重投资换取后续零传输开销”。与 **M1/M2** 的关系: M3 是把 δ_{T} 在 VAE 训练阶段压到极小, 使 M1/M2 的传输几乎无损。

4.4 M4 (新提出): 概率耦合 / 分布矩匹配

M1-M3 都是点对点 (sample-level) 传输。但 XOPD 的 L1 本质是分布匹配 (高斯转移 KL)。我们提出在分布层面对齐: 不要求 $\mathsf{T}(z_0^T)$ 与某个特定 student 隐变量逐点相等, 只要求推前分布匹配 student 的边际:

$$\mathsf{T}^* = \arg \min_{\mathsf{T}} W_2(\mathsf{T}_{\#} p_T, p_S) \quad \text{或} \quad \min_{\mathsf{T}} \text{KL}(\mathsf{T}_{\#} p_T \parallel p_S), \quad (11)$$

其中 $p_T = \mathcal{E}_{T\#} p_{\text{data}}$ 、 $p_S = \mathcal{E}_{S\#} p_{\text{data}}$ 是两个 VAE 在同一图像分布上的隐变量边际。重要更正: 扩散用 VAE 的隐变量边际并不服从高斯 (Rem. 1), 故 (11) 的解一般不是仿射的, 我们不声称”仿射是最优传输”。但可以退一步只对齐前两阶矩: 取仿射 $\mathsf{T}(z) = Az + b$ 使推前的均值/协方差与 p_S 匹配 ($\mathsf{T}_{\#} p_T$ 与 p_S 同均值同协方差), 其解为矩匹配映射 (**moment-matching map**), 由 teacher→student 方向的 Bures 公式给出:

$$A = \Sigma_T^{-1/2} (\Sigma_T^{1/2} \Sigma_S \Sigma_T^{1/2})^{1/2} \Sigma_T^{-1/2}, \quad b = \mu_S - A \mu_T, \quad (12)$$

($\mu_\bullet, \Sigma_\bullet$ 为两边际的均值/协方差, 离线估计; 通道数不同时在公共子空间上做。可验证 $A \Sigma_T A^\top = \Sigma_S$, 即协方差精确对齐。) 矩匹配不需要分布高斯——任何分布都有均值和协方差; 它只在两边际恰好近高斯时才升级为全局 W_2 -最优传输 (11)。贡献: 给出 M2 线性传输一个有原则、无需训练的初始化 (精确对齐二阶结构), 并把”线性够不够”的判据交还给 δ_{T} 实测 (Rem. 2)——而非依赖一个对扩散 VAE 不成立的高斯假设。

4.5 M5 (新提出): cycle-consistent 联合学习传输

同时学正/逆传输 $T_\phi: \mathcal{Z}_T \rightarrow \mathcal{Z}_S$ 与 $T_\psi: \mathcal{Z}_S \rightarrow \mathcal{Z}_T$, 加 cycle 一致性, 直接满足 Cor. 1 对”可逆”的要求 (无需对非线性 T 求解析逆):

$$\mathcal{L}_{\text{cyc}} = \underbrace{\mathbb{E} \|\mathcal{D}_S T_\phi(z^T) - \mathcal{D}_T(z^T)\|^2}_{\text{像素一致}} + \beta \underbrace{\mathbb{E} \|T_\psi T_\phi(z^T) - z^T\|^2}_{\text{cycle}} + \beta \mathbb{E} \|T_\phi T_\psi(z^S) - z^S\|^2. \quad (13)$$

T_ψ 提供 L1 所需的 T^{-1} (查询 teacher), Jacobian 经 autograd JVP. 代价/收益: 比 M2 线性更表达, 比纯非线性 M2 多了可逆保证; 适合 δ 难以被线性压低 (两个 VAE 隐空间几何差异大) 的情形。

4.6 M6 (新提出): shared-decoder 微调 (最小侵入的 M3)

M3 重训整个 VAE 代价大。M6 只冻结 **student** 的 $\mathcal{E}_S$ 、微调一个轻量”适配解码头”使 teacher 隐变量能被 student 解码器读出: 学 $\mathcal{D}_S^{\text{adapt}}$ 使 $\mathcal{D}_S^{\text{adapt}}(T(z^T)) \approx \mathcal{D}_T(z^T)$, 其余 student 组件不动。介于 M2 (不碰 VAE) 与 M3 (重训 VAE) 之间。

4.7 横向对比

	需训练	δ_T (有损)	L0	L1	可逆/可微	额外开销
M1 pixel 桥接	否	中 (2×VAE 重建)	✓	✗ (贵 + 不可逆)	否	每 batch decode+encode
M2 线性 projector	是 (小)	低 (矩匹配残差)	✓	✓ (干净)	是 (伪逆)	一次矩阵乘
M2 非线性 projector	是 (中)	最低	✓	Δ (逆 + JVP)	需额外逆网	JVP/步
M3 CV-VAE 重训	是 (大)	训后极低	✓	✓	$\approx \text{Id}$	VAE 训练 (一次性)
M4 矩匹配 (初始化)	闭式	低 (二阶对齐)	✓	✓ (仿射)	是	离线估计 μ, Σ
M5 cycle 双向	是 (中)	低	✓	✓	显式可逆	两网 + JVP
M6 shared-decoder	是 (小)	低	✓	✓	—	解码头微调
M7 白化/AdaLN 仿射	闭式	低 (对角二阶)	✓	✓ (干净)	解析可逆	逐通道 γ, β

Table 1: 六种 VAE 隐空间传输方法对 XOPD L0/L1 的适配性对比。✓= 干净适配, Δ = 可行但昂贵, ✗= 不适合。

推荐路线

先做 **M1 (L0) + M2-线性 (L1)**, 并用 **M4** 的矩匹配闭式 (12) 初始化 **M2** 的 A, b 。理由: (i) M1 几乎零实现成本, 立刻让 L0 warmup 可跑通, 验证”teacher 数据是否对 student 有用”这一最关键问题; (ii) M2-线性是唯一让 L1 干净成立的最小方案 (几何结论, 不依赖分布假设, Rem. 2), 且 M4 给了它无需训练的二阶矩对齐初始化; (iii) M3/M5/M6 作为后续提升项, 当 δ_T 被测出过大 (线性传输不足以对齐两个隐空间) 时再投入。

5 传输的初始化与 AdaLN 式可逆调制

本节回应两个具体设计问题: (1) transport 权重应如何初始化——恒等映射是否合适? (2) 把 ODE 转成 SDE 后能否用 AdaLN 式的”高斯到高斯”全局调制来构造可逆传输? 两个问题都指向同一个对象——逐通道仿射 (对角白化) 传输——但都需要先澄清一个分布前提。

5.1 初始化: 恒等不是好默认, 矩匹配才是”中性”初始化

Proposition 4 (恒等初始化的失效模式). 把线性传输 $T(z) = Az + b$ 初始化为恒等 ($A = I, b = 0$) 在跨 VAE 下一般不可用:

- (a) 维度不合法: $C_T \neq C_S$ 时 $A = I$ 无定义 (FLUX.2 与 SD3.5 通道数不同);
- (b) 尺度错位: 即使 $C_T = C_S$, 两个 VAE 的 latent 一阶/二阶矩不同 (SD3.5 用 “scaling_factor”/“shift_factor”, FLUX.2 用 BatchNorm 标准化), $A = I$ 把 teacher latent 原样塞入 student 空间 $\Rightarrow$ OOD $\Rightarrow \delta_T$ 巨大。

正确的”中性初始化”是对角矩匹配 (白化-再着色): 对齐逐通道均值/标准差

$$A_{\text{diag}} = \text{diag}\left(\frac{\sigma_S^{(c)}}{\sigma_T^{(c)}}\right), \quad b = \mu_S - A_{\text{diag}} \mu_T, \quad (14)$$

其中 $\mu_{\bullet}^{(c)}, \sigma_{\bullet}^{(c)}$ 是两个 latent 边界的逐通道矩 (离线估计, $C_T \neq C_S$ 时在前 $\min(C_T, C_S)$ 个通道上做, 其余零填充)。

Remark 5 (为什么矩匹配是”恒等的正确推广”). (14) 满足: 当两个空间恰好相同 (同均值同方差) 时 $A_{\text{diag}} = I, b = 0$, 自动退化为恒等。因此”该不该用恒等初始化”的精确答案是: 恒等只在退化 (同空间) 情形正确; 一般情形应该用矩匹配——它在该退化时自己变成恒等。这也正是 §4 M4 闭式 (12) 的对角特例: M4 的全协方差 Bures 解对齐二阶全结构, (14) 只对齐对角, 更便宜、更稳。

Remark 6 (可训练非线性传输的”恒等初始化” = zero-init 残差). 若 transport 含可训练的非线性部分 g_ϕ , ”do no harm”初始化的正解不是把 g_ϕ 设成恒等, 而是 **zero-init** 残差: $T(z) = A_{\text{diag}}z + b + g_\phi(z)$ 且 g_ϕ 末层零初始化 (AdaLN-Zero / ControlNet zero-conv / LoRA-B 的思路)。则训练初始时 T 恰好等于良态的仿射 baseline (14), 非线性修正从 0 开始安全注入。这是想法 1 在非线性情形的正确落地, 并自然衔接下一小节。

5.2 ODE $\rightarrow$ SDE 与 AdaLN 式调制: 纠正前提, 保留机制

前提纠正: **SDE** 的高斯性在转移核, 不在边际。 ”把 ODE 转成 SDE (Flow-SDE / CPS), 中间步为高斯, 于是两个 latent 空间的 latent 都是高斯”——这里要区分两个分布 (与 Rem. 1 同源):

- 转移核 $p(z_{t+dt} | z_t)$: SDE 下是高斯 (加性高斯噪声)。XOPD 的 D_k 闭式高斯 KL 用的正是它——这不需要把 ODE 转成 SDE, pathwise D_k 在两种 dynamics 下都良定义。
- 边际 $p(z_t)$, 其中 $z_t = (1 - \sigma_t)z_0 + \sigma_t\epsilon$: 非高斯 (非高斯的 $p(z_0)$ 与高斯卷积), 仅 $\sigma_t \rightarrow 1$ 时趋于高斯。

所以 **ODE $\rightarrow$ SDE** 并不会使 **latent** 边际变高斯; ”两个空间的 latent 都是高斯”这一前提不成立, ”在两个高斯之间做变换”的字面表述需要放弃。

机制是对的: **AdaLN** 调制 $\equiv$ 可逆逐通道仿射 (白化传输)。 尽管前提不成立, 想法 2 的机制是有价值的: AdaLN 的逐通道 scale+shift $T(z) = \gamma \odot z + \beta$ 恰是 Prop. 2 的对角仿射, 且

$$T^{-1}(z') = (z' - \beta) \oslash \gamma \quad (15)$$

解析可逆 ($\gamma > 0$), 无需像 M5 那样单独学一个逆网络——这正好提供 Cor. 1 要求的 L1 逆映射。换言之, 想法 2 独立地重新发现了”仿射调制是天然的可逆传输”, 且其参数恰由 (14) 的矩匹配给出闭式初始化。我们把这个对象命名为 **M7: WhiteningTransport** (对角 **AdaLN** 仿射), 作为 M2-线性的对角特例: 参数量 $2 \min(C_T, C_S)$ 、可逆、零病态、矩匹配即得, 是最稳的中性默认。

Proposition 5 (时间条件对仿射传输无增益). VAE 的 encode/decode 是与扩散时间 σ 无关的固定映射, 故两个 latent 空间的关系本身与 σ 无关。由 Prop. 2(a), 一个静态仿射 $T(z) = Az + b$ 已把所有 σ 的状态正确传输 (插值路径整体被仿射搬运)。因此给仿射调制再加时间条件 $\gamma(\sigma), \beta(\sigma)$ (AdaLN(t)) 对仿射情形没有收益——时间条件只有当 transport 是非线性 (不同 σ 的边际形状差异需要不同的非线性校正) 时才可能有用。

Remark 7 (一个细致的 caveat: 均值干净, 噪声需正交). 仿射传输对转移均值的搬运是干净的 (D_k 用的就是均值, Prop. 2(b)), 所以 pathwise 蒸馏不受影响。但若还想让传输后的噪声也匹配 student 的各向同性标准噪声, 需要 A 为正交矩阵 (保协方差为各向同性); 而矩匹配/白化的 A 一般非正交, 故传输后的路径分布只是近似 on-distribution。这不影响 mean-matching 的 D_k 使用, 但它 (而非时间条件) 才是引入更富表达传输 (M5 cycle / 正交约束) 的真正动机。若将来上 SDE+REINFORCE, 则噪声项进入 log-prob, 正交性才变得重要。

两个想法的结论

想法 1: 恒等初始化一般不可用 (维度/尺度, Prop. 4); 正解是 矩匹配中性初始化 (14) (同空间时自动退化为恒等, Rem. 5), 非线性情形用 zero-init 残差 (Rem. 6)。
想法 2: ODE→SDE 不使 latent 边际高斯 (前提需放弃), 但 AdaLN 式逐通道仿射调制是天然可逆的传输 ((15))、由矩匹配闭式初始化——即新增的 **M7 WhiteningTransport**。时间条件对仿射无增益 (Prop. 5), 故无需真的转 SDE; 静态对角仿射即可。

6 实现设计 (不写生产代码, 只做架构)

6.1 改动面

1. 放松硬约束: flux2_klein.py:1363 的 in_channels 断言改为”共享 VAE 时断言相等, 跨 VAE 时要求配置了 vae_transport”。
2. **teacher VAE / 解码**: 跨 VAE 时需要 teacher 的 $\mathcal{D}_T$ (M1) 或 teacher $\mathcal{E}_T$ (M2 训练)。新增 load_teacher_vae(...), 与现有 load_teacher_text_encoder 一样仅预处理期常驻、之后 offload (M1 的 $\mathcal{D}_T$ 用于 L0 生成靶子, 可在预处理把 z_0^S 直接缓存)。
3. 抽象 VAETransport: 一个小接口

```
class VAETransport(Protocol):
    def transport_sample(z_T) -> z_S          # M1/M2: 样本传输 (L0)
    def pushforward_velocity(v_T, z_S) -> v_S  # M2 线性: A v_T (L1)
    def inverse(z_S) -> z_T                   # L1 查询 teacher 用
```

实现: PixelBridgeTransport(M1)、LinearTransport(M2/M4)、MLPTransport(M2/M5)。

4. **L0 插入点**(trainer.py:_l0_epoch):teacher rollout 得 z_0^T 后, 插入 $z_0^S = T.transport_sample(z_0^T)$, 其余 L0 不变 ((7), 回归解析靶子或传输后的 teacher 速度)。
5. **L1 插入点** (trainer.py:_teacher_next_latents_mean): teacher forward 前用 T.inverse 把 student 状态映回 $\mathcal{Z}_T$ 查询, 再用 pushforward_velocity 把均值/速度映回 $\mathcal{Z}_S$ 。
6. **config:vae_transport**: {type: pixel|linear|mlp|none, init: gaussian_ot|lstsq|random, train: bool}; none 即现有共享-VAE 行为, 完全向后兼容。

6.2 两阶段用不同传输 (呼应关键洞察 2)

L0 用 PixelBridgeTransport (M1, 无损训练、像素一致最好); L1 用 LinearTransport (M2, 矩匹配 (12) 初始化、可选继续训练)。两者共享同一个 teacher, 互不冲突, 且都走 XOPD 既有的 use_teacher_transformer + DDP-bypass + autocast-cache 关闭路径 (见 CLAUDE.md 的不变量)。

6.3 先验证什么

按 §2 的 δ_T : 实现任何传输前, 先离线测量 δ_{px} (M1 桥接的像素往返误差) 与矩匹配线性传输 (12) 的残差 δ_{linear} , 作为”该任务是否可蒸馏 / 线性是否够用”的前置体检——若 δ_{px} 已经很大 (两个 VAE 语义不兼容), 任何下游 XOPD 都救不回来, 应优先 M3/M6 对齐 VAE; 若 δ_{px} 小但 δ_{linear} 大 (隐空间可互通但非线性关联), 则线性 M2 不足, 升级到非线性 M2 / M5。

7 结论

跨 VAE 的 XOPD 归结为设计隐空间传输 $T: \mathcal{Z}_T \rightarrow \mathcal{Z}_S$ 。核心理论结论:

- L0 与 L1 对 T 的要求分层: L0 只需样本传输 (任何像素一致 T), L1 需速度场推前 (Prop. 1), 实际要求仿射传输才干净 (Prop. 2)。
- 偏好仿射传输是几何结论 (Rem. 2), 不依赖 latent 服从高斯——事实上扩散 VAE 的隐变量边际是非高斯的 (Rem. 1)。M4 的闭式 (12) 是矩匹配初始化 (对齐二阶结构), 只在边际恰好近高斯时才升级为 W_2 -最优传输。
- 所有方法的有损性可用单一经验标量 δ_T ((5)) 量化比较; ”线性够不够”由 δ_{linear} 实测判定, 而非高斯定理。
- 工程上: M1(L0)+M2 线性 (L1)+M4 矩匹配初始化是最小可行且理论自洽的首选; M3/M5/M6 作为 δ 过大时的升级项。